


# API参考

## 火山方舟



# 法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030  
( 周一至周五 10:00-18:00 )

# 目录

|                         |      |
|-------------------------|------|
| 法律声明                    | -1   |
| 目录                      | -1   |
| 1. 准备工作                 | -1   |
| 1.1 获取 API Key 并配置      | -1   |
| 1.2 安装及升级 SDK           | -2   |
| 1.3 Base URL及鉴权         | -6   |
| 2. 对话(Chat) API         | -9   |
| 2.1 对话(Chat) API        | -9   |
| 3. Responses API        | -41  |
| 3.1 创建模型响应              | -41  |
| 3.2 查询模型响应              | -68  |
| 3.3 获取响应上下文             | -69  |
| 3.4 删除模型响应              | -71  |
| 3.5 The response object | -72  |
| 3.6 流式响应                | -86  |
| 4. Files API            | -111 |
| 4.1 上传文件                | -111 |
| 4.2 检索文件                | -115 |
| 4.3 查询文件列表              | -116 |
| 4.4 删除文件                | -118 |
| 4.5 The file object     | -119 |
| 5. 视频生成 API             | -122 |
| 5.1 创建视频生成任务 API        | -122 |
| 5.2 查询视频生成任务 API        | -136 |
| 5.3 查询视频生成任务列表          | -141 |
| 5.4 取消或删除视频生成任务         | -147 |
| 6. 图片生成 API             | -149 |
| 6.1 图片生成 API            | -149 |
| 6.2 流式响应                | -161 |
| 7. 3D生成 API             | -167 |
| 7.1 Seed3D API          | -167 |
| 7.1.1 创建3D生成任务 API      | -167 |
| 7.1.2 查询3D生成任务 API      | -171 |
| 7.1.3 查询3D生成任务列表        | -174 |
| 7.1.4 取消或删除3D生成任务       | -178 |
| 7.2 影眸 API              | -180 |

|                                                |      |
|------------------------------------------------|------|
| 7.2.1 创建3D生成任务                                 | -180 |
| 7.2.2 查询3D生成任务                                 | -186 |
| 7.2.3 查询3D生成任务列表                               | -189 |
| 7.2.4 取消或删除3D生成任务                              | -193 |
| 7.3 数美 API                                     | -195 |
| 7.3.1 创建3D生成任务                                 | -195 |
| 7.3.2 查询3D生成任务                                 | -200 |
| 7.3.3 查询3D生成任务列表                               | -203 |
| 7.3.4 取消或删除3D生成任务                              | -207 |
| 8. 向量化 API                                     | -209 |
| 8.1 向量化 API                                    | -209 |
| 9. 上下文缓存 API                                   | -216 |
| 9.1 创建上下文缓存 API                                | -216 |
| 9.2 上下文缓存对话 API                                | -223 |
| 10. 应用(Bot) API                                | -240 |
| 10.1 应用(bot) API                               | -240 |
| 10.2 联网插件 数据结构                                 | -253 |
| 10.3 知识库插件 数据结构                                | -256 |
| 11. 批量推理 API                                   | -257 |
| 11.1 批量(Job) API                               | -257 |
| 11.1.1 CreateBatchInferenceJob – 创建批量推理任务      | -257 |
| 11.1.2 ListBatchInferenceJobs – 获取批量推理任务列表     | -263 |
| 11.1.3 GetBatchInferenceJob – 获取批量推理任务         | -272 |
| 11.1.4 UpdateBatchInferenceJob – 更新批量推理任务      | -278 |
| 11.1.5 DeleteBatchInferenceJob – 删除批量推理任务      | -280 |
| 11.1.6 StopBatchInferenceJob – 停止批量推理任务        | -282 |
| 11.1.7 ResumeBatchInferenceJob – 重启批量推理任务      | -284 |
| 11.2 批量(Chat) API                              | -286 |
| 12. 管控面 API                                    | -290 |
| 12.1 管理推理接入点 ( Endpoint )                      | -290 |
| 12.1.1 StartEndpoint – 开启推理接入点                 | -290 |
| 12.1.2 StopEndpoint – 停止推理接入点                  | -292 |
| 12.1.3 ListEndpoints – 获取推理接入点列表               | -294 |
| 12.1.4 GetEndpoint – 获取推理接入点                   | -302 |
| 12.1.5 DeleteEndpoint – 删除推理接入点                | -308 |
| 12.1.6 UpdateEndpoint – 更新推理接入点                | -310 |
| 12.1.7 CreateEndpoint – 创建推理接入点                | -314 |
| 12.1.8 GetEndpointCertificate – 获取接入点推理应用层加密证书 | -319 |

|                                                                   |     |
|-------------------------------------------------------------------|-----|
| 12.1.9 InnerDescribeModelEndpoints – 查询模型预置接入点列表                  | 322 |
| 12.2 管理API Key                                                    | 327 |
| 12.2.1 GetApiKey – 获取临时API Key                                    | 327 |
| 12.3 管理模型调优任务                                                     | 330 |
| 12.3.1 TerminateModelCustomizationJob – 停止模型调优任务                  | 330 |
| 12.3.2 GetModelCustomizationJob – 获取模型调优任务信息                      | 332 |
| 12.3.3 CreateModelCustomizationJob – 创建模型调优任务                     | 345 |
| 12.3.4 ListModelCustomizationJobs – 获取模型调优任务列表                    | 355 |
| 12.3.5 UpdateModelCustomizationJob – 更新模型调优任务                     | 368 |
| 12.3.6 DeleteModelCustomizationJob – 删除模型调优任务                     | 371 |
| 12.3.7 ResumeModelCustomizationJob – 重试模型调优任务                     | 374 |
| 12.3.8 GetModelCustomizationJobMetricData – 查询精调效果指标详细数据          | 378 |
| 12.3.9 GetModelCustomizationJobMetrics – 查询精调效果指标                 | 382 |
| 12.4 管理定制模型                                                       | 385 |
| 12.4.1 DeleteCustomModel – 删除定制模型                                 | 385 |
| 12.4.2 GetCustomModel – 获取定制模型信息                                  | 387 |
| 12.4.3 UpdateCustomModel – 更新定制模型                                 | 391 |
| 12.4.4 ListCustomModels – 获取定制模型列表                                | 394 |
| 12.5 管理基础模型                                                       | 401 |
| 12.5.1 ListFoundationModelVersions – 获取基础模型版本列表                   | 401 |
| 12.5.2 GetFoundationModelVersion – 获取基础模型版本信息                     | 405 |
| 12.5.3 ListFoundationModels – 获取基础模型列表                            | 415 |
| 12.5.4 GetFoundationModelVersionConfiguration – 获取基础模型版本配置信息(不推荐) | 425 |
| 12.5.5 GetFoundationModel – 获取基础模型信息                              | 435 |
| 12.6 管理模型评测任务                                                     | 439 |
| 12.6.1 TerminateEvaluationJob – 停止评测任务                            | 439 |
| 12.6.2 GetEvaluationJob – 获取评测任务                                  | 441 |
| 12.6.3 ListEvaluationJobs – 获取评测任务列表                              | 446 |
| 12.6.4 CreateEvaluationJob – 创建评测任务                               | 453 |
| 12.6.5 UpdateEvaluationJob – 更新评测任务                               | 457 |
| 12.6.6 ListEvaluationResults – 获取评测任务结果列表                         | 459 |
| 12.6.7 DeleteEvaluationJob – 删除评测任务                               | 465 |
| 12.6.8 GetEvaluationResult – 获取评测任务结果                             | 467 |
| 12.7 安全审计                                                         | 472 |
| 12.7.1 ListAuditLogs – 获取安全审计日志                                   | 472 |
| 12.8 查询用量                                                         | 492 |
| 12.8.1 GetUsage – 查询推理服务调用量（待弃用）                                  | 492 |
| 12.8.2 GetInferenceUsage – 查询推理用量                                 | 496 |

|                                                                |      |
|----------------------------------------------------------------|------|
| 12.8.3 CreateRecordExportTask – 创建用量明细导出任务                     | -501 |
| 12.8.4 GetRecordExportTask – 查询用量明细导出任务状态                      | -504 |
| 12.9 Agent Plan / Coding Plan API                              | -508 |
| 12.9.1 CreatePersonalPlan – 创建个人版套餐                            | -508 |
| 12.9.2 RenewPersonalPlan – 续费个人版套餐                             | -511 |
| 12.9.3 GetPersonalPlan – 查询个人版套餐                               | -514 |
| 12.9.4 Agent Plan API                                          | -517 |
| 12.9.4.1 ListArkAgentPlanModel – 查询 Agent Plan 支持的模型列表         | -517 |
| 12.9.4.2 RegeneratePersonalApiKey – 轮换个人版 API Key              | -520 |
| 12.9.4.3 GetUsageDetails – 获取套餐用量详情                            | -523 |
| 12.9.4.4 GetAFPUsage – 获取套餐 AFP 额度                             | -529 |
| 12.9.5 Coding Plan API                                         | -534 |
| 12.9.5.1 ListArkCodingPlanModel – 查询 Coding Plan 支持的模型列表       | -534 |
| 12.10 效果上报                                                     | -537 |
| 12.10.1 CasePlatformV1BadcaseReport – 方舟Seedance2.x 效果问题上报API  | -537 |
| 12.10.2 CasePlatformV1BadcaseQuery – 方舟Seedance2.x 效果问题结果查询API | -544 |
| 13. 其他说明                                                       | -552 |
| 13.1 兼容 OpenAI SDK                                             | -552 |
| 13.2 错误码                                                       | -556 |
| 13.3 SDK 常见使用示例                                                | -573 |
| 14. 分词 API                                                     | -589 |
| 14.1 分词 API                                                    | -589 |

# 1. 准备工作

## 1.1 获取 API Key 并配置

您调用方舟平台的模型之前，您需要 API Key 来进行鉴权。同时因为 API Key 信息较为敏感，泄露 API Key 会导致您的模型用量被其他人花费，造成一定的损失，因此我们会给出配置 API Key 进环境变量的方法，方便您合理安全地使用API Key。

### 获取 API Key

1. 打开并登录[API Key 管理](#) 页面。
2. （可选）单击左上角 **账号全部资源** 下拉箭头，切换项目空间。
3. 单击 **创建 API Key** 按钮。
4. 在弹出框的 **名称** 文本框中确认/更改 API Key名称，单击创建。

您可以在[API Key 管理](#) 页面的 **API Key 列表**中查看刚创建的API Key信息。

### 配置 API Key

推荐将 API Key 配置在环境变量中，而不是硬编码进代码中，避免 API Key 随代码泄露，导致配额被他人使用，产生额外花费。

配置方法见：[环境变量配置指南](#)。

### 使用说明

- API Key 配额：一个主账号下支持创建 50 个API Key，如需更多配额请提交[工单](#)申请。
- API Key 权限控制：API Key 创建于您当前所在项目，用于访问当前项目下的资源（即模型服务和应用）。您可为 API Key 额外限制可鉴权的 Model ID /自定义推理接入点，或可调用该 API Key 的 IP。
  - TIPS：您切换项目空间创建 API Key，可限制 API Key 只用于指定项目空间下的模型服务的鉴权凭证。当您的账号是多人使用，可以通过此方法进行权限隔离。
  - 注意：API Key 仅支持访问指定项目下的接入点，不支持跨项目访问。当您跨项目迁移了接入点，则原 API Key 鉴权将失效。

## 1.2 安装及升级 SDK

方舟提供了 Python、Go 和 Java 的 SDK，方便使用对应编程语言快速调用方舟的模型服务。

### Python SDK

#### 前提条件

本地已安装了 Python，且版本不低于 3.7。

可在终端中通过命令确认 Python 版本。

Bash

```
python -V
```

Python 可使用 [UV](#) 安装，并通过它来管理虚拟环境。UV 是一个 Rust 编写的、速度极快的 Python 包和项目管理器，可以方便进行环境隔离，避免干扰您系统中已有的 Python 配置。

#### 安装 Python SDK

在终端中执行命令安装 Python SDK。

Bash

```
pip install 'volcengine-python-sdk[ark]'
```

#### 说明

- 如本地安装错误，可尝试下面方法：
  - [Windows系统安装SDK失败，ERROR: Failed building wheel for volcengine-python-sdk](#)
  - 尝试使用下面命令 `uv pip install volcengine-python-sdk[ark]`
- 如需源码安装，可下载&解压对应版本 SDK 包，进入目录执行命令：  
`python setup.py install --user`
- 如使用了uv，可以通过 `uv pip install 'volcengine-python-sdk[ark]'` 命令安装 SDK。

#### 升级 Python SDK

如需使用方舟提供的最新能力，请升级 SDK 至最新版本。

Bash

```
pip install 'volcengine-python-sdk[ark]' -U
```



## Go SDK

### 前提条件

检查 Go 版本，需 1.18 或以上。

Bash

```
go version
```

如未安装或版本不满足，可访问 [Go 语言官方网站](#) 下载并安装，请选择 1.18 或以上版本。

### 安装 Go SDK

1. Go SDK 使用 go mod 管理，可运行以下命令初始化 go mod。 `<YOUR_PROJECT_NAME>` 替换为项目名称。

Bash

```
# 如在文件夹 ark-demo 下打开终端窗口，运行命令go mod init ark-demo  
go mod init <YOUR_PROJECT_NAME>
```

2. 在本地初始化 go mod 后，运行以下命令安装最新版 SDK。

Bash

```
go get -u github.com/volcengine/volcengine-go-sdk
```

#### 说明

如需安装特定版本的SDK，可使用命令：

```
go get -u github.com/volcengine/volcengine-go-sdk@<VERSION>
```

其中 `<VERSION>` 替换为版本号。SDK 版本可查询：<https://github.com/volcengine/volcengine-go-sdk/releases>

3. 在代码中引入 SDK 使用。

Go

```
import "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
```

4. 更新依赖后，使用命令整理依赖。

Bash

```
go mod tidy
```

## 升级 Go SDK

步骤与安装 Go SDK相同，可参考[安装 Go SDK](#)，第1，2步升级至最新/指定版本SDK。

- 升级至最新版本

Bash

```
go get -u github.com/volcengine/volcengine-go-sdk
```

- 升级至指定版本

Bash

```
go get -u github.com/volcengine/volcengine-go-sdk@<VERSION>
```

## Java SDK

### 适用范围

本 SDK 仅适用于 Java 服务端开发，暂不支持 Android 平台。若需在 Android 平台使用相关功能，需由客户自行开发适配方案。

### 前提条件

1. 检查并安装 Java 版本，Java 版本需 1.8 或以上。

Bash

```
java -version
```

如未安装 Java 或者版本不满足要求，可访问 [Oracle 官方网站](#) 下载并安装适合操作系统的 Java 版本。请确保选择 1.8 或以上版本。

### 安装 Java SDK

火山方舟 Java SDK 支持通过 Maven 安装、通过 Gradle 安装两种方式。

#### 通过 Maven 安装

在 `pom.xml` 文件中进行如下配置，完整配置可参考[Maven Central](#)：

```
...  
<dependency>  
  <groupId>com.volcengine</groupId>  
  <artifactId>volcengine-java-sdk-ark-runtime</artifactId>
```

```
XML<version>LATEST</version>
  </dependency>
...
```

## 通过 Gradle 安装

在 `build.gradle` 文件中进行如下配置，在 `dependencies` 中添加依赖。

Plain

```
implementation 'com.volcengine:volcengine-java-sdk-ark-runtime:LATEST'
```

## 升级 Java SDK

### 说明

获取 SDK 版本信息，替换'LATEST'为指定/最新版本号。SDK版本号可查询：<https://github.com/volcengine/volcengine-java-sdk/releases> [🔗](#)

同安装 Java SDK，指定需升级的版本号即可。

## 第三方SDK

火山方舟模型调用 API 与 OpenAI API 协议兼容，可使用兼容 OpenAI API 协议的多语言社区 SDK 调用火山方舟大模型或应用。可很方便地迁移模型服务至方舟平台以及 Doubao 大模型。具体使用方法请参考[兼容 OpenAI SDK](#)。

## 相关文档

[SDK 常见使用示例](#)：包含SDK的常见用法。

## 1.3 Base URL及鉴权

火山方舟API分为模型调用的API（数据面 API），及管理推理接入点等管控相关的管控面 API。他们支持的鉴权方式有所不同，下面介绍方舟API的鉴权方式。

### 概念解释

- **数据面 API**：是直接面向业务数据传输、实时交互、用户请求处理的接口，聚焦于“实际业务数据的流转与处理”，是系统对外提供核心服务能力的载体。请求大模型服务的 Chat API、Responses API 均为数据面 API。
- **管控面 API**：用于系统资源管理、配置控制和状态监控的接口。它专注于管理和调度数据面及系统资源，是保障系统稳定运行的“控制中枢”。例如，在方舟中用于管理 API Key、基础模型等接口，均属于管控面 API。
- **Base URL**：是构建完整 API 请求 URL 的“基础模板”，包含协议（如 http/https）、host（主机域名或 IP）、端口（可选）和基础路径（可选），是所有具体接口路径的“公共前缀”。你可以根据 Base URL 加接口/版本等参数拼接出完整接口 URL，典型结构：`[协议]://[host]/[基础路径（可选）]`

### Base URL

#### 注意

下面给到的数据面 API 与 Coding Plan 支持的 Base URL 不同。Coding Plan 用户请使用正确的 Base URL，避免因地址错误产生额外费用，具体参见 [Base URL](#)。

各接口类型对应的 Base URL。

- 数据面 API：`https://ark.cn-beijing.volces.com/api/v3`
- 管控面 API：`https://ark.cn-beijing.volcengineapi.com/`

### 数据面 API 鉴权

支持两种鉴权方式，API Key 鉴权（简单方便），与 Access Key 鉴权（传统云上资源权限管控，可以分资源组云产品等维度管理，面向企业精细化管理）。

### API Key 签名鉴权

#### 前提条件

#### 说明

方舟平台的新用户？获取 API Key 及 开通模型等准备工作，请参见 [快速入门](#)。

#### 签名构造

在 HTTP 请求 header 中按如下方式添加 `Authorization` header:

Bash

```
Authorization: Bearer $ARK_API_KEY
```

示例如下

Bash

```
curl https://ark.cn-beijing.volces.com/api/v3/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer $ARK_API_KEY" \
-d '{
  "model": "doubao-seed-2-1-pro-260628",
  "messages": [
    {
      "role": "system",
      "content": "You are a helpful assistant."
    },
    {
      "role": "user",
      "content": "Hello!"
    }
  ]
}'
```

· 可按需替换 Model ID。查询 Model ID见 [模型列表](#)。

## Access Key 签名鉴权

### 前提条件

你已获取到Access Key。如需创建/查看Access Key，请参见[API访问密钥管理](#)。

由于主账号的Access Key拥有较大权限，建议你创建IAM用户并授予方舟等权限，然后使用IAM用户的 Access Key 来进行操作，具体请参见[使用 IAM 管理权限](#)。

### 使用示例

见 [使用Access Key鉴权](#)。

通过Access Key 鉴权，model 字段 需配置为 Endpoint ID。

## 管控面 API 鉴权

管控面的API，如管理API Key、管理推理接入点等接口。

## Access Key 签名鉴权

获取Access Key。如需创建/查看Access Key，请参见[API访问密钥管理](#)。

### 方法：使用示例/说明（简单，推荐）

参见[SDK 接入指南](#)。

### 方法：自行实现签名（实现成本高，不推荐）

1. 使用 Access Key 构造签名。具体方法请参见[签名方法](#)。

签名用到的方舟相关字段信息：

- Service: ark
- Region: cn-beijing

2. 使用cURL发起请求，请求示例如下：

Bash

```
curl -X POST \
  'https://ark.cn-beijing.volcengineapi.com/?Action=ListEndpoints&Version=2024-01-01' \
  -H 'Authorization: HMAC-SHA256 Credential=AKL**/20240710/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date, Signature=a7a****' \
  -H 'Content-Type: application/json' \
  -H 'Host: ark.cn-beijing.volcengineapi.com' \
  -H 'X-Content-Sha256: 44****' \
  -H 'X-Date: 20240710T042925Z' \
  -d '{}'
```

## 2. 对话(Chat) API

### 2.1 对话(Chat) API

POST <https://ark.cn-beijing.volces.com/api/v3/chat/completions> [运行](#)

发送包含文本、图片、视频、音频等模态的消息列表，模型将生成对话中的下一条消息。

#### 鉴权

本接口支持鉴权方式如下，详情请参见 [Base URL 及 鉴权](#)。

- 【推荐】API Key 鉴权，请在 [API Key 管理](#) 页面，获取长效 API Key。
- 【可选】Access Key 鉴权，请在 [Access Key 管理](#) 页面，获取 Access Key。

#### 请求参数

[快速跳转](#) > [响应参数](#)

#### Body 参数

**model** string 必选

调用的模型 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。  
多个应用及精细管理场景，推荐使用 Endpoint ID 调用。详细请参考 [获取 Endpoint ID](#)。

**messages** object[] 必选

消息列表，不同模型支持不同类型的消息，如文本、图片、视频、音频等。

消息类型

系统消息 object

模型需遵循的指令，包括扮演的角色、背景信息等。

属性

**messages.role** string 必选

发送消息的角色，此处应为 `system`。

**messages.content** `string / object[]` 必选  
系统消息的内容。

属性

纯文本内容 `string`  
纯文本消息内容。

多模态内容 `object[]`  
支持文本、图片、视频、音频等模态内容。

各模态内容对象

文本部分 `object`

属性

**messages.content.text** `string` 必选  
文本模态部分的内容。

**messages.content.type** `string` 必选  
内容模态，此处应为 `text`。

图片部分 `object`

属性

**messages.content.type** `string` 必选  
内容模态，此处应为 `image_url`。

**messages.content.image\_url** `object` 必选  
图片模态的内容。

图片输入支持`file_id`、`url`两个字段，需二选一传入。具体使用请参见[图片理解说明](#)。

属性



messages.content.image\_url.file\_id `string`

文件 ID。

- 文件 ID 是通过[Files API](#)上传文件后返回的id。
- **file\_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为**active**。
- **API Key** 所属项目与 **file\_id** 上传时所属项目需保持一致。

#### 注意

Chat API 支持通过 **file\_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

messages.content.image\_url.url `string`

发给模型的图片 URL。支持格式如下：

- 图片链接
- 图片的Base64编码

messages.content.image\_url.detail `string`

取值范围：`low`、`high`、`xhigh`。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

messages.content.image\_url.image\_pixel\_limit `object / null` 默认值 `null`

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

#### 注意

图片像素范围需在 [196, 36,000,000]，否则会直接报错。

- 生效优先级：高于 **detail** 字段，即同时配置 **detail** 与 **image\_pixel\_limit** 字段时，生效 **image\_pixel\_limit** 字段配置。
- 默认生效规则：若未设置 **image\_pixel\_limit**，则使用 **detail** 配置的值对应的 **min\_pixels** / **max\_pixels** 值。

- messages.content.image\_url.image\_pixel\_limit.max\_pixels `integer`

传入图片最大像素限制，大于此像素则等比例缩小至 **max\_pixels** 字段取值以下。若未设置，则取值为 **detail** 配置的值对应的 **max\_pixels** 值。

- doubao-seed-1.8 之前的模型取值范围：(**min\_pixels**, `4014080` ]
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：(**min\_pixels**, `9031680` ]。

- `messages.content.image_url.image_pixel_limit.min_pixels` `integer`  
传入图片最小像素限制，小于此像素则等比例放大至 `min_pixels` 字段取值以上。若未设置，则取值为 `detail` 配置的值对应的 `min_pixels` 值。
  - doubao-seed-1.8 之前的模型取值范围：[ `3136` , `max_pixels` )
  - doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[ `1764` , `max_pixels` )

视频部分 `object`

属性

`messages.content.type` `string` 必选  
内容模态，此处应为 `video_url` 。

`messages.content.video_url` `object` 必选

视频消息的内容部分。  
视频输入支持 `file_id`、`url` 两个字段，需二选一传入。具体使用请参见[视频理解说明](#)。

属性

`messages.content.video_url.file_id` `string`  
文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为 `active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

**注意**

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

`messages.content.video_url.url` `string`  
发给模型的视频 URL。支持格式如下：

- 视频链接
- 视频的Base64编码

`messages.content.video_url.fps` float/ null 默认值 1

取值范围: [0.2, 5]

抽帧频率, 详见[视频理解](#)。

- 取值越高, 对视频中画面变化越敏感。
- 取值越低, 对视频中画面变化越迟钝, 但 token 花费少, 速度更快。

音频部分 `object`

属性

`messages.content.type` string 必选

内容模态, 此处应为 `input_audio`。

`messages.content.input_audio` object 必选

音频模态的内容。

音频输入支持`file_id`、`url`、`data`三个字段, 需三选一传入。具体使用请参见[音频理解](#)。

属性

`messages.content.input_audio.file_id` string

文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致, 且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

### 注意

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件, 支持该能力的模型范围如下:

- `doubao-seed-2.0-mini` 系列: `doubao-seed-2-0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列: 全版本支持。
- `doubao-seed-2.0-pro` 系列: 全版本支持。

`messages.content.input_audio.url` string

音频内容的URL。

`messages.content.input_audio.data` string

音频内容的Base64编码。

`messages.content.input_audio.format` `string`

音频格式。当使用 **data** 时，该参数必填。支持的音频格式 `MIME` 类型如下：  
纯音频格式：

- mp3: `audio/mpeg`
  - wav: `audio/wav`
  - aac: `audio/aac`
  - m4a: `audio/m4a`
- 视频内嵌音频格式：
- mp3: `audio/mpeg`
  - wav: `audio/wav`
  - aac: `audio/aac`
  - m4a: `audio/m4a`
  - pcm: `audio/L16`
  - ac3: `audio/ac3`
  - alac: `audio/m4a`

注意

- 文件大小不超过 25 MB。
- 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。

文件部分 `object`

属性

`messages.content.type` `string` 必选  
消息模态，此处应为 `file`。

`messages.content.file` `object` 必选

文件模态的内容，当前仅支持PDF文件。  
文件输入支持`file_id`、`file_data`、`file_url`三个字段，需三选一传入。多模态理解示例见[文档理解](#)。

属性

`messages.content.file.file_id` `string`  
文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为**active**。
- **API Key** 所属项目与 `file_id` 上传时所属项目需保持一致。

注意

Chat API 支持通过 **file\_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

`messages.content.file.file_data` string  
文件内容的Base64编码。单个文件大小要求不超过50 MB。

`messages.content.file.filename` string  
文件名。当使用 **file\_data** 时该参数必填。

`messages.content.file.file_url` string  
文件的可访问URL。对应文件的大小要求不超过50 MB。

用户消息 object  
用户角色发送的消息。不同模型支持的字段类型不同。

属性

`messages.role` string 必选  
发送消息的角色，此处应为 `user`。

`messages.content` string / object[] 必选  
用户信息内容。

内容类型

纯文本内容 string  
纯文本消息内容。

多模态内容 object[]  
支持文本、图片、视频、音频等模态内容。

内容类型

文本部分 `object`

多模态消息中，文本模态的部分。

属性

`messages.content.text` `string` 必选

文本模态部分的内容。

`messages.content.type` `string` 必选

内容模态，此处应为 `text`。

图片部分 `object`

属性

`messages.content.type` `string` 必选

消息模态，此处应为 `image_url`。

`messages.content.image_url` `object` 必选

图片模态的内容。

图片输入支持`file_id`、`url`两个字段，需二选一传入。具体使用请参见[图片理解说明](#)。

属性

`messages.content.image_url.file_id` `string`

文件 ID。

- 文件 ID 是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

**注意**

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- `doubao-seed-2.0-mini` 系列：`doubao-seed-2-0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列：全版本支持。
- `doubao-seed-2.0-pro` 系列：全版本支持。

`messages.content.image_url.url` `string`

发给模型的图片 URL。支持格式如下：

- 图片链接
- 图片的Base64编码

`messages.content.image_url.detail` `string / null`

取值范围：`low`、`high`、`xhigh`。

理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见[控制图片理解的精细度](#)。

`messages.content.image_url.image_pixel_limit` `object / null` 默认值 `null`

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

#### 注意

图片像素范围需在 [196, 36,000,000]，否则会直接报错。

- 生效优先级：高于 `detail` 字段，即同时配置 `detail` 与 `image_pixel_limit` 字段时，生效 `image_pixel_limit` 字段配置。
- 默认生效规则：若未设置 `image_pixel_limit`，则使用 `detail` 配置的值对应的 `min_pixels` / `max_pixels` 值。

- `messages.content.image_url.image_pixel_limit.max_pixels` `integer`

传入图片最大像素限制，大于此像素则等比例缩小至 `max_pixels` 字段取值以下。若未设置，则取值为 `detail` 配置的值对应的 `max_pixels` 值。

- doubao-seed-1.8 之前的模型取值范围：(`min_pixels`, 4014080 ]
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：(`min_pixels`, 9031680 ]。

- `messages.content.image_url.image_pixel_limit.min_pixels` `integer`

传入图片最小像素限制，小于此像素则等比例放大至 `min_pixels` 字段取值以上。若未设置，则取值为 `detail` 配置的值对应的 `min_pixels` 值。

- doubao-seed-1.8 之前的模型取值范围：[ 3136 , `max_pixels`)
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[ 1764 , `max_pixels`)

视频部分 `object`

属性

`messages.content.type` `string` 必选  
内容模态，此处应为 `video_url`。

`messages.content.video_url` `object` 必选  
视频模态的内容。

视频输入支持`file_id`、`url`两个字段，需二选一传入。具体使用请参见[视频理解说明](#)。

属性

`messages.content.video_url.file_id` `string`  
文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

#### 注意

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- `doubao-seed-2.0-mini` 系列：`doubao-seed-2.0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列：全版本支持。
- `doubao-seed-2.0-pro` 系列：全版本支持。

`messages.content.video_url.url` `string`  
发给模型的视频 URL。支持格式如下：

- 视频链接
- 视频的Base64编码

`messages.content.video_url.fps` `float/ null` 默认值 1  
取值范围：`[0.2, 5]`。  
抽帧频率，详见[视频理解](#)。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

音频部分 `object`

属性

`messages.content.type` `string` 必选  
内容模态，此处应为 `input_audio`。



`messages.content.input_audio` `object` 必选

音频模态的内容。

音频输入支持`file_id`、`url`、`data`三个字段，需三选一传入。具体使用请参见[音频理解](#)。

属性

`messages.content.input_audio.file_id` `string`

文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

#### 注意

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- `doubao-seed-2.0-mini` 系列：`doubao-seed-2-0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列：全版本支持。
- `doubao-seed-2.0-pro` 系列：全版本支持。

`messages.content.input_audio.url` `string`

音频内容的URL。

`messages.content.input_audio.data` `string`

音频内容的Base64编码。

`messages.content.input_audio.format` `string`

音频格式。当使用 `data` 时，该参数必填。支持的音频格式 `MIME` 类型如下：

纯音频格式：

· `mp3`: `audio/mpeg`

· `wav`: `audio/wav`

· `aac`: `audio/aac`

· `m4a`: `audio/m4a`

视频内嵌音频格式：

· `mp3`: `audio/mpeg`

· `wav`: `audio/wav`

· `aac`: `audio/aac`

· `m4a`: `audio/m4a`

· `pcm`: `audio/L16`

· `ac3`: `audio/ac3`

· `alac`: `audio/m4a`

注意

- 文件大小不超过 25 MB。
- 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。

文件部分 `object`

属性

`messages.content.type` `string` `必选`  
消息模态，此处应为 `file`。

`messages.content.file` `object` `必选`

文件模态的内容，当前仅支持PDF文件。  
文件输入支持`file_id`、`file_data`、`file_url`三个字段，需三选一传入。多模态理解示例见[文档理解](#)。

属性

`messages.content.file.file_id` `string`  
文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

注意

Chat API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- `doubao-seed-2.0-mini` 系列：`doubao-seed-2-0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列：全版本支持。
- `doubao-seed-2.0-pro` 系列：全版本支持。

`messages.content.file.file_data` `string`

文件内容的Base64编码。单个文件大小要求不超过50 MB。

`messages.content.file.filename` `string`

文件名。当使用 `file_data` 时该参数必填。

`messages.content.file.file_url` `string`  
文件的可访问URL。对应文件的大小要求不超过50 MB。

模型消息 `object`  
历史对话中，模型角色返回的消息。用以保持对话一致性，多在[多轮对话](#)及[续写模式](#)使用。

属性

**说明**  
`messages.content` 与 `messages.tool_calls` 至少填写其一。

`messages.role` `string` `必选`  
发送消息的角色，此处应为 `assistant` 。

`messages.content` `string / array`  
模型消息的内容。

`messages.reasoning_content` `string`  
模型消息中思维链内容。

仅模型 `doubao-seed-1.8` 、 `deepseek-v3.2` 、 `doubao-seed-2.0` 支持该字段。

`messages.encrypted_content` `string`  
经加密及压缩处理后的思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

**注意**

- 回传 `encrypted_content` 内容需有效，篡改或无法还原时返回错误： `Invalid signature` 。
- `encrypted_content` 优先级高于 `reasoning_content` ，回传 `encrypted_content` 时，将忽略 `reasoning_content` 内容。

`messages.tool_calls` `object[]`  
模型消息中工具调用部分。

属性

`messages.tool_calls.function` `object` `必选`  
模型返回的需调用的函数信息。

属性

`messages.tool_calls.function.name` `string` `必选`  
需调用的函数的名称。

`messages.tool_calls.function.arguments` `string` `必选`  
需调用的函数的入参，JSON 格式。

说明

模型并不总是生成有效的 JSON，可能会虚构出未定义的参数。建议在调用函数前，验证参数是否有效。

`messages.tool_calls.id` `string` `必选`  
需调用的工具的 ID，由模型生成。

`messages.tool_calls.type` `string` `必选`  
消息类型，当前仅支持 `function`。

工具消息 `object`  
历史对话中，调用工具返回的消息。工具调用场景中使用。

属性

`messages.role` `string` `必选`  
发送消息的角色，此处应为 `tool`。

`messages.content` `string / array` `必选`  
工具返回的消息。

`messages.tool_call_id` `string` `必选`  
模型生成的需调用工具请求时，生成的ID。在程序调用工具的返回需要附上同一 ID，来关联工具结构与模型请求。避免多工具调用时混淆信息。

**thinking** `object` 默认值 `{"type":"enabled"}`

控制模型是否开启深度思考模式。

不同模型是否支持以及默认取值不同，详情请查询[文档](#)。

属性

**thinking.type** `string` 必选

取值范围：`enabled`，`disabled`，`auto`。

- `enabled`：开启思考模式，模型强制先思考再回答。
- `disabled`：关闭思考模式，模型直接回答问题，不进行思考。
- `auto`：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。

**stream** `boolean / null` 默认值 `false`

响应内容是否流式返回：

- `false`：模型生成完所有内容后一次性返回结果。
- `true`：按 SSE 协议逐块返回模型生成内容，并以一条 `data: [DONE]` 消息结束。当 **stream** 为 `true` 时，可设置 **stream\_options** 字段以获取 token 用量统计信息。

**stream\_options** `object / null` 默认值 `null`

流式响应的选项。当 **stream** 为 `true` 时，可设置 **stream\_options** 字段。

属性

**stream\_options.include\_usage** `boolean / null` 默认值 `false`

模型流式输出时，是否在输出结束前输出本次请求的 token 用量信息。

- `true`：在 `data: [DONE]` 消息之前会返回一个额外的 chunk。此 chunk 中，**usage** 字段中输出整个请求的 token 用量，**choices** 字段为空数组。
- `false`：输出结束前，没有一个 chunk 来返回 token 用量信息。

**stream\_options.chunk\_include\_usage** `boolean / null` 默认值 `false`

模型流式输出时，输出的每个 chunk 中是否输出本次请求到此 chunk 输出时刻的累计 token 用量信息。

- `true`：在返回的 **usage** 字段中，输出本次请求到此 chunk 输出时刻的累计 token 用量。
- `false`：不在每个 chunk 都返回 token 用量信息。

**max\_tokens** integer / null 默认值 4096

取值范围：各个模型不同，详细见[模型列表](#)。

模型回答最大长度（单位 token）。

#### 说明

- 模型回答不包含思维链内容，模型回答 = 模型输出 - 模型思维链（如有）
- 输出 token 的总长度还受模型的上下文长度限制。

**max\_completion\_tokens** integer / null

支持该字段的模型及使用说明见 [文档](#)。

取值范围：[1,65,536]。

控制模型输出的最大长度（包括模型回答和模型思维链内容长度，单位 token）。

配置了该参数后，可以让模型输出超长内容，**max\_tokens** 默认值失效，模型按需输出内容（回答和思维链），直到达到 **max\_completion\_tokens** 值。

不可与 **max\_tokens** 字段同时设置。

**service\_tier** string / null 默认值 auto

控制使用的在线推理模式。取值范围：**fast**、**auto**、**default**。

- **fast**：本次请求优先使用 [在线推理（低延迟）](#) 模式。
  - 推理接入点（**model** 字段指定）有低延迟限流配额，本次请求将会优先使用低延迟限流配额，获得更高的服务等级（延迟、可用性等）。
  - 推理接入点（**model** 字段指定）无低延迟限流配额，或者限流配额已满，降级至\*\*在线推理（常规）\*\*模式，维持常规的服务等级。
- **auto**：本次请求优先使用 [在线推理（TPM保障包）](#) 模式。
  - 推理接入点（**model** 字段指定）有 TPM 保障包额度，本次请求将会优先使用 TPM 保障包额度，获得最高的服务等级（延迟、可用性等）。
  - 推理接入点（**model** 字段指定）无 TPM 保障包额度或用超额度，降级至\*\*在线推理（常规）\*\*模式，维持常规的服务等级。
- **default**：本次请求只使用 [在线推理（常规）](#) 模式。维持常规的服务等级，即使调用的推理接入点有 TPM 保障包额度 / 低延迟限流额度。

**stop** string / string[] / null 默认值 null

模型遇到 **stop** 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。

[深度思考能力模型](#) 不支持该字段。

["你好", "天气"]

**reasoning\_effort** string / null 默认值 medium

支持该字段的模型、与 **thinking.type** 字段关系见[文档](#)。

限制思考的工作量。减少思考深度可提升速度，思考花费的 token 更少。  
取值范围： `minimal` , `low` , `medium` , `high` , `max` （仅部分模型支持）。

- `minimal` : 关闭思考，直接回答。
- `low` : 轻量思考，侧重快速响应。
- `medium` : 均衡模式，兼顾速度与深度。
- `high` : 深度分析，处理复杂问题。
- `max` : 最高程度思考，适配高难度推理任务。该参数仅对指定模型生效，非适配模型传入将不生效。支持模型列表：
  - `deepseek-v4-pro-260425`
  - `deepseek-v4-flash-260425`

**response\_format** object 默认值 {"type": "text"} beta阶段

指定模型回答格式。

回答格式说明

文本格式 object

模型默认回复文本格式内容。

属性

**response\_format.type** string 必选

此处应为 `text` 。

JSON Object 格式 object

模型回复内容以JSON对象结构来组织。

支持该字段的模型请参见[文档](#)。  
该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

**response\_format.type** string 必选

此处应为 `json_object` 。

JSON Schema 格式 `object`

模型回复内容以JSON对象结构来组织，遵循 **schema** 字段定义的JSON结构。

支持该字段的模型请参见[文档](#) 。  
该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

`response_format.type` `string` 必选

此处应为 `json_schema`。

`response_format.json_schema` `object` 必选

JSON结构体的定义。

属性

`response_format.json_schema.name` `string` 必选

用户自定义的JSON结构的名称。

`response_format.json_schema.description` `string / null`

回复用途描述，模型将根据此描述决定如何以该格式回复。

`response_format.json_schema.schema` `object` 必选

回复格式的 JSON 格式定义，以 JSON Schema 对象的形式描述。

`response_format.json_schema.strict` `boolean / null` 默认值 `false`

是否在生成输出时，启用严格遵循模式。

- `true`：模型将始终严格遵循**schema** 字段中定义的格式。
- `false`：模型会尽可能遵循**schema** 字段中定义的结构。

`frequency_penalty` `float / null` 默认值 `0`

取值范围为 [ `-2.0` , `2.0` ]。

注意

`doubao-seed-1.8`、`doubao-seed-2.0` 系列模型不支持该字段。



频率惩罚系数。如值为正，根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。

**presence\_penalty** float / null 默认值 0  
取值范围为 [ -2.0 , 2.0 ]。

#### 注意

doubao-seed-1.8 、 doubao-seed-2.0 系列模型不支持该字段。

存在惩罚系数。如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。

**temperature** float / null 默认值 1  
取值范围为 [ 0 , 2 ]。

#### 注意

当调用下列模型，字段取值固定为 1 ，手动指定的参数值将被忽略。

- doubao-seed-2-0-pro-260215
- doubao-seed-2-0-lite-260215

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。

通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**top\_p** float / null 默认值 0.7  
取值范围为 [ 0 , 1 ]。

#### 注意

当调用下列模型，字段取值固定为 0.95 ，手动指定的参数值将被忽略。

- doubao-seed-2-0-pro-260215
- doubao-seed-2-0-lite-260215
- doubao-seed-1-8-251228

核采样概率阈值。模型会考虑概率质量在 top\_p 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**logprobs** `boolean / null` 默认值 `false`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

是否返回输出 tokens 的对数概率。

- `false` : 不返回对数概率信息。
- `true` : 返回消息内容中每个输出 token 的对数概率。

**top\_logprobs** `integer / null` 默认值 `0`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

取值范围为 [ 0 , 20 ]。

指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 **logprobs** 为 `true` 时可以设置 **top\_logprobs** 参数。

**logit\_bias** `map / null` 默认值 `null`

带深度思考能力模型不支持该字段，深度思考能力模型参见[文档](#)。

调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。**logit\_bias** 字段接受一个 map 值，其中每个键为词表中的 token ID（使用 tokenization 接口获取），每个值为该 token 的偏差值，取值范围为 [-100, 100]。

-1 会减少选择的可能性，1 会增加选择的可能性；-100 会完全禁止选择该 token，100 会导致仅可选择该 token。该参数的实际效果可能因模型而异。

```
{"<Token_ID>": -100}
```

**tools** `object[] / null` 默认值 `null`

待调用工具的列表，模型返回信息中可包含。当您需要让模型返回待调用工具时，需要配置该结构体。支持该字段的模型请参见[文档](#)。

属性

**tools.type** `string` 必选  
工具类型，此处应为 `function`。

**tools.function** `object` 必选

模型返回中可包含待调用的工具。

属性

**tools.function.name** `string` 必选  
调用的函数的名称。

**tools.function.description** `string`  
调用的函数的描述，大模型会使用它来判断是否调用这个工具。

**tools.function.parameters** `object`  
函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档，格式如下：

JSON

```
{
  "type": "object",
  "properties": {
    "参数名": {
      "type": "string | number | boolean | object | array",
      "description": "参数说明"
    }
  },
  "required": ["必填参数"]
}
```

其中，

- 所有字段名大小写敏感。
- **parameters** 须是合规的 JSON Schema 对象。
- 建议用英文字段名，中文置于 **description** 字段中。

**parallel\_tool\_calls** `boolean` 默认值 `true`  
本次请求，模型返回是否允许包含多个待调用的工具。

- `true`：允许返回多个待调用的工具。
- `false`：允许返回的待调用的工具小于等于1，本取值在 `doubao-seed-1.6` 及之后系列模型生效。

**tool\_choice** `string / object`

仅 `doubao-seed-1.6` 及之后系列模型支持此字段。

本次请求，模型返回信息中是否有待调用的工具。  
当没有指定工具时，`none` 是默认值。如果存在工具，则 `auto` 是默认值。

可选类型

选择模式 `string`

控制模型返回是否包含待调用的工具。

- `none` : 模型返回信息中不可含有待调用的工具。
- `required` : 模型返回信息中必须含待调用的工具。选择此项时请确认存在适合的工具，以减少模型产生幻觉的情况。
- `auto` : 模型自行判断返回信息是否有待调用的工具。

工具调用 `object`

指定待调用工具的范围。模型返回信息中，只允许包含以下模型信息。选择此项时请确认该工具适合用户需求，以减少模型产生幻觉的情况。

属性

`tool_choice.type` `string` `必选`  
调用的类型，此处应为 `function` 。

`tool_choice.function` `object` `必选`  
调用工具的信息。

属性

`tool_choice.function.name` `string` `必选`  
待调用工具的名称。

## 响应参数

### 非流式调用响应

[跳转 流式调用返回](#)

`id` `string`  
本次请求的唯一标识。

`model` `string`  
本次请求实际使用的模型名称和版本。

**service\_tier** `string`

本次请求的请求使用的模式。

- `scale` : 本次请求使用 [在线推理（TPM保障包）](#) 模式。
- `default` : 本次请求使用 [在线推理（常规）](#) 模式。
- `fast` : 本次请求使用 [在线推理（低延迟）](#) 模式。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**object** `string`

固定为 `chat.completion` 。

**choices** `object[]`

本次请求的模型输出内容。

属性

**choices.index** `integer`

当前元素在 **choices** 列表的索引。

**choices.finish\_reason** `string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
- `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
  - 触发 `max_tokens` 限制（回答内容的长度限制）。
  - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。
  - 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。
- `content_filter` : 模型输出被内容审核拦截。
- `tool_calls` : 模型调用了工具。

**choices.message** `object`

模型输出的内容。

属性

**choices.message.role** `string`  
内容输出的角色，此处固定为 `assistant`。

---

**choices.message.content** `string`  
模型生成的消息内容。

---

**choices.message.reasoning\_content** `string / null`  
模型处理问题的思维链内容。  
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。

---

**choices.message.tool\_calls** `object[] / null`  
模型生成的工具调用。

属性

---

**choices.message.tool\_calls.id** `string`  
调用的工具的 ID。

---

**choices.message.tool\_calls.type** `string`  
工具类型，当前仅支持 `function`。

---

**choices.message.tool\_calls.function** `object`  
模型调用的函数。

属性

---

**choices.message.tool\_calls.function.name** `string`  
模型调用的函数的名称。

---

**choices.message.tool\_calls.function.arguments** `string`  
模型生成的用于调用函数的参数，JSON 格式。  
模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

---

**choices.logprobs** `object / null`

当前内容的对数概率信息。

属性

**choices.logprobs.content** `object[] / null`

message列表中每个 content 元素中的 token 对数概率信息。

属性

---

**choices.logprobs.content.token** `string`

当前 token。

---

**choices.logprobs.content.bytes** `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

**choices.logprobs.content.logprob** `float`

当前 token 的对数概率。

---

**choices.logprobs.content.top\_logprobs** `object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 top\_logprobs 指定的数量要少。

属性

---

**choices.logprobs.content.top\_logprobs.token** `string`

当前 token。

---

**choices.logprobs.content.top\_logprobs.bytes** `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

**choices.logprobs.content.top\_logprobs.logprob** `float`

当前 token 的对数概率。

---

`choices.moderation_hit_type` `string`"/ null

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation` ：模型输出文字涉及严重违规。
- `violence` ：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#) [支持返回该字段](#)，且只有在方舟控制台[接入点配置页面](#) [或者](#) [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

---

`usage` `object`

本次请求的 token 用量。

属性

---

`usage.total_tokens` `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

---

`usage.prompt_tokens` `integer`

输入给模型处理的内容 token 数量。

---

`usage.prompt_tokens_details` `object`

输入给模型处理的内容 token 数量的细节。

属性

---

`usage.prompt_tokens_details.cached_tokens` `integer`

缓存命中的输入内容（含文本、音频等所有类型）所消耗的 token 总数。

---

`usage.prompt_tokens_details.audio_tokens` `integer`

音频输入内容所消耗的 token 数量。

---

`usage.prompt_tokens_details.audio_cached_tokens` `integer`

缓存命中的音频输入内容所消耗的 token 数量。

---

`usage.completion_tokens` `integer`

模型输出内容花费的 token。



**usage.completion\_tokens\_details** `object`

模型输出内容花费的 token 的细节。

属性

**usage.completion\_tokens\_details.reasoning\_tokens** `integer`

输出思维链内容花费的 token 数。

支持输出思维链的模型请参见[文档](#)。

## 流式调用响应

[跳转](#) [非流式调用返回](#)

**id** `string`

本次请求的唯一标识。

**model** `string`

本次请求实际使用的模型名称和版本。

**service\_tier** `string`

本次请求是否使用了TPM保障包。

- `scale` : 本次请求使用 [在线推理（TPM保障包）](#) 模式。
- `default` : 本次请求使用 [在线推理（常规）](#) 模式。
- `fast` : 本次请求使用 [在线推理（低延迟）](#) 模式。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**object** `string`

固定为 `chat.completion.chunk`。

**choices** `object[]`

本次请求的模型输出内容。

---

## 属性

---

**choices.index** `integer`

当前元素在 **choices** 列表的索引。

---

**choices.finish\_reason** `string`

模型停止生成 token 的原因。取值范围：

- **stop** : 模型输出自然结束，或因命中请求参数 **stop** 中指定的字段而被截断。
  - **length** : 模型输出因达到模型输出限制而被截断，有以下原因：
    - 触发 **max\_tokens** 限制（回答内容的长度限制）。
    - 触发 **max\_completion\_tokens** 限制（思维链内容+回答内容的长度限制）。
    - 触发 **context\_window** 限制（输入内容+思维链内容+回答内容的长度限制）。
  - **content\_filter** : 模型输出被内容审核拦截。
  - **tool\_calls** : 模型调用了工具。
- 

**choices.delta** `object`

模型输出的增量内容。

## 属性

---

**choices.delta.role** `string`

内容输出的角色，此处固定为 `assistant` 。

---

**choices.delta.content** `string`

模型生成的消息内容。

---

**choices.delta.reasoning\_content** `string / null`

思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，返回思考内容摘要。  
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。

### 注意

针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

---

`choices.delta.encrypted_content` `string`

经加密及压缩处理后的思考内容原文。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

#### 说明

流式输出场景下，将在思考内容输出完成后、正式应答内容输出前，输出包含完整 `encrypted_content` 的数据。其中 `content` 与 `reasoning_content` 字段均为空。

`choices.delta.tool_calls` `object[] / null`

模型生成的工具调用。

属性

`choices.delta.tool_calls.id` `string`

调用的工具的 ID。

`choices.delta.tool_calls.type` `string`

工具类型，当前仅支持 `function`。

`choices.delta.tool_calls.function` `object`

模型调用的函数。

属性

`choices.delta.tool_calls.function.name` `string`

模型调用的函数的名称。

`choices.delta.tool_calls.function.arguments` `string`

模型生成的用于调用函数的参数，JSON 格式。

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`choices.logprobs` `object / null`

当前内容的对数概率信息。

属性

`choices.logprobs.content` `object[] / null`

message列表中每个 content 元素中的 token 对数概率信息。

属性

---

`choices.logprobs.content.token` `string`

当前 token。

---

`choices.logprobs.content.bytes` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

`choices.logprobs.content.logprob` `float`

当前 token 的对数概率。

---

`choices.logprobs.content.top_logprobs` `object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。

属性

---

`choices.logprobs.content.top_logprobs.token` `string`

当前 token。

---

`choices.logprobs.content.top_logprobs.bytes` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

`choices.logprobs.content.top_logprobs.logprob` `float`

当前 token 的对数概率。

---

`choices.moderation_hit_type` `string / null`

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。  
返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。

- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者[CreateEndpoint](#)接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

---

#### `usage` `object`

本次请求的 token 用量。

流式调用时，默认不统计 token 用量信息，返回值为 `null`。

如需统计，需设置 `stream_options.include_usage` 为 `true`。

属性

---

#### `usage.total_tokens` `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

---

#### `usage.prompt_tokens` `integer`

输入给模型处理的内容 token 数量。

---

#### `usage.prompt_tokens_details` `object`

输入给模型处理的内容 token 数量的细节。

属性

---

#### `usage.prompt_tokens_details.cached_tokens` `integer`

缓存输入内容的 token 用量，此处应为 `0`。

---

#### `usage.prompt_tokens_details.audio_tokens` `integer`

音频输入内容所消耗的 token 数量。

---

#### `usage.prompt_tokens_details.audio_cached_tokens` `integer`

缓存音频输入内容的 token 用量。

---

#### `usage.completion_tokens` `integer`

模型输出内容花费的 token。

---

`usage.completion_tokens_details` object

模型输出内容花费的 token 的细节。

属性

---

`usage.completion_tokens_details.reasoning_tokens` integer

输出思维链内容花费的 token 数。

支持输出思维链的模型请参见[文档](#) .

## 3. Responses API

### 3.1 创建模型响应

POST <https://ark.cn-beijing.volces.com/api/v3/responses>

本文介绍 Responses API 创建模型请求时的输入输出参数，供您使用接口时查阅字段含义。

#### 鉴权

本接口支持鉴权方式如下，详情请参见 [Base URL 及 鉴权](#)。

- 【推荐】API Key 鉴权，请在 [API Key 管理](#) 页面，获取长效 API Key。
- 【可选】Access Key 鉴权，请在 [Access Key 管理](#) 页面，获取 Access Key。

#### 请求参数

#### Header 参数

Responses API 支持上报数据用于统计分析，帮助快速排查与定位问题。设置的 header 参数 [开启数据上报](#)。

#### Body 参数

**model** `string` 必选

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。支持的模型请参见 [模型列表](#)。

当您有多个应用调用模型服务或更细粒度权限管理，可[通过 Endpoint ID 调用模型](#)。

**input** `string / array` 必选

输入的内容，模型需要处理的输入信息。

信息类型

**文本输入** `string`

输入给模型的文本类型信息，等同于使用 `user` 角色输入的文本信息。

**输入的元素列表** `array`

输入给模型的信息元素，可以包括不同的信息类型。

信息类型

---

**输入的消息** `object`

发送给模型的消息，其中角色用于指示指令遵循的优先级层级。由 `developer` 或 `system` 角色给出的指令优先于 `user` 角色给出的指令。`assistant` 角色的消息通常被认为是模型在先前交互中生成的回复。

属性

---

**input.content** `string / array` `必选`

用于生成回复的文本、图片、视频或文件输入，也可以包含先前助手的回复内容。

消息类型

---

**文本输入** `string`

输入给模型的文本。

---

**输入的内容列表** `array`

包含一个或多个输入项的列表，每个输入项可包含不同类型的内容。

内容类型

---

**输入模型的文本** `object`

输入模型的文本。

属性

---

**input.content.text** `string` `必选`

输入模型的文本。

---

**input.content.type** `string` `必选`

输入项的类型，此处应为 `input_text`。

---

**input.content.translation\_options** `object`

特定的翻译模型支持该字段，配置翻译场景下的语种等信息。`source_language` 和 `target_language` 取值参见[支持的语言](#)。

---



支持模型为 `doubao-seed-translation-250728`。

属性

`input.content.translation_options.source_language` `string`  
需要翻译的信息的源语言语种。

`input.content.translation_options.target_language` `string` 必选  
需要翻译为何目标语言语种。

输入模型的图片 `object`

输入模型的图片。

图片输入支持 `file_id`、`image_url` 两个字段，需二选一传入。多模态理解示例见 [图片理解](#)。

属性

`input.content.type` `string` 必选  
输入为图片类型，此处应为 `input_image`。

`input.content.file_id` `string`  
文件ID。

- 文件ID是通过 [Files API](#) 上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为 `active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

注意

Responses API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- `doubao-seed-2.0-mini` 系列：`doubao-seed-2-0-mini-260428` 及后续版本。
- `doubao-seed-2.0-lite` 系列：全版本支持。
- `doubao-seed-2.0-pro` 系列：全版本支持。

`input.content.image_url` `string`  
要发送给模型的图片 URL。可以是完整的 URL，或以 data URL 形式编码的 base64 图片。

`input.content.detail` `string`  
取值范围：`low`、`high`、`xhigh`。  
理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见 [控制图片理解的精细度](#)。

`input.content.image_pixel_limit` `object / null` 默认值 `null`

输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

#### 注意

图片像素范围需在 [196, 36,000,000]，否则会直接报错。

- 生效优先级：高于 **detail** 字段，即同时配置 **detail** 与 **image\_pixel\_limit** 字段时，生效 **image\_pixel\_limit** 字段配置。
- 默认生效规则：若未设置 **image\_pixel\_limit**，则使用 **detail** 配置的值对应的 **min\_pixels** / **max\_pixels** 值。

#### 属性

`input.content.image_pixel_limit.max_pixels` `integer`

传入图片最大像素限制，大于此像素则等比例缩小至 **max\_pixels** 字段取值以下。若未设置，则取值为 **detail** 配置的值对应的 **max\_pixels** 值。

- doubao-seed-1.8 之前的模型取值范围：(**min\_pixels**, 4014080 ]
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：(**min\_pixels**, 9031680 ]。

`input.content.image_pixel_limit.min_pixels` `integer`

传入图片最小像素限制，小于此像素则等比例放大至 **min\_pixels** 字段取值以上。若未设置，则取值为 **detail** 配置的值对应的 **min\_pixels** 值。

- doubao-seed-1.8 之前的模型取值范围：[ 3136 , **max\_pixels**)
- doubao-seed-1.8、doubao-seed-2.0 模型的取值范围：[ 1764 , **max\_pixels**)

#### 输入模型的视频 `object`

输入模型的视频。

视频输入支持 **file\_id**、**video\_url** 两个字段，需二选一传入。多模态理解示例见[视频理解](#) [🔗](#)。

#### 属性

`input.content.type` `string` 必选

输入为视频类型，此处为 `input_video`。

`input.content.file_id` `string`

文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- **file\_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active**。
- **API Key** 所属项目与 **file\_id** 上传时所属项目需保持一致。

### 注意

Responses API 支持通过 **file\_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

**input.content.video\_url** string

要发送给模型的视频 URL。可以是完整的 URL，或以 data URL 形式编码的 base64 视频。

**input.content.fps** float

每秒钟从视频中抽取指定数量的图像，取值范围：[0.2, 5]。

如果使用 **file\_id** 参数，**fps** 参数则会失效。

**输入模型的文件** object

输入模型的文件。当前仅支持PDF文件。

文件输入支持**file\_id**、**file\_data**、**file\_url**三个字段，需三选一传入。多模态理解示例见[文档理解](#)。

属性

**input.content.type** string 必选

输入为文件类型，此处为 input\_file。

**input.content.file\_id** string

文件ID。

- 文件ID是通过[Files API](#)上传文件后返回的id。
- **file\_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为**active**。
- **API Key** 所属项目与 **file\_id** 上传时所属项目需保持一致。

### 注意

Responses API 支持通过 **file\_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

`input.content.file_data` `string`

文件内容的Base64编码。单个文件大小要求不超过50 MB。

`input.content.filename` `string`

文件名。当使用 `file_data` 时该参数必填。

`input.content.file_url` `string`

文件的可访问URL。对应文件的大小要求不超过50 MB。

输入模型的音频 `object`

输入模型的音频。

音频输入支持`file_id`、`audio_url`两个字段，需二选一传入。多模态理解示例见[音频理解](#)。

属性

`input.content.type` `string` `必选`

输入为音频类型，此处为 `input_audio`。

`input.content.file_id` `string`

文件ID。

- 文件ID是通过Files API上传文件后返回的id。
- `file_id` 对应的文件类型需要和 `type` 保持一致，且文件状态需要为`active`。
- `API Key` 所属项目与 `file_id` 上传时所属项目需保持一致。

#### 注意

Responses API 支持通过 `file_id` 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：

- doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
- doubao-seed-2.0-lite 系列：全版本支持。
- doubao-seed-2.0-pro 系列：全版本支持。

`input.content.audio_url` `string`

要发送给模型的音频 URL。可以是完整的 URL，或以 data URL 形式编码的 base64 音频。

`input.role` `string` `必选`

输入消息的角色，可以是 `user`，`system`，`assistant` 或 `developer`。

**input.type** string

消息输入的类型，此处应为 `message`。

**input.partial** boolean

模型续写模式。

在 **input** 列表里设置最后一条消息的 **role** 为 `assistant`，并设置 **partial** 为 `true` 开启续写模式，模型会基于 **content** 内容进行续写。在续写模式下，**partial** 为必填项，具体使用见[文档](#)。

**上下文元素** object

表示模型生成回复时需参考的上下文内容。该项可以包含文本、图片和视频输入，以及先前助手的回复和工具调用的输出。

属性

**输入的信息** object

历史请求中，发给模型的信息。

属性

**input.content** array 必选

与 **输入的信息** 中 `content` 字段的结构完全一致。

**input.role** string 必选

输入消息的角色，可选值：`system`，`user` 或 `developer`。

**input.type** string

消息输入的类型，此处应为 `message`。

**input.status** string

项目状态，可选值：`in_progress`，`completed` 或 `incomplete`。

**工具函数信息** object

模型调用工具函数的信息

属性

**input.arguments** `string` 必选  
要传递给函数的参数的 JSON 字符串。

**input.call\_id** `string` 必选  
模型生成的函数工具调用的唯一ID。

**input.name** `string` 必选  
要运行的函数的名称。

**input.type** `string` 必选  
工具调用的类型，始终为 `function_call` 。

**input.status** `string`  
该项的状态。

**工具返回的信息** `object`  
调用工具后，工具返回的信息  
  
属性

**input.call\_id** `string` 必选  
模型生成的函数工具调用的唯一 ID。

**input.output** `string` 必选  
调用工具后，工具输出的结果。

**input.type** `string` 必选  
工具调用的类型，始终为 `function_call_output` 。

**input.status** `string`  
该项的状态。

模型思维链信息 `object`

在模型生成响应时使用的思维链信息。如果需要手动管理，需要设置该字段，以便在后续的对话中进行管理。

仅模型 `doubao-seed-1.8` 、 `deepseek-v3.2` 、 `doubao-seed-2.0` 支持设置思维链信息。

说明

推荐在 Responses API 中使用 `previous_response_id`，API 将自动保存历史轮次的思考内容，并在多轮交互中回传给模型。

属性

`input.id` `string`

思维链信息的唯一标识。

`input.type` `string`

输入对象的类型，此处应为 `reasoning` 。

`input.summary` `array`

思维链内容。

属性

`input.summary.text` `string`

思维链内容的文本部分。

`input.summary.type` `string`

对象的类型，此处应为 `summary_text` 。

`input.status` `string`

思维链内容的状态。

`instructions` `string / null`

在模型上下文中插入系统消息或者开发者作为第一条指令。当与 `previous_response_id` 一起使用时，前一个回复中的指令不会被继承到下一个回复中。这样可以方便地在新的回复中替换系统（或开发者）消

息。  
不可与缓存能力一起使用。配置了instructions 字段后，本轮请求无法写入缓存和使用缓存，表现为：

- caching 字段配置为 {"type":"enabled"} 时报错。
- 传入带缓存的 previous\_response\_id 时，缓存输入（cached\_tokens）为0。

previous\_response\_id string / null

上一个模型回复的唯一标识符。使用该标识符可以实现多轮对话。

说明

- 在请求中传入 previous\_response\_id，会引入上一轮请求的输入和回答内容，本次请求的输入 tokens 会相应增加。工作原理可参见[多轮对话场景](#)。
- 在多轮连续对话中，建议在每次请求之间加入约 100 毫秒的延迟，否则可能会导致调用失败。

expire\_at integer 默认值：创建时刻+259200

取值范围：[创建时刻, 创建时刻+604800]，即最多保留7天。

设置存储的过期时刻，需传入 UTC Unix 时间戳（单位：秒），对 store（上下文存储）和 caching（上下文缓存）都生效。详细配置及示例代码说明请参见[文档](#)。

注意：缓存存储时间计费，过期时刻-创建时刻，不满 1 小时按 1 小时计算。

max\_output\_tokens integer / null

模型输出最大 token 数，包含模型回答和思维链内容。

thinking object 默认值：取决于调用的模型

控制模型是否开启深度思考模式。默认开启深度思考模式，可以手动关闭。

属性

thinking.type string 必选

取值范围：enabled，disabled，auto。

- enabled：开启思考模式，模型一定先思考后回答。
- disabled：关闭思考模式，模型直接回答问题，不会进行思考。
- auto：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。

reasoning object 默认值 {"effort": "medium"}

限制深度思考的工作量。减少深度思考工作量可使响应速度更快，并且深度思考的 token 用量更小。

属性



**reasoning.effort** `string`

支持该字段的模型、与 **thinking.type** 字段关系见[文档](#)。

取值范围：`minimal`，`low`，`medium`，`high`。

- `minimal`：关闭思考，直接回答。
- `low`：轻量思考，侧重快速响应。
- `medium`：均衡模式，兼顾速度与深度。
- `high`：深度分析，处理复杂问题。

**include** `array`

指定要在模型响应中返回的其他输出数据，当前支持的取值如下：

- `reasoning.encrypted_content`：经加密及压缩处理后的思考内容原文，支持手动回传该字段，实现思考内容原文的多轮复用。

**caching** `object` 默认值 `{"type": "disabled"}`

是否开启缓存，阅读[文档](#)，了解缓存的具体使用方式。

不可与 **instructions** 字段、**tools**（除自定义函数 Function Calling 外）字段一起使用。

属性

**caching.type** `string` 必选

取值范围：`enabled`，`disabled`。

- `enabled`：开启缓存。
- `disabled`：关闭缓存。

**caching.prefix** `boolean` 默认值 `false`

- `true`：仅创建公共前缀缓存，模型不回复。
- `false`：不创建公共前缀缓存。

**store** `boolean / null` 默认值 `true`

是否储存生成的模型响应，以便后续通过 API 检索。详细上下文管理使用说明，请见[文档](#)。

- `false`：不储存，对话内容不能被后续的 API 检索到。
- `true`：储存当前模型响应，对话内容能被后续的 API 检索到。

**stream** `boolean / null` 默认值 `false`

响应内容是否流式返回。流式输出示例见[文档](#)。

- `false` : 模型生成完所有内容后一次性返回结果。
- `true` : 按 SSE 协议逐块返回模型生成内容, 并以一条 `data: [DONE]` 消息结束。

**temperature** `float / null` 默认值 `1`

取值范围: `[0, 2]`。

#### 注意

当调用下列模型, 字段取值固定为 `1`, 手动指定的参数值将被忽略。

- `doubao-seed-2-0-code-preview-260215`
- `doubao-seed-2-0-pro-260215`
- `doubao-seed-2-0-lite-260215`

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值 (如 0.8) 会使输出更加随机, 而较低的值 (如 0.2) 会使输出更加集中确定。

通常建议仅调整 `temperature` 或 `top_p` 其中之一, 不建议两者都修改。

**top\_p** `float / null` 默认值 `0.7`

取值范围: `[0, 1]`。

#### 注意

当调用下列模型, 字段取值固定为 `0.95`, 手动指定的参数值将被忽略。

- `doubao-seed-2-0-code-preview-260215`
- `doubao-seed-2-0-pro-260215`
- `doubao-seed-2-0-lite-260215`
- `doubao-seed-1-8-251228`

核采样概率阈值。模型会考虑概率质量在 `top_p` 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token, 取值越大生成的随机性越高, 取值越低生成的确定性越高。通常建议仅调整 `temperature` 或 `top_p` 其中之一, 不建议两者都修改。

**text** `object`

模型文本输出的格式定义, 可以是自然语言, 也可以是结构化的 JSON 数据 (请参见[结构化输出](#))。

属性

**text.format** `object` 默认值 `{"type": "text"}`  
指定模型文本输出的格式。

属性

---

**自然语言** `object`  
响应格式为自然语言。

属性

**text.format.type** `string` 必选  
回复格式的类型，此处应为 `text` 。

---

**JSON Object** `object`  
响应格式为 JSON 对象。结构化输出示例，见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

---

**text.format.type** `string` 必选  
回复格式的类型，此处应为 `json_object` 。

---

**JSON Schema** `object`  
响应格式为 JSON 对象，遵循schema字段定义的 JSON结构。结构化输出示例，见[文档](#)。

该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

---

**text.format.type** `string` 必选  
回复格式的类型，此处应为 `json_schema` 。

---

**text.format.name** `string` 必选  
用户自定义的JSON结构的名称。

---

**text.format.schema** `object` 必选  
回复格式的JSON格式定义，以JSON Schema对象的形式描述。

---

`text.format.description` `string / null`

回复用途描述，模型将根据此描述决定如何以该格式回复。

`text.format.strict` `boolean / null` 默认值 `false`

是否在生成输出时，启用严格遵循模式。

- `true`：模型将始终遵循schema字段中定义的格式。
- `false`：模型将尽可能遵循schema字段中定义的结构。

`tools` `array`

模型

可以调用的工具，当您需要让模型调用工具时，需要配置该结构体。

工具类型

当前支持多种调用方式，包括

- 内置工具（Built-in tools）：由方舟提供的预置工具，用以扩展模型内容，如豆包助手、联网搜索工具、图像处理工具、私域知识库搜索工具等。
- MCP工具：通过自定义 MCP 服务器与第三方系统集成。
- 自定义工具（Function Calling）：您自定义的函数，使模型能够使用强类型参数和输出调用您自己的代码，使用示例见 [文档](#)。

豆包助手

使用豆包助手，快速集成豆包app同款AI能力。详情请参考 [豆包助手文档](#)。

注意：使用前需开通“[豆包助手](#)”功能。

`tools.type` `string` 必选

工具类型，此处填写工具名称，应为 `doubao_app`。

`tools.feature` `object`

豆包助手子功能。

`tools.feature.chat` `object`

日常沟通功能，豆包同款自由对话，默认关闭。

`tools.feature.chat.type` `string` 默认值 `disabled`

取值范围：`enabled`，`disabled`。

- `enabled`：开启此功能。

- `disabled` : 关闭此功能。

`tools.feature.chat.role_description` `string` 默认值: 你的名字是豆包,有很强的专业性。

使用豆包助手时修改角色设定。

此字段与`system prompt`、`instructions` 互斥。

`tools.feature.deep_chat` `object`

深度沟通功能, 豆包同款深度思考对话, 默认关闭。

`tools.feature.deep_chat.type` `string` 默认值 ``disabled`

取值范围: `enabled` , `disabled` 。

- `enabled` : 开启此功能。
- `disabled` : 关闭此功能。

`tools.feature.deep_chat.role_description` `string` 默认值: 你的名字是豆包,有很强的专业性。

使用豆包助手时修改角色设定。

此字段与`system prompt`、`instructions` 互斥。

`tools.feature.ai_search` `object`

联网搜索功能, 豆包同款AI搜索能力, 默认关闭。

`tools.feature.ai_search.type` `string` 默认值 ``disabled`

取值范围: `enabled` , `disabled` 。

- `enabled` : 开启此功能。
- `disabled` : 关闭此功能。

`tools.feature.ai_search.role_description` `string` 默认值: 你的名字是豆包,有很强的专业性。

使用豆包助手时修改角色设定。

此字段与`system prompt`、`instructions` 互斥。

`tools.feature.reasoning_search` `object`

边想边搜功能, 豆包同款结合思考过程的智能搜索能力, 默认关闭。

`tools.feature.reasoning_search.type` `string` 默认值 ``disabled`

取值范围: `enabled` , `disabled` 。

- `enabled` : 开启此功能。
- `disabled` : 关闭此功能。

`tools.feature.reasoning_search.role_description` `string` 默认值: 你的名字是豆包,有很强的专业性。

使用豆包助手时修改角色设定。

此字段与`system prompt`、`instructions` 互斥。

---

`tools.user_location` `object` 默认值 ``{"type": "approximate"}`

用户地理位置, 用于优化对话与搜索结果, 包含 `type`、`country`、`city`、`region` 字段。示例如下:

```
"user_location":{
  "type":"approximate",
```

```
JSON
{
  "country": "中国",
  "region": "浙江",
  "city": "杭州"
}
```

注意：填写 type 后，country、city、region 中 至少1个字段有有效值。

函数调用

**tools.type** `string` 必选  
工具类型，此处应为 `function` 。

**tools.name** `string` 必选  
调用的函数的名称。

**tools.description** `string`  
调用函数的描述，大模型会用它来判断是否调用这个函数。

**tools.parameters** `object` 必选  
函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档，格式如下：

```
JSON
{
  {
    "type": "object",
    "properties": {
      "参数名": {
        "type": "string | number | boolean | object | array",
        "description": "参数说明"
      }
    },
    "required": ["必填参数"]
  }
}
```

其中，

- 所有字段名大小写敏感。
- **parameters** 须是合规的 JSON Schema 对象。
- 建议用英文字段名，中文置于 **description** 字段中。

**tools.strict** `boolean` 默认值 `true`

是否强制执行严格的参数验证。默认为 `true`。

联网搜索工具

在互联网上搜索与该提示相关的资源，详情请参考 [Web Search 基础联网搜索](#)。

注意：使用前需开通“[联网内容插件](#)”组件。

**tools.type** `string` 必选

工具类型，此处填写工具名称，应为 `web_search`。

**tools.sources** `string[]`

选择联网搜索的附加内容源。可选头条图文、抖音百科、墨迹天气。

- `toutiao`：联网搜索的附加头条图文内容源。
- `douyin`：联网搜索的附加抖音百科内容源。
- `moji`：联网搜索的附加墨迹天气内容源。

**tools.limit** `integer` 默认值 `10`

取值范围：`[1, 50]`。

单轮搜索最大召回条数。

说明：影响输入规模与性能，单次搜索最多返回20条结果（单轮可能有多次搜索），默认召回10条。

**tools.user\_location** `object` 默认值 `{"type": "approximate"}`

用户地理位置，用于天气查询等场景，包含 `type`、`country`、`city`、`region` 字段。示例如下：

JSON

```
"user_location":{
  "type":"approximate",
  "country": "中国",
  "region":"浙江",
  "city":"杭州"
}
```

注意：填写 `type` 后，`country`、`city`、`region` 中至少1个字段有有效值。

`tools.max_keyword` `integer`

取值范围：`[1, 50]`。

工具一轮使用，最大并行搜索关键词的数量。

举例：如模型判断需要搜索关键词：“大模型最新进展”，“2025年科技创新”，“火山方舟进展”。

此时`max_keyword = 1`，则实际仅搜索第一个关键词“大模型最新进展”。

图像处理工具

使用画点、画线、旋转、缩放、框选/裁剪关键区域等基础图像处理工具，详情请参考 [Image Process 图像处理工具](#)。

`tools.type` `string` 必选

工具类型，此处填写工具名称，应为 `image_process`。

`tools.point` `object`

画点/连线功能开关，控制是否启用点绘制与连线功能。

属性

`tools.point.type` `string` 默认值 `enabled`

取值范围：`enabled`，`disabled`。

- `enabled`：开启此功能。
- `disabled`：关闭此功能。

`tools.grounding` `object`

框选/裁剪功能开关，控制是否启用关键区域框选或裁剪。

属性

`tools.grounding.type` `string` 默认值 `enabled`

取值范围：`enabled`，`disabled`。

- `enabled`：开启此功能。
- `disabled`：关闭此功能。

`tools.zoom` `object`

缩放功能开关，控制是否启用全图/指定区域缩放（支持0.5–2.0倍）。

属性

`tools.zoom.type` `string` 默认值 `enabled`

取值范围：`enabled`，`disabled`。

- `enabled`：开启此功能。
- `disabled`：关闭此功能。



**tools.rotate** object

旋转功能开关，控制是否启用顺时针旋转（支持0-359度）。

属性

**tools.rotate.type** string 默认值 enabled

取值范围：enabled，disabled。

- enabled：开启此功能。
- disabled：关闭此功能。

MCP 工具

**tools.type** string 必选

工具类型，此处填写工具名称，应为 mcp。

**tools.server\_label** string 必选

MCP Server标签，建议设定与工具用途/Server名称一致。

**tools.server\_url** string 必选

MCP Server访问地址。

**tools.headers** object

要发送至 MCP 服务器的可选 HTTP 请求头，用于身份验证或其他用途。包含：

- Authorization 鉴权信息（不存储）。
- 自定义key-value。

**tools.require\_approval** object/string 默认值 always

指定哪些 MCP 服务器工具需要授权。

属性

**工具批准设置** string

取值范围：

- always：所有工具需用户确认后调用。
- never：所有工具无需确认，直接调用（可能存在安全风险）。

**工具批准筛选** object

指定 MCP 服务器的哪些工具需要审批。可以是 always、never或与需要审批的工具关联的过滤器对象。

属性

`tools.require_approval.always` `object`

指定哪些工具需要用户确认批准。

属性

`tools.require_approval.always.tool_names` `array`

需要用户确认批准的工具名称列表。

---

`tools.require_approval.never` `object`

指定哪些工具不需要用户确认批准使用。

属性

`tools.require_approval.never.tool_names` `array`

不需要用户确认批准的工具名称列表。

---

`tools.allowed_tools` `array/object`

工具加载范围，默认包含当前MCP Server所有工具。

属性

`工具加载范围` `array`

允许加载的工具名称的字符串数组。

---

`工具筛选` `object`

指定 MCP 服务器的哪些工具允许使用。

属性

`tools.allowed_tools.tool_names` `array`

允许的工具名称列表。

私域知识库搜索工具

`tools.type` `string` `必选`

工具类型，此处填写工具名称，应为 `knowledge_search`。

---

`tools.knowledge_resource_id` `string` `必选`

填写需使用的私域知识库ID。

---

`tools.limit` `integer` `默认值 10`

取值范围：`[1, 200]`。

最大可被采用的搜索结果。

`tools.max_keyword` `integer`

取值范围：`[1, 50]`。

工具一轮使用，最大并行搜索关键词的数量。

举例：如模型判断需要搜索关键词：“大模型最新进展”，“2025年科技创新”，“火山方舟进展”。

此时`max_keyword = 1`，则实际仅搜索第一个关键词“大模型最新进展”。

`tools.doc_filter` `object`

设置文档字段级别的检索过滤条件，确保只在符合条件的文档中检索。

- 支持用作过滤条件的文档字段包括：
  - 系统字段：
    - `doc_id`（仅适用于手动创建的知识库）
    - `_sys_auto_doc_id`（适用于手动创建的知识库和 API 创建的知识库）
  - 自定义字段：
    - 已为知识库文档添加的**文档标签**（对应知识库 `index_config` 的 `fields` 字段中的 `field`）
- 支持单一条件过滤和多条件组合过滤（支持 `And` 和 `Or` 逻辑运算）。详细使用方式和支持字段参见 [filter 表达式](#)。

#### 说明

若自定义字段的类型为 `Boolean`，则它的默认取值范围是 `True / False`，但大小写规则有所不同：在 cURL 中必须写作 `true / false`，在 Python 中必须写作 `True / False`。

单一条件过滤示例（在所给的 `doc_id` 范围内检索）：

JSON

```
"doc_filter": {
  "op": "must", // Query scope operators: must/must_not/range/range_out
  "field": "doc_id",
  "conds": [
    "_sys_auto_gen_doc_id-*****01",
    "_sys_auto_gen_doc_id-*****02",
    "_sys_auto_gen_doc_id-*****03"
  ]
}
```

多条件组合过滤示例（在所给的自定义地域和 `doc_id` 范围内检索）：

```
"doc_filter": {
  "op": "and", // Logical operators: and/or
```

```
JSON "conds": [ // Condition list. At least one condition is required.
  {
    "op": "must",
    "field": "region",
    "conds": [
      "cn",
      "sg"
    ]
  },
  {
    "op": "must",
    "field": "doc_id",
    "conds": [
      "_sys_auto_gen_doc_id-*****01",
      "_sys_auto_gen_doc_id-*****02",
      "_sys_auto_gen_doc_id-*****03"
    ]
  }
]
```

**tools.description** string

私域知识库的描述信息。

**tools.dense\_weight** float 默认值 0.5

取值范围：[0.2, 1]。

稠密向量的权重。

- 1 表示纯稠密检索，趋向于 0 表示纯字面检索。
- 只有在请求的知识库使用的是混合检索时有效，即索引算法为 hnsw\_hybrid。

**tools.ranking\_options** object

检索后处理选项。可参考 [知识库API文档](#) [post\\_processing](#) 字段。

属性

**tools.ranking\_options.rerank\_switch** bool 默认值 false

是否自动对检索结果做 rerank。

若设置为true，则会自动请求 rerank 模型排序。

`tools.ranking_options.retrieve_count` `integer` 默认值 25

进入重排的切片数量。此项只有在 `rerank_switch` 为 `true` 时生效。

注意：`retrieve_count` 需要大于等于 `limit`，否则会抛出错误。

`tools.ranking_options.get_attachment_link` `bool` 默认值 `false`

是否获取切片中图片的临时下载链接。

`tools.ranking_options.chunk_diffusion_count` `integer` 默认值 0

取值范围 [0, 5]

检索阶段返回命中切片的上下几片邻近切片。默认为 0，表示不进行 chunk diffusion。

`tools.ranking_options.chunk_group` `bool` 默认值 `false`

文本聚合。

默认不聚合，对于非结构化文件，考虑到原始文档内容语序对大模型的理解，可开启文本聚合。开启后，会根据文档及文档顺序，对切片进行重新聚合排序返回。

`tools.ranking_options.rerank_model` `string` 默认值 "base-multilingual-rerank"

rerank 模型选择。仅在 `rerank_switch` 为 `True` 的时候生效。

可选模型：

- （推荐）" `base-multilingual-rerank` "：速度快、长文本、支持70+种语言。
- " `m3-v2-rerank` "：常规文本、支持100+种语言。

`tools.ranking_options.rerank_only_chunk` `bool` 默认值 `false`

是否仅根据 chunk 内容计算重排分数。可选值：

- `True` ：只根据 chunk 内容计算分
- `False` ：根据 chunk title + 内容 一起计算排序分

`tool_choice` `string / object`

仅 Doubao Seed 1.8 和 Doubao Seed 2.0 系列模型支持此字段。

本次请求，模型返回信息中是否有待调用的工具。

当没有指定工具时，`none` 是默认值。如果存在工具，则 `auto` 是默认值。

可选类型

**工具选择模式** `string`

控制模型返回是否包含待调用的工具。

- `none` : 模型返回信息中不可含有待调用的工具。
- `required` : 模型返回信息中必须含待调用的工具。选择此项时请确认存在适合的工具，以减少模型产生幻觉的情况。
- `auto` : 模型自行判断返回信息是否有待调用的工具。

**工具调用** `object`

指定待调用工具的范围。模型返回信息中，只允许包含以下模型信息。选择此项时请确认该工具适合用户需求，以减少模型产生幻觉的情况。

属性

**tool\_choice.type** `string` 必选

调用的类型。

- 如果为自定义Function此处应为 `function`，此时 `tool_choice.name` 字段为必选。
- 如果为内置工具，此处填写工具名称，请参考 [Responses API 内置工具](#)。

**tool\_choice.name** `string`

待调用工具的名称。

如果 `tool_choice.type` 为 `function`，此项为必选。

**max\_tool\_calls** `integer`

取值范围：`[1, 10]`。

最大工具调用轮次（一轮里不限制次数）。在工具调用达到此限制次数后，提示模型停止更多工具调用并进行回答。

注意：该参数为尽力而为（best effort）机制，不保证成功，最终调用次数会受模型推理效果、工具返回结果有效性等因素影响。

豆包助手不支持此参数。

Web Search 基础联网搜索工具的默认值 `3`。

Image Process 图像处理工具的默认值 `10`，不支持修改。

Knowledge Search 私域知识库搜索工具的默认值为 `3`。

**context\_management** `object`

上下文管理策略，帮助模型有效利用上下文窗口。

属性

**context\_management.edits** `array`

支持的上下文编辑策略，用于管理上下文中思考块和工具调用内容。

策略类型

---

思考块清除 `object`

在开启思考时管理思维链内容。

属性

---

`context_management.edits.type` `string`  
上下文编辑策略类型，此处应为 `clear_thinking` 。

---

`context_management.edits.keep` `object/string`  
思维链保留策略。

类型

---

保留最近 N 轮思维链 `object`

属性

`context_management.edits.keep.type` `string`  
思维链保留策略类型，此处应为 `thinking_turns` 。

---

`context_management.edits.keep.value` `integer` 默认值 1  
保留最近 N 轮的思维链。

---

保留所有思维链 `string`  
保留所有思维链，此处应为 `all` 。

---

工具调用内容清除 `object`

在对话上下文增长超过配置的阈值时清除工具调用内容。

属性

---

`context_management.edits.type` `string`  
上下文编辑策略类型，此处应为 `clear_tool_uses` 。

---

`context_management.edits.keep` `object`  
工具调用内容保留策略。

属性

`context_management.edits.keep.type` `string`  
工具调用内容保留策略类型，此处应为 `tool_uses` 。

`context_management.edits.keep.value` `integer` 默认值 3  
保留最近 N 轮工具调用内容。

`context_management.edits.exclude_tools` `array`  
不会被清除的工具名称列表，用于保留重要上下文。

`context_management.edits.clear_tool_input` `boolean` 默认值 false  
是否清除工具调用参数。

`context_management.edits.trigger` `object`  
触发工具调用内容清除策略的阈值。

属性

`context_management.edits.trigger.type` `string`  
触发工具调用内容清除策略类型，此处应为 `tool_uses` 。

`context_management.edits.trigger.value` `integer`  
工具调用达到 N 轮时触发清除策略。

`service_tier` `string / null` 默认值 default  
控制使用的在线推理模式。取值范围：`default` 、 `fast` 。

- `default` ：本次请求只使用 [在线推理（常规）](#) 模式。维持常规的服务等级，即使调用的推理接入点有低延迟限流额度。
- `fast` ：本次请求优先使用 [在线推理（低延迟）](#) 模式。
  - 推理接入点（`model` 字段指定）有低延迟限流配额，本次请求将会优先使用低延迟限流配额，获得更高的服务等级（延迟、可用性等）。



- 推理接入点（**model** 字段指定）无低延迟限流配额，或者限流配额已满，降级至\*\*在线推理（常规）\*\*模式，维持常规的服务等级。

## 响应参数

跳转 [请求参数](#)

---

## 非流式调用响应

返回一个 [response object](#)。

---

## 流式调用响应

服务器会在生成 Response 的过程中，通过 Server-Sent Events（SSE）实时向客户端推送事件。具体事件介绍请参见 [流式响应](#)。

## 3.2 查询模型响应

GET [https://ark.cn-beijing.volces.com/api/v3/responses/{response\\_id}](https://ark.cn-beijing.volces.com/api/v3/responses/{response_id})

通过 response id 获取模型响应。

### 请求参数

#### Path

**response\_id** string 必选

待检索的响应 id。

### 响应参数

- 如果您调用的 response 响应已完成，模型会返回对应的 [response object](#)。
- 如果您调用的 response 响应未完成，模型会返回错误码。

## 3.3 获取响应上下文

GET `https://ark.cn-beijing.volces.com/api/v3/responses/{response_id}/input_items?after={after}&before={before}&limit={limit}&order={order}&include[]={include}`

获取某次模型响应对应的全部上下文信息。

### 鉴权说明

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

### 快速入门

[模型列表](#) [模型计费](#) [Responses API 教程](#) [上下文缓存教程](#) [API Key](#)

### 请求参数

[跳转 响应参数](#)

### 路径参数

**response\_id** `string` %%require%%  
待检索上下文元素所对应的响应 id。

### 查询参数

在 URL String 中传入。

**after** `string/ null`  
返回该 ID 之后的输入项。

**before** `string/ null`  
返回该 ID 之前的输入项。

**\*\*include[]** `** array/ null`  
用于指定在响应中要额外包含的字段。部分接口默认返回基础字段，通过 include 可让服务端补充返回更多信息。

属性

**message.input\_image.image\_url**  
包含输入消息中的图像 URL。

- 图像为 url 时，返回url。

- 图像为 base64 编码时，返回 base64 编码信息。

---

**limit** `integer` 默认值: 20

控制单次返回的最大项目数。  
取值范围: 1 ~ 100。

---

**order** `string` 默认值: desc

控制输入项的排序方式。

- asc: 按照正序排列。
- desc: 按照倒序排列。

## 响应参数

[跳转](#) [请求参数](#)

返回本次响应对应的所有上下文元素。

**object** `string`

固定为 `list` 。

---

**data** `object[] / null`

上下文元素列表，与 [创建模型请求](#) 时的 **input**（输入的元素列表）字段结构完全一致。  
如果请求中引用了 `previous_response_id`，服务器也会返回 `previous_response` 包含的上下文。

---

**first\_id** `string`

列表中第一条数据的 ID。

---

**has\_more** `boolean`

标识是否还有更多数据未返回。

- true: 存在未返回的数据。
- false: 已返回全部数据。

---

**last\_id** `string`

列表中最后一条数据的 ID。

## 3.4 删除模型响应

DELETE [https://ark.cn-beijing.volces.com/api/v3/responses/{response\\_id}](https://ark.cn-beijing.volces.com/api/v3/responses/{response_id})

本文介绍如何删除指定 ID 的模型请求。

### 鉴权说明

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

### 快速入门

 [模型列表](#)   [模型计费](#)   [Responses API 教程](#)   [上下文缓存教程](#)   [API Key](#) 

### 请求参数

#### 路径参数

---

**response\_id** `string` %%require%%  
待删除请求的id。

#### 响应参数

---

**id** `string`  
待删除请求的id。

---

**object** `string`  
固定为 `response` 。

---

**deleted** `boolean`  
取值范围：

- `true` ： 删除成功。
- `false` ： 未删除成功。

## 3.5 The response object

[创建模型请求](#) 或 [获取模型响应](#) 后，模型会返回一个 response 对象。本文为您介绍 response 对象包含的详细参数。

**created\_at** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**error** `object / null`

模型未能生成响应时返回的错误对象。

- code：相应的错误码。
- message：错误描述。

**id** `string`

本次请求的唯一标识。

**incomplete\_details** `object / null`

响应未能完成的细节。

`reason`：响应未能完成的原因。

**instructions** `string / null`

在模型上下文中插入一条系统（或开发者）消息，作为首项。

当与 `previous_response_id` 一起使用时，前一响应中的指令不会延续到下一响应。

**max\_output\_tokens** `integer / null`

模型输出最大 token 数，包含模型回答和思维链内容。

**model** `string`

本次请求实际使用的模型名称和版本。

**object** `string`

固定为 `response`。

**output** `array`

模型的输出消息列表，包含模型响应本次请求生成的回答、思维链、工具调用。

属性

---

**模型回答** `object`

模型回答，不包含思维链。

属性

---

**output.\*\*content \*\*** `array`

输出消息的内容。

属性

---

**文本回答** `object`

模型回答的文本消息。

属性

---

**output.content.\*\*text \*\*** `string`

模型回答的文本内容。

---

**output.content.\*\*type \*\*** `string`

模型回答的类型，固定为 `output_text` 。

---

**output.\*\*role \*\*** `string`

输出信息的角色，固定为 `assistant` 。

---

**output.\*\*status \*\*** `string`

输出消息的状态。

---

**output.\*\*id \*\*** `string`

此回答的唯一标识。

---

`output.**type` `string`  
输出消息的类型，此处应为 `message` 。

---

`output.**partial` `boolean`  
模型开启续写模式时会返回该字段，此处应为 `true` 。

---

### 模型思维链

本次请求，当触发深度思考时，模型会返回问题拆解的思维链内容。

属性

---

`output.**summary` `array` `** **`  
思考内容原文。自 [Doubao-Seed-2.0-lite/260428](#) 版本起，该字段用于返回思考内容摘要。

属性

---

`output.summary.**text` `string`  
思维链内容的文本部分。

---

#### 注意

针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

---

`output.summary.**type` `string`  
对象的类型，此处应为 `summary_text` 。

---

`output.**content` `array` `** **`  
思考内容原文。

属性

`output.content.**text` `string`  
思维链内容的文本部分。

---

`output.content.**type` `string`  
对象的类型，此处应为 `reasoning_text` 。

---



output.\*\*type\*\* string

本输出对象的类型，此处应为 `reasoning`。

output.\*\*status\*\* string

本次思维链内容返回的状态。

output.\*\*encrypted\_content\*\* string

经加密及压缩处理后的思考内容原文。仅当在 `include` 参数中指定 `reasoning.encrypted_content` 时，才会在生成响应时返回该字段。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

output.\*\*id\*\* string

本思维链消息的唯一标识。

### 工具调用

本次请求，模型根据信息认为需要调用的工具信息以及对应参数。

属性

output.\*\*arguments\*\* string

要传递给函数的参数，格式为 JSON 字符串。

output.\*\*call\_id\*\* string

本次工具调用信息的唯一 ID。

output.\*\*name\*\* string

要运行的函数的名称。

output.\*\*type\*\* string

工具调用的类型，此处应为 `function_call`。

output.\*\*status\*\* string

此时消息返回的状态。

**output.\*\*id \*\*** `string`  
本次输出的唯一标识。

#### MCP 工具

**output.\*\*id \*\*** `string`  
本次输出的唯一标识。

---

**output.\*\*server\_label \*\*** `string`  
MCP Server标签。

---

**output.\*\*tools \*\*** `object`  
mcp工具返回信息

#### McpCall

**arguments** `string`  
传递给工具的参数的 JSON 字符串。

---

**id** `string`  
本次输出的唯一标识。

---

**name** `string`  
运行工具的名称。

---

**\*\*server\_label \*\*** `string`  
MCP Server标签。

---

**type** `string`  
始终为 `mcp_call` 。

---

**error** `string`  
工具调用中出现的错误（如有）。

---

**output** `string`  
工具调用的输出结果。

#### McpListTools

**id** `string`  
MCP 列表的唯一标识。

---

**\*\*server\_label\*\*** `string`  
MCP Server标签。

---

**\*\*tools\*\*** `array`  
服务端可用工具。

**属性**  
**tools . \*\*input\_schema\*\*** `object`  
描述工具输入的 JSON 模式。

---

**tools . name** `string`  
运行工具的名称。

---

**tools . annotations** `object`  
关于该工具的其他说明。

---

**tools . description** `string`  
工具描述。

联网搜索工具  
**output.\*\*tools\*\*** `object`  
mcp工具返回信息

**属性**  
**id** `string`  
本次输出的唯一标识。

---

**type** `string`  
始终为 `web_search_call` 。

---

**action** `object`  
此次搜索调用中执行的具体操作的对象。

**属性**  
**action.\*\*type\*\*** `string`  
一般为 `search`

---

`action.**query**` `string`  
搜索内容。

`action.source**` `string[]`  
联网搜索的附加内容源。可能为头条图文、抖音百科、墨迹天气。

- `toutiao` : 联网搜索的附加头条图文内容源。
- `douyin` : 联网搜索的附加抖音百科内容源。
- `moji` : 联网搜索的附加墨迹天气内容源。

图像处理工具

`output.**tools**` `object`  
mcp工具返回信息

属性

`type` `string`  
始终为 `image_process` 。

`**point**` `object`  
画点/连线功能开关，是否启用点绘制与连线功能。

- `"type":"enabled"` : 已开启此功能。
- `"type":"disabled"` : 未开启此功能。

`**grounding**` `object`  
框选/裁剪功能开关，控制是否启用关键区域框选或裁剪。

- `"type":"enabled"` : 已开启此功能。
- `"type":"disabled"` : 未开启此功能。

`**zoom**` `object`  
缩放功能开关，控制是否启用全图/指定区域缩放（支持0.5–2.0倍）。

- `"type":"enabled"` : 已开启此功能。
- `"type":"disabled"` : 未开启此功能。

`**rotate**` `object`  
旋转功能开关，控制是否启用顺时针旋转（支持0–359度）。

- `"type":"enabled"` : 已开启此功能。
- `"type":"disabled"` : 未开启此功能。

**previous\_response\_id** string / null

本次请求时传入的历史响应ID。

**\*\*thinking\*\*** object / null

是否开启深度思考模式。

属性

**thinking.\*\*type\*\*** string

取值范围：enabled，disabled，auto。

- enabled：开启思考模式，模型一定先思考后回答。
- disabled：关闭思考模式，模型直接回答问题，不会进行思考。
- auto：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。

**service\_tier** string

本次请求是否使用了TPM保障包。

- default：本次请求未使用TPM保障包额度。

**status** string

生成响应的状态。

- completed：响应已完成。
- failed：响应失败。
- in\_progress：响应中。
- incomplete：响应未完成。

**text** object

用于定义输出的格式，可以是纯文本，也可以是结构化的JSON数据。详情请看[结构化输出](#)。

属性

**text.\*\*format\*\*** object

指定模型必须输出的格式的对象。

属性

**自然语言输出** object

模型回复以自然语言输出。

`text.format.**type**` `string`  
回复格式的类型，固定为 `text` 。

---

JSON Object `object`  
响应格式为 JSON 对象。

属性

---

`text.format.**type**` `string`  
回复格式的类型，固定为 `json_object` 。

---

JSON Schema `object`  
响应格式为 JSON 对象，遵循schema字段定义的 JSON结构。

属性

---

`text.format.**type**` `string`  
回复格式的类型，固定为 `json_schema` 。

---

`text.format.**name**` `string`  
用户自定义的JSON结构的名称。

---

`text.format.**schema**` `object`  
回复格式的JSON格式定义，以JSON Schema对象的形式描述。

---

`text.format.description` `string / null`  
回复用途描述，模型将根据此描述决定如何以该格式回复。

---

`text.format.strict` `boolean / null`  
是否在生成输出时，启用严格遵循模式。

- `true`：模型将始终遵循schema字段中定义的格式。
  - `false`：模型将尽可能遵循schema字段中定义的结构。
-

**tools** `array`

模型可以调用的工具列表。

属性

---

**tools.\*\*function** `object`

模型可以调用的类型为 `function` 的工具列表。

属性

---

**tools.function.\*\*name** `string`

调用的函数的名称。

---

**tools.function.\*\*parameters** `object`

函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档，格式如下：

JSON

```
{
  "type": "object",
  "properties": {
    "参数名": {
      "type": "string | number | boolean | object | array",
      "description": "参数说明"
    }
  },
  "required": ["必填参数"]
}
```

其中，

- 所有字段名大小写敏感。
  - **parameters** 须是合规的 JSON Schema 对象。
  - 建议用英文字段名，中文置于 **description** 字段中。
- 

**tools.function.\*\*type** `string`

工具调用的类型，固定为 `function`。

---

**tools.function.\*\*description** `string`

调用的函数的描述，大模型会使用它来判断是否调用这个函数。

---

---

**top\_p** float / null  
核采样概率阈值。

---

**\*\*usage\*\*** object  
本次请求的 token 用量，包括输入 token 数量、输入 token 的详细分解、输出 token 数量、输出 token 的详细分解，以及总共使用的 token 数。  
如果使用了工具，还会输出使用的工具类型和次数，以及工具的使用详情。

属性

---

**usage.input\_tokens** integer  
输入的 token 量。

---

**usage.input\_tokens\_details** object  
输入 token 的详细信息。

属性

---

**usage.input\_tokens\_details.cached\_tokens** integer  
缓存命中的输入内容（含文本、音频等所有类型）所消耗的 token 总数。

---

**usage.input\_tokens\_details.audio\_tokens** integer  
音频输入内容所消耗的 token 数量。

---

**usage.input\_tokens\_details.audio\_cached\_tokens** integer  
缓存命中的音频输入内容所消耗的 token 数量。

---

**usage.output\_tokens** integer  
输出的 token 量。

---

**usage.output\_tokens\_details** object  
输出 token 的详细信息。

属性

---



usage.output\_tokens\_details.\*\*reasoning\_tokens\*\* integer  
思考用 token 的数量。

---

usage.\*\*total\_tokens\*\* integer  
消耗 token 的总量。

---

usage.\*\*tool\_usage\*\* object  
使用工具的信息。

属性

usage.tool\_usage.\*\*image\_process\*\* integer  
调用图像处理工具的数量。

---

usage.tool\_usage.\*\*mcp\*\* integer  
调用mcp工具的数量。

---

usage.tool\_usage.\*\*web\_search\*\* integer  
调用网络搜索工具的数量。

---

usage.\*\*tool\_usage\_details\*\* object  
使用工具的详细信息。

属性

usage.tool\_usage\_details.\*\*image\_process\*\* object  
调用图像处理工具的详细信息。例如：

JSON

```
"tool_usage_details":{
  "image_process":{
    "zoom": 1,
    "point": 1,
    "grounding": 1
  }
}
```

usage.tool\_usage\_details.\*\*mcp\*\* object  
调用mcp工具的详细信息。例如：

## JSON

```
"tool_usage_details":{
  "mcp":{
    "mcp_server_tos": 1,
    "mcp_server_tls": 1
  }
}
```

`usage.tool_usage_details.**web_search**` `object`  
调用网络搜索工具的详细信息。例如：

## JSON

```
"tool_usage_details":{
  "web_search":{
    "toutiao": 1,
    "moji": 1,
    "search_engine": 1
  }
}
```

`store` `boolean` 默认值 `true`

是否存储生成的模型响应，以便后续通过 API 检索。

- `false`：不存储，对话内容不能被后续的 API 检索到。
- `true`：存储当前模型响应，对话内容能被后续的 API 检索到。

`**caching**` `object`

是否开启缓存。

属性

`caching.type` `***` `string`

取值范围：`enabled`，`disabled`。

- `enabled`：开启缓存。
- `disabled`：关闭缓存。

**expire\_at** integer/null  
存储的有效期。

---

**temperature** float/null  
采样温度。

---

**\*\*context\_management\*\*** object  
上下文管理响应，请求过程中应用的上下文管理策略信息。

属性

**context\_management.applied\_edits** array  
已应用的上下文编辑策略列表。

策略类型

---

**\*\*思考块清除\*\*** object

属性

---

**context\_management.applied\_edits.type** string  
上下文编辑策略类型，此处应为 `clear_thinking`。

---

**context\_management.applied\_edits.cleared\_thinking\_turns** integer  
已清除的思考轮次次数。

---

**工具调用内容清除** object

属性

---

**context\_management.applied\_edits.type** string  
上下文编辑策略类型，此处应为 `clear_tool_uses`。

---

**context\_management.applied\_edits.cleared\_tool\_uses** integer  
已清除的工具调用次数。

## 3.6 流式响应

当你创建 response 并将 `stream` 设置为 `true` 时，服务器会在生成 Response 的过程中，通过 Server-Sent Events ( SSE ) 实时向客户端推送事件。本节内容介绍服务器会推送的各类事件。

### 说明

流式输出的示例代码及返回示例，详见[流式输出](#) [教程](#)。

## response.created

当响应被创建时触发的事件。

**response** `object`

创建状态的响应。包含参数与[创建模型请求](#)时，非流式调用返回的参数一致。

**sequence\_number** `integer`

事件的序列号。

**type** `string`

事件的类型，总是 `response.created` 。

response.created 响应示例

```
{
  "type": "response.created",
  "response": {
    "created_at": 1764229579,
    "id": "resp_021764229578658fe9a0f6cb2cc6c828e7a59adbdb971872aee70",
    "max_output_tokens": 32768,
    "model": "doubao-seed-1-6-251015",
    "object": "response",
    "thinking": {
      "type": "enabled"
    },
    "service_tier": "default",
    "caching": {
      "type": "disabled"
    }
  }
}
```

```
JSON{
  "store": true,
  "expire_at": 1764488778
},
"sequence_number": 0
}
```

## response.in\_progress

当响应在进程中触发的事件。

**response** `object`

进行中状态的响应。包含参数与[创建模型请求](#)时，非流式调用返回的参数一致。

**sequence\_number** `integer`

事件的序列号。

**type** `string`

事件的类型，总是 `response.in_progress`。

response.in\_progress 响应示例

```
{
  "type": "response.in_progress",
  "response": {
    "created_at": 1764229579,
    "id": "resp_021764229578658fe9a0f6cb2cc6c828e7a59adbdb971872aee70",
    "max_output_tokens": 32768,
    "model": "doubao-seed-1-6-251015",
    "object": "response",
    "thinking": {
      "type": "enabled"
    },
    "service_tier": "default",
    "caching": {
      "type": "disabled"
    }
  }
}
```

```
JSON},
  "store": true,
  "expire_at": 1764488778
},
"sequence_number": 1
}
```

## response.completed

当响应已完成触发的事件。

response **object**

已完成状态的响应。包含参数与[创建模型请求](#)时，非流式调用返回的参数一致。

sequence\_number integer

事件的序列号。

type string

事件的类型，总是 `response.completed`。

### response.completed 响应示例

```
{
  "type": "response.completed",
  "response": {
    "created_at": 1776222945,
    "id": "resp_021776222944180e3c0010419774ef230e4bef6206f9366409cf2",
    "max_output_tokens": 32768,
    "model": "doubao-seed-2-1-pro-260628",
    "object": "response",
    "output": [
      {
        "id": "rs_021776222945377000000000000000000000ffffac15ee27794623",
        "type": "reasoning",
        "summary": [
          {
```

```
JSON {
  "type": "summary_text",
  "text": "Model reasoning process summary content example."
},
{
  "status": "completed"
},
{
  "type": "message",
  "role": "assistant",
  "content": [
    {
      "type": "output_text",
      "text": "Final assistant response content example."
    }
  ],
  "status": "completed",
  "id": "msg_021776222991181000000000000000000000ffffac15ee273242ae"
},
{
  "service_tier": "default",
  "status": "completed",
  "usage": {
    "input_tokens": 58,
    "output_tokens": 1647,
    "total_tokens": 1705,
    "input_tokens_details": {
      "cached_tokens": 0
    },
    "output_tokens_details": {
      "reasoning_tokens": 1273
    }
  },
  "caching": {
    "type": "disabled"
  },
  "store": true,
  "expire_at": 1776482144
},
{
  "sequence_number": 1635
}
}
```

**response.failed**

当响应失败触发的事件。

**response** `object`

失败状态的响应。包含参数与[创建模型请求](#)时，非流式调用返回的参数一致。

**sequence\_number** `integer`

事件的序列号。

**type** `string`

事件的类型，总是 `response.failed`。

response.failed 响应示例

JSON

```
{
  "type": "response.failed",
  "response": {
    "created_at": 1764229579,
    "error": {
      "code": "server_error",
      "message": "The model encountered an internal error while generating a response."
    },
    "id": "resp_021764229578658fe9a0f6cb2cc6c828e7a59adbdb971872aee70",
    "max_output_tokens": 32768,
    "model": "doubao-seed-1-6-251015",
    "object": "response",
    "output": [],
    "thinking": {"type": "enabled"},
    "service_tier": "default",
    "status": "failed",
    "tools": [],
    "caching": {"type": "disabled"},
    "store": true,
    "expire_at": 1764488778,
    "sequence_number": 5
  }
}
```

**response.incomplete**

当响应以未完成状态结束时触发的事件。



**response** `object`

未完成状态的响应。包含参数与[创建模型请求](#)时，非流式调用返回的参数一致。

**sequence\_number** `integer`

事件的序列号。

**type** `string`

事件的类型，总是 `response.incomplete`。

`response.incomplete` 响应示例

JSON

```
{
  "type": "response.incomplete",
  "response": {
    "response_id": "resp_4jqrc20000801",
    "created_at": 1738123456,
    "status": "incomplete",
    "usage": null,
    "output": []
  },
  "sequence_number": 0
}
```

## **response.output\_item.added**

表示添加了新的输出项。

**item** `object`

模型输出内容。

属性

**文本输出** `object`

增加的模型回答的内容。

属性

---

**item.content** `array`

输出消息的内容。

文本信息 `object`

模型的文本输出。

属性

---

**item.content.text** `string`

模型的文本输出。

---

**item.content.type** `string`

输出文本的类型，总是 `output_text` 。

---

**item.role** `string`

输出信息的角色，总是 `assistant` 。

---

**item.status** `string`

输出消息的状态。

---

**item.id** `string`

output message 请求的唯一标识。

---

**item.type** `string`

输出消息的类型。

---

**内容链** `object`

请求中触发了深度思考时的思维链内容。

属性

---

**item.summary** `array`

思考内容原文。自 `seed-2-0-pro-260328` 版本起，该字段用于返回思考内容摘要。自 `doubao-seed-2-0-lite-260428` 版本起，该字段用于返回思考内容摘要。

属性

---

**item.summary.text** `string`

模型生成答复时的推理内容。

#### 注意

针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

**item.summary.type** `string`

对象的类型，总是 `summary_text`。

**item.content** `array`

思考内容原文。

属性

**item.content.text** `string`

模型生成答复时的推理内容。

**item.content.type** `string`

对象的类型，总是 `reasoning_text`。

**item.type** `string`

对象的类型，此处应为 `reasoning`。

**item.encrypted\_content** `string`

经加密及压缩处理后的思考内容原文。仅当在 `include` 参数中指定 `reasoning.encrypted_content` 时，才会在生成响应时返回该字段。自 `bytedance-seed-2-0-pro-260328` 版本起，支持该字段输出。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

**item.status** `string`

该内容项的状态。

**item.id** `string`

请求的唯一标识。

**工具信息** `object`  
模型调用工具的信息

属性

---

**item.arguments** `string`  
要传递给函数的参数的 JSON 字符串。

---

**item.call\_id** `string`  
模型生成的函数工具调用的唯一ID。

---

**item.name** `string`  
要运行的函数的名称。

---

**item.type** `string`  
工具调用的类型，始终为 `function_call` 。

---

**item.status** `string`  
该项的状态。

---

**item.id** `string`  
工具调用请求的唯一标识。

---

**output\_index** `integer`  
被添加的输出项的索引。

---

**sequence\_number** `integer`  
事件的序列号。

---

**type** `string`  
事件的类型，总是 `response.output_item.added` 。

---

response.output\_item.added 响应示例

## JSON

```
{  
  "type": "response.output_item.added",  
  "output_index": 0,  
  "item": {  
    "id": "rs_021764229579637000000000000000000000ffffac15dd335c9c43",  
    "type": "reasoning",  
    "status": "in_progress"  
  },  
  "sequence_number": 2  
}
```

## response.output\_item.done

表示输出项已完成。

**item** object

已完成的输出项。

属性

文本输出 `object`

增加的模型回答的内容。

属性

item.content array

输出消息的内容。

文本信息

object

模型的文本输出。

属性

item.content.text string

模型的文本输出。

item.content.type string

输出文本的类型，总是 `output_text`。

**item.role** `string`

输出信息的角色，总是 `assistant` 。

---

**item.status** `string`

输出消息的状态。

---

**item.id** `string`

output message 请求的唯一标识。

---

**item.type** `string`

输出消息的类型。

---

**内容链** `object`

请求中触发了深度思考时的思维链内容。

属性

---

**item.summary** `array`

思考内容原文。自 `bytedance-seed-2-0-pro-260328` 版本起，该字段用于返回思考内容摘要。自 `doubao-  
seed-2-0-lite-260428` 版本起，该字段用于返回思考内容摘要。

属性

---

**item.summary.text** `string`

模型生成答复时的推理内容。

#### 注意

针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

---

**item.summary.type** `string`

对象的类型，总是 `summary_text` 。

---

**item.content** `array`

思考内容原文。

属性

**item.content.text** `string`

模型生成答复时的推理内容。

**item.content.type** `string`

对象的类型，总是 `reasoning_text`。

**item.type** `string`

对象的类型，此处应为 `reasoning`。

**item.encrypted\_content** `string`

经加密及压缩处理后的思考内容原文。仅当在 `include` 参数中指定 `reasoning.encrypted_content` 时，才会在生成响应时返回该字段。自 `bytedance-seed-2-0-pro-260328` 版本起，支持该字段输出。自 `doubao-seed-2-0-lite-260428` 版本起，支持该字段输出。

**item.status** `string`

该内容项的状态。

**item.id** `string`

请求的唯一标识。

**工具信息** `object`

模型调用工具的信息

属性

**item.arguments** `string`

要传递给函数的参数的 JSON 字符串。

**item.call\_id** `string`

模型生成的函数工具调用的唯一ID。





```
JSON{"status": "completed",
      "sequence_number": 1261
}
```

---

## response.content\_part.added

当有新的内容部分被添加时触发。

---

**content\_index** `integer`

内容部分的索引。

---

**item\_id** `string`

内容部分所添加的输出项的 ID 。

---

**output\_index** `integer`

内容部分所添加的输出项的索引 。

---

**part** `object`

所添加的内容部分。

属性

**输出文本** `object`

模型输出的文本对象

**part.text** `string`

模型输出的文本内容。

**part.type** `string`

output text 的类型，此处应是 `output_text` 。

---

**sequence\_number** `integer`

事件的序列号。

---

**type** `string`

事件的类型，总是 `response.content_part.added` 。

---























**param** `string/null`

错误参数。

---

**sequence\_number** `integer`

事件的序列号。

---

**type** `string`

事件的类型，总是 `error` 。

---

error 响应示例

JSON

```
{
  "type": "error",
  "code": "InvalidParameter",
  "message": "Invalid value for 'max_output_tokens'",
  "param": "max_output_tokens",
  "sequence_number": 5
}
```

---

# 4. Files API

## 4.1 上传文件

POST `https://ark.cn-beijing.volces.com/api/v3/files`

本文介绍使用 Files API 上传文件请求时的输入输出参数，供您使用接口时查阅字段含义。

### 请求参数

跳转 [响应参数](#)

### 请求体

**file** `file` 条件必填

需要上传的文件，要求为二进制文件。具体限制请参见 [Files API教程](#)。

#### 注意

文件上传支持二进制文件和文件URL两种传入方式，**file**、**url** 为二选一必填参数，不可同时传参。

**purpose** `string` 默认值: `user_data` `%%require%%`

文件用途。

`user_data`：可以灵活使用的文件，能够用于任意用途。

**\*\*url\*\*** `string` 条件必填

文件 URL，支持以下两种 URL 类型：

- HTTP/HTTPS URL：公网可直接访问的文件 URL，请确保文件 URL 可被访问。
- TOS URI：对象存储 TOS 专属的资源定位标识，格式为 `tos://<bucket>/<prefix>/<file_name>`。其中，`<bucket>`、`<prefix>` 和 `<file_name>` 分别表示存储桶名称、存储路径和文件名。详细使用说明可参考 [TOS URI 上传方式](#) 部分，也可前往 [火山引擎对象存储 TOS Bucket](#) 中管理存储桶。

#### 注意

- 文件上传支持二进制文件和文件 URL 两种传入方式，**file**、**url** 为二选一必填参数，不可同时传参。
- 传入 TOS URI 时，必须将文件存储到火山引擎对象存储 TOS Bucket 中，此时 `tos.bucket`、`tos.prefix` 为必填参数。

**tos** object

文件存储的 TOS 信息。TOS 即火山引擎对象存储服务；配置本参数后，上传文件将存储至用户指定的火山引擎对象存储 TOS Bucket 中，不再存入方舟平台默认托管存储空间。

**说明**

- 不传 `tos` 参数：文件存储在方舟平台托管的默认存储空间，单文件不超过 512 MB。已存入方舟平台托管存储的历史文件，不会自动迁移至其他存储位置。
- 传 `tos` 参数：文件存储在用户指定的火山引擎对象存储 TOS Bucket 中，视频文件不超过 2 GB，其他类型文件不超过 512 MB，支持格式详见[文件类型](#)。授权写入用户指定 TOS Bucket 中的文件，不支持在 TOS 侧删除或修改；如需删除文件，可调用 Files API 删除。参考[删除文件](#)。

## 属性

**tos.bucket** string 条件必填

目标文件待写入的 TOS 存储桶名称，该存储桶需提前完成创建，参考[创建存储桶](#)。

**tos.prefix** string 条件必填

文件在目标 TOS 存储桶内的存放前缀路径，入参填写相对路径格式，上传后文件将落地至该前缀目录下。示例：`arkfiles/`。

**preprocess\_configs** object / null

用于设置不同文件类型的预处理规则。

## 属性

**preprocess\_configs.video** object

视频预处理相关配置。

**说明**

配置 `model` 字段后，系统将根据对应模型的抽帧策略，自动填充 `max_video_tokens`、`min_frame_tokens`、`max_frame_tokens`、`min_frames` 四个字段的默认值，具体取值参考[模型抽帧策略说明](#)。

## 属性

**preprocess\_configs.video.fps** float / null 默认值：1

取值范围：`[0.2, 5]`。

每秒钟从视频中抽取指定数量的图像。取值越高，对于视频中画面变化理解越精细；取值越低，对于视频中画面变化感知减弱，但是使用的 token 花费少，速度也更快。单视频 token 用量范围在 [10k, 80k]，具体参见[视频理解](#)。

`preprocess_configs.video.model` `string`

使用该文件进行推理时，要使用的视频理解模型 ID（Model ID）或 Endpoint ID。

#### 说明

Files API 中设置的模型 ID 与推理使用的模型 ID 不强耦合，只影响上传视频文件时预处理抽帧策略。关于预处理抽帧策略，参见[抽帧策略](#)。

- 传入模型 ID：传入不同的模型 ID 会采用不同的抽帧策略。
- 传入 Endpoint ID：会按照上传时 Endpoint ID 映射的模型对应的抽帧策略进行抽帧。
- 不传该参数时：默认采用 `doubao-seed-1.8` 之前的模型对应的抽帧策略。

#### 注意

- `doubao-seed-1.8` 及后续模型支持更长的视频理解能力，抽帧数已从 640 帧提升至 1280 帧。
- 如果要使用 `doubao-seed-1.8-251228` 进行视频理解，但通过 Files API 上传文件时未设置该模型 ID，则采用的是 `doubao-seed-1.8` 之前模型对应的抽帧策略，模型实际理解的帧数会减少。
- 如需处理视频中的音频内容，该字段需指定为支持音频理解的模型，具体支持的模型可参见[模型列表](#)。

`preprocess_configs.video.max_video_tokens` `Integer`

取值范围：[10240, 204800]。

视频最大 tokens 数，值越大保留的视频信息越多。

`preprocess_configs.video.min_frame_tokens` `Integer`

取值范围：[16, 128]。

单帧最小 tokens 数，用于控制单帧压缩的下限。值越小，允许对单帧进行更大的压缩，但单帧细节下降。

`preprocess_configs.video.max_frame_tokens` `Integer`

取值范围：[128, 640]。

单帧最大 tokens 数，用于控制单帧质量的上限。值越大，允许对单帧保留更多的细节。

`preprocess_configs.video.min_frames` `Integer`

取值范围：[5, 16]。

最小抽帧数，用于保证短视频具备足够的处理帧数。若 `fps` 字段抽帧总数小于 `min_frames`，则优先按照 `min_frames` 配置要求抽帧。

`expire_at` `integer` 默认值：当前时刻+604800

取值范围：[当前时刻+86400, 当前时刻+2592000]，即最少保留1天，最多保留30天。

设置存储的有效期，需要传入UTC Unix时间戳（单位：秒）。

## 响应参数

跳转 [请求参数](#)

模型会返回对应的 [file object](#)。



## 4.2 检索文件

GET `https://ark.cn-beijing.volces.com/api/v3/files/{file_id}`  
通过 File id 获取文件信息。

### 鉴权说明

本接口支持 API Key /Access Key 鉴权，详见[鉴权认证方式](#)。

### 快速入口

 [模型列表](#)   [模型计费](#)   [Files](#)  [API 教程](#)   [API Key](#) 

### 请求参数

#### 路径参数

---

id `string` %%require%%  
待检索的文件 id。

### 响应参数

模型会返回对应的 [file object](#)。

## 4.3 查询文件列表

GET `https://ark.cn-beijing.volces.com/api/v3/files?after={after}&limit={limit}&purpose={purpose}&order={order}`  
获取文件列表。

### 请求参数

[跳转](#) [响应参数](#)

### Query 参数

在 URL String 中传入。

**after** `string / null`

返回该文件 ID 之后的文件。

**limit** `integer` 默认值: 100

取值范围: 1 ~ 100。

控制单次返回的最大文件数。

**purpose** `string`

按文件用途进行筛选，仅返回具有指定用途的文件。

**order** `string` 默认值: desc

按照文件created\_at的时间戳顺序，控制文件的排序方式。

- asc: 按照正序排列。
- desc: 按照倒序排列。

### 响应参数

[跳转](#) [请求参数](#)

返回本次响应对应的文件列表。

**object** `string`

固定为 `list`。

**data** `object[] / null`

文件的列表，与上传文件时的请求参数字段结构完全一致。

**first\_id** `string`

列表中第一条数据的 ID。

---

**has\_more** `boolean`

标识是否还有更多数据未返回。

- true: 存在未返回的数据。
  - false: 已返回全部数据。
- 

**last\_id** `string`

列表中最后一条数据的 ID。

# 4.4 删除文件

`DELETE https://ark.cn-beijing.volces.com/api/v3/files/{file_id}`  
根据文件ID删除文件，并将文件从存储空间中移除。

## 快速入口

 [模型列表](#)   [模型计费](#)   [模型调用教程](#)   [API Key](#) 

## 鉴权说明

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

## 请求参数

### 路径参数

---

**id** `string` `%%require%%`  
待删除的文件id。

### 响应参数

---

**id** `string`  
被删除的文件id。

---

**object** `string`  
固定为 `file` 。

---

**deleted** `boolean`  
文件被删除，取值 `true` 表明删除成功。

## 4.5 The file object

上传文件或检索文件后，模型会返回一个 file 对象。本文为您介绍 file 对象包含的详细参数。

---

**object** `string`  
固定为 `file`。

---

**id** `string`  
文件的唯一标识符。

---

**purpose** `string`  
文件用途。

---

**filename** `string`  
文件名。

---

**tos** `object`  
文件存储的 TOS 信息。TOS 即火山引擎对象存储服务，仅当用户传入 `tos` 参数时才会返回。

属性  
**tos.bucket** `string`  
目标文件待写入的 TOS 存储桶名称。

---

**tos.object\_key** `string`  
文件存储在 TOS 中的路径信息。

---

**bytes** `integer`  
文件大小，以bytes为单位。

---

**created\_at** `integer`  
本次请求上传文件时的Unix时间戳(秒)。

---

**expire\_at** `integer`  
文件过期时间的Unix时间戳（秒）。

**mime\_type** `string`

文件的MIME类型，如 `application/pdf`。

**status** `string`

文件处理状态。

- `processing`: 文件正在预处理，无法使用。
- `active`: 文件已处理完成，可以使用。
- `failed`: 文件上传失败，错误详情查看**error**字段。

**error** `object / null`

文件上传失败时返回的错误对象，即**status**取值为 `failed` 时才会返回该字段。

- `code`: 错误码。
- `message`: 错误描述信息。

**preprocess\_configs** `object / null`

用于设置不同文件类型的预处理规则。

属性

**preprocess\_configs.video** `object`

视频预处理相关配置。

属性

**preprocess\_configs.video.fps** `float / null`

每秒钟从视频中抽取指定数量的图像。取值越高，对于视频中画面变化理解越精细；取值越低，对于视频中画面变化感知减弱，但是使用的token花费少，速度也更快。

**preprocess\_configs.video.model** `string`

使用该文件进行推理时，要使用的视频理解模型 ID（Model ID）或 Endpoint ID。

**preprocess\_configs.video.max\_video\_tokens** `Integer`

视频最大 tokens 数，值越大保留的视频信息越多。

**preprocess\_configs.video.min\_frame\_tokens** `Integer`

单帧最小 tokens 数，用于控制单帧压缩的下限。值越小，允许对单帧进行更大的压缩，但单帧细节下降。

`preprocess_configs.video.max_frame_tokens` Integer

单帧最大 tokens 数，用于控制单帧质量的上限。值越大，允许对单帧保留更多的细节。

---

`preprocess_configs.video.min_frames` Integer

最小抽帧数，用于保证短视频具备足够的处理帧数。

## 5. 视频生成 API

### 5.1 创建视频生成任务 API

POST <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks> [运行](#)

本文介绍创建视频生成任务 API 的输入输出参数，供您使用接口时查阅字段含义。模型会依据传入的图片及文本信息生成视频，待生成完成后，您可以按条件查询任务并获取生成的视频。

#### 说明

开通 Seedance 2.0 系列模型前，请确保您满足以下任一条件：

- 账户余额 > 200 元（[前往充值](#)）
- 已购买 Seedance 2.0 系列资源包且有可用余量（[前往购买](#)）  
详细规则见 [Seedance 2.0 系列模型资源包使用规则](#)。

#### 模型能力<sup>new</sup>

- **Doubao Seedance 2.0 系列<sup>new</sup>（有声视频/无声视频）**
  - **多模态参考生视频<sup>new</sup>**：输入参考图片（0-9）+参考视频（0-3）+参考音频（0-3）+文本提示词（可选）生成 1 个目标视频。注意不可单独输入音频，应至少包含 1 个参考视频或图片。支持生成全新视频、编辑视频、延长视频，[阅读教程](#) 获取详细代码示例。
  - **图生视频-首尾帧**：输入首帧图片+尾帧图片+文本提示词（可选）生成 1 个目标视频。
  - **图生视频-首帧**：输入首帧图片+文本提示词（可选）生成 1 个目标视频。
  - **文生视频**：输入文本提示词生成 1 个目标视频。
- **Doubao Seedance 1.5 Pro（有声视频/无声视频）**  
【图生视频-首尾帧】【图生视频-首帧】【文生视频】
- **Doubao Seedance 1.0 Pro**  
【图生视频-首尾帧】【图生视频-首帧】【文生视频】
- **Doubao Seedance 1.0 Pro Fast**  
【图生视频-首帧】【文生视频】

#### 鉴权

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

#### 请求参数

[跳转](#) [响应参数](#)

#### Body 参数



**model** string 必选

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。  
您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

**content** object[] 必选

输入给模型，生成视频的信息，支持文本、图片、音频、视频、样片任务 ID。

注意

Seedance 2.0 系列模型不支持直接上传含有真人人脸的参考图/视频。为了便利创作者对肖像的使用，平台推出了以下解决方案，详情参见[教程](#)。

- 支持使用部分模型的含人脸原始产物作为输入素材
- 支持使用预置虚拟人像作为输入素材
- 支持使用已授权真人素材作为输入

- 支持以下几种组合：
- 文本
  - 文本（可选）+ 图片
  - 文本（可选）+ 视频
  - 文本（可选）+ 图片 + 音频
  - 文本（可选）+ 图片 + 视频
  - 文本（可选）+ 视频 + 音频
  - 文本（可选）+ 图片 + 视频 + 音频
  - 样片任务 ID：样片指使用 Seedance 模型成功生成的样片视频，模型可基于样片生成高质量正式视频。

信息类型

**文本信息** object

输入给模型的提示词信息。

属性

**content.type** string 必选  
输入内容的类型，此处应为 text。

**content.text** string 必选  
输入给模型的文本提示词，描述期望生成的视频。

说明

- 提示词语言支持：所有模型均支持中英文提示词；Seedance 2.0 系列额外支持日语、印尼语、西班牙语、葡萄牙语。
- 提示词字数建议：中文提示词不超过500字，英文提示词不超过1000词。字数过多易导致信息分散，模型可能忽略细节、仅关注重点，进而造成视频缺失部分元素。
- 更多使用技巧：提示词的详细使用技巧，请参见 [Seedance 提示词指南](#)。

图片信息<sup>new</sup> object

输入给模型的图片信息。

属性

content.type string 必选

输入内容的类型，此处应为 image\_url。

content.image\_url object 必选

输入给模型的图片对象。

属性

content.image\_url.url string 必选

图片 URL、图片 Base64 编码、素材 ID。

- 图片 URL：填入图片的公网 URL。
- Base64 编码：将本地文件转换为 Base64 编码字符串，然后提交给大模型。遵循格式：  
data:image/<图片格式>;base64,<Base64编码>，注意 <图片格式> 需小写，如 data:image/png;base64,{base64\_image}。
- 素材 ID：用于视频生成的预置素材及虚拟人像的 ID，遵循格式：asset://<ASSET\_ID>。可从 [素材&虚拟人像库](#) 获取。

说明

传入单张图片要求

- 格式：jpeg、png、webp、bmp、tiff、gif。其中，Seedance 1.5 Pro 和 Seedance 2.0 系列模型新增支持 heic 和 heif。
- 宽高比（宽/高）：(0.4, 2.5)
- 宽高长度（px）：(300, 6000)
- 大小：单张图片小于 30 MB。请求体大小不超过 64 MB。大文件请勿使用Base64编码。
- 图片数量：
  - 图生视频-首帧：1 张

- 图生视频-首尾帧：2 张
- Seedance 2.0 系列 多模态参考生视频：1~9 张

`content.role` `string` 条件必填  
图片的位置或用途。

- 注意
- 图生视频-首帧、图生视频-首尾帧、多模态参考生视频（包括参考图、视频、音频）为 3 种互斥场景，不可混用。
  - 多模态参考生视频可通过提示词指定参考图片作为首帧/尾帧，间接实现“首尾帧+多模态参考”效果。若需严格保障首尾帧和指定图片一致，优先使用图生视频-首尾帧（配置 `role` 为 `first_frame/last_frame`）。

- 图生视频-首帧
- 支持模型：所有模型
  - 字段`role`取值：需要传入1个 `image_url` 对象，字段 `role` 为 `first_frame` 或不填。

- 图生视频-首尾帧
- 支持模型：Seedance 2.0 系列，Seedance 1.5 Pro、Seedance 1.0 Pro
  - 字段`role`取值：需要传入2个`image_url`对象，且字段 `role` 必填。
    - 首帧图片对应的字段 `role` 为：`first_frame`
    - 尾帧图片对应的字段 `role` 为：`last_frame`

说明

传入的首尾帧图片可相同。首尾帧图片的宽高比不一致时，以首帧图片为主，尾帧图片会自动裁剪适配。

- 图生视频-参考图
- 支持模型：Seedance 2.0 系列（1~9 张图片）
  - 字段`role`取值：必填，每张参考图对应的字段 `role` 均为：`reference_image`

视频信息`==new==` `object`  
输入给模型的视频信息。仅 Seedance 2.0 系列支持输入视频。  
方舟平台信任 Seedance 2.0 系列模型生成的含人脸视频，您可使用本账号下近30天内由上述模型生成的含人脸原始视频，作为输入素材进行二次创作，详情参见 [教程](#)。

属性  
`content.type` `string` 必选  
输入内容的类型，此处应为 `video_url`。

`content.video_url` object 必选  
输入给模型的视频对象。

属性  
`content.video_url.url` string 必选  
视频URL、素材 ID。

- 视频 URL：填入视频的公网 URL。
- 素材 ID：用于视频生成的预置素材及虚拟人像视频的 ID，遵循格式：asset://<ASSET\_ID>。可从[素材&虚拟人像库](#) 获取。

说明

传入单个视频要求

- 视频格式：mp4、mov，支持编码格式见下表。
- 分辨率：480p，720p，1080p，4k
- 时长：单个视频时长 [2, 15] s，最多传入 3 个参考视频，所有视频总时长不超过 15s。
- 尺寸：
  - 宽高比（宽/高）：[0.4, 2.5]
  - 宽高长度（px）：[300, 6000]
  - 总像素数：[640 × 640=409600, 3326 × 2494=8295044]，即宽和高的乘积符合 [409600, 8295044] 的区间要求。
- 大小：单个视频不超过 200 MB。
- 帧率 (FPS)：[24, 60]

| 容器格式      | 常用文件扩展名 | MIME            | 支持编码                                  |
|-----------|---------|-----------------|---------------------------------------|
| MP4       | .mp4    | video/mp4       | 视频：H.264/AVC、H.265/HEVC<br>音频：AAC、MP3 |
| QuickTime | .mov    | video/quicktime | 视频：H.264/AVC、H.265/HEVC<br>音频：AAC、MP3 |

`content.role` string 条件必填  
视频的位置或用途。当前仅支持 reference\_video：参考视频。

`音频信息==new==` object  
输入给模型的音频信息。仅 Seedance 2.0 系列支持输入音频。  
注意不可单独输入音频，应至少包含 1 个参考视频或图片。

属性

**content.type** string 必选  
输入内容的类型，此处应为 `audio_url`。

**content.audio\_url** object 必选  
输入给模型的音频对象。

属性

**content.audio\_url.url** string 必选  
音频 URL、音频 Base64 编码、素材 ID。

- 音频 URL：填入音频的公网 URL。
- Base64 编码：将本地文件转换为 Base64 编码字符串，然后提交给大模型。遵循格式：`data:audio/<音频格式>;base64,<Base64编码>`，注意 `<音频格式>` 需小写，如 `data:audio/wav;base64,{base64_audio}`。
- 素材 ID：用于视频生成的虚拟人的音频素材 ID，遵循格式：`asset://<ASSET_ID>`。可从[素材&虚拟人像库](#)获取。

说明

传入单个音频要求

- 格式：wav、mp3
- 时长：单个音频时长 [2, 15] s，最多传入 3 段参考音频，所有音频总时长不超过 15 s。
- 大小：单个音频不超过 15 MB，请求体大小不超过 64 MB。大文件请勿使用Base64编码。

**content.role** string 条件必填  
音频的位置或用途。当前仅支持 `reference_audio`：参考音频。

样片信息 object

基于样片任务 ID，生成正式视频。仅 Seedance 1.5 Pro 支持该功能。[阅读文档](#) 获取 draft 功能的使用教程和注意事项。

属性

**content.type** string 必选  
输入内容的类型，此处应为 `draft_task`。

**content.draft\_task** object 必选  
输入给模型的样片任务。

属性

**content.draft\_task.id** `string` 必选

样片任务 ID。平台将自动复用 Draft 视频使用的用户输入 ( `**model`、`**content.**text`、`**content.image_url`、`generate_audio`、`seed`、`ratio`、`duration`、`camera_fixed` )，生成正式视频。其余参数支持指定，不指定将使用本模型的默认值。

使用分为两步：Step1: 调用本接口生成 Draft 视频。Step2: 如果确认 Draft 视频符合预期，可基于 Step1 返回的 Draft 视频任务 ID，调用本接口生成最终视频。[阅读文档](#) 获取详细教程。

**callback\_url** `string`

填写本次生成任务结果的回调通知地址。当视频生成任务有状态变化时，方舟将向此地址推送 POST 请求。

回调请求内容结构与[查询任务API](#)的返回体一致。

回调返回的 `status` 包括以下状态：

- `queued`：排队中。
- `running`：任务运行中。
- `succeeded`：任务成功。（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）
- `failed`：任务失败。（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）
- `expired`：任务超时，即任务处于**运行中或排队中**状态超过过期时间。可通过`execution_expires_after`字段设置过期时间。

**return\_last\_frame** `boolean` 默认值 `false`

- `true`：返回生成视频的尾帧图像。设置为 `true` 后，可通过[查询视频生成任务接口](#)获取视频的尾帧图像。尾帧图像的格式为 `png`，宽高像素值与生成的视频保持一致，无水印。  
使用该参数可实现生成多个连续视频：以上一个生成视频的尾帧作为下一个视频任务的首帧，快速生成多个连续视频，调用示例详见[教程](#)。
- `false`：不返回生成视频的尾帧图像。

**service\_tier** `string` 默认值 `default`

不支持修改已提交任务的服务等级

Seedance 2.0 系列仅支持在线推理模式，不支持配置该参数

指定处理本次请求的服务等级类型，枚举值：

- `default`：在线推理模式，RPM 和并发数配额较低（详见[模型列表](#)），适合对推理时效性要求较高的场景。
- `flex`：离线推理模式，TPD 配额更高（详见[模型列表](#)），价格为在线推理的 50%，适合对推理时延要求不高的场景。

**execution\_expires\_after** `integer` 默认值 `172800`

任务超时阈值。指定任务提交后的过期时间（单位：秒），从 `created at` 时间戳开始计算。默认值 172800 秒，即 48 小时。取值范围：[3600, 259200]。

不论使用哪种 `service_tier`，都建议根据业务场景设置合适的超时时间。超过该时间后任务会被自动终止，并标记为 `expired` 状态。

`generate_audio` `boolean` 默认值 `true`

仅 Seedance 2.0 系列、Seedance 1.5 Pro 支持

控制生成的视频是否包含与画面同步的声音。

- `true`：模型输出的视频包含同步音频。模型会基于文本提示词与视觉内容，自动生成与之匹配的人声、音效及背景音乐。建议将对话部分置于双引号内，以优化音频生成效果。例如：男人叫住女人说：“你记住，以后不可以用手指月亮。”
- `false`：模型输出的视频为无声视频。

注意

生成的有声视频均为单声道，和传入的音频声道数无关。

`draft` `boolean` 默认值 `false`

仅 Seedance 1.5 Pro 支持

控制是否开启样片模式。[阅读文档](#) 获取使用教程和注意事项。

- `true`：开启样片模式，生成一段预览视频，快速验证场景结构、镜头调度、主体动作与 Prompt 意图是否符合预期。消耗 token 数较正常视频更少，使用成本更低。
- `false`：关闭样片模式，正常生成一段视频。

说明

开启样片模式后，将使用 480p 分辨率生成 Draft 视频（使用其他分辨率会报错），不支持返回尾帧功能，不支持离线推理功能。

`tools==new==` `object[]`

仅 Seedance 2.0 系列 支持

配置模型要调用的工具。

属性

`tools.type` `string`

指定使用的工具类型。

- `web_search`：联网搜索工具。[阅读教程](#) 获取详细代码示例。

### 说明

- 开启联网搜索后，模型会根据用户的提示词自主判断是否搜索互联网内容（如商品、天气等）。可提升生成视频的时效性，但也会增加一定的时延。
- 实际搜索次数可通过 [查询视频生成任务 API](#) 返回的 `usage.tool_usage.web_search` 字段获取，如果为 0 表示未搜索。

`safety_identifier==new==` `string`

终端用户的唯一标识符，用于协助平台检测您的应用中可能违反火山方舟使用政策的用户。该标识符为英文字符串，需保证对单个用户固定且唯一，长度不超过 64 个字符。推荐传入对用户名、用户 ID 或邮箱进行哈希处理后生成的字符串，避免泄露用户隐私信息。

`priority==new==` `integer` 默认值 0

仅 Seedance 2.0 系列支持

设置当前请求的执行优先级，决定其在队列中的排序位置。取值范围：0~9，数值越大，优先级越高。默认情况下，请求按 FIFO（First In, First Out，先进先出）顺序执行。设置较高优先级后，该请求将插队到同 Endpoint（推理接入点）下所有低优先级请求之前。

示例：

某 Endpoint 当前队列中有 3 个排队中（`status=queued`）任务，优先级均为 0（默认）。

队列：[任务A: priority=0] → [任务B: priority=0] → [任务C: priority=0]

此时提交一个 `priority=5` 的新请求，该请求将直接排到队首：

队列：[新请求: priority=5] → [任务A: priority=0] → [任务B: priority=0] → [任务C: priority=0]

### 说明

- 相同优先级的请求之间仍按 FIFO 排序。
- 优先级仅影响排队顺序，不会中断正在执行中（`status=running`）的任务。
- 优先级仅在同一 Endpoint 内生效，不影响其他 Endpoint。
- 离线推理模式（`service_tier=flex`）不支持配置优先级。

### 注意

部分参数升级说明

- 对于 `resolution`、`ratio`、`duration`、`frames`、`seed`、`camera_fixed`、`watermark` 参数，平台升级了参数传入方式，示例如下。所有模型依然兼容支持旧方式。
- 不同模型，可能对应支持不同的参数与取值，详见 [输出视频格式](#) [🔗](#)。当输入的参数或取值不符合所选的模型时，该参数将被忽略或触发报错：
  - 新方式：在 request body 中直接传入参数。此方式为**强校验**，若参数填写错误，模型会返回错误提示。



- 旧方式：在文本提示词后追加 `--[parameters]`。此方式为弱校验，若参数填写错误，该参数将被忽略或触发报错。

### 新方式（推荐）：在 request body 中直接传入参数

JSON

```
...
// Specify the aspect ratio of the generated video as 16:9, duration as 5 seconds, resolution as 720p,
seed as 11, and include a watermark. The camera is not fixed.
"model": "doubao-seedance-1-5-Pro-251215",
"content": [
  {
    "type": "text",
    "text": "小猫对着镜头打哈欠"
  }
],
// All parameters must be written in full; abbreviations are not supported
"resolution": "720p",
"ratio": "16:9",
"duration": 5,
// "frames": 29, Either duration or frames is required
"seed": 11,
"camera_fixed": false,
"watermark": true
...
```

### 旧方式：在文本提示词后追加 `--[parameters]`

JSON

```
...
// Specify the aspect ratio of the generated video as 16:9, duration as 5 seconds, resolution as 720p,
seed as 11, and include a watermark. The camera is not fixed.
"model": "doubao-seedance-1-5-Pro-251215",
"content": [
  {
    "type": "text",
    "text": "小猫对着镜头打哈欠 --rs 720p --rt 16:9 --dur 5 --seed 11 --cf false --wm true"
    // "text": "小猫对着镜头打哈欠 --resolution 720p --ratio 16:9 --duration 5 --seed 11 --
camerafixed false --watermark true"
  }
]
...
```

resolution string

Seedance 2.0 系列、Seedance 1.5 Pro 默认值： 720p  
Seedance 1.0 Pro、Seedance 1.0 Pro Fast 默认值： 1080p

视频分辨率，枚举值：

- 480p
- 720p
- 1080p: Seedance 2.0 Fast 和 Seedance 2.0 Mini 不支持。
- 4k\*\*new\*\*: 仅 Seedance 2.0 支持。

说明

- 相较于一般的 8bit 位深，Seedance 2.0 输出的 4k 视频采用 10bit 位深编码，能够完整保留丰富的色彩层次与平滑的渐变过渡，满足专业影视制作与 HDR 视频内容的要求。
- 4K 视频采用 H.265 编码，少数播放环境可能不兼容，如遇问题，建议升级系统、更换设备或使用 VLC、MPV、QuickTime Player 等播放器查看。

ratio string

Seedance 2.0 系列、Seedance 1.5 Pro 默认值为 adaptive  
其他模型：文生视频默认值 16:9 ，图生视频默认值 adaptive

生成视频的宽高比例。不同宽高比对应的宽高像素值见下方表格。

- 16:9
- 4:3
- 1:1
- 3:4
- 9:16
- 21:9
- adaptive: 根据输入自动选择最合适的宽高比（详见下文说明）

注意

adaptive 适配规则

当配置 ratio 为 adaptive 时，模型会根据生成场景自动适配宽高比；实际生成的视频宽高比可通过 查询视频生成任务 API 返回的 ratio 字段获取。

支持模型：

- Seedance 2.0 系列、Seedance 1.5 Pro 支持
- 其他模型仅图生视频场景支持

取值规则：

- 文生视频：根据输入的提示词，智能选择最合适的宽高比。
- 首帧 / 首尾帧生视频：根据上传的首帧图片比例，自动选择最接近的宽高比。

· 多模态参考生视频：根据用户提示词意图判断，如果是首帧生视频/编辑视频/延长视频，以该图片/视频为准选择最接近的宽高比；否则，以传入的第一个媒体文件为准（优先级：视频 > 图片）选择最接近的宽高比。

不同宽高比对应的宽高像素值  
Note：图生视频，选择的宽高比与您上传的图片宽高比不一致时，方舟会对您的图片进行裁剪，裁剪时会居中裁剪，详细规则见 [图片裁剪规则](#)。

| 分辨率                                                         | 宽高比  | 宽高像素值<br>Seedance 2.0 系列 | 宽高像素值<br>Seedance 1.5 pro | 宽高像素值<br>Seedance 1.0 系列 |
|-------------------------------------------------------------|------|--------------------------|---------------------------|--------------------------|
| 480p                                                        | 16:9 | 864 × 496                | 864 × 496                 | 864 × 480                |
|                                                             | 4:3  | 752 × 560                | 752 × 560                 | 736 × 544                |
|                                                             | 1:1  | 640 × 640                | 640 × 640                 | 640 × 640                |
|                                                             | 3:4  | 560 × 752                | 560 × 752                 | 544 × 736                |
|                                                             | 9:16 | 496 × 864                | 496 × 864                 | 480 × 864                |
|                                                             | 21:9 | 992 × 432                | 992 × 432                 | 960 × 416                |
| 720p                                                        | 16:9 | 1280 × 720               | 1280 × 720                | 1248 × 704               |
|                                                             | 4:3  | 1112 × 834               | 1112 × 834                | 1120 × 832               |
|                                                             | 1:1  | 960 × 960                | 960 × 960                 | 960 × 960                |
|                                                             | 3:4  | 834 × 1112               | 834 × 1112                | 832 × 1120               |
|                                                             | 9:16 | 720 × 1280               | 720 × 1280                | 704 × 1248               |
|                                                             | 21:9 | 1470 × 630               | 1470 × 630                | 1504 × 640               |
| 1080p<br><div>Seedance 2.0 Fast、Seedance 2.0 Mini 不支持</div> | 16:9 | 1920 × 1080              | 1920 × 1080               | 1920 × 1088              |
|                                                             | 4:3  | 1664 × 1248              | 1664 × 1248               | 1664 × 1248              |
|                                                             | 1:1  | 1440 × 1440              | 1440 × 1440               | 1440 × 1440              |
|                                                             | 3:4  | 1248 × 1664              | 1248 × 1664               | 1248 × 1664              |
|                                                             | 9:16 | 1080 × 1920              | 1080 × 1920               | 1088 × 1920              |
|                                                             | 21:9 | 2206 × 946               | 2206 × 946                | 2176 × 928               |
| 4k                                                          | 16:9 | 3840 × 2160              | —                         | —                        |

| 分辨率                     | 宽高比  | 宽高像素值<br>Seedance 2.0 系列 | 宽高像素值<br>Seedance 1.5 pro | 宽高像素值<br>Seedance 1.0 系列 |
|-------------------------|------|--------------------------|---------------------------|--------------------------|
| 仅<br>Seedance<br>2.0 支持 | 4:3  | 3326 × 2494              | —                         | —                        |
|                         | 1:1  | 2880 × 2880              | —                         | —                        |
|                         | 3:4  | 2494 × 3326              | —                         | —                        |
|                         | 9:16 | 2160 × 3840              | —                         | —                        |
|                         | 21:9 | 4398 × 1886              | —                         | —                        |

**duration** integer 默认值 5

duration 和 frames 二选一即可，frames 的优先级高于 duration。如果您希望生成整数秒的视频，建议指定 duration。

生成视频时长，仅支持整数，单位：秒。

- Seedance 1.0 Pro、Seedance 1.0 Pro Fast: [2, 12] s。
- Seedance 1.5 Pro: [4,12] 或设置为 -1
- Seedance 2.0 系列: [4,15] 或设置为 -1

注意

Seedance 2.0 系列、Seedance 1.5 Pro 支持两种配置方法

- 指定具体时长：支持有效范围内的任一整数。
- 智能指定：设置为 -1，表示由模型在有效范围内自主选择合适的视频长度（整数秒）。实际生成视频的时长可通过 [查询视频生成任务 API](#) 返回的 duration 字段获取。注意视频时长与计费相关，请谨慎设置。

**frames** integer

Seedance 2.0 系列、Seedance 1.5 Pro 暂不支持  
duration 和 frames 二选一即可，frames 的优先级高于 duration。如果您希望生成小数秒的视频，建议指定 frames。

生成视频的帧数。通过指定帧数，可以灵活控制生成视频的长度，生成小数秒的视频。  
由于 frames 的取值限制，仅能支持有限小数秒，您需要根据公式推算最接近的帧数。

- 计算公式：帧数 = 时长 × 帧率（24）。

- 取值范围：支持 [29, 289] 区间内所有满足 `25 + 4n` 格式的整数值，其中 n 为正整数。  
例如：假设需要生成 2.4 秒的视频，帧数=2.4 × 24=57.6。由于 frames 不支持 57.6，此时您只能选择一个最接近的值。根据 25+4n 计算出最接近的帧数为 57，实际生成的视频为 57/24=2.375 秒。

**seed** integer 默认值 -1

Seedance 2.0 系列暂不支持

种子整数，用于控制生成内容的随机性。  
取值范围：[-1, 2^32-1]之间的整数。

注意

- 相同的请求下，模型收到不同的 seed 值，如：不指定 seed 值或令 seed 取值为-1（会使用随机数替代）、或手动变更 seed 值，将生成不同的结果。
- 相同的请求下，模型收到相同的 seed 值，会生成类似的结果，但不保证完全一致。

**camera\_fixed** boolean 默认值 false

参考图场景不支持，Seedance 2.0 系列 暂不支持

是否固定摄像头。枚举值：

- true：固定摄像头。平台会在用户提示词中追加固定摄像头，实际效果不保证。
- false：不固定摄像头。

**watermark** boolean 默认值 false

生成视频是否包含水印。枚举值：

- false：生成视频不含水印。
- true：生成视频右下角会展示 AI 生成 水印。

响应参数

跳转 [请求参数](#)

**id** string

视频生成任务 ID。仅保存 7 天（从 **created at** 时间戳开始计算），超时后将自动清除。

- 设置 `"draft": true`，为 Draft 视频任务 ID。
- 设置 `"draft": false`，为正常视频任务 ID。  
创建视频生成任务为异步接口，获取 ID 后，需要通过 [查询视频生成任务 API](#) 来查询视频生成任务的状态。任务成功后，会输出生成视频的 `video_url`。

## 5.2 查询视频生成任务 API

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}` [运行](#)

查询视频生成任务的状态。

### 说明

仅支持查询最近 7 天的任务记录，时间区间为 [T-7天, T)，其中 T 为请求发起时刻的 UTC 时间戳（精确到秒）。注意：视频 URL 有效期为 24 小时，请及时下载或转存。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

**id** `string` `%%require%%`  
您需要查询的视频生成任务的 ID。

### 说明

上面参数为Query String Parameters，在URL String中传入。

### 响应参数

[跳转](#) [请求参数](#)

**\*\*id** `string`  
视频生成任务 ID。

**model** `string`

任务使用的模型名称和版本， `模型名称-版本` 。

---

**status** `string`

任务状态，以及相关的信息：

- `queued` ： 排队中。
  - `running` ： 任务运行中。
  - `cancelled` ： 取消任务，取消状态24h自动删除（只支持排队中状态的任务被取消）。
  - `succeeded` ： 任务成功。
  - `failed` ： 任务失败。
  - `expired` ： 任务超时。
- 

**error** `object / null`

错误提示信息，任务成功返回 `null` ，任务失败时返回错误数据，错误信息具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**content** `object`

视频生成任务的输出内容。

属性

---

**content.video\_url** `string`

生成视频的 URL，格式为 mp4。有效期为 24 小时，请及时下载或转存。

推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

**content.\*\*last\_frame\_url** `string`

视频的尾帧图像 URL。有效期为 24 小时，请及时下载或转存。

说明：[创建视频生成任务](#) 时设置 `"return_last_frame": true` 时，会返回该参数。

**seed** `integer`

本次请求使用的种子整数值。

**\*\*resolution** `string`

生成视频的分辨率。

**\*\*ratio** `string`

生成视频的宽高比。

**duration** `integer`

生成视频的时长，单位：秒。

说明：**duration** 和 **frames** 参数只会返回一个。[创建视频生成任务](#) 时未指定 frames，会返回 duration。

**frames** `integer`

生成视频的帧数。

说明：**duration** 和 **frames** 参数只会返回一个。[创建视频生成任务](#) 时指定了 frames，会返回 frames。

**framespersecond** `integer`

生成视频的帧率。

**generate\_audio** `boolean`

生成的视频是否包含与画面同步的声音。仅 seedance 2.0 & 2.0 fast、seedance 1.5 pro 会返回该参数。

- `true`：模型输出的视频包含同步音频。
- `false`：模型输出的视频为无声视频。

**tools==new==** `object[]`

本次请求模型实际使用的工具。未使用工具时不返回。



属性

**tools.\*\*type\*\*** `string`

实际使用的工具类型

- `web_search`: 联网搜索工具。

**safety\_idenfifier==new==** `string`

终端用户的唯一标识符。若 [创建视频生成任务](#) 时设置了该参数，接口会原样返回此信息。

**priority==new==** `integer`

当前请求的执行优先级。

**draft** `boolean`

生成的视频是否为 Draft 视频。仅 seedance 1.5 pro 会返回该参数。

- `true` : 表示当前输出为 Draft 视频。
- `false` : 表示当前输出为正常视频。

**\*\*draft\_task\_id\*\*** `string`

Draft 视频任务 ID。基于 Draft 视频生成正式视频时，会返回该参数。

**\*\*service\_tier\*\*** `string`

实际处理任务使用的服务等级。

**execution\_expires\_after** `** **integer`

任务超时阈值，单位：秒。

**usage** `object`

本次请求的 token 用量。

属性

**usage.completion\_tokens** `integer`

模型生成视频消耗的 token 数量，可作为计费对账依据。

## 说明

seedance 2.0 系列模型存在最低 token 用量限制，如果实际 token 用量 < 最低 token 用量，本字段会返回最低 token 用量，平台按最低 token 用量计费。

`usage.total_tokens` `integer`

本次请求消耗的总 token 数量。视频生成模型不统计输入 token，输入 token 为 0，故 `total_tokens=completion_tokens`。

`usage.tool_usage` `new` `**` `object`

使用工具的用量信息。

属性

`usage.tool_usage.web_search` `**` `integer`

实际调用联网搜索工具的次数，仅开启联网搜索时返回。

## 5.3 查询视频生成任务列表

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?page_num={page_num}&page_size={page_size}&filter.status={filter.status}&filter.task_ids={filter.task_ids}&filter.model={filter.model}` [运行](#)

通过传入筛选参数，查询符合条件的视频生成任务。

**说明**

仅支持查询最近 7 天的任务记录，时间区间为 [T-7天, T)，其中 T 为请求发起时刻的 UTC 时间戳（精确到秒）。注意：视频 URL 有效期为 24 小时，请及时下载或转存。

**快速入口**

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

**鉴权说明**

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

**请求参数**

[跳转](#) [响应参数](#)

**说明**

下面参数为Query String Parameters，在URL String中传入。

**page\_num** `integer / null` 默认值：1  
返回结果的页码。  
取值范围：[1, 500]

**page\_size** `integer / null` 默认值：20  
每页显示的结果数量。  
取值范围：[1, 500]

**filter.status** `string / null`  
过滤参数，查询某个任务状态。

- `queued`：排队中的任务。
- `running`：运行中任务。

- `cancelled` : 取消的任务。
- `succeeded` : 成功的任务。
- `failed` : 失败的任务。

---

**\*\*filter.task\_ids\*\*** `string[] / null`

视频生成任务 ID，精确搜索，支持同时搜索多个任务 ID。需通过重复参数名的方式传递，示例：

`filter.task_ids=id1&filter.task_ids=id2` 。

---

**\*\*filter.model\*\*** `string / null`

与返回参数不同，该字段为任务使用的推理接入点 ID，精确搜索。

---

**\*\*filter.service\_tier\*\*** `string / null` 默认值 `default`

处理任务使用的服务等级。

- `default` : 在线推理模式
- `flex` : 离线推理模式

## 响应参数

跳转 [请求参数](#)

---

**\*\*items\*\*** `object[]`

查询到的视频生成任务列表。

属性

---

**items.\*\*id\*\*** `string`

视频生成任务 ID 。

---

**items.model** `string`

任务使用的模型名称和版本， `模型名称-版本` 。

---

**items.status** `string`

任务状态，以及相关的信息：

- `queued` : 排队中。
- `running` : 任务运行中。
- `cancelled` : 取消任务（只支持排队中状态的任务被取消）。

- `succeeded` : 任务成功。
- `failed` : 任务失败。
- `expired` : 任务超时。

---

`items.error` `object / null`

错误提示信息，任务成功返回 `null`，任务失败时返回错误数据，错误信息具体参见 [错误处理](#)。

属性

---

`error.code` `string`

错误码。

---

`error.message` `string`

错误提示信息。

---

`items.created_at` `integer`

任务创建时间的 Unix 时间戳（秒）。

---

`items.updated_at` `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

`items.content` `object`

当视频生成任务完成，会输出该字段，包含生成视频下载的 URL。

属性

---

`content.video_url` `string`

生成视频的 URL。有效期为 24 小时，请及时下载或转存。

---

`content.**last_frame_url**` `string`

视频的尾帧图像 URL。有效期为 24 小时，请及时下载或转存。

说明：[创建视频生成任务](#) 时设置 `"return_last_frame": true` 时，会返回参数。

---

`items.seed` `integer`

本次请求使用的种子整数值。

---

`items.**resolution **` `string`  
生成视频的分辨率。

---

`items.**ratio **` `string`  
生成视频的宽高比。

---

`items.duration` `integer`  
生成视频的时长，单位：秒。  
说明：**duration** 和 **frames** 参数只会返回一个。[创建视频生成任务](#) 时未指定 frames，会返回 duration。

---

`items.**frames **` `integer`  
生成视频的帧数。  
说明：**duration** 和 **frames** 参数只会返回一个。[创建视频生成任务](#) 时指定了 frames，会返回 frames。

---

`items.framespersecond` `integer`  
生成视频的帧率。

---

`items.generate_audio` `boolean`  
生成的视频是否包含与画面同步的声音。仅 Seedance 2.0 系列、Seedance 1.5 pro 会返回该参数。

- `true`：模型输出的视频包含同步音频。
  - `false`：模型输出的视频为无声视频。
- 

`items.tools==new== **` `object[]`  
本次请求模型实际使用的工具。未使用工具时不返回。

属性

`items.tools.**type **` `string`  
实际使用的工具类型

- `web_search`：联网搜索工具。
- 

`items.safety_identifier==new==` `string`  
终端用户的唯一标识符。若 [创建视频生成任务](#) 时设置了该参数，接口会原样返回此信息。

---

`items.priority==new==` `integer`

当前请求的执行优先级。

`items.draft` `boolean`

生成的视频是否为 Draft 视频。仅 Seedance 1.5 pro 会返回该参数。

- `true` : 表示当前输出为 Draft 视频。
- `false` : 表示当前输出为正常视频。

`items.**draft_task_id **` `string`

Draft 视频任务 ID。基于 Draft 视频生成正式视频时，会返回该参数。

`items.**service_tier **` `string`

实际处理任务使用的服务等级。

`items.execution_expires_after **` `integer`

任务超时阈值，单位：秒。

`items.usage` `object`

本次请求的 token 用量。

属性

`items.usage.completion_tokens` `integer`

模型生成视频消耗的 token 数量，可作为计费对账依据。

#### 说明

Seedance 2.0 系列模型存在最低 token 用量限制，如果实际 token 用量 < 最低 token 用量，本字段会返回最低 token 用量，平台按最低 token 用量计费。

`items.usage.total_tokens` `integer`

本次请求消耗的总 token 数量。视频生成模型不统计输入 token，输入 token 为 0，故 `total_tokens=completion_tokens`。

`items.usage.tool_usage==new== ** **` `object`

使用工具的用量信息。

属性

`items.usage.tool_usage.**web_search **` `integer`

实际调用联网搜索工具的次数，仅开启联网搜索时返回。

---

`**total **` `integer`

符合筛选条件的任务数量。



## 5.4 取消或删除视频生成任务

DELETE `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}` [运行](#)

取消排队中的视频生成任务，或者删除视频生成任务记录。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)

[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

**说明**

下面参数为Query String Parameters，在URL String中传入。

**id** `string` `%%require%%`  
需要取消或者删除的视频生成任务。  
任务状态不同，调用 `DELETE` 接口，执行的操作有所不同，具体说明如下：

| 当前任务状态    | 是否支持DELETE操作 | 操作含义                      | DELETE操作后任务状态 |
|-----------|--------------|---------------------------|---------------|
| queued    | 是            | 任务取消排队，任务状态被变更为cancelled。 | cancelled     |
| running   | 否            | -                         | -             |
| succeeded | 是            | 删除视频生成任务记录，后续将不支持查询。      | -             |
| failed    | 是            | 删除视频生成任务记录，后续将不支持查询。      | -             |
| cancelled | 否            | -                         | -             |
| expired   | 是            |                           | -             |

| 当前任务状态 | 是否支持DELETE操作 | 操作含义                 | DELETE操作后任务状态 |
|--------|--------------|----------------------|---------------|
|        |              | 删除视频生成任务记录，后续将不支持查询。 |               |

### 响应参数

跳转 [请求参数](#)

本接口无返回参数。

# 6. 图片生成 API

## 6.1 图片生成 API

POST <https://ark.cn-beijing.volces.com/api/v3/images/generations> [运行](#)

本文介绍图片生成模型如 Seedream 5.0 lite 的调用 API，包括输入输出参数，取值范围，注意事项等信息，供您使用接口时查阅字段含义。

### 不同模型支持的图片生成能力简介

- doubao seedream 5.0 lite<sup>new</sup>、doubao seedream 4.5/4.0
  - 生成组图（组图：基于您输入的内容，生成的一组内容关联的图片；需配置 `**sequential_image_generation**` 为 `auto`）
    - 多图生组图，根据您输入的 \*\*多张参考图片（2-14）\*\* + 文本提示词 生成一组内容关联的图片（输入的参考图数量+最终生成的图片数量≤15张）。
    - 单图生组图，根据您输入的 单张参考图片 + 文本提示词 生成一组内容关联的图片（最多生成14张图片）。
    - 文生组图，根据您输入的 文本提示词 生成一组内容关联的图片（最多生成15张图片）。
  - 生成单图（配置 `**sequential_image_generation**` 为 `disabled`）
    - 多图生图，根据您输入的 \*\*多张参考图片（2-14）\*\* + 文本提示词 生成单张图片。
    - 单图生图，根据您输入的 单张参考图片 + 文本提示词 生成单张图片。
    - 文生图，根据您输入的 文本提示词 生成单张图片。

### 鉴权说明

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

### 快速入门

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

### 请求参数

#### 请求体

`model` `string` `%%require%%`

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

**\*\*prompt\*\*** `string` `%%require%%`  
用于生成图像的提示词，支持中英文。（查看提示词指南：[Seedream 4.0-5.0 提示词指南](#)）  
建议不超过300个汉字或600个英文单词。字数过多信息容易分散，模型可能因此忽略细节，只关注重点，造成图片缺失部分元素。

**image** `string/array`  
输入的图片信息，支持 URL 或 Base64 编码。其中，doubao-seedream-5.0-lite/4.5/4.0 支持单图或多图输入（[查看多图融合示例](#)）。

- 图片URL：请确保图片URL可被访问。
- Base64编码：请遵循此格式 `data:image/<图片格式>;base64,<Base64编码>`。注意 `<图片格式>` 需小写，如 `data:image/png;base64,<base64_image>`。

说明

- 传入单张图片要求：
  - 图片格式：jpeg、png（doubao-seedream-5.0-lite/4.5/4.0 模型新增支持 webp、bmp、tiff、gif、heic、heif 格式`**new**`）
  - 宽高比（宽/高）范围：
    - [1/16, 16] (适用模型：doubao-seedream-5.0-lite/4.5/4.0)
  - 宽高长度（px）> 14
  - 大小：不超过 30MB
  - 总像素：不超过 `6000x6000=36000000` px（对单张图宽度和高度的像素乘积限制，而不是对宽度或高度的单独值进行限制）
- doubao-seedream-5.0-lite/4.5/4.0 最多支持传入 14 张参考图。

**\*\*size\*\*** `string`

doubao-seedream-5.0-lite

指定生成图像的尺寸信息，支持以下两种方式，不可混用。

- 方式 1 | 指定生成图像的分辨率，并在prompt中用自然语言描述图片宽高比、图片形状或图片用途，最终由模型判断生成图片的大小。
  - 可选值：`2K`、`3K`、`4K`
- 方式 2 | 指定生成图像的宽高像素值：
  - 默认值：`2048x2048`
  - 总像素取值范围：`[ 2560x1440=3686400 , 4096x4096=16777216 ]`
  - 宽高比取值范围：`[1/16, 16]`

说明

采用方式 2 时，需同时满足总像素取值范围和宽高比取值范围。其中，总像素是对单张图宽度和高度的像素乘积限制，而不是对宽度或高度的单独值进行限制。

· 有效示例： 3750x1250

总像素值  $3750 \times 1250 = 4687500$ ，符合  $[3686400, 16777216]$  的区间要求；宽高比  $3750/1250 = 3$ ，符合  $[1/16, 16]$  的区间要求，故该示例值有效。

· 无效示例： 1500x1500

总像素值  $1500 \times 1500 = 2250000$ ，未达到 3686400 的最低要求；宽高  $1500/1500 = 1$ ，虽符合  $[1/16, 16]$  的区间要求，但因其未同时满足两项限制，故该示例值无效。

推荐的宽高像素值：

| 分辨率 | 宽高比  | 宽高像素值     |
|-----|------|-----------|
| 2K  | 1:1  | 2048x2048 |
|     | 4:3  | 2304x1728 |
|     | 3:4  | 1728x2304 |
|     | 16:9 | 2848x1600 |
|     | 9:16 | 1600x2848 |
|     | 3:2  | 2496x1664 |
|     | 2:3  | 1664x2496 |
|     | 21:9 | 3136x1344 |
| 3K  | 1:1  | 3072x3072 |
|     | 4:3  | 3456x2592 |
|     | 3:4  | 2592x3456 |
|     | 16:9 | 4096x2304 |
|     | 9:16 | 2304x4096 |
|     | 2:3  | 2496x3744 |
|     | 3:2  | 3744x2496 |
|     | 21:9 | 4704x2016 |
| 4K  | 1:1  | 4096x4096 |

| 分辨率 | 宽高比  | 宽高像素值     |
|-----|------|-----------|
|     | 3:4  | 3520x4704 |
|     | 4:3  | 4704x3520 |
|     | 16:9 | 5504x3040 |
|     | 9:16 | 3040x5504 |
|     | 2:3  | 3328x4992 |
|     | 3:2  | 4992x3328 |
|     | 21:9 | 6240x2656 |

doubao-seedream-4.5

指定生成图像的尺寸信息，支持以下两种方式，不可混用。

- 方式 1 | 指定生成图像的分辨率，并在prompt中用自然语言描述图片宽高比、图片形状或图片用途，最终由模型判断生成图片的大小。
  - 可选值： 2K 、 4K
- 方式 2 | 指定生成图像的宽高像素值：
  - 默认值： 2048x2048
  - 总像素取值范围： [ 2560x1440=3686400 , 4096x4096=16777216 ]
  - 宽高比取值范围： [1/16, 16]

说明

采用方式 2 时，需同时满足总像素取值范围和宽高比取值范围。其中，总像素是对单张图宽度和高度的像素乘积限制，而不是对宽度或高度的单独值进行限制。

· 有效示例： 3750x1250

总像素值  $3750 \times 1250 = 4687500$ ，符合  $[3686400, 16777216]$  的区间要求；宽高比  $3750/1250=3$ ，符合  $[1/16, 16]$  的区间要求，故该示例值有效。

· 无效示例： 1500x1500

总像素值  $1500 \times 1500 = 2250000$ ，未达到 3686400 的最低要求；宽高  $1500/1500=1$ ，虽符合  $[1/16, 16]$  的区间要求，但因其未同时满足两项限制，故该示例值无效。

推荐的宽高像素值：

| 分辨率 | 宽高比 | 宽高像素值     |
|-----|-----|-----------|
| 2K  | 1:1 | 2048x2048 |
|     | 4:3 | 2304x1728 |

| 分辨率 | 宽高比  | 宽高像素值     |
|-----|------|-----------|
|     | 3:4  | 1728x2304 |
|     | 16:9 | 2848x1600 |
|     | 9:16 | 1600x2848 |
|     | 3:2  | 2496x1664 |
|     | 2:3  | 1664x2496 |
|     | 21:9 | 3136x1344 |
| 4K  | 1:1  | 4096x4096 |
|     | 3:4  | 3520x4704 |
|     | 4:3  | 4704x3520 |
|     | 16:9 | 5504x3040 |
|     | 9:16 | 3040x5504 |
|     | 2:3  | 3328x4992 |
|     | 3:2  | 4992x3328 |
|     | 21:9 | 6240x2656 |

doubao-seedream-4.0

指定生成图像的尺寸信息，支持以下两种方式，不可混用。

- 方式 1 | 指定生成图像的分辨率，并在prompt中用自然语言描述图片宽高比、图片形状或图片用途，最终由模型判断生成图片的大小。
  - 可选值： 1K 、 2K 、 4K
- 方式 2 | 指定生成图像的宽高像素值：
  - 默认值： 2048x2048
  - 总像素取值范围： [ 1280x720=921600 , 4096x4096=16777216 ]
  - 宽高比取值范围： [1/16, 16]

说明

采用方式 2 时，需同时满足总像素取值范围和宽高比取值范围。其中，总像素是对单张图宽度和高度的像素乘积限制，而不是对宽度或高度的单独值进行限制。

- 有效示例： 1600x600

总像素值  $1600 \times 600 = 960000$ ，符合  $[921600, 16777216]$  的区间要求；宽高比  $1600/600 = 8/3$ ，符合  $[1/16, 16]$  的区间要求，故该示例值有效。

· 无效示例：800x800

总像素值  $800 \times 800 = 640000$ ，未达到 921600 的最低要求；宽高  $800/800 = 1$ ，虽符合  $[1/16, 16]$  的区间要求，但因其未同时满足两项限制，故该示例值无效。

推荐的宽高像素值：

| 分辨率 | 宽高比  | 宽高像素值     |
|-----|------|-----------|
| 1K  | 1:1  | 1024x1024 |
|     | 4:3  | 1152x864  |
|     | 3:4  | 864x1152  |
|     | 16:9 | 1280x720  |
|     | 9:16 | 720x1280  |
|     | 3:2  | 1248x832  |
|     | 2:3  | 832x1248  |
|     | 21:9 | 1512x648  |
| 2K  | 1:1  | 2048x2048 |
|     | 4:3  | 2304x1728 |
|     | 3:4  | 1728x2304 |
|     | 16:9 | 2848x1600 |
|     | 9:16 | 1600x2848 |
|     | 3:2  | 2496x1664 |
|     | 2:3  | 1664x2496 |
|     | 21:9 | 3136x1344 |
| 4K  | 1:1  | 4096x4096 |
|     | 3:4  | 3520x4704 |
|     | 4:3  | 4704x3520 |
|     | 16:9 | 5504x3040 |



| 分辨率 | 宽高比  | 宽高像素值     |
|-----|------|-----------|
|     | 9:16 | 3040x5504 |
|     | 2:3  | 3328x4992 |
|     | 3:2  | 4992x3328 |
|     | 21:9 | 6240x2656 |

doubao-seedream-3.0-t2i

指定生成图像的宽高像素值。

- 默认值： 1024x1024
- 单张图片像素取值范围： [ 512x512 , 2048x2048 ]

推荐的宽高像素值：

| 宽高比  | 宽高像素值     |
|------|-----------|
| 1:1  | 1024x1024 |
| 4:3  | 864x1152  |
| 3:4  | 1152x864  |
| 16:9 | 1280x720  |
| 9:16 | 720x1280  |
| 3:2  | 832x1248  |
| 2:3  | 1248x832  |
| 21:9 | 1512x648  |

sequential\_image\_generation string 默认值 disabled

仅 doubao-seedream-5.0-lite/4.5/4.0 支持该参数 | [查看组图输出示例](#)

控制是否关闭组图功能。

**说明**  
组图：基于您输入的内容，生成的一组内容关联的图片。

- auto：自动判断模式，模型会根据用户提供的提示词自主判断是否返回组图以及组图包含的图片数量。
- disabled：关闭组图功能，模型只会生成一张图。

**sequential\_image\_generation\_options** **\*\*** `object`

仅 doubao-seedream-5.0-lite/4.5/4.0 支持该参数

组图功能的配置。仅当 **sequential\_image\_generation** **\*\*** 为 `auto` 时生效。

属性

**sequential\_image\_generation\_options.max\_images** **\*\*** **\*\*** `integer` 默认值 15

指定本次请求，最多可生成的图片数量。

- 取值范围：[1, 15]

#### 说明

实际可生成的图片数量，除受到 **max\_images** **\*\*** 影响外，还受到输入的参考图数量影响。输入的参考图数量+最终生成的图片数量≤15张。

**tools==new==** **\*\*** **\*\*** `array of object`

仅 doubao-seedream-5.0-lite 支持该参数

配置模型要调用的工具。

属性

**tools.type** **\*\*** `string`

指定使用的工具类型。

- `web_search`：联网搜索功能。

#### 说明

- 开启联网搜索后，模型会根据用户的提示词自主判断是否搜索互联网内容（如商品、天气等），提升生成图片的时效性，但也会增加一定的时延。
- 实际搜索次数可通过字段 `usage.tool_usage.web_search` 查询，如果为 0 表示未搜索。

**stream** `Boolean` 默认值 `false`

仅 doubao-seedream-5.0-lite/4.5/4.0 支持该参数 | [查看流式输出示例](#) 

控制是否开启流式输出模式。

- `false`：非流式输出模式，等待所有图片全部生成结束后再一次性返回所有信息。

- `true`：流式输出模式，即时返回每张图片输出的结果。在生成单图和组图的场景下，流式输出模式均生效。

**\*\*guidance\_scale \*\*** `Float`

仅 doubao-seedream-5.0-lite/4.5/4.0 不支持

模型输出结果与prompt的一致程度，生成图像的自由度，又称为文本权重；值越大，模型自由度越小，与用户输入的提示词相关性越强。

取值范围：[ 1 , 10 ]。

**output\_format==<sup>new</sup>** `string` 默认值 `jpeg`

仅 doubao-seedream-5.0-lite 支持该参数

指定生成图像的文件格式。可选值：

- `png`
- `jpeg`

#### 说明

doubao-seedream-4.5/4.0 模型生成图像的文件格式默认为 `jpeg`，不支持自定义设置。

**response\_format** `string` 默认值 `url`

指定生成图像的返回格式。支持以下两种返回方式：

- `url`：返回图片下载链接；链接在图片生成后24小时内有效，请及时下载图片。
- `b64_json`：以 Base64 编码字符串的 JSON 格式返回图像数据。

**watermark** `Boolean` 默认值 `true`

是否在生成的图片中添加水印。

- `false`：不添加水印。
- `true`：在图片右下角添加“AI生成”字样的水印标识。

**\*\*optimize\_prompt\_options \*\*** `object`

仅 doubao-seedream-5.0-lite/4.5/4.0 支持该参数

提示词优化功能的配置。

属性  
optimize\_prompt\_options.\*\*mode\*\* string 默认值 standard  
设置提示词优化功能使用的模式。

- standard：标准模式，生成内容的质量更高，耗时较长。
- fast：快速模式，生成内容的耗时更短，质量一般；doubao-seedream-5.0-lite/4.5 当前不支持。

## 响应参数

### 流式响应参数

请参见[文档](#)。

### 非流式响应参数

model string  
本次请求使用的模型 ID（模型名称-版本）。

created integer  
本次请求创建时间的 Unix 时间戳（秒）。

data array  
输出图像的信息。

**说明**

doubao-seedream-5.0-lite/4.5/4.0 模型生成组图场景下，组图生成过程中某张图生成失败时：

- 若失败原因为审核不通过：仍会继续请求下一个图片生成任务，即不影响同请求内其他图片的生成流程。
- 若失败原因为内部服务异常（500）：不会继续请求下一个图片生成任务。

可能类型  
图片信息 object  
生成成功的图片信息。

属性  
data.\*\*url\*\* string  
图片的 url 信息，当 \*\*response\_format\*\* 指定为 url 时返回。该链接将在生成后 24 小时内失效，请务必及时保存图像。

推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

**data.b64\_json** `string`

图片的 base64 信息，当 **response\_format** 指定为 `b64_json` 时返回。

**data.size** `string`

仅 doubao-seedream-5.0-lite/4.5/4.0 支持该字段。

图像的宽高像素值，格式 `<宽像素>x<高像素>`，如 `2048 × 2048`。

**错误信息** `object`

某张图片生成失败，错误信息。

属性

**data.error** `object`

错误信息结构体。

属性

**data.error.code**

某张图片生成错误的错误码，请参见[错误码](#)。

**data.error.message**

某张图片生成错误的提示信息。

**tools** `array of object`

本次请求，配置的模型调用工具

属性

**tools.\*\*type\*\*** `string`

配置的调用工具类型。

- `web_search`：联网搜索工具。

**usage** `object`

本次请求的用量信息。

属性

---

**usage.generated\_images** `integer`

模型成功生成的图片张数，不包含生成失败的图片。  
仅对成功生成图片按张数进行计费。

---

**usage.output\_tokens** `integer`

模型生成的图片花费的 token 数量。  
计算逻辑为：计算  $\text{sum}(\text{图片长} \times \text{图片宽}) / 256$ ，然后取整。

---

**usage.total\_tokens** `integer`

本次请求消耗的总 token 数量。  
当前不计算输入 token，故与 **output\_tokens** 值一致。

---

**usage.tool\_usage** `object`

使用工具的用量信息。

属性

---

**usage.tool\_usage.web\_search** `integer`

调用联网搜索工具次数，仅开启联网搜索时返回。

---

**error** `object`

本次请求，如发生错误，对应的错误信息。

属性

---

**error.code** `string`

请参见[错误码](#)。

---

**error.message** `string`

错误提示信息

---

## 6.2 流式响应

Doubao-seedream-5.0-lite/4.5/4.0 支持流式输出模式。当您调用图片生成API 并将 **stream** 设置为 `true` 时，服务器会在生成响应的过程中，通过 Server-Sent Events（SSE）实时向客户端推送事件。本节内容介绍服务器会推送的各类事件。

### image\_generation.partial\_succeeded

当前仅 doubao-seedream-5.0-lite/4.5/4.0 支持流式响应。

在流式响应模式下，当任意图片生成成功时返回该事件。

#### 参数说明

**type** `string`  
此处应为 `image_generation.partial_succeeded`。

**model** `string`  
本次请求使用的模型 ID，格式为 `<模型名称>-<版本>`。

**created** `integer`  
本次请求创建时间的 Unix 时间戳（秒）。

**image\_index** `integer`  
本次生图请求中，本次事件对应图片在请求中的序号。  
从 `0` 开始累加，不管生图是否成功，即在 `image_generation.partial_succeeded`、`image_generation.partial_failed` 事件，均会自动累加 1。

**\*\*url\*\*** `string`  
本次事件对应图片的下载 URL。当请求中配置字段 **response\_format** 为 `url` 时返回。

**\*\*b64\_json\*\*** `string`  
本次事件对应图片的 Base64 编码。当请求中配置字段 **response\_format** 为 `b64_json` 时返回。

**size** `string`  
图像的宽高像素值，格式 `<宽像素> × <高像素>`，如 `2048 × 2048`。

## 返回示例

Shell

```
{
  "type": "image_generation.partial_succeeded",
  "model": "doubao-seedream-5-0-260128",
  "created": 1589478378,
  "image_index": 0,
  "url": "https://...",
  "size": "2048 × 2048"
}
```

## image\_generation.partial\_failed

当前仅 doubao-seedream-5.0-lite/4.5/4.0 支持流式响应。

在流式返回模式下，当任意图片生成失败时返回该事件。

- 若失败原因为审核不通过：仍会继续请求下一个图片生成任务，即不影响同请求内其他图片的生成流程。
- 若失败原因为内部服务异常（500）：不会继续请求下一个图片生成任务。

## 参数说明

**type** `string`

此处应为 `image_generation.partial_failed`。

**model** `string`

本次请求使用的模型 ID，格式为 `<模型名称>-<版本>`。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**image\_index** `integer`

本次生图请求中，本次事件对应图片在请求中的序号。

从 0 开始累加，不管图片是否生成成功，即在 `image_generation.partial_succeeded`、`image_generation.partial_failed` 事件，均会自动累加 1。



**error** `object`

本次生图请求中，本次事件对应的错误原因。

属性

**error.code** `string`

请参见[错误码](#)。

**error.message** `string`

错误提示信息

## 返回示例

Shell

```
{
  "type": "image_generation.partial_failed",
  "model": "doubao-seedream-5-0-260128",
  "created": 1589478378,
  "image_index": 2,
  "error": {
    "code": "OutputImageSensitiveContentDetected",
    "message": "The request failed because the output image may contain sensitive information."
  }
}
```

## image\_generation.completed

当前仅 doubao-seedream-5.0-lite/4.5/4.0 支持流式响应。

请求的所有图片（无论成功或失败）均处理完毕后返回，是该流式返回的最后一个响应事件。

## 参数说明

**type** `string`

此处应为 `image_generation.completed`。

**model** `string`

本次请求使用的模型 ID， 格式为 `<模型名称>-<版本>`。

---

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

---

**tools** `array of object`

本次请求，配置的模型调用工具。

属性

---

`tools.**type**` `string`

配置的调用工具类型。

- `web_search`：联网搜索工具。
- 

**usage** `object`

本次请求的用量信息。

属性

---

`usage.**generated_images**` `integer`

模型成功生成的图片张数，不包含生成失败的图片。

仅对成功生成图片按张数进行计费。

---

`usage.output_tokens` `integer`

模型生成的图片花费的 token 数量。

计算逻辑为：计算  $\text{sum}(\text{图片长} \times \text{图片宽}) / 256$ ，然后取整。

---

`usage.total_tokens` `integer`

本次请求消耗的总 token 数量。

当前不计算输入 token，故与 `output_tokens` 值一致。

---

`usage.**tool_usage**` `object`

使用工具的用量信息。

属性

---

`usage.tool_usage.**web_search` `integer`

调用联网搜索工具次数，仅开启联网搜索时返回。

## 返回示例

Shell

```
{
  "type": "image_generation.completed",
  "model": "doubao-seedream-5-0-260128",
  "created": 1589478378,
  "tools": [
    {
      "type": "web_search",
    }
  ],
  "usage": {
    "generated_images": 2,
    "output_tokens": xx,
    "total_tokens": xx,
    "tool_usage": {
      "web_search": 1
    }
  }
}
```

## error

本次请求如发生错误，对应的错误信息。

## 参数说明

`**error` `object`

本次请求错误，返回的错误信息。

属性

`error.code` `string`

请参见[错误码](#)。

**error.message** `string`

错误提示信息。

## 返回示例

Shell

```
"error": {  
  "code": "BadRequest",  
  "message": "The request failed because it is missing one or multiple required parameters. Request  
ID: {id}"  
}
```

## 7. 3D生成 API

### 7.1 Seed3D API

#### 7.1.1 创建3D生成任务 API

POST <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks> [运行](#)

本文介绍创建3D生成任务 API 的输入输出参数，供您使用接口时查阅字段含义。模型会依据传入的图片信息生成3D，待生成完成后，您可以按条件查询任务并获取生成的3D文件。

##### 模型支持的3D生成能力简介

###### · doubao-seed3d

- doubao-seed3d-2-0-260328：图生3D，根据您输入图片（1张）+参数（可选）生成一个带纹理和PBR材质的3D文件。

##### 在线调试

###### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

##### 鉴权说明

本接口仅支持 API Key 鉴权，请在 [获取 API Key](#) 页面，获取长效 API Key。

##### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

##### 请求参数

[跳转](#) [响应参数](#)

##### 请求体

**model** [string](#) [%%require%%](#)

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

**content** `object[]` `%%require%%`  
输入给模型，用于生成3D文件的信息。

信息类型

**图片信息** `object` `%%require%%`  
输入给模型的图片内容，模型会根据输入的图片生成完整的3D文件。

属性

`content.**type**` `string` `%%require%%`  
输入内容的类型，此处应为 `image_url`。

`content.**image_url**` `object` `%%require%%`  
输入给模型的图片对象。

属性

`content.image_url.**url**` `string` `%%require%%`  
图片信息，可以是图片URL或图片 Base64 编码。

- 图片URL：请确保图片URL可被访问。
- Base64编码：请遵循此格式 `data:image/<图片格式>;base64,<Base64编码>`，注意 `<图片格式>` 需小写，如 `data:image/png;base64,{base64_image}`。

**说明**

传入图片需要满足以下条件：

- 总像素：小于 4096 × 4096 px
- 大小：小于等于10MB
- 宽高比：(0.4, 2.5)
- 格式支持：jpg、jpeg、png、webp、bmp

**文本信息** `object`  
输入给模型的文本内容，当前仅支持参数。

## 属性

`content.**type**` `string` `%%require%%`  
输入内容的类型，此处应为 `text` 。

`content.**text**` `string` `%%require%%`  
输入给模型的文本内容，包括：  
**参数（选填）**：通过 `--[parameters]` 的方式，控制3D文件输出的规格，详情见 **模型文本命令(选填)** 。

## 模型文本命令(选填)

控制3D文件输出的规格。

### 示例

#### JSON

// 指定生成的3D文件的多边形面的数量为100000面，生成的有纹理的模型文件格式为obj

```
"content": [
  {
    "type": "text",
    "text": "--subdivisionlevel medium --fileformat obj"
  }
]
```

`**subdivisionlevel**` `string` 默认值 `medium` 简写 `sl`  
3D文件中多边形面的数量。取值范围：`high`、`medium`、`low`。  
具体对应的值根据不同模型不同取值。  
`doubao-seed3d-2-0-260328` 模型实际取值：

- `high` : 1000000
- `medium` : 500000
- `low` : 100000

**\*\*fileformat\*\*** `string` 默认值 `glb` 简写 `ff`  
生成的3D文件格式。  
枚举值：

· `glb` 、 `obj` 、 `usd` 、 `usdz`

---

## 响应参数

跳转 [请求参数](#)

**\*\*id\*\*** `string`  
3D生成任务 ID。创建3D生成任务为异步接口，获取 ID 后，需要通过 [查询3D生成任务 API](#) 来查询3D生成任务的状态。任务成功后，会输出生成3D的 `file_url`。

---



## 7.1.2 查询3D生成任务 API

GET <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}> [运行](#) [🔗](#)  
查询3D生成任务的状态。

### 说明

仅支持查询最近 7 天的历史数据。时间计算统一采用UTC时间戳，返回的7天历史数据范围以用户实际发起查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

### 快速入口

[体验中心](#) [📖](#) [模型列表](#) [📊](#) [模型计费](#) [🔑](#) [API Key](#) [🔗](#)  
[📖](#) [调用教程](#) [🔗](#) [</>](#) [接口文档](#) [❓](#) [常见问题](#) [🔗](#) [🔌](#) [开通模型](#) [🔗](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

**id** `string` `%%require%%`  
您需要查询的3D生成任务的 ID 。

### 说明

上面参数为Query String Parameters，在URL String中传入。

### 响应参数

[跳转](#) [请求参数](#)

**\*\*id \*\*** `string`  
3D生成任务 ID 。

**model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**status** `string`

任务状态，以及相关的信息：

- `queued` ： 排队中。
  - `running` ： 任务运行中。
  - `cancelled` ： 取消任务，取消状态24h自动删除（只支持 `queued` 状态的任务被取消）。
  - `succeeded` ： 任务成功。
  - `failed` ： 任务失败。
- 

**error** `object`

错误提示信息。

任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**content** `object`

3D生成任务的输出内容。

属性

---

**content.file\_url** `string`

生成的3D文件的url。为保障信息安全，生成的3D文件会在24小时后被清理，请及时转存。

---

### 说明

- 模型会自动将生成的3D文件打包为.zip格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。
- 推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

**subdivisionlevel** `string`

3D文件中多边形面的数量。

**fileformat** `string`

生成的3D文件格式。

**usage** `object`

本次请求的 token 用量。

属性

**usage.completion\_tokens** `integer`

模型输出3D文件花费的 token 数量。

**usage.total\_tokens** `integer`

本次请求消耗的总 token 数量。3D生成模型不统计输入 token，输入 token 为 0，故 **total\_tokens=completion\_tokens**。

### 7.1.3 查询3D生成任务列表

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?page_num={page_num}&page_size={page_size}&filter.status={filter.status}&filter.task_ids={filter.task_ids}&filter.model={filter.model}` [运行](#)

当您查询符合条件的任务，您可以传入条件筛选参数，返回符合要求的任务。

#### 说明

仅支持查询最近 7 天的历史数据。时间计算统一采用UTC时间戳，返回的7天历史数据范围以用户实际发起批量查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

#### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

#### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

#### 请求参数

[跳转 响应参数](#)

#### 说明

下面参数为Query String Parameters，在URL String中传入。

**page\_num** `integer`

返回结果的页码。数值大于0。

**page\_size** `integer`

返回结果的每页的结果数量。  
取值范围：[1, 500]

**filter** `Object`

过滤参数。

#### 属性

**\*\*filter.status\*\*** `string`

过滤参数，查询某个任务状态。

- `queued` : 排队中的任务。
- `running` : 运行中任务。
- `cancelled` : 取消的任务，只能查询到24h内取消的任务。取消任务超出24h，会被删除。
- `succeeded` : 成功的任务。
- `failed` : 失败的任务。

**\*\*filter.task\_ids\*\*** `string[]`

3D生成任务 ID，精确搜索，支持同时搜索多个任务 ID。多个任务 ID 之间通过 `&` 连接。

示例：同时搜索多个任务 ID

JSON

```
curl -X GET "https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?
filter.task_ids=cgt-2025*****_*****&filter.task_ids=cgt-2025*****_*****" \
--header "Content-Type: application/json" \
--header "Authorization: Bearer $ARK_API_KEY"
```

**\*\*filter.model\*\*** `string`

与返回参数不同，该字段为任务使用的推理接入点 ID，精确搜索。

## 响应参数

[跳转](#) [请求参数](#)

**\*\*items\*\*** `object[]`

查询到的3D生成任务列表。

属性

**items.\*\*id\*\*** `string`

3D生成任务 ID。

**items.model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**items.status** `string`

任务状态，以及相关的信息：

- `queued` ：排队中。
  - `running` ：任务运行中。
  - `cancelled` ：取消任务，取消状态24h自动删除（只支持排队中状态的任务被取消）。
  - `succeeded` ：任务成功。
  - `failed` ：任务失败。
- 

**items.error** `object`

错误提示信息。

任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**items.created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**items.updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**items.content** `object`

3D生成任务的输出内容。

属性

---

**content.\*\*file\_url \*\*** `string`

生成的3D文件的url。为保障信息安全，生成的3d文件会在24小时后被清理，请及时转存。

---

### 说明

模型会自动将生成的3D文件打包为.zip格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。

**items.subdivisionlevel** `string`

3D文件中多边形面的数量。

**items.fileformat** `string`

生成的3D文件格式。

**items.usage** `object`

本次请求的 token 用量。

属性

**usage.completion\_tokens** `integer`

模型输出3D文件花费的 token 数量。

**usage.total\_tokens** `integer`

本次请求消耗的总 token 数量。3D生成模型不统计输入 token，输入 token 为 0，故 **total\_tokens=completion\_tokens**。

**\*\*total \*\*** `integer`

所有符合筛选条件的item数量。

## 7.1.4 取消或删除3D生成任务

DELETE <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}> [运行](#)

取消排队中的3D生成任务，或者删除3D生成任务记录。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[调用教程](#) [接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

#### 说明

下面参数为Query String Parameters，在URL String中传入。

**id** `string` `%%require%%`  
需要取消或者删除的3D生成任务ID。  
任务状态不同，调用 `DELETE` 接口，执行的操作有所不同，具体说明如下：

| 当前任务状态    | 支持DELETE操作 | 操作含义                      | DELETE操作后任务状态 |
|-----------|------------|---------------------------|---------------|
| queued    | 是          | 任务取消排队，任务状态被变更为cancelled。 | cancelled     |
| running   | 不支持        | -                         | -             |
| succeeded | 是          | 删除3D生成任务记录，后续将不支持查询。      | -             |
| failed    | 是          | 删除3D生成任务记录，后续将不支持查询。      | -             |
| cancelled |            | -                         | -             |



| 当前任务状态 | 支持DELETE操作       | 操作含义 | DELETE操作后任务状态 |
|--------|------------------|------|---------------|
|        | 不支持<br>24小时后自动删除 |      |               |

### 响应参数

跳转 [请求参数](#)

本接口无返回参数。

## 7.2 影眸 API

### 7.2.1 创建3D生成任务

POST <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks> [🔗](#)

本文介绍创建影眸 3D 生成任务 API 的输入输出参数，供您使用接口时查阅字段含义。模型会依据传入的图片信息生成 3D，待生成完成后，您可以按条件查询任务并获取生成的 3D 文件。

#### 说明

调用本 API 时，按输出 Token 计费，价格为 **0.06 元 / 千 Token**。每输出一个 3D 模型固定消耗 3 万 Token（即 1.8 元/次），另有资源包可供选择，详见 [模型价格](#) [🔗](#)。

#### 模型支持的 3D 生成能力简介

##### · Hyper3d-Gen2

- 文生 3D：根据您输入 文本提示词 + 参数（可选） 生成一个 3D 模型文件。
- 图生 3D：根据您输入 图片（1-5张）+ 文本提示词（可选）+ 参数（可选） 生成一个 3D 模型文件。

#### 快速入口

[体验中心](#) [🔗](#) [📄 模型列表](#) [🔗](#) [💰 模型计费](#) [🔗](#) [🔑 API Key](#) [🔗](#)  
[🔗 </> 接口文档](#) [🔗 ? 常见问题](#) [🔗 ⏻ 开通模型](#) [🔗](#)

#### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

#### 请求参数

[跳转](#) [响应参数](#)

#### 请求体

**model** `string` %%require%%

您需要调用的模型的 ID（Model ID），[开通模型服务](#) [🔗](#)，并 [查询 Model ID](#) [🔗](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#) [🔗](#)。

**content** `object[]` `%%require%%`

输入给模型用于生成 3D 模型文件的信息。目前支持的输入组合：

**文生 3D：**

- 文本
- 文本 + 参数（可选）

**图生 3D：**

- 图片
- 图片 + 文本（可选）
- 图片 + 参数（可选）
- 图片 + 文本（可选） + 参数（可选）

信息类型

**图片信息** `object`

输入给模型的图片内容，模型会根据输入的图像生成完整的 3D 模型文件。

属性

`content.**type` `string` `%%require%%`

输入内容的类型，此处应为 `image_url`。

`content.**image_url` `object` `%%require%%`

输入给模型的图片对象。

属性

`content.image_url.**url` `string` `%%require%%`

图片信息，可以是图片 URL 或图片 Base64 编码。

- 图片 URL：请确保图片 URL 可被访问。
- Base64 编码：请遵循此格式 `data:image/<图片格式>;base64,<Base64编码>`，注意 `<图片格式>` 需小写，如 `data:image/png;base64,{base64_image}`。

**说明**

传入图片需要满足以下条件：

- 格式支持：jpg、jpeg、png
- 总像素：小于 4096 × 4096 px
- 大小：小于等于 30 MB
- 最多上传 5 张图片

### 文本信息 `object`

输入给模型的文本内容。

属性

`content.**type` `string` `%%require%%`

输入内容的类型，此处应为 `text` 。

`content.**text` `string` `%%require%%`

输入给模型的文本内容，包括：

**文本提示词：** 仅支持英文，长度不超过 400 字符，超过后将截断。

**参数（选填）：** 通过 `--[parameters]` 的方式，控制 3D 文件输出的规格，详情见 [模型文本命令\(选填\)](#) 。

### `seed` `integer`

种子整数，用于控制生成内容的随机性。

取值范围：[0, 65535] 之间的整数。

#### 注意

- 相同的请求下，模型收到不同的 `seed` 值，将生成不同的结果。
- 相同的请求下，模型收到相同的 `seed` 值，会生成类似的结果，但不保证完全一致。

### `callback_url` `string`

填写本次生成任务结果的回调通知地址。当 3D 生成任务有状态变化时，方舟将向此地址推送 POST 请求。

回调请求内容结构与 [查询任务API](#) 的返回体一致。

回调返回的 `status` 包括以下状态：

- `queued`：排队中
- `running`：任务运行中
- `succeeded`：任务成功（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）
- `failed`：任务失败（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）

## 模型文本命令（选填）

控制 3D 模型文件输出的规格。

示例

JSON

```
"content": [
  {
    "type": "text",
    "text": "Complete full-body quadrupedal mech robot, orange and black armored, rounded head with glowing blue sensors, 4 articulated mechanical legs, hard-surface sci-fi design, high-detail joints, photorealistic 8K, fully assembled, no missing parts. --mesh_mode Raw --hd_texture true --material PBR --addons HighPack --quality_override 1000000 --use_original_alpha false --bbox_condition [100,100,100] --TAPose false"
  }
]
```

**material** `string` 默认值 `PBR`

用于控制 3D 模型的材质类型。可选值：

- `PBR`：物理基础材质，包括基础颜色纹理、金属度纹理、法线纹理和粗糙度纹理，提供高真实感并在动态光照下具有物理准确性。
- `Shaded`：风格化材质，包括基础颜色纹理和烘焙光照。
- `All`：同时生成 PBR 和 Shaded 材质。
- `None`：无纹理，即生成白模。

**mesh\_mode** `string` 默认值 `Quad`

用于控制生成模型的网格形状。可选值：

- `Raw`：生成三角面模型。
- `Quad`：生成四边面模型。

**\*\*quality\_override\*\*** `number`

用于自定义 3D 模型的多边形面的面数。

- 当参数 **mesh\_mode** 为 `Raw` 时：[500, 1000000]，默认值：`500000`
- 当参数 **mesh\_mode** 为 `Quad` 时：[1000, 200000]，默认值：`18000`

说明

- 参数 **quality\_override** 与 **subdivisionlevel** 同时使用时，**subdivisionlevel** 将失效。
- 建议指定面数  $\geq 150000$  面。

**addons** `string`

用于增强纹理贴图的分辨率。可选值：

- `HighPack`：提供 4K 分辨率的纹理贴图。

**说明**

不配置该参数时，将默认生成 2K 分辨率的纹理贴图。

**use\_original\_alpha** `boolean` 默认值 `false`

用于控制 3D 模型的透明度信息。

- `true`：上传图片的透明部分会被保留，生成的 3D 模型或贴图会按原图的透明轮廓处理。
- `false`：透明部分会被自动填充，可能丢失原始透明效果。

**bbox\_condition** `integer[]`

指定模型边界的尺寸和缩放因子的数组。该数组包含三个元素，分别是宽度（x轴），高度（y轴）和长度（z轴）。如：

[100,100,100]

**说明**

如无特殊需求，建议不指定该参数，模型将自行判定边界。

**TAPose** `boolean` 默认值 `false`

生成类人模型时，控制生成的结果是否为T/A Pose。

- `false`：不强制 T/A Pose，由模型自行决定姿态。
- `true`：强制使用标准绑定姿态，并由模型判定是 T-Pose 还是 A-Pose。

**\*\*subdivisionlevel\*\*** `string` 简写 `sl`

控制 3D 模型的多边形面的数量。可选值：

当 **\*\*mesh\_mode\*\*** 为 `Raw` 时，默认值为 `high`。

- `high`：500k
- `medium`：150k
- `low`：20k

当 **\*\*mesh\_mode\*\*** 为 `Quad` 时，默认值为 `medium`。

- `high`：50k
- `medium`：18k
- `low`：8k

**\*\*fileformat\*\*** `string` 默认值 `glb` 简写 `ff`

生成的有纹理的 3D 模型文件的格式。可选值：

- `glb`
- `obj`
- `usdz`
- `fbx`
- `stl`

**hd\_texture** `boolean` 默认值 `false`

是否启用 HD 纹理。

- `true` ： 启用 HD 纹理。
- `false` ： 不启用 HD 纹理

## 响应参数

跳转 [请求参数](#)

**\*\*id\*\*** `string`

3D 生成任务 ID。创建 3D 生成任务为异步接口，获取 ID 后，需要通过 [查询3D生成任务 API](#) 来查询3D 生成任务的状态。任务成功后，会输出生成 3D 的 `file_url`。

## 7.2.2 查询3D生成任务

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}`  
查询 3D 生成任务的状态。

### 说明

仅支持查询最近 7 天的历史数据。时间计算统一采用 UTC 时间戳，返回的 7 天历史数据范围以用户实际发起查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转 响应参数](#)

**id** `string` `%%require%%`  
您需要查询的 3D 生成任务的 ID。

### 说明

该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的 {id} 占位符。

### 响应参数

[跳转 请求参数](#)

**\*\*id\*\*** `string`  
3D 生成任务 ID。



**model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**status** `string`

任务状态，以及相关的信息：

- `queued` ：排队中。
  - `running` ：任务运行中。
  - `cancelled` ：取消任务，取消状态 24h 自动删除（只支持 `queued` 状态的任务被取消）。
  - `succeeded` ：任务成功。
  - `failed` ：任务失败。
- 

**error** `object`

错误提示信息。

任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**content** `object`

3D 生成任务的输出内容。

属性

---

**content.file\_url** `string`

生成的 3D 模型文件的 url。为保障信息安全，生成的 3D 模型文件会在 24 小时后被清理，请及时转存。

---

### 说明

- 模型会自动将生成的 3D 文件打包为 .zip 格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。
- 推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

### usage object

本次请求的 token 用量。

属性

### usage.completion\_tokens integer

模型输出 3D 模型文件消耗的 token 数量。

### usage.total\_tokens integer

本次请求消耗的总 token 数量。3D 生成模型不统计输入 token，输入 token 为 0，故 **total\_tokens=completion\_tokens**。

### 7.2.3 查询3D生成任务列表

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?page_num={page_num}&page_size={page_size}&filter.status={filter.status}&filter.task_ids={filter.task_ids}&filter.model={filter.model}`

当您要查询符合条件的任务，您可以传入条件筛选参数，返回符合要求的任务。

**说明**

仅支持查询最近 7 天的历史数据。时间计算统一采用UTC时间戳，返回的7天历史数据范围以用户实际发起批量查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

**快速入口**

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

**鉴权说明**

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

**请求参数**

[跳转](#) [响应参数](#)

**说明**

该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的占位符。

**page\_num** `integer`

返回结果的页码。数值大于 0。

**page\_size** `integer`

返回结果的每页的结果数量。  
取值范围：[1, 500]

**filter** `object`

过滤参数。

**属性**

filter.\*\*status\*\* `string`

过滤参数，查询某个任务状态。

- `queued` : 排队中的任务。
- `running` : 运行中任务。
- `cancelled` : 取消的任务，只能查询到 24h 内取消的任务。取消任务超出24h，会被删除。
- `succeeded` : 成功的任务。
- `failed` : 失败的任务。

filter.\*\*task\_ids\*\* `string[]`

3D 生成任务 ID，精确搜索，支持同时搜索多个任务 ID。多个任务 ID 之间通过 `&` 连接。

示例：同时搜索多个任务 ID

JSON

```
curl -X GET https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?
filter.task_ids=cgt-2026*****_*****&filter.task_ids=cgt-2026*****_***** \
-H "Content-Type: application/json" \
-H "Authorization: Bearer $ARK_API_KEY"
```

filter.\*\*model\*\* `string`

与返回参数不同，该字段为任务使用的推理接入点 ID，精确搜索。

## 响应参数

[跳转](#) [请求参数](#)

\*\*items\*\* `object[]`

查询到的 3D 生成任务列表。

属性

items.\*\*id\*\* `string`

3D 生成任务 ID。

**items.model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**items.status** `string`

任务状态，以及相关的信息：

- `queued` ：排队中。
  - `running` ：任务运行中。
  - `cancelled` ：取消任务，取消状态24h自动删除（只支持排队中状态的任务被取消）。
  - `succeeded` ：任务成功。
  - `failed` ：任务失败。
- 

**items.error** `object`

错误提示信息。任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**items.created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**items.updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**items.content** `object`

3D 生成任务的输出内容。

属性

---

**content.\*\*file\_url \*\*** `string`

生成的 3D 模型文件的 url 。为保障信息安全，生成的 3D 文件会在 24 小时后被清理，请及时转存。

---

### 说明

- 模型会自动将生成的 3D 文件打包为 .zip 格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。
- 推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

---

`items.usage` `object`

本次请求的 token 用量。

属性

---

`usage.completion_tokens` `integer`

模型输出 3D 模型文件消耗的 token 数量。

---

`usage.total_tokens` `integer`

本次请求消耗的总 token 数量。3D 生成模型不统计输入 token，输入 token 为 0，故 **total\_tokens=completion\_tokens**。

---

`**total` `integer`

所有符合筛选条件的 item 数量。

## 7.2.4 取消或删除3D生成任务

DELETE https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}

取消排队中的 3D 生成任务，或者删除 3D 生成任务记录。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

**说明**

该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的 {id} 占位符。

**id** `string` `%%require%%`  
需要取消或者删除的 3D 生成任务 ID。  
任务状态不同，调用 `DELETE` 接口，执行的操作有所不同，具体说明如下：

| 当前任务状态    | 支持DELETE操作 | 操作含义                       | DELETE操作后任务状态 |
|-----------|------------|----------------------------|---------------|
| queued    | 是          | 任务取消排队，任务状态被变更为 cancelled。 | cancelled     |
| running   | 不支持        | -                          | -             |
| succeeded | 是          | 删除3D生成任务记录，后续将不支持查询。       | -             |
| failed    | 是          | 删除3D生成任务记录，后续将不支持查询。       | -             |
| cancelled |            | -                          | -             |

| 当前任务状态 | 支持DELETE操作       | 操作含义 | DELETE操作后任务状态 |
|--------|------------------|------|---------------|
|        | 不支持<br>24小时后自动删除 |      |               |

## 响应参数

跳转 [请求参数](#)

本接口无返回参数。



## 7.3 数美 API

### 7.3.1 创建 3D 生成任务

POST <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks> [🔗](#)

本文介绍创建数美 3D 生成任务 API 的输入输出参数，供您使用接口时查阅字段含义。模型会依据传入的图片信息生成 3D，待生成完成后，您可以按条件查询任务并获取生成的 3D 文件。

#### 说明

调用本 API 时，按输出 Token 计费，价格为 **0.08 元 / 千 Token**，每输出一个 3D 模型花费 5 元至 13 元之间（视生成模式而定），详见 [模型价格](#) [🔗](#)。

#### 模型支持的 3D 生成能力简介

##### · Hitem3d-2.0

- 图生 3D：根据您输入 [图片（1-4 张）](#) + [文本提示词（可选）](#) + [参数（可选）](#) 生成一个 3D 模型文件。

#### 快速入口

[体验中心](#) [🔗](#) [📄 模型列表](#) [🔗](#) [💰 模型计费](#) [🔗](#) [🔑 API Key](#) [🔗](#)  
[🔗 </> 接口文档](#) [🔗 ? 常见问题](#) [🔗 ⏻ 开通模型](#) [🔗](#)

#### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

#### 请求参数

[跳转](#) [响应参数](#)

#### 请求体

**model** `string` `%%require%%`

您需要调用的模型的 ID（Model ID），[开通模型服务](#) [🔗](#)，并 [查询 Model ID](#) [🔗](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#) [🔗](#)。

**content** `object[]` `%%require%%`

输入给模型用于生成 3D 模型文件的信息。目前支持的输入组合：

**图生 3D：**

- 图片
- 图片 + 参数（可选）

信息类型

**图片信息** `object` `%%require%%`

输入给模型的图片内容，模型会根据输入的图像生成完整的 3D 模型文件。

属性

`content.**type**` `string` `%%require%%`

输入内容的类型，此处应为 `image_url`。

`content.**image_url**` `object` `%%require%%`

输入给模型的图片对象。

属性

`content.image_url.**url**` `string` `%%require%%`

图片信息。仅支持图片 URL，请确保图片 URL 可被访问。

**说明**

传入图片需要满足以下条件：

- 格式支持：jpg、jpeg、png、webp
- 大小：小于等于 10 MB
- 总像素：小于 4096 × 4096 px
- 数量：最多上传 4 张图片

**文本信息** `object`

输入给模型的文本内容，当前仅支持传入参数。

属性

`content.**type**` `string` `%%require%%`  
输入内容的类型，此处应为 `text`。

`content.**text**` `string` `%%require%%`  
输入给模型的文本内容。

参数（选填）：通过 `--[parameters]` 的方式，控制 3D 文件输出的规格，详情见 [模型文本命令\(选填\)](#)。

`callback_url` `string`

填写本次生成任务结果的回调通知地址。当 3D 生成任务有状态变化时，方舟将向此地址推送 POST 请求。

回调请求内容结构与 [查询任务API](#) 的返回体一致。

回调返回的 status 包括以下状态：

- `queued`：排队中
- `running`：任务运行中
- `succeeded`：任务成功（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）
- `failed`：任务失败（如发送失败，即5秒内没有接收到成功发送的信息，回调三次）

## 模型文本命令(选填)

控制3D文件输出的规格。

示例

JSON

```
"content": [
  {
    "type": "text",
    "text": "--resolution 1536 --request_type 3 --ff 1 --face 2000000"
  }
]
```

`**resolution**` `string` 默认值 1536

用于控制 3D 模型的分辨率。可选值：

- `1536`
- `1536pro`

**\*\*face\*\*** `integer`  
模型面数，支持自定义配置。取值范围为 [100000, 2000000]。  
不同分辨率的推荐面数：

- 1536: `2000000`
- 1536 pro: `2000000`

**\*\*fileformat\*\*** `integer` 默认值 1 简写 ff  
生成的有纹理的 3D 模型文件的格式。可选值：

- `1` : 对应的文件格式为 obj
- `2` : 对应的文件格式为 glb
- `3` : 对应的文件格式为 stl
- `4` : 对应的文件格式为 fbx
- `5` : 对应的文件格式为 usdz

**\*\*request\_type\*\*** `integer` 默认值 3  
请求类型，可选值：

- `1` : 仅生成纯几何模型
- `3` : 一次性生成几何 + 纹理模型

**\*\*multi\_images\_bit\*\*** `string`  
上传的图像数组位图标识，用于标记 content.image\_url 图像中各图像的视图类型。字符串由 0 和 1 组成，1 表示该位置为有效视图图像；0 表示该位置无对应视图图像。  
视图类型按顺序依次为：前视图、后视图、左视图、右视图。  
示例：

| 参数取值 | 含义            | 数组内容顺序               |
|------|---------------|----------------------|
| 1010 | 存在前视图、左视图     | [前视图, 左视图]           |
| 1011 | 存在前视图、左视图、右视图 | [前视图, 左视图, 右视图]      |
| 1111 | 四个视图均存在       | [前视图, 后视图, 左视图, 右视图] |
| 0101 | 存在后视图、右视图     | [后视图, 右视图]           |

## 响应参数

[跳转](#) [请求参数](#)

**\*\*id\*\*** `string`

3D 生成任务 ID。创建 3D 生成任务为异步接口，获取 ID 后，需要通过 [查询3D生成任务 API](#) 来查询3D生成任务的状态。任务成功后，会输出生成 3D 的 `file_url`。

---

## 7.3.2 查询3D生成任务

GET <https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}>  
查询 3D 生成任务的状态。

### 说明

仅支持查询最近 7 天的历史数据。时间计算统一采用 UTC 时间戳，返回的 7 天历史数据范围以用户实际发起查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转 响应参数](#)

**id** `string` `%%require%%`  
您需要查询的 3D 生成任务的 ID。

### 说明

该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的 {id} 占位符。

### 响应参数

[跳转 请求参数](#)

**\*\*id\*\*** `string`  
3D 生成任务 ID。

**model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**status** `string`

任务状态，以及相关的信息：

- `queued` ： 排队中。
  - `running` ： 任务运行中。
  - `cancelled` ： 取消任务，取消状态24h自动删除（只支持 `queued` 状态的任务被取消）。
  - `succeeded` ： 任务成功。
  - `failed` ： 任务失败。
- 

**error** `object`

错误提示信息。

任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**content** `object`

3D 生成任务的输出内容。

属性

---

**content.file\_url** `string`

生成的 3D 文件的 url。为保障信息安全，生成的 3D 文件会在24小时后被清理，请及时转存。

---

### 说明

- 模型会自动将生成的 3D 文件打包为.zip格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。
- 推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

### usage object

本次请求的 token 用量。

属性

### usage.completion\_tokens integer

模型输出 3D 文件消耗的 token 数量。

### usage.total\_tokens integer

本次请求消耗的总 token 数量。3D 生成模型不统计输入 token，输入 token 为 0，故 **total\_tokens=completion\_tokens**。



### 7.3.3 查询3D生成任务列表

GET `https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?page_num={page_num}&page_size={page_size}&filter.status={filter.status}&filter.task_ids={filter.task_ids}&filter.model={filter.model}`

当您要查询符合条件的任务，您可以传入条件筛选参数，返回符合要求的任务。

#### 说明

仅支持查询最近 7 天的历史数据。时间计算统一采用UTC时间戳，返回的7天历史数据范围以用户实际发起批量查询请求的时刻为基准（精确到秒），时间戳区间为 [T-7天, T)。

#### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

#### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

#### 请求参数

[跳转](#) [响应参数](#)

#### 说明

该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的占位符。

**page\_num** `integer`

返回结果的页码。数值大于 0。

**page\_size** `integer`

返回结果的每页的结果数量。  
取值范围：[1, 500]

**filter** `object`

过滤参数。

#### 属性

filter.\*\*status\*\* `string`

过滤参数，查询某个任务状态。

- `queued` : 排队中的任务。
- `running` : 运行中任务。
- `cancelled` : 取消的任务，只能查询到24h内取消的任务。取消任务超出24h，会被删除。
- `succeeded` : 成功的任务。
- `failed` : 失败的任务。

filter.\*\*task\_ids\*\* `string[]`

3D 生成任务 ID，精确搜索，支持同时搜索多个任务 ID。多个任务 ID 之间通过 `&` 连接。

示例：同时搜索多个任务 ID

JSON

```
curl -X GET https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks?
filter.task_ids=cgt-2026*****_*****&filter.task_ids=cgt-2026*****_***** \
-H "Content-Type: application/json" \
-H "Authorization: Bearer $ARK_API_KEY"
```

filter.\*\*model\*\* `string`

与返回参数不同，该字段为任务使用的推理接入点 ID，精确搜索。

## 响应参数

[跳转](#) [请求参数](#)

\*\*items\*\* `object[]`

查询到的 3D 生成任务列表。

属性

items.\*\*id\*\* `string`

3D 生成任务 ID。

**items.model** `string`

任务实际使用的模型名称和版本， `模型名称-版本` 。

---

**items.status** `string`

任务状态，以及相关的信息：

- `queued` ：排队中。
  - `running` ：任务运行中。
  - `cancelled` ：取消任务，取消状态24h自动删除（只支持排队中状态的任务被取消）。
  - `succeeded` ：任务成功。
  - `failed` ：任务失败。
- 

**items.error** `object`

错误提示信息。

任务失败时返回错误数据，具体参见 [错误处理](#)。

属性

---

**error.code** `string`

错误码。

---

**error.message** `string`

错误提示信息。

---

**items.created\_at** `integer`

任务创建时间的 Unix 时间戳（秒）。

---

**items.updated\_at** `integer`

任务当前状态更新时间的 Unix 时间戳（秒）。

---

**items.content** `object`

3D 生成任务的输出内容。

属性

---

**content.\*\*file\_url \*\*** `string`

生成的 3D 文件的 url。为保障信息安全，生成的 3D 模型文件会在 24 小时后被清理，请及时转存。

---

### 说明

- 模型会自动将生成的 3D 模型文件打包为 .zip 格式以供下载，压缩包内文件的格式与您创建任务时所指定的格式一致。
- 推荐配置火山引擎 TOS 提供的数据订阅功能，将您的模型推理产物自动转存到自己的 TOS 桶中，便于长期备份或二次加工。详细介绍请参见 [TOS 数据订阅](#)。

`items.usage` `object`

本次请求的 token 用量。

属性

`usage.completion_tokens` `integer`

模型输出 3D 文件消耗的 token 数量。

`usage.total_tokens` `integer`

本次请求消耗的总 token 数量。3D 生成模型不统计输入 token，输入 token 为 0，故 `total_tokens=completion_tokens`。

`**total` `integer`

所有符合筛选条件的 item 数量。

## 7.3.4 取消或删除3D生成任务

`DELETE https://ark.cn-beijing.volces.com/api/v3/contents/generations/tasks/{id}`  
取消排队中的 3D 生成任务，或者删除 3D 生成任务记录。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

**说明**  
该参数为 Path Parameter。您需要将待查询的 3D 生成任务的 ID，直接替换 URL 中的 {id} 占位符。

**id** `string` `%%require%%`  
需要取消或者删除的 3D 生成任务 ID。  
任务状态不同，调用 `DELETE` 接口，执行的操作有所不同，具体说明如下：

| 当前任务状态    | 支持DELETE操作 | 操作含义                       | DELETE操作后任务状态 |
|-----------|------------|----------------------------|---------------|
| queued    | 是          | 任务取消排队，任务状态被变更为 cancelled。 | cancelled     |
| running   | 不支持        | -                          | -             |
| succeeded | 是          | 删除 3D 生成任务记录，后续将不支持查询。     | -             |
| failed    | 是          | 删除 3D 生成任务记录，后续将不支持查询。     | -             |
| cancelled |            | -                          | -             |

| 当前任务状态 | 支持DELETE操作       | 操作含义 | DELETE操作后任务状态 |
|--------|------------------|------|---------------|
|        | 不支持<br>24小时后自动删除 |      |               |

### 响应参数

跳转 [请求参数](#)

本接口无返回参数。

# 8. 向量化 API

## 8.1 向量化 API

POST <https://ark.cn-beijing.volces.com/api/v3/embeddings/multimodal> [运行](#)

当您需通过语义来处理视频、图像和文本，如以图搜图、语义检索等，可以调用多模态向量化服务，将视频、图像和文本转化为向量，来分析其语义关系。本文为您提供接口的参数详细说明供您查阅。

### 快速入口

[模型列表](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

如需使用 Access Key 来鉴权，推荐使用 SDK 的方式，具体请参见 [SDK概述](#)。

### 请求参数

[跳转](#) [响应参数](#)

### 请求体

**model** `string` 必选

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

**input** `object[]` 必选

需要向量化的内容列表。列表元素支持文本信息和图片信息以及视频信息。不同模型的支持情况不同，详情请查询[文档](#)。

属性

**文本信息** `object`

输入给模型转化为向量的内容，文本内容部分。

属性

**input.type** `string` 必选  
输入内容的类型，此处应为 `text` 。

**input.text** `string` 必选  
输入给模型的文本内容。  
单条文本以 utf-8 编码，长度不超过模型的最大输入 token 数。

**图片信息** `object`  
输入给模型转化成向量的内容，图片信息部分。  
传入图片需要满足的条件请参见[文档](#)。

属性

**input.type** `string` 必选  
输入内容的类型，此处应为 `image_url` 。

**input.image\_url** `object` 必选  
输入给模型的图片对象。

属性

**input.image\_url.url** `string` 必选  
图片信息，可以是图片URL或图片Base64编码。

- 图片URL：请确保图片URL可被访问。
- Base64编码：请遵循此格式 `data:image/{图片格式};base64,{图片Base64编码}` 。

**视频信息** `object`  
输入给模型转化成向量的内容，视频信息部分。

#### 说明

传入视频需要满足以下条件：

- 格式：`.mp4`、`.avi`、`.mov`，视频格式需小写。
- 传入 Base64 编码时使用：[Base64 编码输入](#)。
- 单视频文件需在 50MB 以内。
- 暂不支持对视频文件中的音频信息进行理解。



`input.type` `string` 必选

输入内容的类型，此处应为 `video_url`。

`input.video_url` `object` 必选

输入给模型的视频对象。

属性

`input.video_url.url` `string` 必选

支持传入视频链接或视频的Base64编码。具体使用请参见[文档](#)。

`input.video_url.fps` `number`

取值范围：`[0.2, 5]`。

每秒钟从视频中抽取指定数量的图像。取值越高，对于视频中画面变化理解越精细；取值越低，对于视频中画面变化感知减弱，但是使用的 token 花费少，速度也更快。该参数会直接影响视频 embedding 的抽帧数量与 token 消耗。

`input.video_url.max_video_tokens` `integer`

取值范围：`[10240, 204800]`。

视频最大 tokens 数，值越大保留的视频信息越多。该参数用于控制视频抽帧后最多送入模型的 token 数；超过此值时，会按帧数上限截断。

`input.video_url.min_frame_tokens` `integer`

取值范围：`[16, 128]`。

单帧最小 tokens 数，用于控制单帧压缩的下限。值越小，允许对单帧进行更大的压缩，但单帧细节下降；若单帧 token 过少，也会影响最终向量表征质量。

`input.video_url.max_frame_tokens` `integer`

取值范围：`[128, 640]`，且必须大于等于 `min_frame_tokens`。

单帧最大 tokens 数，用于控制单帧质量的上限。值越大，允许对单帧保留更多的细节；该参数会与 `max_video_tokens` 一起控制单帧和整体的 token 消耗。

`input.video_url.min_frames` `integer`

取值范围：`[5, 16]`。

最小抽帧数，用于保证短视频具备足够的处理帧数。若 `fps` 字段抽帧总数小于 `min_frames`，则优先按照 `min_frames` 配置要求抽帧，以避免极短视频抽不到帧。

说明

- 视频自定义抽帧参数 `fps`、`max_video_tokens`、`min_frame_tokens`、`max_frame_tokens`、`min_frames` 均为可选参数。
- 仅 `doubao-embedding-vision-251215` 及后续版本支持这些参数。
- 这些字段不传时，会根据模型对应的抽帧策略使用[默认值](#)。
- 抽帧策略会综合这些参数协同生效：按 `fps` 抽帧后，每帧按 `max_frame_tokens` 控制 token 上限，总 token 数不超过 `max_video_tokens`，实际抽帧数不低于 `min_frames`。
- 抽帧数量会直接影响视频 embedding 的 token 消耗，但并非帧数越多效果越好；若单帧 token 过少，视频 embedding 质量也会下降。
- 建议结合 `max_video_tokens` 与 `min_frame_tokens` 进行权衡，在控制总 token 消耗的同时，保证单帧保留足够信息。
- 当视频时长极短且 `fps` 过低，导致抽帧后实际帧数为 `0` 时，会以 `min_frames` 兜底，保证至少有帧送入编码器。

**encoding\_format** `string / null` 默认值 `float`

取值范围：`float`、`base64`、`null`。

embedding 返回的格式。

**dimensions** `integer` 默认值 `2048`

取值范围：`1024` 或 `2048`。

用于指定输出的向量维度。

**instructions** `string`

推理提示词，用户传入时直接使用，未传入时按输入模态生成默认值。详情请参见[配置instructions](#)。

**sparse\_embedding** `object`

稀疏向量开关配置，仅纯文本输入支持配置此字段。

属性

**sparse\_embedding.type** `string` 默认值 `disabled`

取值范围：`enabled`、`disabled`。

用于控制是否输出稀疏向量。

- `disabled`：仅输出稠密向量。
- `enabled`：同时输出稠密向量和稀疏向量。

**multi\_embedding** object

多向量（multi-vector）输出配置，控制是否输出多向量及其压缩方式。  
开启后，每个输入除返回稠密向量外，额外返回一组 token 级别的向量（二维数组）。

属性

**multi\_embedding.type** string 默认值 disabled

取值范围： enabled 、 disabled 。

多向量输出开关。

- type="disabled" ：不输出多向量。
- type="enabled" ：在稠密向量基础上，额外返回 data.multi\_embedding 。

**multi\_embedding.compression** string

多向量的压缩方式，仅在 type="enabled" 时生效。传入后， data.multi\_embedding 会返回压缩并 base64 编码后的字符串，可显著降低传输体积，客户端需按解码协议还原。

取值范围： blosc2 、 zstd 。

- blosc2 ：专门为数字数组优化的，同样的向量能压得更小、更省带宽。
- zstd ：通用高速压缩方式，几乎所有语言都有现成解码库，接入简单、解压快。

说明

- multi\_embedding.type="disabled" 时， compression 字段会被忽略。
- multi\_embedding.type="enabled" 且 compression 不传时，表示返回未压缩的二维数组。
- multi\_embedding 可以与 sparse\_embedding 同时开启，但 sparse\_embedding 仍仅支持纯文本输入。
- multi\_embedding 不允许传空对象 {}，否则会返回 400 MissingParameter 。
- 压缩与 encoding\_format 是两个正交维度：compression 控制 multi\_embedding 的压缩方式，encoding\_format 控制向量字段整体的响应序列化格式。

响应参数

[跳转 请求参数](#)

**id** string

本次请求的唯一标识。

**model** string

本次请求实际使用的模型名称和版本。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**object** `string`

固定为 `list`。

**data** `object`

本次请求的算法输出内容。

属性

**data.embedding** `float[]`

对应内容的向量化结果。

**data.sparse\_embedding** `array`

稀疏向量，仅 `sparse_embedding.type="enabled"` 时返回；每个成员为 `{"index": 维度索引, "value": 非零值}` 结构，仅返回非零元素。

**data.multi\_embedding** `float[][] / string`

多向量，仅 `multi_embedding.type="enabled"` 时返回。

- 未开启压缩时，返回 `float[][]`，外层表示 token 维度，内层表示每个 token 的子向量。
- 开启 `compression=blosc2/zstd` 时，返回经过压缩并 Base64 编码后的字符串。

**data.object** `string`

固定为 `embedding`。

### 说明

当 `data.multi_embedding` 以压缩字符串返回时，客户端应按以下规则解码：

1. 对返回的 Base64 字符串进行解码，并按 `compression` 指定的算法解压。
2. 将解压后的二进制数据按 `fp16`（2 字节，小端序）解析为一维数组。
3. 按 `[num_tokens, dimensions]` 将一维数组重塑为二维数组。

压缩返回场景下，响应不会单独返回 `shape` 或 `dtype` 字段。

---

**usage** `object`

本次请求的 token 用量。

属性

---

**usage.prompt\_tokens** `integer`

输入内容 token 数量。

---

**usage.total\_tokens** `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

---

**usage.prompt\_tokens\_details** `object`

输入的内容使用 token 量的细节信息。

属性

---

**usage.prompt\_tokens\_details.text\_tokens** `integer`

输入内容中，文本内容对应的 token 量，以及视频内容时间轴产生的 token 量。  
为保证模型效果，当图片或视频传入时，会生成少量的预设文本 token，产生额外的 **text\_tokens**。

---

**usage.prompt\_tokens\_details.image\_tokens** `integer`

输入内容中，图片内容以及视频内容抽帧图片对应的 token 量。

---

## 9. 上下文缓存 API

### 9.1 创建上下文缓存 API

POST <https://ark.cn-beijing.volces.com/api/v3/context/create> [运行](#)

上下文缓存（Context API）是方舟提供的一个高效的缓存机制。它通过缓存上下文数据，减少重复加载或处理，提高响应速度和一致性。本文介绍上下文缓存 API 的输入输出参数，供您使用接口时查阅字段含义。

#### 快速入口

[计费说明](#) [API Key](#) [支持模型](#)  
[调用教程](#) [开通模型](#)

#### 鉴权说明

本接口支持 API Key / Access Key 鉴权，详见[鉴权认证方式](#)。

#### 请求参数

[跳转](#) [响应参数](#)

#### 请求体

**model** `string` 必选

通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

暂不支持通过 Model ID 来调用。

**messages** `object[]` 必选

对话组成的消息列表。您希望缓存的信息。

注意：初始化的信息如系统人设，背景信息等，请使用系统消息（System message）放在消息列表最前。这部分信息在2种缓存模式下，均会一直存储在缓存中，直到缓存到期（触达最大生命周期）释放。

属性

**系统消息** `object`

系统消息，开发人员提供的指令，模型应遵循这些指令。如模型扮演的角色或者目标等。

属性

**messages.role** string 必选  
发送消息的角色，此处应为 system 。

**messages.content** string 必选  
系统信息内容。

**用户消息** object  
用户发送的消息，包含提示或附加上下文信息。

属性

**messages.role** string 必选  
发送消息的角色，此处应为 user 。

**messages.content** string 必选  
用户信息内容。

**messages.name** string  
发送此消息的角色的姓名。用于区别同一个角色但是不同主体发送的消息。

**模型消息** object  
模型响应用户消息而回复的消息。

说明

**messages.content** \*\* \*\* 与 **messages.tool\_calls** \*\* \*\* 字段二者至少填写其一。

**messages.role** string 必选  
发送消息的角色，此处应为 assistant 。

**messages.content** string  
模型回复的消息。

**messages.tool\_calls** `object[]`

模型回复的工具调用信息。

属性

**messages.tool\_calls.\*\*function\*\*** `object` 必选

模型调用工具对应的函数信息。

属性

**messages.tool\_calls . function.\*\*name\*\*** `string` 必选

模型需要调用的函数名称。

**messages.tool\_calls . function.\*\*arguments\*\*** `string` 必选

模型生成的用于调用函数的参数，JSON 格式。

### 说明

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

**messages.tool\_calls.\*\*id\*\*** `string` 必选

调用的工具的 ID。

**messages.tool\_calls.\*\*type\*\*** `string` 必选

工具类型，当前仅支持 `function`。

**mode** `string` 默认值 `session`

本次请求创建的上下文缓存的类型。[点此](#) 了解类型介绍。[点此](#) 了解支持的模型。

- `session` : Session 缓存。
- `common_prefix` : 前缀缓存。

**tll** `integer / null` 默认值 `86400`

过期时长，单位为秒，设置范围：[3600, 604800]，即1小时到7天。

信息在创建后即开始计时，每次使用则重置为0。计时超过ttl，信息会被从缓存中删除。每次调用chat均根据ttl更新过期时间。



**truncation\_strategy** object / null 默认值 null

缓存的上下文长度的窗口长度策略配置，只在当 **mode** 字段设置为 **session**，该字段可设置。支持 Session 缓存的模型能且只能支持 1 种 Session 缓存模式。如不配置该字段，方舟会根据您调用的模型自动适配合适的 Session 缓存模式。

属性

**last\_history\_tokens** 模式 object

触发缓存上限不会重新计算。

属性

**truncation\_strategy.type** string 必选

此处应为 **last\_history\_tokens**。

**truncation\_strategy.last\_history\_tokens** integer 默认值 4096

取值范围：(0,32768)。

缓存上下文窗口大小，即可缓存的上下文的最大 token 数。触发该上限将根据缓存上下文窗口大小对缓存内容进行清除。清除顺序按照信息被缓存时间长短排序，先清除缓存时间长的信息。

**rolling\_tokens** 模式 object

触发缓存上限会进行重新计算。

属性

**truncation\_strategy.type** string 必选

此处应为 **rolling\_tokens**。

**truncation\_strategy.rolling\_tokens** boolean 默认值 true

在缓存中历史消息长度接近 **max\_window\_tokens** 字段值时，是否自动对历史上下文进行裁剪（按照 message 元素粒度裁剪，按照 message 元素取整，即删除的信息的长度在 **rolling\_window\_tokens** 范围内，不会截断任意信息）。

- **false**：在历史消息长度超过上下文长度时模型会停止输出（返回字段 **finish\_reason** 为 **length**）。
- **true**：在历史消息长度接近上下文长度时模型按照先进先出的顺序，自动删除定量（**rolling\_window\_tokens** 字段值 token 数）的内容，为新对话内容腾挪缓存空间；同时对缓存中的信息进行重新计算和读入，保障内容理解一致性。具体的计算逻辑，请参见 [rolling\\_tokens 模式](#)。

**truncation\_strategy.max\_window\_tokens** integer / null 默认值 32768

在缓存中可存储的历史消息长度最大值。

取值满足下面条件：0 < **rolling\_tokens** < **max\_window\_tokens** < context window（模型最大上下文）。

`truncation_strategy.rolling_window_tokens` **\*\* integer / null 默认值 4096**

当缓存触发了`max_window_tokens` **\*\*** 上限，则会裁剪滚动窗口长度。

取值满足下面条件：`0 < **rolling_tokens** < **max_window_tokens** < context window`（模型最大上下文）。

## 响应参数

[跳转](#) [请求参数](#)

**id** **string**

本次请求创建的上下文缓存的ID，在后续创建带缓存的[上下文缓存对话 API](#) [需要](#)使用。

**model** **string**

本次请求使用的推理接入点的 ID 。

**mode** **string**

本次请求创建的上下文缓存的类型。[点此](#) [了解](#)支持的模型 。

- **session** : Session 缓存。
- **common\_prefix** : 前缀缓存。

**ttl** **integer**

本次请求创建的上下文缓存过期时长，单位为秒。信息在创建后即开始计时，每次使用则重置为0。计时超过ttl，信息会被从缓存中删除。每次调用chat均根据ttl更新过期时间。  
过期时间可以设置的范围在1小时到7天，即[3600, 604800]。

**\*\*truncation\_strategy** **\*\* object**

本次请求创建的 Session 缓存使用的截断策略信息。

属性

**\*\*last\_history\_tokens 模式** **\*\* object**

触发缓存上限，自动滚动缓存内容，无需重新计算。

属性

---

`truncation_strategy.**type` **string**

本次请求创建的 Session 缓存的截断策略，此处应为 `last_history_tokens` 。

---

`truncation_strategy.**last_history_tokens` **integer**

本次请求创建的 Session 缓存可缓存的最大 token 数。

---

`**rolling_tokens 模式` **object**

触发缓存上限，进行重新计算。

属性

---

`truncation_strategy.**type` **string**

本次请求创建的 Session 缓存的截断策略，此处应为 `rolling_tokens` 。

---

`truncation_strategy.**rolling_tokens` **boolean**

本次请求创建的 Session 缓存，当缓存的信息量达到最大缓存窗口时，是否自动处理。

---

`usage` **object**

本次请求的 token 用量。

属性

---

`usage.**prompt_tokens` **integer**

输入的 prompt token 数量。

---

`usage.**completion_tokens` **integer**

模型生成的 token 数量。

---

`usage.**total_tokens` **integer**

本次请求消耗的总 token 数量（输入 + 输出）。

---

`usage.**prompt_tokens_details` **object**

命中上下文缓存的 token 细节。

属性

---

---

```
usage.prompt_tokens_details.**cached_tokens** integer
```

命中上下文缓存的 token 数。

## 9.2 上下文缓存对话 API

POST <https://ark.cn-beijing.volces.com/api/v3/context/chat/completions> [运行](#)

上下文缓存（Context API）是方舟提供的一个高效的缓存机制。它通过缓存上下文数据，减少重复加载或处理，提高响应速度和一致性。本文介绍上下文缓存 API 的输入输出参数，供您使用接口时查阅字段含义。

### 快速入口

[计费说明](#) [API Key](#) [支持模型](#)  
[调用教程](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key / Access Key 鉴权，详见[鉴权认证方式](#)。

#### 说明

大部分字段与[对话\(Chat\)-文本 API](#)一致，除了下面参数：

- **model**：暂时不支持直接通过 Model ID 调用模型。
- **messages**：不支持最后一个元素的 role 设置为 `assistant`。
  - 如使用 session 缓存（**mode** 设置为 `session`），传入最新一轮对话的信息，无需传入历史信息。
- **tools**：不支持 **tools** 字段。
- **context\_id**：增加的字段，指定本次请求使用上下文缓存。
- **thinking**：不支持 **thinking** 字段。
- **response\_format**：不支持结构化输出参数。

### 请求参数

[跳转 响应参数](#)

**model** `string` 必选

您需要调用的模型的 ID（Model ID），[开通模型服务](#)，并[查询 Model ID](#)。

您也可通过 Endpoint ID 来调用模型，获得限流、计费类型（前付费/后付费）、运行状态查询、监控、安全等高级能力，可参考[获取 Endpoint ID](#)。

**messages** `object[]` 必选

到目前为止的对话组成的消息列表。不同模型支持不同类型的消息，如文本、图片、视频等。

消息类型

---

**系统消息** `object`

开发人员提供的指令，模型应遵循这些指令。如模型扮演的角色或者目标等。

属性

---

`messages.role` `string` 必选

发送消息的角色，此处应为 `system` 。

---

`messages.content` `string / object[]` 必选

系统信息内容。

属性

---

**纯文本消息内容** `string`

纯文本消息内容，大语言模型支持传入此类型。

---

**多模态消息内容** `object[]`

支持文本、图像、视频等类型，视觉理解模型等多模态模型、部分大语言模型支持此字段。

各模态消息部分

---

**文本消息部分** `object`

多模态消息中，内容文本输入。[具备视觉理解能力模型](#) 、部分大语言模型支持此类型消息。

属性

---

`messages.content.**text**` `string` 必选

文本消息部分的内容。

---

`messages.content.**type**` `string` 必选

文本消息类型，此次应为 `text` 。

---

**用户消息** `object`

用户发送的消息，包含提示或附加上下文信息。不同模型支持的字段类型不同，最多支持文本、图片、视频形式的消息。

属性

`messages.role` `string` 必选  
发送消息的角色，此处应为 `user`。

`messages.content` `string / object[]` 必选  
用户信息内容。

内容类型

**纯文本消息内容** `string`  
纯文本消息内容，大语言模型支持传入此类型。

**多模态消息内容** `object[]`  
支持文本、图像、视频等类型，视觉理解模型等多模态模型、部分大语言模型支持此字段。

内容类型

**文本消息部分** `object`  
多模态消息中，内容文本输入。视觉理解模型、部分大语言模型支持此类型消息。

属性

`messages.content.**text` `string` 必选  
文本消息部分的内容。

`messages.content.**type` `string` 必选  
文本消息类型，此次应为 `text`。

**模型消息** `object`

历史对话中，模型回复的消息。往往在多轮对话传入历史对话记录以及 [Prefill Response](#) 时让模型按照预置的回复内容继续回复时使用。

属性

说明

`messages.content` **\*\* \*\*** 与 `messages.tool_calls` **\*\* \*\*** 字段二者至少填写其一。

`messages.role` `string` **必选**  
发送消息的角色，此处应为 `assistant` 。

`messages.content` `string / array`  
模型回复的消息。

`messages.tool_calls` `object[]`  
历史对话中，模型回复的工具调用信息。

显示子字段

`messages.tool_calls.**function` `object` **必选**  
模型调用工具对应的函数信息。

显示子字段

`messages.tool_calls.function.**name` `string` **必选**  
模型需要调用的函数名称。

`messages.tool_calls.function.**arguments` `string` **必选**  
模型生成的用于调用函数的参数，JSON 格式。

说明

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

`messages.tool_calls.**id` `string` **必选**  
调用的工具的 ID。



**messages.tool\_calls** **\*\*type** **\*\*** `string` 必选  
工具类型，当前仅支持 `function` 。

---

**context\_id** `string` 必选  
指定本次请求使用上下文缓存的 ID。在使用[接口](#)创建缓存时，从返回信息中获得。

---

**stream** `boolean / null` 默认值 `false`  
响应内容是否流式返回：

- `false` ：模型生成完所有内容后一次性返回结果。
  - `true` ：按 SSE 协议逐块返回模型生成内容，并以一条 `data: [DONE]` 消息结束。
- 

**stream\_options** `object / null` 默认值 `null`  
流式响应的选项。当 **stream** 为 `true` 时可设置 **stream\_options** 字段。

属性

---

**stream\_options.\*\*include\_usage** `boolean / null` 默认值 `false`  
是否包含本次请求的 token 用量统计信息。

- `false` ：不返回 token 用量信息。
  - `true` ：在 `data: [DONE]` 消息之前会返回一个额外的块，此块上的 **usage** 字段代表整个请求的 token 用量，**choices** 字段为空数组。所有其他块也将包含 **usage** 字段，但值为 `null` 。
- 

**max\_tokens** `integer / null` 默认值 `4096`  
模型回复最大长度（单位 token），取值范围各个模型不同，详细见[模型列表](#) [🔗](#)。  
输入 token 和输出 token 的总长度还受模型的上下文长度限制。

---

**service\_tier** `string / null` 默认值 `auto`  
指定是否使用[TPM保障包](#) [🔗](#)。生效对象为购买了保障包推理接入点。取值范围：

- `default` ：本次请求，不使用 TPM 保障包，使用默认的限流和普通的服务响应速度，即使请求的是有 TPM保障包额度的推理接入点。

缓存不支持TPM保障包，故不支持 `auto` 。

---

**stop** `string / string[] / null` 默认值 `null`  
模型遇到 **stop** 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。

---

[深度思考能力模型](#) [🔗](#)不支持该字段。

`["你好", "天气"]`

**response\_format** `object` 默认值 `{"type": "text"}`  
模型输出内容须遵循此处指定的格式。

遵循格式

**遵循文本格式** `object`  
模型默认回复文本格式内容。

属性

**response\_format.type** `string` 必选  
此处应为 `text`。

**遵循JSON对象结构** `object`  
模型回复内容以JSON对象结构来组织。

支持该字段的模型请参见[文档](#) [🔗](#)。

属性

**response\_format.\*\*type\*\*** `string` 必选  
此处应为 `json_object`。

**遵循JSON Schema定义的结构** `object` `beta功能`  
模型回复内容以JSON对象结构来组织，遵循 `**schema**` 字段定义的JSON结构。

支持该字段的模型请参见[文档](#) [🔗](#)。  
该能力尚在 beta 阶段，请谨慎在生产环境使用。

属性

**response\_format.\*\*type\*\*** `string` 必选  
此处应为 `json_schema`。

**response\_format.json\_schema** `object` 必选  
JSON结构体的定义。

属性

**response\_format.json\_schema.name** `string` 必选  
用户自定义的JSON结构的名称。

**response\_format.json\_schema.description** `string / null`  
回复用途描述，模型将根据此描述决定如何以该格式回复。

**response\_format.json\_schema.schema** `object` 必选  
回复格式的JSON格式定义，以JSON Schema对象的形式描述。

**response\_format.json\_schema.strict** `boolean / null` 默认值 `false`  
是否在生成输出时，启用严格遵循模式。

- `true`：模型将始终严格遵循**schema**字段中定义的格式。
- `false`：模型会尽可能遵循**schema**字段中定义的结构。

**frequency\_penalty** `float / null` 默认值 `0`

取值范围为  $[-2.0, 2.0]$ 。

频率惩罚系数。如果值为正，会根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。

**presence\_penalty** `float / null` 默认值 `0`

取值范围为  $[-2.0, 2.0]$ 。

存在惩罚系数。如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。

**temperature** `float / null` 默认值 `1`

取值范围为  $[0, 2]$ 。

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。

通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**top\_p** float / null 默认值 0.7

取值范围为 [0, 1]。

核采样概率阈值。模型会考虑概率质量在 top\_p 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**logprobs** boolean / null 默认值 false

是否返回输出 tokens 的对数概率。

- false : 不返回对数概率信息。
- true : 返回消息内容中每个输出 token 的对数概率。

**top\_logprobs** integer / null 默认值 0

取值范围为 [0, 20]。

指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 logprobs 为 true 时可以设置 top\_logprobs 参数。

**logit\_bias** map / null 默认值 null

调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。logit\_bias 字段接受一个 map 值，其中每个键为词表中的 token ID（使用 tokenization 接口获取），每个值为该 token 的偏差值，取值范围为 [-100, 100]。

-1 会减少选择的可能性，1 会增加选择的可能性；-100 会完全禁止选择该 token，100 会导致仅可选择该 token。该参数的实际效果可能因模型而异。

```
{"1234": -100}
```

## 响应参数

[跳转](#) [请求参数](#)

## 非流式调用返回

[跳转](#) [流式调用返回](#)

**id** string

本次请求的唯一标识。

**model** `string`

本次请求实际使用的模型名称和版本。

doubao 1.5 代模型的模型名称格式为 doubao-1-5-\*\*。如调用部署doubao-1.5-pro-32k 250115模型的推理接入点，返回model字段信息doubao-1-5-pro-32k-250115。

**service\_tier** `string`

本次请求是否使用了TPM保障包。

- `scale` : 本次请求使用TPM保障包额度。
- `default` : 本次请求未使用TPM保障包额度。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**object** `string`

固定为 `chat.completion` 。

**choices** `object[]`

本次请求的模型输出内容。

属性

**choices.\*\*index** `integer`

当前元素在 **choices** 列表的索引。

**choices.\*\*finish\_reason** `string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
- `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
  - 触发 `max_token` 限制（回答内容的长度限制）。
  - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。
  - 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。
- `content_filter` : 模型输出被内容审核拦截。
- `tool_calls` : 模型调用了工具。

`choices.**message **` `object`

模型输出的内容。

属性

---

`choices.message.**role **` `string`

内容输出的角色，此处固定为 `assistant` 。

---

`choices.message.**content **` `string`

模型生成的消息内容。

---

`choices.message.**reasoning_content **` `string / null`

模型处理问题的思维链内容。

仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#) [🔗](#)。

---

`choices.message.**tool_calls **` `object[] / null`

模型生成的工具调用。

属性

---

`choices.message.tool_calls.**id **` `string`

调用的工具的 ID。

---

`choices.message.tool_calls.**type **` `string`

工具类型，当前仅支持 `function` 。

---

`choices.message.tool_calls.**function **` `object`

模型调用的函数。

属性

---

`choices.message.tool_calls.function.**name **` `string`

模型调用的函数的名称。

---

`choices.message.tool_calls.function.**arguments **` `string`

模型生成的用于调用函数的参数，JSON 格式。

---

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

---

`choices.**logprobs ** object / null`

当前内容的对数概率信息。

属性

---

`choices.logprobs.**content ** object[] / null`

message列表中每个 content 元素中的 token 对数概率信息。

属性

---

`choices.logprobs.content.**token ** string`

当前 token。

---

`choices.logprobs.content.**bytes ** integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

`choices.logprobs.content.**logprob ** float`

当前 token 的对数概率。

---

`choices.logprobs.content.**top_logprobs ** object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 top\_logprobs 指定的数量要少。

属性

---

`choices.logprobs.content.top_logprobs.**token ** string`

当前 token。

---

`choices.logprobs.content.top_logprobs.**bytes ** integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.top_logprobs.**logprob ** float`

当前 token 的对数概率。

`choices.**moderation_hit_type ** string/ null`

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation` ：模型输出文字涉及严重违规。
- `violence` ：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

`usage object`

本次请求的 token 用量。

属性

`usage.**prompt_tokens ** integer`

输入给模型的内容的 token 用量。

`usage.**completion_tokens ** integer`

模型输出内容的 token 用量。

`usage.**total_tokens ** integer`

本次请求消耗的总 token 数量（输入 + 输出）。

`usage.**prompt_tokens_details ** object`

命中上下文缓存的tokens细节。

属性

`usage.prompt_tokens_details.**cached_tokens ** integer`

提示词命中缓存的 token 用量。

`usage.**completion_tokens_details ** object`

本次请求，模型输出内容的 token 用量的细节。



属性

`usage.completion_tokens_details.**reasoning_tokens` `integer`  
输出思维链内容花费的 token 数。  
支持输出思维链的模型请参见[文档](#)。

流式调用返回

[跳转 非流式调用返回](#)

`id` `string`  
本次请求的唯一标识。

`model` `string`  
本次请求实际使用的模型名称和版本。  
doubao 1.5 代模型的模型名称格式为 `doubao-1-5-*`。如调用部署 `doubao-1.5-pro-32k 250115` 模型的推理接入点，返回 `model` 字段信息 `doubao-1-5-pro-32k-250115`。

`service_tier` `string`  
本次请求是否使用了TPM保障包。

- `scale`：本次请求使用TPM保障包额度。
- `default`：本次请求未使用TPM保障包额度。

`created` `integer`  
本次请求创建时间的 Unix 时间戳（秒）。

`object` `string`  
固定为 `chat.completion.chunk`。

`choices` `object[]`  
本次请求的模型输出内容。

属性

`choices.**index** integer`

当前元素在 **choices** 列表的索引。

---

`choices.**finish_reason** string`

模型停止生成 token 的原因。取值范围：

- `stop` : 模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
  - `length` : 模型输出因达到模型输出限制而被截断，有以下原因：
    - 触发 `max_token` 限制（回答内容的长度限制）。
    - 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。
    - 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。
  - `content_filter` : 模型输出被内容审核拦截。
  - `tool_calls` : 模型调用了工具。
- 

`choices.**delta** object`

模型输出的增量内容。

属性

---

`choices.delta.**role** string`

内容输出的角色，此处固定为 `assistant` 。

---

`choices.delta.**content** string`

模型生成的消息内容。

---

`choices.delta.**reasoning_content** string / null`

模型处理问题的思维链内容。

仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#) .

---

`choices.delta.**tool_calls** string / null`

模型生成的工具调用。

属性

---

`choices.delta.tool_calls.**id** string`

调用的工具的 ID。

---

`choices.delta.tool_calls.**type**` `string`  
工具类型，当前仅支持 `function` 。

---

`choices.delta.tool_calls.**function**` `object`  
模型调用的函数。

属性

---

`choices.delta.tool_calls.function.**name**` `string`  
模型调用的函数的名称。

---

`choices.delta.tool_calls.function.**arguments**` `string`  
模型生成的用于调用函数的参数，JSON 格式。  
模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

---

`choices.**logprobs**` `object / null`  
当前内容的对数概率信息。

属性

---

`choices.logprobs.**content**` `object[] / null`  
message列表中每个 content 元素中的 token 对数概率信息。

属性

---

`choices.logprobs.content.**token**` `string`  
当前 token。

---

`choices.logprobs.content.**bytes**` `integer[] / null`  
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

---

`choices.logprobs.content.**logprob**` `float`  
当前 token 的对数概率。

---

`choices.logprobs.content.**top_logprobs**` `object[]`

在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。

属性

`choices.logprobs.content.top_logprobs.**token**` `string`

当前 token。

`choices.logprobs.content.top_logprobs.**bytes**` `integer[] / null`

当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。

`choices.logprobs.content.top_logprobs.**logprob**` `float`

当前 token 的对数概率。

`choices.**moderation_hit_type**` `string / null`

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

- `severe_violation`：模型输出文字涉及严重违规。
- `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

`usage` `object`

本次请求的 token 用量。

流式调用时，默认不统计 token 用量信息，返回值为 `null`。

如需统计，需设置 `stream_options.include_usage` 为 `true`。

属性

`usage.**prompt_tokens**` `integer`

输入给模型的内容的 token 用量。

`usage.**completion_tokens**` `integer`

模型输出内容的 token 用量。

---

`usage.**total_tokens**` `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

---

`usage.**prompt_tokens_details**` `object`

输入给模型的内容的 token 用量的细节。

属性

---

`usage.prompt_tokens_details.**cached_tokens**` `integer`

通过缓存输入内容的 token 用量。

---

`usage.**completion_tokens_details**` `object`

本次请求，模型输出内容的 token 用量的细节

属性

---

`usage.completion_tokens_details.**reasoning_tokens**` `integer`

输出思维链内容花费的 token 数。

支持输出思维链的模型请参见[文档](#) [🔗](#)。

# 10. 应用(Bot) API

## 10.1 应用(bot) API

POST <https://ark.cn-beijing.volces.com/api/v3/bots/chat/completions> [运行](#)

本文介绍方舟应用 API 的输入输出参数，供您使用接口时查阅字段含义。

### 快速入口

[体验中心](#) [模型列表](#) [模型计费](#) [API Key](#)  
[获取Bot ID](#) [接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

如需使用 Access Key 来鉴权，推荐使用 SDK 的方式，具体请参见 [SDK概述](#)。

### 请求参数

[跳转](#) [响应参数](#)

### 请求体

- **model** `string` **必选**  
您需要调用的应用的 ID（Bot ID），[获取 Bot ID](#)。
- **messages** `object[]` **必选**  
到目前为止的对话组成的消息列表。不同模型支持不同类型的消息，如文本、图片等。

### System message

`object`

系统消息，开发人员提供的指令，模型应遵循这些指令。如模型扮演的角色或者目标等。

- **messages.role** `string` **必选**  
发送消息的角色，此处应为 `system`。
- **messages.content** `string / object[]` **必选**  
系统信息内容。

### 纯文本消息内容

`string`

纯文本的消息内容。

### 多模态消息内容

`object[]`

视觉理解模型等多模态模型、部分大语言模型支持此类型。

#### 文本消息部分 `object`

多模态消息中，内容文本输入。[视觉理解模型](#)、部分大语言模型支持此类型消息。

- `messages.content.**text**` `string` 必选  
文本消息内容部分。
- `messages.content.**type**` `string` 必选  
文本消息类型，此次应为 `text`。

#### 图像消息部分 `object`

多模态消息中，图像内容部分。[视觉理解模型](#)支持此类型消息。

- `messages.content.**image_url**` `object` 必选  
图片消息的内容部分。
  - `messages.content.image_url.**url**` `string` 必选  
支持传入图片链接或图片的Base64编码，不同模型支持图片大小略有不同，具体请参见[使用说明](#)。
    - 传入图片URL：传入图片的可访问链接，推荐使用TOS（火山引擎对象存储）存储图片，并生成图片链接。
    - 传入Base64编码：请遵循格式 `data:image/<图片格式>;base64,<Base64编码>`，可见[示例](#)。
  - `messages.content.image_url.**detail**` `string` 默认值 `auto`  
支持手动设置图片的质量，取值范围 `high`、`low`、`auto`。
    - `high`：高细节模式，适用于需要理解图像细节信息的场景，如对图像的多个局部信息/特征提取、复杂/丰富细节的图像理解等场景，理解更全面。
    - `low`：低细节模式，适用于简单的图像分类/识别、整体内容理解/描述等场景，理解更快速。
    - `auto`：默认模式，不同模型选择的模式略有不同，具体请参见[理解图像的深度控制](#)。
- `messages.content.**type**` `string` 必选  
图像消息类型，此次应为 `image_url`。

## User message

`object`

用户发送的消息，包含提示或附加上下文信息。

- `messages.role` `string` 必选  
发送消息的角色，此处应为 `user`。
- `messages.content` `string / object[]` 必选  
用户信息内容。

## 纯文本消费内容

`string`

大语言模型支持此类型。

## 多模态消息内容

`object[]`

视觉理解模型等多模态模型、部分大语言模型支持此类型。

#### 文本消息部分 `object`

多模态消息中，内容文本输入。[视觉理解模型](#)、部分大语言模型支持此类型消息。

- `messages.content.**text**` `string` 必选  
文本消息内容部分。
- `messages.content.**type**` `string` 必选  
文本消息类型，此次应为 `text`。

#### 图像消息部分 `object`

多模态消息中，图像内容部分。[视觉理解模型](#)支持此类型消息。

- `messages.content.**image_url**` `object` 必选  
图片消息的内容部分。
  - `messages.content.image_url.**url**` `string` 必选  
支持传入图片链接或图片的Base64编码，不同模型支持图片大小略有不同，具体请参见[使用说明](#)。
    - 传入图片URL：传入图片的可访问链接，推荐使用 TOS（火山引擎对象存储）存储图片，并生成图片链接。
    - 传入Base64编码：请遵循格式 `data:image/<图片格式>;base64,<Base64编码>`，可见[示例](#)。
  - `messages.content.image_url.**detail**` `string / null` 默认值 `auto`  
支持手动设置图片的质量，取值范围 `high`、`low`、`auto`。
    - `high`：高细节模式，适用于需要理解图像细节信息的场景，如对图像的多个局部信息/特征提取、复杂/丰富细节的图像理解等场景，理解更全面。
    - `low`：低细节模式，适用于简单的图像分类/识别、整体内容理解/描述等场景，理解更快速。
    - `auto`：默认模式，不同模型选择的模式略有不同，具体请参见[理解图像的深度控制](#)。
- `messages.content.**type**` `string` 必选  
图像消息类型，此次应为 `image_url`。
- `messages.name` `string`  
发送此消息的角色的姓名。用于区别同一个角色但是不同主体发送的消息。

### Assistant message

`object`

模型响应用户消息而回复的消息。

#### 说明

`messages.content` 与 `messages.tool_calls` 字段二者至少填写其一。

- `messages.role` `string` 必选  
发送消息的角色，此处应为 `assistant`。
- `messages.content` `string / array`  
模型回复的消息。



- **messages.tool\_calls** `object[]`  
模型回复的工具调用信息。
  - **messages.tool\_calls.\*\*function\*\*** `object` 必选  
模型调用工具对应的函数信息。
    - **messages.tool\_calls.function.\*\*name\*\*** `string` 必选  
模型需要调用的函数名称。
    - **messages.tool\_calls.function.\*\*arguments\*\*** `string` 必选  
模型生成的用于调用函数的参数，JSON 格式。

### 说明

模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。

- **messages.tool\_calls.\*\*id\*\*** `string` 必选  
调用的工具的 ID。
- **messages.tool\_calls.\*\*type\*\*** `string` 必选  
工具类型，当前仅支持 `function`。

## Tool message

`object`

模型调用工具的消息。

- **messages.role** `string` 必选  
发送消息的角色，此处应为 `tool`。
- **messages.content** `string / array` 必选  
工具返回的消息。
- **messages.\*\*tool\_call\_id\*\*** `string` 必选  
模型调用的工具的 ID。
- **thinking** `object` 默认值 `{"type":"enabled"}`

控制模型是否开启深度思考模式。默认开启深度思考模式，可以手动关闭。

支持此字段的模型以及使用示例请参见[文档](#)。

属性

**thinking.\*\*type\*\*** `string` 必选

取值范围：`enabled`，`disabled`，`auto`。

- **enabled**：开启思考模式，模型一定先思考后回答。
- **disabled**：关闭思考模式，模型直接回答问题，不会进行思考。
- **auto**：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。
- **stream** `boolean / null` 默认值 `false`  
响应内容是否流式返回：
  - **false**：模型生成完所有内容后一次性返回结果。
  - **true**：按 SSE 协议逐块返回模型生成内容，并以一条 `data: [DONE]` 消息结束。

- **stream\_options** `object / null` 默认值 `null`  
 流式响应的选项。当 **stream** 为 `true` 时可设置 **stream\_options** 字段。
  - **stream\_options.\*\*include\_usage\*\*** `boolean / null` 默认值 `false`  
 是否包含本次请求的 token 用量统计信息。
    - `false` : 不返回 token 用量信息。
    - `true` : 在 `data: [DONE]` 消息之前会返回一个额外的块, 此块上的 **usage** 字段代表整个请求的 token 用量, **choices** 字段为空数组。所有其他块也将包含 **usage** 字段, 但值为 `null`。
- **max\_tokens** `integer / null` 默认值 `4096`  
 模型回复最大长度 (单位 token), 取值范围各个模型不同, 详细见[模型列表](#)。输入 token 和输出 token 的总长度还受模型的上下文长度限制。
- **stop** `string / string[] / null` 默认值 `null`  
 模型遇到 stop 字段所指定的字符串时将停止继续生成, 这个词语本身不会输出。最多支持 4 个字符串。  
`["你好", "天气"]`
- **frequency\_penalty** `float / null` 默认值 `0`  
 取值范围为 `[-2.0, 2.0]`。  
 频率惩罚系数。如果值为正, 会根据新 token 在文本中的出现频率对其进行惩罚, 从而降低模型逐字重复的可能性。
- **presence\_penalty** `float / null` 默认值 `0`  
 取值范围为 `[-2.0, 2.0]`。  
 存在惩罚系数。如果值为正, 会根据新 token 到目前为止是否出现在文本中对其进行惩罚, 从而增加模型谈论新主题的可能性。
- **temperature** `float / null` 默认值 `1`  
 取值范围为 `[0, 2]`。  
 采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。。当取值为 0 时模型仅考虑对数概率最大的一个 token。  
 较高的值 (如 0.8) 会使输出更加随机, 而较低的值 (如 0.2) 会使输出更加集中确定。  
 通常建议仅调整 temperature 或 top\_p 其中之一, 不建议两者都修改。
- **top\_p** `float / null` 默认值 `0.7`  
 取值范围为 `[0, 1]`。  
 核采样概率阈值。模型会考虑概率质量在 top\_p 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。  
 0.1 意味着只考虑概率质量最高的前 10% 的 token, 取值越大生成的随机性越高, 取值越低生成的确定性越高。通常建议仅调整 temperature 或 top\_p 其中之一, 不建议两者都修改。
- **logprobs** `boolean / null` 默认值 `false`  
 是否返回输出 tokens 的对数概率。
  - `false` : 不返回对数概率信息。
  - `true` : 返回消息内容中每个输出 token 的对数概率。
- **top\_logprobs** `integer / null` 默认值 `0`  
 取值范围为 `[0, 20]`。  
 指定每个输出 token 位置最有可能返回的 token 数量, 每个 token 都有关联的对数概率。仅当 **logprobs** 为 `true` 时可以设置 **top\_logprobs** 参数。
- **logit\_bias** `map / null` 默认值 `null`  
 调整指定 token 在模型输出内容中出现的概率, 使模型生成的内容更加符合特定的偏好。**logit\_bias** 字段接受一个 map 值, 其中每个键为词表中的 token ID (使用 tokenization 接口获取), 每个值为该 token 的偏差值, 取值范围为 `[-100, 100]`。  
 -1 会减少选择的可能性, 1 会增加选择的可能性; -100 会完全禁止选择该 token, 100 会导致仅可选择

该 token。该参数的实际效果可能因模型而异。

```
{ "1234": -100 }
```

· **tools** `object[] / null` 默认值 `null`

模型可以调用的工具列表。目前仅函数作为工具被支持。用这个来提供模型可能为其生成 JSON 输入的函数列表。支持该字段的模型请参见[文档](#)。

◦ **tools.\*\*type\*\*** `string` 必选

工具类型，当前仅支持 `function`。

◦ **tools.\*\*function\*\*** `object` 必选

模型可以调用的类型为 `function` 的工具列表。

■ **tools.function.\*\*name\*\*** `string` 必选

调用的函数的名称。

■ **tools.function.\*\*description\*\*** `string` 必选

调用的函数的描述，大模型会使用它来判断是否调用这个函数。

■ **tools.function.\*\*parameters\*\*** `object` 必选

函数请求参数，以 JSON Schema 格式描述。具体格式请参考 [JSON Schema](#) 文档。

JSON

```
{
  "type": "object",
  "properties": {
    "location": {
      "type": "string",
      "description": "城市，如：北京"
    }
  },
  "required": ["location"]
}
```

· **metadata** `object / null` 默认值 `null`

额外参数。

◦ **metadata.group\_chat\_config** `object` 必选

运行时动态传入的角色配置。

■ **metadata.group\_chat\_config.characters** `object[]` 必选

群聊角色列表。

■ **metadata.group\_chat\_config.characters.name** `string` 必选

群聊角色名称。

■ **metadata.group\_chat\_config.characters.system\_prompt** `string` 必选

群聊角色设定，用于告知应用需要扮演的角色。

■ **metadata.group\_chat\_config.characters.model\_desc** `object` 必选

模型说明。

■ **metadata.group\_chat\_config.characters.model\_desc.endpoint\_id** `string` 必选

您创建的[推理接入点](#) ID。

■ **metadata.group\_chat\_config.description** `string / null` 默认值 `null`

群聊场景描述，可设定群聊的主题、时间地点、事件场景、用户扮演的角色等信息。

■ `metadata.group_chat_config.user_name` `string / null` 默认值 用户

表示“我”所扮演的角色名称，默认值为“用户”。

◦ `metadata.user_info` `string / null` 默认值 `null`

联网的智能体可使用，如查询天气场景，前端可以直接通过该字段传地点信息给模型，方便查对应地点的天气。

传入的信息需满足条件：可以被反序列化成 json 的字符串，并需包含 `city` 和 `district` 两个字段。

◦ `metadata.emit_intention_signal_extra` `string / null` 默认值 `"false"`

值是 `"true"` 时，会中途返回intention状态“正在搜索”。

◦ `metadata.target_character_name` `string / null` 默认值 `null`

群聊Bot对话时填写，指定本次要发言的角色名，必须是存在于 `characters` 里的角色。

## 响应参数

[跳转 请求参数](#)

## 非流式调用返回

· `id` `string`

本次请求的唯一标识。

· `model` `string`

本次请求实际使用的模型名称和版本。

doubao 1.5 代模型的模型名称格式为 `doubao-1-5-*`。如调用部署 `doubao-1.5-pro-32k 250115` 模型的推理接入点，返回 `model` 字段信息 `doubao-1-5-pro-32k-250115`。

· `created` `integer`

本次请求创建时间的 Unix 时间戳（秒）。

· `object` `string`

固定为 `chat.completion`。

· `choices` `object[]`

本次请求的模型输出内容。

◦ `choices.**index**` `integer`

当前元素在 `choices` 列表的索引。

◦ `choices.**finish_reason**` `string`

模型停止生成 token 的原因。取值范围：

■ `stop`：模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。

■ `length`：模型输出因达到模型输出限制而被截断，有下面几种原因：

■ 触发 `max_token` 限制（回答内容的长度限制）。

■ 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。

■ 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。

■ `content_filter`：模型输出被内容审核拦截。

■ `tool_calls`：模型调用了工具。

◦ `choices.**message**` `object`

模型输出的内容。

■ `choices.message.**role**` `string`

内容输出的角色，此处固定为 `assistant`。

■ `choices.message.**content**` `string`

模型生成的消息内容。

- `choices.message.**reasoning_content**` `string / null`  
模型处理问题的思维链内容。  
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。
- `choices.message.**tool_calls**` `object[] / null`  
模型生成的工具调用。
  - `choices.message.tool_calls.**id**` `string`  
调用的工具的 ID。
  - `choices.message.tool_calls.**type**` `string`  
工具类型，当前仅支持 `function`。
  - `choices.message.tool_calls.**function**` `object`  
模型调用的函数。
    - `choices.message.tool_calls.function.**name**` `string`  
模型调用的函数的名称。
    - `choices.message.tool_calls.function.**arguments**` `string`  
模型生成的用于调用函数的参数，JSON 格式。  
模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。
- `choices.**logprobs**` `object / null`  
当前内容的对数概率信息。
  - `choices.logprobs.**content**` `object[] / null`  
message 列表中每个 content 元素中的 token 对数概率信息。
    - `choices.logprobs.content.**token**` `string`  
当前 token。
    - `choices.logprobs.content.**bytes**` `integer[] / null`  
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。
    - `choices.logprobs.content.**logprob**` `float`  
当前 token 的对数概率。
    - `choices.logprobs.content.**top_logprobs**` `object[]`  
在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。
      - `choices.logprobs.content.top_logprobs.**token**` `string`  
当前 token。
      - `choices.logprobs.content.top_logprobs.**bytes**` `integer[] / null`  
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。
      - `choices.logprobs.content.top_logprobs.**logprob**` `float`  
当前 token 的对数概率。
  - `choices.**moderation_hit_type**` `string / null`  
模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。  
返回值及含义：
    - `severe_violation`：模型输出文字涉及严重违规。
    - `violence`：模型输出文字涉及激进行为。
 注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 `CreateEndpoint` 接口中，将内容护栏方案（`ModerationStrategy`）设置为基础方案（`Basic`）时，才会返回风险分类标签。

- **bot\_usage** `object`

本次请求的 token 用量。

- **bot\_usage.model\_usage** `object[]`  
本次请求不同 endpoint 的 token 消耗。
  - **bot\_usage.model\_usage.name** `string`  
调用的模型 ID。
  - **bot\_usage.model\_usage.prompt\_tokens** `integer`  
输入的 prompt token 数量，包含用户输入的提示词和调用插件返回的信息。
  - **bot\_usage.model\_usage.completion\_tokens** `integer`  
模型生成的 token 数量。
  - **bot\_usage.model\_usage.total\_tokens** `integer`  
本次请求消耗的总 token 数量（输入 + 输出）。
- **action\_usage** `object[]`  
本次请求插件用量信息。
  - **action\_usage.action\_name** `string`  
插件分类名称，如 `content_plugin`（内容插件）等。
  - **action\_usage.count** `integer`  
本次请求某插件分类插件总调用次数。
- **action\_details** `object[]`  
本次请求插件调用详情。
  - **action\_details.name** `string`  
插件分类名称，如 `content_plugin`（内容插件）等。
  - **action\_details.count** `integer`  
本次请求某插件分类中插件调用次数。
  - **action\_details.tool\_details** `object[]`  
某插件分类中插件调用详细信息。
    - **action\_details.tool\_details.name** `string`  
具体调用的工具名称。
    - **action\_details.tool\_details.input** `object`  
插件输入参数，调用插件的数据结构。
    - **action\_details.tool\_details.output** `object`  
插件输出结果，调用插件返回的数据结构。
    - **action\_details.tool\_details.created\_at** `integer`  
插件调用开始时间。
    - **action\_details.tool\_details.completed\_at** `integer`  
插件调用结束时间。

- **metadata** `object / null`

额外参数。

- **metadata.group\_chat\_config** `object` 必选  
运行时动态传入的角色配置。
  - **metadata.group\_chat\_config.characters** `object[]` 必选  
群聊角色列表。
    - **metadata.group\_chat\_config.characters.name** `string` 必选  
群聊角色名称。
    - **metadata.group\_chat\_config.characters.system\_prompt** `string` 必选  
群聊角色设定，用于告知应用需要扮演的角色。

■ `metadata.group_chat_config.characters.model_desc` `object` 必选

模型说明。

■ `metadata.group_chat_config.characters.model_desc.endpoint_id` `string` 必选

您创建的[推理接入点](#) ID。

■ `metadata.group_chat_config.description` `string / null` 默认值 `null`

群聊场景描述，可设定群聊的主题、时间地点、事件场景、用户扮演的角色等信息。

■ `metadata.group_chat_config.user_name` `string / null` 默认值 用户

表示“我”所扮演的角色名称，默认值为“用户”。

◦ `metadata.user_info` `string / null` 默认值 `null`

可以被反序列化成 json 的字符串，需要包含 `city` 和 `district` 两个字段。

◦ `metadata.emit_intention_signal_extra` `string / null` 默认值 `"false"`

值是 `"true"` 时，会中途返回 intention 状态“正在搜索”。

◦ `metadata.target_character_name` `string / null` 默认值 `null`

群聊 Bot 对话时填写，指定本次要发言的角色名，必须是存在于 `characters` 里的角色。

• `references` `object[]`

本次请求中应用调用了插件的信息。字段参考具体见各个插件的数据结构。

◦ [联网插件](#)

◦ [知识库插件](#)

## 流式调用返回

• `id` `string`

本次请求的唯一标识。

• `model` `string`

本次请求实际使用的模型名称和版本。

doubao 1.5 代模型的模型名称格式为 `doubao-1-5-*`。如调用部署 `doubao-1.5-pro-32k 250115` 模型的推理接入点，返回 `model` 字段信息 `doubao-1-5-pro-32k-250115`。

• `created` `integer`

本次请求创建时间的 Unix 时间戳（秒）。

• `object` `string`

固定为 `chat.completion.chunk`。

• `choices` `object[]`

本次请求的模型输出内容。

◦ `choices.**index**` `integer`

当前元素在 `choices` 列表的索引。

◦ `choices.**finish_reason**` `string`

模型停止生成 token 的原因。取值范围：

■ `stop`：模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。

■ `length`：模型输出因达到模型输出限制而被截断，有下面几种原因：

■ 触发 `max_token` 限制（回答内容的长度限制）。

■ 触发 `max_completion_tokens` 限制（思维链内容+回答内容的长度限制）。

■ 触发 `context_window` 限制（输入内容+思维链内容+回答内容的长度限制）。

■ `content_filter`：模型输出被内容审核拦截。

■ `tool_calls`：模型调用了工具。



- `choices.**delta **` `object`  
模型输出的增量内容。
  - `choices.delta.**role **` `string`  
内容输出的角色，此处固定为 `assistant`。
  - `choices.delta.**content **` `string`  
模型生成的消息内容。
  - `choices.delta.**reasoning_content **` `string / null`  
模型处理问题的思维链内容。  
仅深度推理模型支持返回此字段，深度推理模型请参见[支持模型](#)。
  - `choices.delta.**tool_calls **` `object[] / null`  
模型调用的工具列表。
    - `choices.delta.tool_calls.**id **` `string`  
调用的工具的 ID。
    - `choices.delta.tool_calls.index` `integer`  
当前元素在模型调用的工具列表的索引。
    - `choices.delta.tool_calls.**type **` `string`  
工具类型，当前仅支持 `function`。
    - `choices.delta.tool_calls.**function **` `object`  
模型调用的函数。
      - `choices.delta.tool_calls.function.**name **` `string`  
模型调用的函数的名称。
      - `choices.delta.tool_calls.function.**arguments **` `string`  
模型生成的用于调用函数的参数，JSON 格式。  
模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效。
- `choices.**logprobs **` `object / null`  
当前内容的对数概率信息。
  - `choices.logprobs.**content **` `object[] / null`  
message列表中每个 `content` 元素中的 token 对数概率信息。
    - `choices.logprobs.content.**token **` `string`  
当前 token。
    - `choices.logprobs.content.**bytes **` `integer[] / null`  
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。
    - `choices.logprobs.content.**logprob **` `float`  
当前 token 的对数概率。
    - `choices.logprobs.content.**top_logprobs **` `object[]`  
在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 `top_logprobs` 指定的数量要少。
      - `choices.logprobs.content.top_logprobs.**token **` `string`  
当前 token。
      - `choices.logprobs.content.top_logprobs.**bytes **` `integer[] / null`  
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空。
      - `choices.logprobs.content.top_logprobs.**logprob **` `float`  
当前 token 的对数概率。



◦ `choices.**moderation_hit_type` `string/ null`

模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

返回值及含义：

■ `severe_violation`：模型输出文字涉及严重违规。

■ `violence`：模型输出文字涉及激进行为。

注意：当前只有[视觉理解模型](#)支持返回该字段，且只有在方舟控制台[接入点配置页面](#)或者 [CreateEndpoint](#) 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

· `bot_usage` `object`

本次请求的 token 用量。

◦ `bot_usage.**model_usage` `object[]`

本次请求不同 endpoint 的 token 消耗。

■ `bot_usage.model_usage.name` `string`

调用的模型 ID。

■ `bot_usage.model_usage.prompt_tokens` `integer`

输入的 prompt token 数量，包含用户输入的提示词和调用插件返回的信息。

■ `bot_usage.model_usage.completion_tokens` `integer`

模型生成的 token 数量。

■ `bot_usage.model_usage.total_tokens` `integer`

本次请求消耗的总 token 数量（输入 + 输出）。

◦ `action_usage` `object[]`

本次请求插件用量信息。

■ `action_usage.action_name` `string`

插件分类名称，如 `content_plugin`（内容插件）等。

■ `action_usage.count` `integer`

本次请求某插件分类插件总调用次数。

◦ `action_details` `object[]`

本次请求插件调用详情。

■ `action_details.name` `string`

插件分类名称，如 `content_plugin`（内容插件）等。

■ `action_details.count` `integer`

本次请求某插件分类中插件调用次数。

■ `action_details.tool_details` `object[]`

某插件分类中插件调用详细信息。

■ `action_details.tool_details.name` `string`

具体调用的工具名称。

■ `action_details.tool_details.input` `object`

插件输入参数，调用插件的数据结构。

■ `action_details.tool_details.output` `object`

插件输出结果，调用插件返回的数据结构。

■ `action_details.tool_details.created_at` `integer`

插件调用开始时间。

■ `action_details.tool_details.completed_at` `integer`

插件调用结束时间。

- **metadata** `object / null`

额外参数。

- **metadata.group\_chat\_config** `object` 必选

运行时动态传入的角色配置。

- **metadata.group\_chat\_config.characters** `object[]` 必选

群聊角色列表。

- **metadata.group\_chat\_config.characters.name** `string` 必选

群聊角色名称。

- **metadata.group\_chat\_config.characters.system\_prompt** `string` 必选

群聊角色设定，用于告知应用需要扮演的角色。

- **metadata.group\_chat\_config.characters.model\_desc** `object` 必选

模型说明。

- **metadata.group\_chat\_config.characters.model\_desc.endpoint\_id** `string` 必选

您创建的[推理接入点](#) ID。

- **metadata.group\_chat\_config.description** `string / null` 默认值 `null`

群聊场景描述，可设定群聊的主题、时间地点、事件场景、用户扮演的角色等信息。

- **metadata.group\_chat\_config.user\_name** `string / null` 默认值 `用户`

表示“我”所扮演的角色名称，默认值为“用户”。

- **metadata.user\_info** `string / null` 默认值 `null`

可以被反序列化成 json 的字符串，需要包含 `city` 和 `district` 两个字段。

- **metadata.emit\_intention\_signal\_extra** `string / null` 默认值 `"false"`

值是 `"true"` 时，会中途返回intention状态“正在搜索”。

- **metadata.target\_character\_name** `string / null` 默认值 `null`

群聊Bot对话时填写，指定本次要发言的角色名，必须是存在于 `characters` 里的角色。

- **references** `object[]`

本次请求中应用调用了插件的信息。字段参考具体见各个插件的数据结构。

- [联网插件](#)
  - [知识库插件](#)

## 10.2 联网插件 数据结构

联网插件返回的数据结构如下：

### SearchDocument

| 参数名称         | 类型                                   | 描述                                | 示例值  |
|--------------|--------------------------------------|-----------------------------------|------|
| site_name    | String                               | 站点名                               | 抖音百科 |
| summary      | String                               | 对该搜索结果的总结<br>部分文本                 | -    |
| publish_time | String                               | 发布时间                              | -    |
| title        | String                               | 标题<br><br>部分内容源的搜索结果含有该字段信息。      | -    |
| url          | String                               | 引用链接<br><br>部分内容源的搜索结果含有该字段信息。    | -    |
| logo_url     | String                               | logo链接<br><br>部分内容源的搜索结果含有该字段信息。  | -    |
| mobile_url   | String                               | 移动端引用链接<br><br>部分内容源的搜索结果含有该字段信息。 | -    |
| cover_image  | Object of <a href="#">CoverImage</a> | 封面图片                              | -    |

| 参数名称  | 类型                                     | 描述                          | 示例值 |
|-------|----------------------------------------|-----------------------------|-----|
|       |                                        | 部分内容源的搜索结果含有该字段信息。          |     |
| extra | Object of <a href="#">ExtraContent</a> | 非通用字段<br>部分内容源的搜索结果含有该字段信息。 | -   |

CoverImage

| 参数名称   | 类型      | 描述                          | 示例值 |
|--------|---------|-----------------------------|-----|
| url    | String  | 封面图链接<br>部分内容源的搜索结果含有该字段信息。 | -   |
| width  | Integer | 宽度                          | -   |
| height | Integer | 高度                          | -   |

ExtraContent

| 参数名称              | 类型                                        | 描述        | 示例值 |
|-------------------|-------------------------------------------|-----------|-----|
| weather_card_data | Object of <a href="#">WeatherCardData</a> | 天气相关的额外信息 | -   |

WeatherCardData

| 参数名称    | 类型                                               | 描述         | 示例值 |
|---------|--------------------------------------------------|------------|-----|
| display | Object of <a href="#">WeatherCardDataDisplay</a> | 天气卡片展示相关信息 | -   |

WeatherCardDataDisplay

| 参数名称                | 类型     | 描述             | 示例值 |
|---------------------|--------|----------------|-----|
| aqi                 | object | 当前时刻空气质量指数详细情况 | -   |
| aqiForecast         | object | 7日空气质量指数预报     | -   |
| aqiForecastHourly   | object | 7日每小时空气质量指数预报  | -   |
| aqi_url             | String | 空气质量指数url      | -   |
| city                | object | 城市信息           | -   |
| condition           | object | 当天天气情况         | -   |
| condition_url       | String | 当天天气情况url      | -   |
| seven_forecast_data | object | 近7日天气预报        | -   |

# 10.3 知识库插件 数据结构

知识库插件返回的数据结构如下：

## KnowledgeBaseChunk

| 参数名称            | 类型     | 描述                          | 示例值 |
|-----------------|--------|-----------------------------|-----|
| collection_name | String | Collection 名字               | .   |
| project         | String | Collection 所在的 project name | .   |
| doc_id          | String | 文档 id                       | .   |
| doc_name        | String | 文档名字                        | .   |
| doc_type        | String | 文档类型                        | .   |
| doc_title       | String | 文档标题                        | .   |
| chunk_id        | String | 分块 id                       | .   |
| chunk_title     | String | 分块标题                        | .   |

# 11. 批量推理 API

## 11.1 批量(Job) API

### 11.1.1 CreateBatchInferenceJob – 创建批量推理任务

创建批量推理任务。

为了避免异常情况下重复提交任务带来额外推理和计费，平台在创建批量推理任务时提供幂等控制：当用户、项目名（Project Name）、存储桶（bucket）和输入文件名（object-key）完全相同时，平台仅保留一个任务处于活跃状态（运行或排队），其他重复提交将报错，并在错误信息中包含在运行或排队中任务的ID，供用户查询。

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数          | 类型     | 是否必填 | 示例值                     | 描述                                                                                                |
|-------------|--------|------|-------------------------|---------------------------------------------------------------------------------------------------|
| Action      | String | 是    | CreateBatchInferenceJob | 要执行的操作，取值：CreateBatchInferenceJob。                                                                |
| Version     | String | 是    | 2024-01-01              | API的版本，取值：2024-01-01。                                                                             |
| ProjectName | String | 否    | my-project              | <ul style="list-style-type: none"><li>资源所属的项目名称，默认值为default。</li><li>若资源不在默认项目中，需填写正确的项</li></ul> |

| 参数                                                                                                       | 类型     | 是否必填 | 示例值                    | 描述                                                                |
|----------------------------------------------------------------------------------------------------------|--------|------|------------------------|-------------------------------------------------------------------|
|                                                                                                          |        |      |                        | 目名称，获取项目名称，请查看 <a href="#">文档</a> <a href="#">🔗</a> 。             |
| Name                                                                                                     | String | 是    | my-batch-Inference-job | 批量推理任务名称                                                          |
| Description                                                                                              | String | 否    | my-batch-Inference-job | 批量推理任务描述                                                          |
|  ModelReference       | Object | 是    | -                      | 批量推理任务选择的模型。CustomModelId（定制模型）、FoundationModel（基础模型），两个参数需要指定一个。 |
| CustomModelId                                                                                            | String | 否    |                        | 定制模型的ID                                                           |
|  FoundationModel      | Object | 否    |                        | 基础模型                                                              |
| Name                                                                                                     | String | 是    |                        | 基础模型名称                                                            |
| ModelVersion                                                                                             | String | 是    |                        | 基础模型版本                                                            |
|  InputFileTosLocation | Object | 是    | -                      | 批量推理输入的文件                                                         |
| ObjectKey                                                                                                | String | 是    |                        | TOS对象路径                                                           |



| 参数                                                                                                         | 类型              | 是否必填 | 示例值  | 描述                                                                                         |
|------------------------------------------------------------------------------------------------------------|-----------------|------|------|--------------------------------------------------------------------------------------------|
| Bucket Name                                                                                                | String          | 是    |      | TOS桶名称<br>在创建和选择 TOS 桶时<br>请注意，当前火山方舟<br>只支持 华北2-北京 地域<br>( region: cn-beijing ) 的<br>存储桶。 |
|  OutputDir<br>TosLocation | Object          | 是    | -    | 批量推理任务输出结果<br>的文件夹                                                                         |
| Object<br>Key                                                                                              | String          | 是    |      | TOS对象路径                                                                                    |
| Bucket<br>Name                                                                                             | String          | 是    |      | TOS桶名称<br>在创建和选择 TOS 桶时<br>请注意，当前火山方舟<br>只支持 华北2-北京 地域<br>( region: cn-beijing ) 的<br>存储桶。 |
| Completi<br>onWindow                                                                                       | String          | 否    | -    | 批量推理任务的最大等<br>待时间                                                                          |
|  Tags                   | Array of Object | 否    | -    | 批量推理任务绑定的标<br>签                                                                            |
| Key                                                                                                        | String          | 是    |      | 标签键                                                                                        |
| Value                                                                                                      | String          | 是    |      | 标签值                                                                                        |
| DryRun                                                                                                     | Boolean         | 否    | true |                                                                                            |

| 参数 | 类型 | 是否必填 | 示例值 | 描述                                                                                                             |
|----|----|------|-----|----------------------------------------------------------------------------------------------------------------|
|    |    |      |     | 是否仅对此请求进行预检。<br>取值： <ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求。</li></ul> |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值                   | 描述        |
|----|--------|-----------------------|-----------|
| Id | String | bi-20240918****-r2*** | 批量推理任务的Id |

请求示例

```
POST /?Action=CreateBatchInferenceJob&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T132743Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Name": "批量推理任务",
  "Description": "这是一个批量推理任务",
  "ModelReference": {
    "FoundationModel": {
      "Name": "doubao-pro-32k",
      "ModelVersion": "240615"
    }
  },
  "InputFileTosLocation": {
```

```
text  "BucketName": "my-bucket-name",
      "ObjectKey": "batch-inference-job/dataset/my-job.jsonl"
    },
    "OutputDirTosLocation": {
      "ObjectKey": "batch-inference-job/output/",
      "BucketName": "my-bucket-name"
    },
    "ProjectName": "default",
    "CompletionWindow": "1d",
    "Tags": [
      {
        "Key": "test_key",
        "Value": "test_value"
      }
    ]
  }
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20240918194640ECB302768CB287CEDAC6",
    "Action": "CreateBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "bi-2024091****-****"
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码             | 错误信息                                            | 说明                     |
|-----|-----------------|-------------------------------------------------|------------------------|
| 400 | DryRunOperation | The request is validated by a dryrun operation. | DryRun请求通过了全部检查，空运行成功。 |
| 400 |                 |                                                 |                        |

| 状态码 | 错误码                                      | 错误信息                                                                                  | 说明                                  |
|-----|------------------------------------------|---------------------------------------------------------------------------------------|-------------------------------------|
|     | InvalidParameter.<br>{{Parameter}}       | The specified parameter<br>{{Parameter}} is invalid.                                  | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。     |
| 403 | AccessDenied                             | You are not authorized<br>to perform this action.                                     | 请求未通过IAM权限验<br>证。                   |
| 403 | OperationDenied.InputFi<br>leTosLocation | Operation is denied<br>because the<br>InputFileTosLocation<br>specified is not found. |                                     |
| 500 | InternalError                            | The request has failed<br>due to an unknown<br>error.                                 | 未知错误，请稍后重<br>试。如果多次尝试仍失<br>败，请提交工单。 |

# 11.1.2 ListBatchInferenceJobs – 获取批量推理任务列表

获取批量推理任务列表

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型      | 是否必填 | 示例值                    | 描述                                                                                                                                                                                                                                     |
|-------------|---------|------|------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Action      | String  | 是    | ListBatchInferenceJobs | 要执行的操作，取值：ListBatchInferenceJobs。                                                                                                                                                                                                      |
| Version     | String  | 是    | 2024-01-01             | API的版本，取值：2024-01-01。                                                                                                                                                                                                                  |
| ProjectName | String  | 否    | default                | <ul style="list-style-type: none"><li>资源所属的项目名称，默认值为 <code>default</code>。</li><li>若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a> .</li></ul> |
| PageNumber  | Integer | 否    | -                      | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                                                                                                                                                |
| PageSize    | Integer | 否    | 10                     | 分页查询时每页显示的记录数，取值：- 最小                                                                                                                                                                                                                  |

| 参数                                                                                                       | 类型              | 是否必填 | 示例值        | 描述                                              |
|----------------------------------------------------------------------------------------------------------|-----------------|------|------------|-------------------------------------------------|
|                                                                                                          |                 |      |            | 值：1 – 最大值：100 – 默认值：10                          |
| SortOrder                                                                                                | String          | 否    | -          | 指定排序顺序。可指定值：- Asc：升序排列 - Desc: 降序排列             |
| SortBy                                                                                                   | String          | 否    | CreateTime | 指定排序指标。可指定值：* CreateTime：创建时间 * UpdateTime：更新时间 |
|  TagFilters            | Array of Object | 否    | -          | 基于绑定的标签的筛选条件                                    |
| Key                                                                                                      | String          | 是    |            | 标签键                                             |
| Values                                                                                                   | Array of String | 否    |            | 标签值                                             |
|  Filter               | Object          | 否    | -          | 带查询批量推理任务的筛选条件                                  |
| Ids                                                                                                      | Array of String | 否    |            | 指定批量推理任务的ID                                     |
| Name                                                                                                     | String          | 否    |            | 模糊搜索批量推理任务名称                                    |
|  Founda<br>tionModels | Array of Object | 否    |            | 基础模型                                            |
|                                                                                                          |                 |      |            |                                                 |

| 参数             | 类型              | 是否必填 | 示例值 | 描述              |
|----------------|-----------------|------|-----|-----------------|
| Name           | String          | 是    |     | 基础模型名称          |
| ModelVersions  | Array of String | 否    |     | 基础模型版本          |
| CustomModelIds | Array of String | 否    |     | 批量推理任务对应的定制模型ID |
| Phases         | Array of String | 否    |     | 指定批量推理任务的状态值    |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                        | 类型              | 示例值 | 描述                                          |
|-------------------------------------------------------------------------------------------|-----------------|-----|---------------------------------------------|
| TotalCount                                                                                | Integer         | -   | 批量推理任务数量                                    |
| PageNumber                                                                                | Integer         | 1   | 分页查询时的起始页码，从 1 开始，默认为 1。                    |
| PageSize                                                                                  | Integer         | 10  | 分页查询时每页显示的记录数，取值：- 最小值：1 - 最大值：100 - 默认值：10 |
|  Items | Array of Object | -   | 批量推理任务数组                                    |
| Id                                                                                        | String          |     | 批量推理任务的ID                                   |
| Name                                                                                      | String          |     |                                             |

| 参数                                                                                                       | 类型     | 示例值 | 描述                     |
|----------------------------------------------------------------------------------------------------------|--------|-----|------------------------|
|                                                                                                          |        |     | 批量推理任务名称               |
| Description                                                                                              | String |     | 批量推理任务描述               |
|  InputFileTosLocation   | Object |     | 批量推理任务传入的文件的TOS地址      |
| ObjectKey                                                                                                | String |     | TOS对象路径                |
| BucketName                                                                                               | String |     | TOS桶名称                 |
|  OutputDirTosLocation | Object |     | 批量推理任务的结果输出的TOS地址      |
| ObjectKey                                                                                                | String |     | TOS对象路径                |
| BucketName                                                                                               | String |     | TOS桶名称                 |
| CompletionWindow                                                                                         | String |     | 批量推理任务的最大等待时间          |
|  Status               | Object |     | 批量推理任务的状态元信息           |
| PhaseTime                                                                                                | String | -   | 批量推理任务状态更新时间，RFC3339格式 |
|                                                                                                          |        |     |                        |



| 参数                                                                                                   | 类型     | 示例值     | 描述                                                                                                                                                                                                                                                                                                                                                       |
|------------------------------------------------------------------------------------------------------|--------|---------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Message                                                                                              | String | -       | 批量推理任务状态信息                                                                                                                                                                                                                                                                                                                                               |
| Phase                                                                                                | String | Running | <p>批量推理任务的状态。</p> <ul style="list-style-type: none"><li>· "Queued": 任务排队中，任务由于账号下并发任务数达到上限等原因需排队等候。</li><li>· "Initializing": 任务初始化中。</li><li>· "Running": 任务运行中。</li><li>· "Terminating": 由于到期等系统原因或手动终止，任务当前处于取消中状态。</li><li>· "Terminated": 任务已被终止。</li><li>· "Completed": 任务已完成，所有请求已经处理完毕，任务已完成。</li><li>· "Failed": 输入文件校验失败或其他原因导致任务失败。</li></ul> |
|  ModelReference   | Object |         | 批量推理任务选中的模型                                                                                                                                                                                                                                                                                                                                              |
| CustomModelId                                                                                        | String |         | 定制模型的ID                                                                                                                                                                                                                                                                                                                                                  |
|  Foundation Model | Object |         | 基础模型                                                                                                                                                                                                                                                                                                                                                     |
| Name                                                                                                 | String |         | 基础模型名称。                                                                                                                                                                                                                                                                                                                                                  |

| 参数                                                                                              | 类型              | 示例值 | 描述                                                                                                                                                                       |
|-------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                                 |                 |     | <ul style="list-style-type: none"><li>· 请注意模型名称为小写。</li><li>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。</li></ul> |
| ModelVersion                                                                                    | String          |     | 基础模型版本                                                                                                                                                                   |
|  RequestCounts | Object          |     | 批量推理任务的request数量                                                                                                                                                         |
| Total                                                                                           | Long            | -   | 所有request数量                                                                                                                                                              |
| Completed                                                                                       | Long            | -   | 完成的request数量                                                                                                                                                             |
| Failed                                                                                          | Long            | -   | 失败的request数量                                                                                                                                                             |
|  Tags        | Array of Object |     | 批量推理任务绑定的标签                                                                                                                                                              |
| Key                                                                                             | String          |     | 标签键                                                                                                                                                                      |
| Value                                                                                           | String          |     | 标签值                                                                                                                                                                      |

| 参数          | 类型     | 示例值 | 描述                   |
|-------------|--------|-----|----------------------|
| CreateTime  | String |     | 批量推理任务创建时间，RFC3339格式 |
| UpdateTime  | String |     | 批量推理任务更新时间，RFC3339格式 |
| ProjectName | String |     | 项目名称                 |
| ExpireTime  | String |     | 批量推理任务到期时间，RFC3339格式 |

请求示例

```
{
  "ProjectName": "\\-",
  "PageNumber": 0,
  "PageSize": 10,
  "SortOrder": "\\-",
  "SortBy": "CreateTime",
  "TagFilters": [
    {
      "Key": "4e74ql",
      "Values": [
        "oEG"
      ]
    }
  ],
  "Filter": {
    "Ids": [
      "PhiQsNAH3Z"
    ],
    "Name": "Sy0pz",
    "FoundationModels": [
      {
        "Name": "jWyMB1c9ar",
        "ModelVersions": [
```

```
text    "I"  
  ]  
}  
],  
"CustomModelIds": [  
  "8iwBx"  
],  
"Phases": [  
  "f5yt"  
]  
}  
}
```

## 返回示例

```
{  
  "ResponseMetadata": {  
    "RequestId": "2024091819503335D2321703C1A3CCA381",  
    "Action": "ListBatchInferenceJobs",  
    "Version": "2024-01-01",  
    "Service": "ark",  
    "Region": "cn-beijing"  
  },  
  "Result": {  
    "TotalCount": 1,  
    "PageNumber": 1,  
    "PageSize": 10,  
    "Items": [  
      {  
        "Id": "bi-20240918194641-r2nwg",  
        "Name": "批量推理任务",  
        "Description": "这是一个批量推理任务",  
        "InputFileTosLocation": {  
          "BucketName": "my-bucket-name",  
          "ObjectKey": "batch-inference-job/dataset/my-job.jsonl"  
        },  
        "OutputDirTosLocation": {  
          "BucketName": "my-bucket-name",  
          "ObjectKey": "batch-inference-job/output/"  
        },  
        "CompletionWindow": "1d",  
        "Status": {  
          "Phase": "Completed",  
          "PhaseTime": "2024-09-18T11:50:00Z",  
        }  
      }  
    ]  
  }  
}
```

```
json    "Message": "批量推理任务已完成"
      },
      "ModelReference": {
        "FoundationModel": {
          "Name": "doubao-pro-32k",
          "ModelVersion": "240615"
        }
      },
      "RequestCounts": {
        "Total": 2,
        "Completed": 2,
        "Failed": 0
      },
      "Tags": [
        {
          "Key": "sys:ark:createdBy",
          "Value": "IAMUser/30805480/test@bytedance.com"
        },
        {
          "Key": "test_key",
          "Value": "test_value"
        }
      ],
      "ProjectName": "default",
      "CreateTime": "2024-09-18T11:46:41Z",
      "UpdateTime": "2024-09-18T11:50:00Z",
      "ExpireTime": "2024-09-19T11:46:41Z"
    }
  ]
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

### 11.1.3 GetBatchInferenceJob – 获取批量推理任务

获取批量推理任务

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                  | 描述                              |
|---------|--------|------|----------------------|---------------------------------|
| Action  | String | 是    | GetBatchInferenceJob | 要执行的操作，取值：GetBatchInferenceJob。 |
| Version | String | 是    | 2024-01-01           | API的版本，取值：2024-01-01。           |
| Id      | String | 是    | -                    | 批量推理任务的ID                       |

#### 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数          | 类型     | 示例值 | 描述        |
|-------------|--------|-----|-----------|
| Id          | String | -   | 批量推理任务的ID |
| Name        | String | -   | 批量推理任务名称  |
| Description | String | -   | 批量推理任务描述  |

| 参数                                                                                                       | 类型     | 示例值 | 描述                  |
|----------------------------------------------------------------------------------------------------------|--------|-----|---------------------|
|  InputFileTosLocation   | Object | -   | 批量推理任务传入的文件的TOS地址   |
| ObjectKey                                                                                                | String |     | TOS对象路径             |
| BucketName                                                                                               | String |     | TOS桶名称              |
|  OutputDirTosLocation   | Object | -   | 批量推理任务的结果输出的TOS地址   |
| ObjectKey                                                                                                | String |     | TOS对象路径             |
| BucketName                                                                                               | String |     | TOS桶名称              |
|  ErrorFileTosLocation | Object | -   | 批量推理任务输出的错误信息的TOS地址 |
| ObjectKey                                                                                                | String |     | TOS对象路径             |
| BucketName                                                                                               | String |     | TOS桶名称              |
| CompletionWindow                                                                                         | String | -   | 批量推理任务的最大等待时间       |
|  Status               | Object | -   | 批量推理任务的状态元信息        |
|                                                                                                          |        |     |                     |

| 参数                                                                                                 | 类型     | 示例值     | 描述                                                                                                                                                                                                                                                                                                                                                       |
|----------------------------------------------------------------------------------------------------|--------|---------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| PhaseTime                                                                                          | String | -       | 批量推理任务状态更新时间，RFC3339格式                                                                                                                                                                                                                                                                                                                                   |
| Message                                                                                            | String | -       | 批量推理任务状态信息                                                                                                                                                                                                                                                                                                                                               |
| Phase                                                                                              | String | Running | <p>批量推理任务的状态。</p> <ul style="list-style-type: none"><li>· "Queued": 任务排队中，任务由于账号下并发任务数达到上限等原因需排队等候。</li><li>· "Initializing": 任务初始化中。</li><li>· "Running": 任务运行中。</li><li>· "Terminating": 由于到期等系统原因或手动终止，任务当前处于取消中状态。</li><li>· "Terminated": 任务已被终止。</li><li>· "Completed": 任务已完成，所有请求已经处理完毕，任务已完成。</li><li>· "Failed": 输入文件校验失败或其他原因导致任务失败。</li></ul> |
|  ModelReference | Object | -       | 批量推理任务选中的模型                                                                                                                                                                                                                                                                                                                                              |
| CustomModelId                                                                                      | String |         | 定制模型的ID                                                                                                                                                                                                                                                                                                                                                  |
|                 | Object |         | 基础模型                                                                                                                                                                                                                                                                                                                                                     |



| 参数                                                                                                | 类型              | 示例值 | 描述                                                                                                                                         |
|---------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------------------------------------|
| FoundationModel                                                                                   |                 |     |                                                                                                                                            |
| Name                                                                                              | String          |     | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。 |
| ModelVersion                                                                                      | String          |     | 基础模型版本                                                                                                                                     |
|  RequestCounts | Object          | -   | 批量推理任务的request数量                                                                                                                           |
| Total                                                                                             | Long            | -   | 所有request数量                                                                                                                                |
| Completed                                                                                         | Long            | -   | 完成的request数量                                                                                                                               |
| Failed                                                                                            | Long            | -   | 失败的request数量                                                                                                                               |
|  Tags          | Array of Object | -   | 批量推理任务绑定的标签                                                                                                                                |
| Key                                                                                               | String          |     | 标签键                                                                                                                                        |

| 参数          | 类型     | 示例值 | 描述                   |
|-------------|--------|-----|----------------------|
| Value       | String |     | 标签值                  |
| ProjectName | String | -   | 资源所属的项目名称            |
| CreateTime  | String | -   | 批量推理任务创建时间，RFC3339格式 |
| UpdateTime  | String | -   | 批量推理任务更新时间，RFC3339格式 |
| ExpireTime  | String | -   | 批量推理任务到期时间，RFC3339格式 |

请求示例

```
text
{
  "Id": "7WtYtkPG9x"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "2024091910512025A35A851624E4541879",
    "Action": "GetBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "bi-20240918194641-r2nwq",
```

```
json  {"Name": "批量推理任务",
      "Description": "这是一个批量推理任务",
      "InputFileTosLocation": {
        "BucketName": "my-bucket-name",
        "ObjectKey": "batch-inference-job/dataset/my-job.jsonl"
      },
      "OutputDirTosLocation": {
        "BucketName": "my-bucket-name",
        "ObjectKey": "batch-inference-job/output/"
      },
      "CompletionWindow": "1d",
      "Status": {
        "Phase": "Completed",
        "PhaseTime": "2024-09-18T11:50:00Z",
        "Message": "批量推理任务已完成"
      },
      "ModelReference": {
        "FoundationModel": {
          "Name": "doubao-pro-32k",
          "ModelVersion": "240615"
        }
      },
      "RequestCounts": {
        "Total": 2,
        "Completed": 2,
        "Failed": 0
      },
      "Tags": [
        {
          "Key": "sys:ark:createdBy",
          "Value": "IAMUser/30805480/test@bytedance.com"
        },
        {
          "Key": "test_key",
          "Value": "test_value"
        }
      ],
      "ProjectName": "default",
      "CreateTime": "2024-09-18T11:46:41Z",
      "UpdateTime": "2024-09-18T11:50:00Z",
      "ExpireTime": "2024-09-19T11:46:41Z"
    }
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 11.1.4 UpdateBatchInferenceJob – 更新批量推理任务

更新批量推理任务1

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型      | 是否必填 | 示例值                     | 描述                                              |
|-------------|---------|------|-------------------------|-------------------------------------------------|
| Action      | String  | 是    | UpdateBatchInferenceJob | 要执行的操作，取值：UpdateBatchInferenceJob。              |
| Version     | String  | 是    | 2024-01-01              | API的版本，取值：2024-01-01。                           |
| Name        | String  | 否    | -                       | 批量推理任务名称                                        |
| Description | String  | 否    | -                       | 批量任务描述                                          |
| DryRun      | Boolean | 否    | true                    | 是否仅对此请求进行预检。取值：- true：发送检查请求。- false(默认)：发送正常请求 |
| Id          | String  | 是    | -                       | 批量推理任务的ID                                       |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#) [🔗](#)。

## 请求示例

text

```
{
  "Id": "jTcq2HdZCY",
  "Name": "2izb27TqbM",
  "Description": "lup3fM4Mu5",
  "DryRun": true
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "20241101204820216194191074D4638D",
    "Action": "UpdateBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 11.1.5 DeleteBatchInferenceJob – 删除批量推理任务

删除批量推理任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型      | 是否必填 | 示例值                     | 描述                                              |
|---------|---------|------|-------------------------|-------------------------------------------------|
| Action  | String  | 是    | DeleteBatchInferenceJob | 要执行的操作，取值：DeleteBatchInferenceJob。              |
| Version | String  | 是    | 2024-01-01              | API的版本，取值：2024-01-01。                           |
| DryRun  | Boolean | 否    | true                    | 是否仅对此请求进行预检。取值：- true：发送检查请求。- false(默认)：发送正常请求 |
| Id      | String  | 是    | bi-20240**-7q**         | 批量推理任务的ID                                       |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

## 请求示例

text

```
POST /?Action=DeleteBatchInferenceJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T094923Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "DryRun": true,
  "Id": "bi-20240**-7q**"
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "20250115174930217216139059A62D03",
    "Action": "DeleteBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 11.1.6 StopBatchInferenceJob – 停止批量推理任务

停止批量推理任务1

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型      | 是否必填 | 示例值                    | 描述                                                                                                                 |
|---------|---------|------|------------------------|--------------------------------------------------------------------------------------------------------------------|
| Action  | String  | 是    | StopBatchInferenceJob  | 要执行的操作，取值：StopBatchInferenceJob。                                                                                   |
| Version | String  | 是    | 2024-01-01             | API的版本，取值：2024-01-01。                                                                                              |
| Id      | String  | 是    | bi-202409181****-r2*** | 批量推理任务的ID                                                                                                          |
| DryRun  | Boolean | 否    | false                  | 是否仅对此请求进行预检。<br><br>取值： <ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求。</li></ul> |



## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

## 请求示例

text

```
POST /?Action=StopBatchInferenceJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241101T132518Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241101/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "WT8BOKFw"
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "202411012125322342121442116F88A9",
    "Action": "StopBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 11.1.7 ResumeBatchInferenceJob – 重启批量推理任务

重启批量推理任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                     | 描述                                 |
|---------|--------|------|-------------------------|------------------------------------|
| Action  | String | 是    | ResumeBatchInferenceJob | 要执行的操作，取值：ResumeBatchInferenceJob。 |
| Version | String | 是    | 2024-01-01              | API的版本，取值：2024-01-01。              |
| Id      | String | 是    | bi-2024**-**            | 批量推理任务 id                          |

## 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值          | 描述        |
|----|--------|--------------|-----------|
| Id | String | bi-2024**-** | 批量推理任务 id |

## 请求示例

text

```
POST /?Action=ResumeBatchInferenceJob&Version=2024-01-01&Id=bi-2024**-** HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T094652Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

{}

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "202501151747141031441900110C4B1C",
    "Action": "ResumeBatchInferenceJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "bi-2024**-**"
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 11.2 批量(Chat) API

POST <https://ark.cn-beijing.volces.com/api/v3/batch/chat/completions> [运行](#)

本文介绍批量推理调用模型服务的 API 的输入输出参数，供您使用接口时查阅字段含义。通过批量推理您可享受更高的限流配额以及实惠的价格，适合进行大批量数据处理时使用。

推荐的调用方式请见[示例代码](#)。

### 快速入口



[模型列表](#)



[模型计费](#)



[API Key](#)



[开通模型](#)



[调用教程](#)



[常见问题](#)

### 鉴权说明

本接口支持 API Key 与 Access Key 鉴权，详见[鉴权认证方式](#)。

### 请求参数

[跳转](#) [响应参数](#)

### 请求体

**model** `string` 必选

通过 Endpoint ID 来调用模型，可参考[获取 Endpoint ID](#)。

**messages** `object[]` 必选

到目前为止的对话组成的消息列表。不同模型支持不同类型的消息，如文本、图片、视频等。

**thinking** `object` 默认值 `{"type":"enabled"}`

控制模型是否开启深度思考模式。默认开启深度思考模式，可以手动关闭。

支持此字段的模型以及使用示例请参见[文档](#)。

**max\_tokens** `integer / null` 默认值 4096

模型回复最大长度（单位 token），取值范围各个模型不同，详细见[模型列表](#)。

输入 token 和输出 token 的总长度还受模型的上下文长度限制。

**max\_completion\_tokens** `integer / null`

支持该字段的模型 `doubao-seed-1-6-250615`，`doubao-seed-1-6-flash-250615`。

取值范围：`[0, 64k]`。

使用示例见[文档](#)。控制模型输出的最大长度（包括模型回答和模型思维链内容长度，单位 token）。配置了该参数后，可以让模型输出超长内容，**max\_tokens**（默认值 4k）与思维链最大长度将失效，模型按需输出内容，直到达到 **max\_completion\_tokens** 配置的值。

不可与 **max\_tokens** 字段同时设置，会直接报错。

**stop** `string / string[] / null` 默认值 `null`

模型遇到 **stop** 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。

[深度思考能力模型](#) 不支持该字段。

`["你好", "天气"]`

**frequency\_penalty** `float / null` 默认值 0

取值范围为 `[-2.0, 2.0]`。

频率惩罚系数。如果值为正，会根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。

**presence\_penalty** `float / null` 默认值 0

取值范围为 `[-2.0, 2.0]`。

存在惩罚系数。如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。

**temperature** `float / null` 默认值 1

取值范围为 `[0, 2]`。

采样温度。控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。

较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**top\_p** float / null 默认值 0.7

取值范围为 [0, 1]。

核采样概率阈值。模型会考虑概率质量在 top\_p 内的 token 结果。当取值为 0 时模型仅考虑对数概率最大的一个 token。

0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。通常建议仅调整 temperature 或 top\_p 其中之一，不建议两者都修改。

**logprobs** boolean / null 默认值 false

是否返回输出 tokens 的对数概率。

- **false** : 不返回对数概率信息。
- **true** : 返回消息内容中每个输出 token 的对数概率。

**top\_logprobs** integer / null 默认值 0

取值范围为 [0, 20]。

指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 **logprobs** 为 **true** 时可以设置 **top\_logprobs** 参数。

**logit\_bias** map / null 默认值 null

调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。**logit\_bias** 字段接受一个 map 值，其中每个键为词表中的 token ID（使用 tokenization 接口获取），每个值为该 token 的偏差值，取值范围为 [-100, 100]。

-1 会减少选择的可能性，1 会增加选择的可能性；-100 会完全禁止选择该 token，100 会导致仅可选择该 token。该参数的实际效果可能因模型而异。

```
{"<Token_ID>": -100}
```

**tools** object[] / null 默认值 null

待调用工具的列表，模型返回信息中可包含。当您需要让模型返回待调用工具时，需要配置该结构体。支持该字段的模型请参见[文档](#)。

## 响应参数

[跳转](#) [请求参数](#)

## 非流式调用返回

---

**id** `string`

本次请求的唯一标识。

---

**model** `string`

本次请求实际使用的模型名称和版本。

doubao 1.5 代模型的模型名称格式为 `doubao-1-5-*`。如调用部署 `doubao-1.5-pro-32k 250115` 模型的推理接入点，返回 `model` 字段信息 `doubao-1-5-pro-32k-250115`。

---

**service\_tier** `string`

本次请求是否使用了TPM保障包。

- `default` : 本次请求未使用TPM保障包额度。
- 

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

---

**object** `string`

固定为 `chat.completion` 。

---

**choices** `object[]`

本次请求的模型输出内容。

---

**usage** `object`

本次请求的 token 用量。

---

## 12. 管控面 API

### 12.1 管理推理接入点（Endpoint）

#### 12.1.1 StartEndpoint – 开启推理接入点

开启推理接入点

##### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

##### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值           | 描述                       |
|---------|--------|------|---------------|--------------------------|
| Action  | String | 是    | StartEndpoint | 要执行的操作，取值：StartEndpoint。 |
| Version | String | 是    | 2024-01-01    | API的版本，取值：2024-01-01。    |
| Id      | String | 是    | test-ep-id    | 模型接入ID                   |

##### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

##### 请求示例

```
POST /?Action=StartEndpoint&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
```



```
text
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T133330Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "test-ep-id"
}
```

## 返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "202405142133340440650771964D358D",
    "Action": "StartEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.1.2 StopEndpoint – 停止推理接入点

停止推理接入点

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值          | 描述                      |
|---------|--------|------|--------------|-------------------------|
| Action  | String | 是    | StopEndpoint | 要执行的操作，取值：StopEndpoint。 |
| Version | String | 是    | 2024-01-01   | API的版本，取值：2024-01-01。   |
| Id      | String | 是    | test-ep-id   | 模型接入ID                  |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

## 请求示例

```
POST /?Action=StopEndpoint&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T133401Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
text
{
  "Id": "test-ep-id"
}
```

## 返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20240514213405040224254042DAC9DB",
    "Action": "StopEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.1.3 ListEndpoints – 获取推理接入点列表

获取推理接入点列表

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型      | 是否必填 | 示例值           | 描述                                                                                                           |
|-------------|---------|------|---------------|--------------------------------------------------------------------------------------------------------------|
| Action      | String  | 是    | ListEndpoints | 要执行的操作，取值：ListEndpoints。                                                                                     |
| Version     | String  | 是    | 2024-01-01    | API的版本，取值：2024-01-01。                                                                                        |
| PageNumber  | Integer | 否    | 1             | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                      |
| PageSize    | Integer | 否    | 10            | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
| ProjectName | String  | 否    | default       | <ul style="list-style-type: none"><li>· 资源所属的项目名称，默认值为 <code>default</code>。</li></ul>                       |

| 参数                                                                                           | 类型              | 是否必填 | 示例值 | 描述                                                                        |
|----------------------------------------------------------------------------------------------|-----------------|------|-----|---------------------------------------------------------------------------|
|                                                                                              |                 |      |     | · 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看 <a href="#">文档</a> <a href="#">🔗</a> 。 |
|  TagFilters | Array of Object | 否    | -   | 基于绑定的标签的筛选条件                                                              |
| Key                                                                                          | String          | 是    |     | 标签键                                                                       |
| Values                                                                                       | Array of String | 否    |     | 标签值                                                                       |
|  Filter   | Object          | 否    | -   | 待查询接入点的筛选条件                                                               |
| EndpointModelTypes                                                                           | Array of String | 否    | -   | 接入模型类型，模型广场上的基础模型或模型仓库中的定制模型                                              |
| ModelVersions                                                                                | Array of String | 否    | -   | 模型版本                                                                      |
| CustomModelIds                                                                               | Array of String | 否    | -   | 定制模型的ID                                                                   |
| FoundationModelName                                                                          | String          | 否    | -   | 基础模型名称，模糊查询                                                               |
| Ids                                                                                          | Array of String | 否    | -   | 接入点的ID                                                                    |
| Name                                                                                         | String          | 否    |     |                                                                           |

| 参数                 | 类型              | 是否必填 | 示例值        | 描述                                                                                                                     |
|--------------------|-----------------|------|------------|------------------------------------------------------------------------------------------------------------------------|
|                    |                 |      | -          | 接入点名称，模糊查询                                                                                                             |
| Status             | Array of String | 否    | -          | 接入点状态。<br><br>· Running：运行中的接入点<br>· Stopped：停止的接入点<br>· Abnormal：异常的接入点<br>· Scheduling：调度中的接入点，往往在提交创建接入点任务后，接入点运行前。 |
| ServiceIds         | Array of String | 否    | -          | mlp服务Id列表                                                                                                              |
| ModelOrServiceName | String          | 否    | -          | 方舟模型名称或mlp服务名称                                                                                                         |
| Domain             | String          | 否    | Ark        | 接入点的类型。取值：<br>- Ark:方舟接入点，<br>- Mlp: mlp接入点。为空默认表示查询所有类型的接入点                                                           |
| SortBy             | String          | 否    | CreateTime | SortBy                                                                                                                 |
| SortOrder          | String          | 否    | Asc        | 指定排序顺序。可指定值：<br><br>· Asc：升序排列                                                                                         |

| 参数 | 类型 | 是否必填 | 示例值 | 描述                                                           |
|----|----|------|-----|--------------------------------------------------------------|
|    |    |      |     | <ul style="list-style-type: none"><li>· Desc: 降序排列</li></ul> |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                        | 类型              | 示例值 | 描述                                                                                                           |
|-------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------|
| TotalCount                                                                                | Integer         | 100 | 总接入点数                                                                                                        |
| PageNumber                                                                                | Integer         | 1   | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                      |
| PageSize                                                                                  | Integer         | 10  | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
|  Items | Array of Object | -   | 接入点信息                                                                                                        |
| RollingId                                                                                 | String          |     | 接入点切换的Id                                                                                                     |
| SupportRolling                                                                            | Boolean         |     | 是否支持接入点切换模型版本                                                                                                |
| Id                                                                                        | String          |     | 接入点的ID                                                                                                       |
| Name                                                                                      | String          |     | 接入点名称                                                                                                        |
|                                                                                           |                 |     |                                                                                                              |

| 参数                                                                                                 | 类型      | 示例值 | 描述                                                   |
|----------------------------------------------------------------------------------------------------|---------|-----|------------------------------------------------------|
| StatusReason                                                                                       | String  |     | 状态附加说明信息                                             |
|  RateLimit        | Object  |     | 接入点限流                                                |
| Tpm                                                                                                | Integer | -   | Tokens Per Minute，每分钟请求 token 数                      |
| Rpm                                                                                                | Integer | -   | Requests Per Minute，每分钟请求数                           |
| CreateTime                                                                                         | String  |     | 接入点创建时间，RFC3339格式                                    |
| UpdateTime                                                                                         | String  |     | 接入点更新时间，RFC3339格式                                    |
| Status                                                                                             | String  |     | 接入点状态                                                |
| ModelUnitId                                                                                        | String  |     | 模型单元                                                 |
| EndpointModel<br>Type                                                                              | String  |     | 接入点模型类型。取值：- FoundationModel：基础模型 - CustomModel：定制模型 |
|  ModelReference | Object  |     | 接入点接入模型                                              |
|                                                                                                    | String  |     | 定制模型的ID                                              |



| 参数                          | 类型              | 示例值 | 描述                                                                                                                                         |
|-----------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------------------------------------|
| CustomModelId               |                 |     |                                                                                                                                            |
| <div>Foundation Model</div> | Object          |     | 基础模型                                                                                                                                       |
| Name                        | String          |     | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。 |
| ModelVersion                | String          |     | 基础模型版本                                                                                                                                     |
| <div>Tags</div>             | Array of Object |     | 接入点绑定的标签                                                                                                                                   |
| Key                         | String          |     | 标签键                                                                                                                                        |
| Value                       | String          |     | 标签值                                                                                                                                        |
| ProjectName                 | String          |     | 项目名称                                                                                                                                       |
| Description                 | String          |     | 接入点描述                                                                                                                                      |

请求示例

text

```
{
  "PageNumber": 1,
  "PageSize": 10,
  "ProjectName": "default",
  "TagFilters": [
    {
      "Key": "SPVdl",
      "Values": [
        "4oQ"
      ]
    }
  ],
  "Filter": {
    "EndpointModelTypes": [
      "rhT"
    ],
    "Statuses": [
      "OM"
    ],
    "ModelVersions": [
      "gQVMJhca1P"
    ],
    "CustomModelIds": [
      "3938w"
    ],
    "FoundationModelName": "vnFbTbR1I",
    "Ids": [
      "592oblI5Rho"
    ],
    "Name": "0724147D"
  },
  "SortBy": "4",
  "SortOrder": "IC"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514213143172211079122D5C1C8",
    "Action": "ListEndpoints",
    "Version": "2024-01-01",
```

```
json {
  "Service": "ark",
  "Region": "cn-beijing"
},
"Result": {
  "TotalCount": 100,
  "PageNumber": 1,
  "PageSize": 10,
  "Items": [
    {
      "Id": "h3w92m",
      "Name": "TT7LbL8V",
      "Description": "eoxAtz8pb01",
      "ProjectName": "IvaqGj",
      "Tags": [
        {
          "Key": "X5b4S2EiYb",
          "Value": "EJUSY0fl"
        }
      ],
      "ModelReference": {
        "CustomModelId": "V0",
        "FoundationModel": {
          "Name": "i",
          "ModelVersion": "6vXDzwOuB7"
        }
      },
      "EndpointModelType": "glqecA",
      "ModelUnitId": "K",
      "Status": "mekO1h",
      "UpdateTime": "zmUtyY",
      "CreateTime": "oFBriqbTLII",
      "RateLimit": {
        "Rpm": 91,
        "Tpm": 712
      },
      "StatusReason": "fXFny6N"
    }
  ]
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.1.4 GetEndpoint – 获取推理接入点

获取推理接入点

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数      | 类型     | 是否必填 | 示例值         | 描述                     |
|---------|--------|------|-------------|------------------------|
| Action  | String | 是    | GetEndpoint | 要执行的操作，取值：GetEndpoint。 |
| Version | String | 是    | 2024-01-01  | API的版本，取值：2024-01-01。  |
| Id      | String | 是    | test-ep-id  | 模型接入的ID                |

### 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#) .

| 参数                                                                                             | 类型     | 示例值 | 描述                                                |
|------------------------------------------------------------------------------------------------|--------|-----|---------------------------------------------------|
|  Moderation | Object | -   | 内容护栏方案                                            |
| Strategy                                                                                       | String |     | 内容安全护栏方案。取值：<br>· Default: 默认方案。更低延迟，广泛覆盖内容安全通用需求 |

| 参数                                                                                                  | 类型     | 示例值             | 描述                                                                                                                                            |
|-----------------------------------------------------------------------------------------------------|--------|-----------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                                     |        |                 | <ul style="list-style-type: none"><li>Basic：基本方案（公测中）。支持在接口响应中提供命中的风险分类，暂时只包含严重违规和激进行为两类风险。注意：如果是流式接口调用，不建议此方案，会导致吐出的每个分片的长度变长，延时变高</li></ul> |
| CreateTime                                                                                          | String | -               | 接入点创建时间，RFC3339格式                                                                                                                             |
| Description                                                                                         | String | -               | 接入点描述                                                                                                                                         |
| EndpointModelType                                                                                   | String | FoundationModel | 接入点模型类型。取值： <ul style="list-style-type: none"><li>FoundationModel：基础模型</li><li>CustomModel：定制模型</li></ul>                                     |
| Id                                                                                                  | String | ep--            | 推理接入点的ID                                                                                                                                      |
|  ModelReference  | Object | -               | 接入点接入模型                                                                                                                                       |
| CustomModelId                                                                                       | String |                 | 定制模型的ID                                                                                                                                       |
|  FoundationModel | Object |                 | 基础模型                                                                                                                                          |
| Name                                                                                                | String |                 |                                                                                                                                               |

| 参数                                                                                            | 类型      | 示例值 | 描述                                                                                                                                         |
|-----------------------------------------------------------------------------------------------|---------|-----|--------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                               |         |     | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。 |
| ModelVersion                                                                                  | String  |     | 基础模型版本                                                                                                                                     |
| ModelUnitId                                                                                   | String  | -   | 模型单元                                                                                                                                       |
| Name                                                                                          | String  | -   | 接入点名称                                                                                                                                      |
| ProjectName                                                                                   | String  | -   | <br>· 资源所属的项目名称，默认值为default。<br><br>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看 <a href="#">文档</a> 。                                                |
|  RateLimit | Object  | -   | 接入点限流                                                                                                                                      |
| Tpm                                                                                           | Integer | -   | Tokens Per Minute，每分钟请求 token 数                                                                                                            |
| Rpm                                                                                           | Integer | -   | Requests Per Minute，每分钟请求数                                                                                                                 |

| 参数                                                                                     | 类型              | 示例值   | 描述                                                    |
|----------------------------------------------------------------------------------------|-----------------|-------|-------------------------------------------------------|
| Status                                                                                 | String          | -     | 接入点状态                                                 |
| StatusReason                                                                           | String          | -     | 状态附加说明信息                                              |
| SupportScaleTier                                                                       | Boolean         | false | 是否支持TPM保障包                                            |
|  Tags | Array of Object | -     | 接入点绑定的标签                                              |
| Key                                                                                    | String          |       | 标签键                                                   |
| Value                                                                                  | String          |       | 标签值                                                   |
| UpdateTime                                                                             | String          | -     | 接入点更新时间，RFC3339格式                                     |
| RollingId                                                                              | String          | -     | 接入点切换的Id                                              |
| ScaleTierId                                                                            | String          | -     | 如果存在 TPM 保障包，则为 TPM 保障包 ID                            |
| BatchOnly                                                                              | Boolean         | true  | 是否只支持 BatchChat。如果为true，只能访问 Batch 推理接口，否则只能访问在线推理接口。 |
| SupportRolling                                                                         | Boolean         | false | 是否支持接入点切换模型版本                                         |

| 参数 | 类型 | 示例值 | 描述 |
|----|----|-----|----|
|    |    |     |    |

请求示例

```
text

POST /?Action=GetEndpoint&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241231T111513Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241231/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "test-ep-id"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20241231191522021037040243127434",
    "Action": "GetEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "SupportRolling": false,
    "CreateTime": "ZFC",
    "Description": "4i2e8gPBufo",
    "EndpointModelType": "R3",
    "Id": "n9lt",
    "ModelReference": {
      "CustomModelId": "ok",
      "FoundationModel": {
        "Name": "JarKT21",
        "ModelVersion": "EQS"
      }
    },
    "ModelUnitId": "E",

```



```
json {"Name": "AGEWR",
      "ProjectName": "b0",
      "RateLimit": {
        "Rpm": 118,
        "Tpm": 251
      },
      "Status": "b22",
      "StatusReason": "IQ",
      "SupportScaleTier": false,
      "Tags": [
        {
          "Key": "oT0JUKb9G",
          "Value": "m9PYoDk7"
        }
      ],
      "UpdateTime": "FPPT",
      "RollingId": "gKU9eyRE",
      "ScaleTierId": "kJQWZk2DqL"
    }
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.1.5 DeleteEndpoint – 删除推理接入点

删除推理接入点

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值            | 描述                        |
|---------|--------|------|----------------|---------------------------|
| Action  | String | 是    | DeleteEndpoint | 要执行的操作，取值：DeleteEndpoint。 |
| Version | String | 是    | 2024-01-01     | API的版本，取值：2024-01-01。     |
| Id      | String | 是    | test-ep-id     | 模型接入ID                    |

### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

### 请求示例

```
POST /?Action=DeleteEndpoint&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T133213Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
text
{
  "Id": "test-ep-id"
}
```

## 返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20240514213217222022025159D49F9E",
    "Action": "DeleteEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.1.6 UpdateEndpoint – 更新推理接入点

更新推理接入点

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数                                                                                              | 类型              | 是否必填 | 示例值            | 描述                        |
|-------------------------------------------------------------------------------------------------|-----------------|------|----------------|---------------------------|
| Action                                                                                          | String          | 是    | UpdateEndpoint | 要执行的操作，取值：UpdateEndpoint。 |
| Version                                                                                         | String          | 是    | 2024-01-01     | API的版本，取值：2024-01-01。     |
|  Tags        | Array of Object | 否    | -              | 标签                        |
| Key                                                                                             | String          | 是    |                | 标签键                       |
| Value                                                                                           | String          | 是    |                | 标签值                       |
|  ServiceInfo | Object          | 否    | -              | mlp服务信息                   |
| Id                                                                                              | String          | 否    |                | mlp service的唯一Id          |
|                                                                                                 | String          | 否    |                | mlp的模型名称                  |

| 参数                                                                                           | 类型     | 是否必填 | 示例值             | 描述                                                                                                                                                                                                                |
|----------------------------------------------------------------------------------------------|--------|------|-----------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ModelName                                                                                    |        |      |                 |                                                                                                                                                                                                                   |
| Region                                                                                       | String | 否    |                 | mlp服务所在地域                                                                                                                                                                                                         |
| Service Name                                                                                 | String | 否    |                 | mlp服务名称                                                                                                                                                                                                           |
| Id                                                                                           | String | 是    | ep-id           | 模型接入的ID                                                                                                                                                                                                           |
| Name                                                                                         | String | 否    | testname        | 接入点名称                                                                                                                                                                                                             |
|  Moderation | Object | 否    | -               | 内容护栏方案                                                                                                                                                                                                            |
| Strategy                                                                                     | String | 是    |                 | 内容安全护栏方案。取值:<br><ul style="list-style-type: none"><li>· Default: 默认方案。更低延迟, 广泛覆盖内容安全通用需求</li><li>· Basic: 基本方案 (公测中)。支持在接口响应中提供命中的风险分类, 暂时只包含严重违规和激进行为两类风险。注意: 如果是流式接口调用, 不建议此方案, 会导致吐出的每个分片的长度变长, 延时变高</li></ul> |
| Description                                                                                  | String | 否    | testdescription | 接入点描述                                                                                                                                                                                                             |

| 参数                                                                                          | 类型      | 是否必填 | 示例值 | 描述                              |
|---------------------------------------------------------------------------------------------|---------|------|-----|---------------------------------|
|  RateLimit | Object  | 否    | -   | 接入点限流                           |
| Tpm                                                                                         | Integer | 是    |     | Tokens Per Minute，每分钟请求 token 数 |
| Rpm                                                                                         | Integer | 是    |     | Requests Per Minute，每分钟请求数      |

返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

请求示例

```
text
POST /?Action=UpdateEndpoint&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T133257Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "ep-id",
  "Name": "testname",
  "Description": "testdescription",
  "RateLimit": {
    "Rpm": 111,
    "Tpm": 237
  }
}
```

返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "20240514213302095012180018DD91C7",
    "Action": "UpdateEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.1.7 CreateEndpoint – 创建推理接入点

创建推理接入点

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数                                                                                              | 类型     | 是否必填 | 示例值            | 描述                                        |
|-------------------------------------------------------------------------------------------------|--------|------|----------------|-------------------------------------------|
| Action                                                                                          | String | 是    | CreateEndpoint | 要执行的操作，取值：CreateEndpoint。                 |
| Version                                                                                         | String | 是    | 2024-01-01     | API的版本，取值：2024-01-01。                     |
|  ServiceInfo | Object | 否    | -              | mlp服务信息，若创建MLP接入点，ServiceInfo的Id和Region必填 |
| Id                                                                                              | String | 否    |                | mlp service的唯一Id                          |
| Model Name                                                                                      | String | 否    |                | mlp的模型名称                                  |
| Region                                                                                          | String | 否    |                | mlp服务所在地域                                 |
| Service Name                                                                                    | String | 否    |                | mlp服务名称                                   |



| 参数                                                                                                  | 类型     | 是否必填 | 示例值             | 描述                                                                                                                                                                                   |
|-----------------------------------------------------------------------------------------------------|--------|------|-----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Domain                                                                                              | String | 否    | Ark             | 创建接入点的类型。取值：<br><ul style="list-style-type: none"><li>Ark:方舟接入点，</li><li>Mlp: mlp接入点。为空默认表示方舟接入点</li></ul>                                                                           |
| Name                                                                                                | String | 是    | testname        | 接入点名称                                                                                                                                                                                |
| Description                                                                                         | String | 否    | TestDescription | 接入点描述                                                                                                                                                                                |
|  ModelReference  | Object | 是    | -               | 接入点接入模型                                                                                                                                                                              |
| CustomModelId                                                                                       | String | 否    |                 | 定制模型的ID                                                                                                                                                                              |
|  FoundationModel | Object | 否    |                 | 基础模型                                                                                                                                                                                 |
| Name                                                                                                | String | 是    |                 | 基础模型名称。<br><ul style="list-style-type: none"><li>· 请注意模型名称为小写。</li><li>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。举例： "Doubao-1.5-pro-32k" 模型Name 字段为 "doubao-1-5-pro-32k"。</li></ul> |
|                                                                                                     | String | 是    |                 |                                                                                                                                                                                      |

| 参数                                                                                            | 类型              | 是否必填 | 示例值     | 描述                                                                                                                                                                                                                            |
|-----------------------------------------------------------------------------------------------|-----------------|------|---------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ModelVersion                                                                                  |                 |      |         | 基础模型版本                                                                                                                                                                                                                        |
| ModelUnitId                                                                                   | String          | 否    | -       | 模型单元，为空表示后付费；否则预付费                                                                                                                                                                                                            |
|  Tags        | Array of Object | 否    | -       | 接入点绑定的标签                                                                                                                                                                                                                      |
| Key                                                                                           | String          | 是    |         | 标签键                                                                                                                                                                                                                           |
| Value                                                                                         | String          | 是    |         | 标签值                                                                                                                                                                                                                           |
| ProjectName                                                                                   | String          | 否    | default | <ul style="list-style-type: none"><li>· 资源所属的项目名称，默认值为 default。</li><li>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a> .</li></ul> |
| DryRun                                                                                        | Boolean         | 否    | true    | <p>是否仅对此请求进行预检。取值：</p> <ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求</li></ul>                                                                                                              |
|  RateLimit | Object          | 否    | -       | 接入点限流                                                                                                                                                                                                                         |
| Tpm                                                                                           | Integer         | 是    | -       | Tokens Per Minute，每分钟请求 token 数                                                                                                                                                                                               |

| 参数                                                                                           | 类型      | 是否必填 | 示例值 | 描述                                                                                                                                                                                                            |
|----------------------------------------------------------------------------------------------|---------|------|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Rpm                                                                                          | Integer | 是    | -   | Requests Per Minute, 每分钟请求数                                                                                                                                                                                   |
|  Moderation | Object  | 否    | -   | 内容护栏方案                                                                                                                                                                                                        |
| Strategy                                                                                     | String  | 是    |     | 内容安全护栏方案。取值: <ul style="list-style-type: none"><li>· Default: 默认方案。更低延迟, 广泛覆盖内容安全通用需求</li><li>· Basic: 基本方案(公测中)。支持在接口响应中提供命中的风险分类, 暂时只包含严重违规和激进行为两类风险。注意: 如果是流式接口调用, 不建议此方案, 会导致吐出的每个分片的长度变长, 延时变高</li></ul> |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值        | 描述     |
|----|--------|------------|--------|
| Id | String | ep-test-id | 接入点的ID |

请求示例

```
{
  "Name": "testname",
```

```
text
{
  "Description": "TestDescription",
  "ModelReference": {
    "CustomModelId": "SxU71Q1t",
    "FoundationModel": {
      "Name": "yzcHNZMJ736",
      "ModelVersion": "4Rh90omlqN"
    }
  },
  "ModelUnitId": "\\-",
  "Tags": [
    {
      "Key": "B",
      "Value": "3ScqC"
    }
  ],
  "ProjectName": "default",
  "DryRun": true,
  "RateLimit": {
    "Rpm": 651,
    "Tpm": 798
  }
}
```

## 返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20240514212750152186163065FE5A2A",
    "Action": "CreateEndpoint",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "ep-test-id"
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.1.8 GetEndpointCertificate – 获取接入点推理应用层加密证书

获取接入点推理应用层加密证书

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                    | 描述                                |
|---------|--------|------|------------------------|-----------------------------------|
| Action  | String | 是    | GetEndpointCertificate | 要执行的操作，取值：GetEndpointCertificate。 |
| Version | String | 是    | 2024-01-01             | API的版本，取值：2024-01-01。             |
| Id      | String | 是    | ep-****-****           | endpoint ID                       |

## 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数      | 类型     | 示例值                    | 描述   |
|---------|--------|------------------------|------|
| PCAHost | String | Volcano Engine PCA     | 证书方  |
| PCAName | String | MaaS Crypto SDK Online | 证书名称 |

| 参数                     | 类型     | 示例值        | 描述                        |
|------------------------|--------|------------|---------------------------|
| PCAInstanceCertificate | String | -          | PEM 格式的叶子证书               |
| PCASubCACertificate    | String | -          | PEM 格式的中间根证书和根证书          |
| PCARootCACertificate   | String | -          | PEM 格式的根证书                |
| NotAfter               | Long   | 1679673599 | X509私有证书过期的时间。使用秒级时间戳表示   |
| NotBefore              | Long   | 1678794684 | X509私有证书开始生效的时间。使用秒级时间戳表示 |

请求示例

```
text
POST /?Action=GetEndpointCertificate&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240925T074408Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240925/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "ep-20240522022935-4pwju"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "2024092515442219622214919971137B",
    "Action": "GetEndpointCertificate",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "PCAHost": "Volcano Engine PCA",
    "PCAName": "MaaS Crypto SDK Online",
    "PCAInstanceCertificate": "-----BEGIN CERTIFICATE-----\nMIICxjC-----END CERTIFICATE-----\n",
    "PCASubCACertificate": "-----BEGIN CERTIFICATE-----\nMIIDCDDCAq-----END CERTIFICATE-----\n",
    "PCARootCACertificate": "-----BEGIN CERTIFICATE-----\nMIIDCzCCArCgA-----END CERTIFICATE-----\n",
    "NotAfter": 1679673599,
    "NotBefore": 1678794684
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                    | 错误信息                                                             | 说明                          |
|-----|------------------------|------------------------------------------------------------------|-----------------------------|
| 404 | NotFound.{{Parameter}} | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalServerError    | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

# 12.1.9 InnerDescribeModelEndpoints – 查询模型预置接入点列表

查询模型预置接入点列表

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: InnerDescribeModelEndpoints  
要执行的操作，取值: InnerDescribeModelEndpoints。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值: 2024-01-01。

**Filter** object 可选 示例值: \-  
过滤条件。用于按模型 ID 或基础模型名称过滤模型预置接入点。格式如下：

```
json
{
  "ModelIds": ["doubao-seed-1-6"],
  "FuzzyModelId": "doubao",
  "FuzzyFoundationModelName": "Doubao",
  "FoundationModelNames": ["Doubao-embedding"]
}
```

**ModelIds** string[] 可选  
模型 ID 列表。

**FoundationModelNames** string[] 可选  
模型名称列表。

**FuzzyModelId** string 可选  
模型 ID 关键字。用于按模型 ID 进行模糊匹配。

**FuzzyFoundationModelName** string 可选  
基础模型名称关键字。用于按基础模型名称进行模糊匹配。



**ProjectName** string 可选 示例值: default  
项目名称。默认值为 default。

**PageSize** integer 可选 示例值: 10  
分页查询时每页显示的记录数，取值：

- 最小值：1
- 最大值：100
- 默认值：10

**PageNumber** integer 可选 示例值: 1  
分页查询时的起始页码，从 1 开始。默认值： 1 。

**SortOrder** string 可选 示例值: Asc  
排序方向。可选值：

- Asc （默认）：升序排列
- Desc ：降序排列

**SortBy** string %%require%% 示例值: \-  
排序依据字段。

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Items** object[] 示例值: \-  
预置接入点信息列表。

**Id** string  
预置接入点 ID

**ProjectName** string  
项目名称

**Name** string  
预置接入点名称

**ModelId** string  
模型 ID

**ModelReference** object  
模型信息

**CustomModelId** string  
定制模型的 ID

**FoundationModel** object  
基础模型

**Name** string  
基础模型名称

**ModelVersion** string  
基础模型版本

**EndpointModelType** string  
接入点类型

**Status** string  
接入点状态

**CreateTime** string  
创建时间

**UpdateTime** string  
更新时间

**WatermarkInfo** object  
水印信息

**SubjectName** string  
水印主体名称

**SocialUnifiedCreditCode** string  
统一社会信用代码

**IsContentDissemination** float  
是否允许内容传播

**NeedWatermark** boolean  
是否存在水印

**ContentGeneration** object  
生视频模型限流信息

**ConcurrentRequests** long  
并发请求数限制

**CreateTaskRpm** long  
每分钟创建任务数限制

**Moderation** object  
审核信息

**Strategy** string  
内容安全护栏方案。取值:

- **Default** (默认): 更低延迟, 广泛覆盖内容安全通用需求
- **Basic**: 基本方案(公测中)。支持在接口响应中提供命中的风险分类, 暂时只包含严重违规和激进行为两类风险。

**注意**

流式调用场景下不建议使用 **Basic**, 否则可能导致响应延迟升高。

**RateLimit** object

模型限流信息

**RPM** integer

每分钟处理请求数

**TPM** integer

每分钟处理内容量

**TokenWindow** object[]

Token限流配置

**DurationSeconds** integer

限流时间窗口长度，单位为秒

**Token** integer

当前时间窗口内允许使用的 Token 上限

**TotalCount** integer 示例值：100

预置接入点总数。

**PageNumber** integer 示例值：1

分页查询时的起始页码，从 1 开始。默认值： 1 。

**PageSize** integer 示例值：10

分页查询时每页显示的记录数。

## 请求示例

```
text
{
  "PageNumber": 1,
  "PageSize": 10,
  "Filter": {
    "FoundationModelNames": [
      "Doubao-embedding"
    ]
  }
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20260108111702F7BC756C045F9E686A40",
  }
}
```

```
json  {"Action": "InnerDescribeModelEndpoints",
      "Version": "2024-01-01",
      "Service": "ark_boe",
      "Region": "cn-beijing"
    },
    "Result": {
      "TotalCount": 0,
      "PageNumber": 1,
      "PageSize": 10,
      "Items": []
    }
  }
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.2 管理API Key

### 12.2.1 GetApiKey – 获取临时API Key

获取临时API Key，用于在有效期内指定推理接入点、智能体等资源的调用的鉴权

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: GetApiKey

要执行的操作，取值: GetApiKey。

**Version** string %%require%% 示例值: 2024-01-01

API的版本，取值: 2024-01-01。

**DurationSeconds** integer %%require%% 示例值: 86400

token有效期 单位是s，允许范围0-30d(2592000s)

**ProjectName** string 可选 示例值: \-

项目名称。当 **ResourceType** 取值为 **presetendpoint** 时，本参数必填

**ResourceType** string %%require%% 示例值: endpoint

资源类型，取值范围

- endpoint** : 模型推理接入点
- bot** : 智能体
- presetendpoint** : 预置推理接入点

**ResourceIds** string[] %%require%% 示例值: ["ep-\\*\\*\\*-\*\\*", "ep-\\*\\*\\*-\*\\*"]

**ResourceType**字段指定的资源的ID列表

- endpoint id: 可在“方舟控制台 > 推理”模块获取。
- bot id: 可在“方舟控制台 > 我的应用”获取。

#### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**ExpiredTime** integer 示例值: \-

Apikey过期时间，RFC3339格式

**ApiKey string** 示例值: \-  
ApiKey

## 请求示例

text

```
POST /?Action=GetApiKey&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250108T072336Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250108/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "DurationSeconds": 86400,
  "ResourceType": "endpoint",
  "ResourceIds": [
    ["ep-***\","ep-***\"]
  ]
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "20250108152350029189016106C67393",
    "Action": "GetApiKey",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "ExpiredTime": 0,
    "ApiKey": "*****_*****"
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                       | 说明                              |
|-----|------------------------------------|------------------------------------------------------------|---------------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified<br>parameter<br>{{Parameter}} is<br>invalid. | 请求参数值不合法。<br>请检查参数值的正确<br>性后重试。 |

## 12.3 管理模型调优任务

### 12.3.1 TerminateModelCustomizationJob – 停止模型调优任务

停止模型调优任务

#### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                            | 描述                                        |
|---------|--------|------|--------------------------------|-------------------------------------------|
| Action  | String | 是    | TerminateModelCustomizationJob | 要执行的操作，取值：TerminateModelCustomizationJob。 |
| Version | String | 是    | 2024-01-01                     | API的版本，取值：2024-01-01。                     |
| Id      | String | 是    | -                              | 待更新的模型调优任务的ID                             |

#### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

#### 请求示例



text

```
POST /?Action=TerminateModelCustomizationJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T083642Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "Id": "\\-"
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "202501151637080932522361157D1536",
    "Action": "TerminateModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.3.2 GetModelCustomizationJob – 获取模型调优任务信息

获取模型训练任务信息

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                      | 描述                                  |
|---------|--------|------|--------------------------|-------------------------------------|
| Action  | String | 是    | GetModelCustomizationJob | 要执行的操作，取值：GetModelCustomizationJob。 |
| Version | String | 是    | 2024-01-01               | API的版本，取值：2024-01-01。               |
| Id      | String | 是    | mcj-test-id              | 模型调优任务的ID                           |

## 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                | 类型     | 示例值                  | 描述      |
|-------------------|--------|----------------------|---------|
| CreateTime        | String | 2024-01-01T00:00:00Z | 资源创建时间戳 |
| CustomizationType | String | FinetuneLoRA         |         |

| 参数                                | 类型     | 示例值                                                                                                                                                                                                                                                                                                                                                                      | 描述                                                                    |
|-----------------------------------|--------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------|
|                                   |        |                                                                                                                                                                                                                                                                                                                                                                          | 训练类型，取值范围：<br>FinetuneSft,<br>FinetuneLoRA, Pretrain,<br>DPOLoRA, DPO |
| <div><div></div>Data</div>        | Object | <pre>{   "TrainingSet": {     "TosBucket": "ark- auto-created- required-210000000 0-cn-beijing",     "TosPaths": [       "model- customization-job- upload-set/ 1712561985763/ test.jsonl"     ]   },   "EncryptionKeyringT ype":     "ManagedKeyring",   "KMSTrn":     "trn:kms:cn-beijing: 2100000000:keyring s/datapipe_keyring/ keys/ datapipe_key_ml_ma as" }</pre> | 模型微调使用的数据集                                                            |
| <div><div></div>TrainingSet</div> | Object |                                                                                                                                                                                                                                                                                                                                                                          | 训练数据集                                                                 |
| PresetData                        | String |                                                                                                                                                                                                                                                                                                                                                                          | 预置数据集名称，不填不<br>适用预置数据集                                                |

| 参数                                                                                               | 类型              | 示例值 | 描述                                                  |
|--------------------------------------------------------------------------------------------------|-----------------|-----|-----------------------------------------------------|
| PresetDataPercentage                                                                             | Integer         |     | 预置数据集使用百分比（0-100），仅在填写了PresetData时有效                |
|  PresetDatasets | Array of Object |     | 预置数据集列表                                             |
| DatasetVersionId                                                                                 | String          |     | 预置数据集版本                                             |
| InjectMultiplier                                                                                 | Double          |     | 预置数据集混入倍率                                           |
| InjectSampleCount                                                                                | Long            |     | 预置数据集混入的样本数                                         |
|  Datasets     | Array of Object |     | 数据集列表，当此字段不为空时表示使用数据集数据训练。不可与TosBucket，TosPaths同时存在 |
| DatasetId                                                                                        | String          |     | 数据集ID                                               |
| DatasetVersionId                                                                                 | String          |     | 数据集版本ID                                             |
| Multiplier                                                                                       | Double          |     | 采样倍率                                                |
| SampleCount                                                                                      | Long            |     | 采样的样本数                                              |
| TosBucket                                                                                        | String          |     |                                                     |

| 参数                                                                                               | 类型              | 示例值 | 描述                                                                      |
|--------------------------------------------------------------------------------------------------|-----------------|-----|-------------------------------------------------------------------------|
|                                                                                                  |                 |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训练，不可与 Datasets 同时存在。    |
| TosPaths                                                                                         | Array of String |     | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训练，不可与 Datasets 同时存在。 |
|  ValidationSet | Object          |     | 验证数据集                                                                   |
|  Datasets     | Array of Object |     | 数据集列表                                                                   |
| DatasetId                                                                                        | String          |     | 数据集ID                                                                   |
| DatasetVersionId                                                                                 | String          |     | 数据集版本ID                                                                 |
| Multiplier                                                                                       | Double          |     | 采样倍率                                                                    |
| SampleCount                                                                                      | Long            |     | 采样的样本数                                                                  |
| TosBucket                                                                                        | String          |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。      |

| 参数                                                                                                  | 类型              | 示例值                                                             | 描述                                                                                            |
|-----------------------------------------------------------------------------------------------------|-----------------|-----------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| TosPaths                                                                                            | Array of String |                                                                 | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。                         |
| ValidationPercentage                                                                                | Integer         |                                                                 | 使用训练集数据作为验证集的比例（0-100）                                                                        |
| KMSTrn                                                                                              | String          |                                                                 | 加密密钥TRN，可在 KMS 中获取。当 EncryptionKeyringType为 ManagedKeyring(默认情况) 会自动生成不可填写。为CustomKeyring则必填。 |
| EncryptionKeyringType                                                                               | String          | ManagedKeyring                                                  | 加密密钥类型，默认为 ManagedKeyring。取值范围：ManagedKeyring,Custom Keyring                                  |
| Id                                                                                                  | String          | mcj-20240101000000-a1b2c                                        | 模型精调任务资源 ID                                                                                   |
|  Hyperparameters | Array of Object | <pre>[ {   "Name": "epoch",   "Value": "6" }, {   "Name":</pre> | 微调配置的超参数                                                                                      |

| 参数                                                                                                  | 类型     | 示例值                                                                                                                                                              | 描述                           |
|-----------------------------------------------------------------------------------------------------|--------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
|                                                                                                     |        | "learning_rate",<br>"Value": "0.00001"<br>}}                                                                                                                     |                              |
| Name                                                                                                | String |                                                                                                                                                                  | 超参数的参数名                      |
| Value                                                                                               | String |                                                                                                                                                                  | 超参数的参数值                      |
| Description                                                                                         | String | 这是一个测试任务                                                                                                                                                         | 模型调优任务描述                     |
|  ModelReference  | Object | {<br>"FoundationModel":<br>{<br>"Name": "doubao-<br>lite-4k",<br>"ModelVersion":<br>"240328",<br>"ConfigurationId":<br>"fmvc-20240101000<br>000-a1b2c"<br>}<br>} | 微调基于的模型                      |
| CustomModelId                                                                                       | String |                                                                                                                                                                  | 定制模型的ID                      |
|  FoundationModel | Object |                                                                                                                                                                  | 基础模型                         |
| Name                                                                                                | String |                                                                                                                                                                  | 基础模型名称。<br><br>· 请注意模型名称为小写。 |

| 参数                            | 类型              | 示例值                                                                                                                                                                                                                                                                                                                                                              | 描述                                                                                                                                               |
|-------------------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
|                               |                 |                                                                                                                                                                                                                                                                                                                                                                  | <ul style="list-style-type: none"><li>doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。</li></ul> |
| ModelVersion                  | String          |                                                                                                                                                                                                                                                                                                                                                                  | 基础模型版本                                                                                                                                           |
| <div><div></div>Outputs</div> | Array of Object | <pre>[ {   "Index": 0,   "Name":     "global_step_1",   "CreateTime":     "2024-01-01T12:57:08Z",   "Status": "Available" }, {   "Index": 1,   "CustomModelId":     "cm-20240913210309-xc8rz",   "CustomModelCreateTime":     "2024-09-13T13:03:09Z",   "Name":     "global_step_2",   "CreateTime":     "2024-01-01T12:57:28Z",   "Status": "Exported" }]</pre> | 模型精调产物列表                                                                                                                                         |
|                               |                 |                                                                                                                                                                                                                                                                                                                                                                  |                                                                                                                                                  |



| 参数                                                                                         | 类型      | 示例值                                           | 描述                                              |
|--------------------------------------------------------------------------------------------|---------|-----------------------------------------------|-------------------------------------------------|
| Index                                                                                      | Integer |                                               | 索引                                              |
| CustomModelId                                                                              | String  |                                               | 自定义模型 id                                        |
| CustomModelCreateTimeUnix                                                                  | Long    |                                               | 自定义模型创建时间                                       |
| Name                                                                                       | String  |                                               | 模型产物名称                                          |
| Status                                                                                     | String  |                                               | 模型产物状态                                          |
| ProjectName                                                                                | String  | default                                       | 项目名                                             |
| Name                                                                                       | String  | 测试任务                                          | 模型精调任务名称                                        |
| PublishedOutputCount                                                                       | Integer | 1                                             | 已发布模型精调任务产物数量                                   |
| Reason                                                                                     | String  | InvalidData                                   | 任务失败原因，有 InvalidData,InternalError,UnknownError |
| SaveModelLimit                                                                             | Integer | 1                                             | SaveModel 数量的最大限制                               |
|  Status | Object  | {<br>"Phase":<br>"Completed",<br>"PhaseTime": | 模型精调任务状态                                        |

| 参数                | 类型      | 示例值                                                                                                                                                                                                                 | 描述                    |
|-------------------|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|
|                   |         | "2024-01-01T00:00:00Z",<br>"RetryCount": 0,<br>"OutputExpiredTime":<br>:<br>"2024-01-01T13:03:09Z",<br>"Resumable": false,<br>"RetryLimit": 3,<br>"TrainingTokensPerEpoch": 41422,<br>"BillableTokens": 414220<br>} |                       |
| PhaseTime         | String  |                                                                                                                                                                                                                     | 模型微调任务进入到当前状态的时间戳     |
| QueuePosition     | Integer |                                                                                                                                                                                                                     | 排队时，模型微调任务在所属队列中的当前位次 |
| RetryCount        | Integer |                                                                                                                                                                                                                     | 模型微调任务已经失败重试的次数       |
| Message           | String  |                                                                                                                                                                                                                     | 对当前模型微调任务所处状态的解释性信息   |
| OutputExpiredTime | String  |                                                                                                                                                                                                                     | 模型微调产物（如果有）计划过期的时间戳   |
| Resumable         | Boolean |                                                                                                                                                                                                                     | 任务处于失败状态时，是否可以被重试     |

| 参数                                                                                       | 类型              | 示例值                                                                                                               | 描述                        |
|------------------------------------------------------------------------------------------|-----------------|-------------------------------------------------------------------------------------------------------------------|---------------------------|
| RetryLimit                                                                               | Integer         |                                                                                                                   | 模型精调任务可以被重试的次数上限          |
| TrainingTokens<br>PerEpoch                                                               | Long            |                                                                                                                   | 数据集总tokens，包括训练集、验证集和混入数据 |
| BillableTokens                                                                           | Long            |                                                                                                                   | 训练tokens量，用于精调任务计费        |
| Phase                                                                                    | String          | Preprocessing,Queued,Deploying,Running,Completing,Completed,Terminating,Terminated,Failed                         | 模型微调任务状态                  |
|  Tags | Array of Object | [<br>{<br>"Key":<br>"sys:ark:createdBy",<br>"Value": "IAMUser/<br>23454321/<br>test.user@bytedance.<br>com"<br>}] | 标签                        |
| Key                                                                                      | String          |                                                                                                                   | 标签键                       |
| Value                                                                                    | String          |                                                                                                                   | 标签值                       |
| TotalOutputCount                                                                         | Integer         | 1                                                                                                                 | 模型精调产物总数                  |

| 参数         | 类型     | 示例值                  | 描述      |
|------------|--------|----------------------|---------|
| UpdateTime | String | 2024-01-01T00:00:00Z | 资源更新时间戳 |

请求示例

```
text

POST /?Action=GetModelCustomizationJob&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T035622Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "mcj-20240101000000-a1b2cr"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "2025011511564424916310121745440A",
    "Action": "GetModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "CreateTime": "2024-01-01T00:00:00Z",
    "CustomizationType": "FinetuneLoRA",
    "Data": {
      "TrainingSet": {
        "TosBucket": "ark-auto-2100466578-ap-southeast-1-default",
        "TosPaths": [
          "model-customization-job-training-set/1740646772293/train_5k.jsonl"
        ]
      }
    }
  }
}
```

```
json {
  "EncryptionKeyringType": "ManagedKeyring",
  "KMSTrn": "trn:kms:cn-beijing:2100466578:keyrings/managed_ark_keyring/keys/
modelcustomization"
},
  "Id": "mcj-20240101000000-a1b2c",
  "Hyperparameters": [{
    "Name": "epoch",
    "Value": "1"
  }],
  "Description": "这是一个测试任务",
  "ModelReference": {
    "FoundationModel": {
      "Name": "doubao-pro-32k",
      "ModelVersion": "240828"
    }
  },
  "Outputs": [{
    "Index": 1,
    "Name": "global_step_1",
    "Status": "Exported"
  }],
  "ProjectName": "default",
  "Name": "测试任务",
  "PublishedOutputCount": 1,
  "Reason": "",
  "SaveModelLimit": 1,
  "Status": {
    "Phase": "Completed",
    "PhaseTime": "2024-01-04T07:04:29Z",
    "RetryLimit": 1
  },
  "Tags": [{
    "Key": "sys:ark:createdBy",
    "Value": "IAMUser/123/zhangsan"
  }],
  "TotalOutputCount": 1,
  "UpdateTime": "2024-01-01T00:00:00Z"
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码 | 错误信息 | 说明 |
|-----|-----|------|----|
|     |     |      |    |

| 状态码 | 错误码                                | 错误信息                                                                      | 说明                                  |
|-----|------------------------------------|---------------------------------------------------------------------------|-------------------------------------|
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter<br>{{Parameter}} is missing.                       | 缺少必要的请求参数。<br>请确认请求参数后重<br>试。       |
| 404 | NotFound.{{Parameter}}             | The specified<br>{{ResourceType}}<br>{{ResourceContent}} is<br>not found. | 指定资源找不到。请确<br>认参数后重试。               |
| 500 | InternalServerError                | The request has failed<br>due to an unknown<br>error.                     | 未知错误，请稍后重<br>试。如果多次尝试仍失<br>败，请提交工单。 |

# 12.3.3 CreateModelCustomizationJob – 创建模型调优任务

创建模型调优任务

调试

## API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数                                                                                              | 类型      | 是否必填 | 示例值                         | 描述                                     |
|-------------------------------------------------------------------------------------------------|---------|------|-----------------------------|----------------------------------------|
| Action                                                                                          | String  | 是    | CreateModelCustomizationJob | 要执行的操作，取值：CreateModelCustomizationJob。 |
| Version                                                                                         | String  | 是    | 2024-01-01                  | API的版本，取值：2024-01-01。                  |
|  Data        | Object  | 是    | -                           | 模型微调数据集                                |
|  TrainingSet | Object  | 是    |                             | 训练数据集                                  |
| PresetData                                                                                      | String  | 否    |                             | 预置数据集名称，不填不适用预置数据集                     |
| PresetDataPercentage                                                                            | Integer | 否    |                             | 预置数据集使用百分比（0-100），仅在填写了PresetData时有效   |

| 参数                                        | 类型              | 是否必填 | 示例值 | 描述                                                    |
|-------------------------------------------|-----------------|------|-----|-------------------------------------------------------|
| <div><div></div>Prese<br/>tDatasets</div> | Array of Object | 否    |     | 预置数据集列表                                               |
| <div>D<br/>atasetVersion<br/>Id</div>     | String          | 是    |     | 预置数据集版本                                               |
| <div>Inj<br/>ectMultiplier</div>          | Double          | 否    |     | 预置数据集混入倍率                                             |
| <div>Inj<br/>ectSampleCo<br/>unt</div>    | Long            | 否    |     | 预置数据集混入的样本数                                           |
| <div><div></div>Data<br/>sets</div>       | Array of Object | 否    |     | 数据集列表，当此字段不为空时表示使用数据集数据训练。不可与 TosBucket，TosPaths 同时存在 |
| <div>D<br/>atasetId</div>                 | String          | 是    |     | 数据集ID                                                 |
| <div>D<br/>atasetVersion<br/>Id</div>     | String          | 是    |     | 数据集版本ID                                               |
| <div>M<br/>ultiplier</div>                | Double          | 否    |     | 采样倍率                                                  |
| <div>Sa<br/>mpleCount</div>               | Long            | 否    |     | 采样的样本数                                                |
| <div>TosB<br/>ucket</div>                 | String          | 否    |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训      |



| 参数               | 类型              | 是否必填 | 示例值 | 描述                                                                      |
|------------------|-----------------|------|-----|-------------------------------------------------------------------------|
|                  |                 |      |     | 练，不可与 Datasets 同时存在。                                                    |
| TosPaths         | Array of String | 否    |     | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训练，不可与 Datasets 同时存在。 |
| ValidationSet    | Object          | 否    |     | 验证数据集                                                                   |
| Datasets         | Array of Object | 否    |     | 数据集列表                                                                   |
| DatasetId        | String          | 是    |     | 数据集ID                                                                   |
| DatasetVersionId | String          | 是    |     | 数据集版本ID                                                                 |
| Multiplier       | Double          | 否    |     | 采样倍率                                                                    |
| SampleCount      | Long            | 否    |     | 采样的样本数                                                                  |
| TosBucket        | String          | 否    |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。      |
|                  | Array of String | 否    |     |                                                                         |

| 参数                                                                                                  | 类型      | 是否必填 | 示例值            | 描述                                                                                           |
|-----------------------------------------------------------------------------------------------------|---------|------|----------------|----------------------------------------------------------------------------------------------|
| TosPaths                                                                                            |         |      |                | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。                        |
| ValidationPercentage                                                                                | Integer | 否    |                | 使用训练集数据作为验证集的比例（0-100）                                                                       |
| KMSTrn                                                                                              | String  | 否    |                | 加密密钥TRN，可在 KMS 中获取。当 EncryptionKeyringType 为ManagedKeyring(默认情况)会自动生成不可填写。为CustomKeyring则必填。 |
| EncryptionKeyringType                                                                               | String  | 否    | ManagedKeyring | 加密密钥类型，默认为ManagedKeyring。取值范围：ManagedKeyring,CustomKeyring                                   |
|  ModelReference  | Object  | 是    | -              | 微调基于的模型，必须在定制模型和基座模型中二选一                                                                     |
| CustomModelId                                                                                       | String  | 否    |                | 定制模型的ID                                                                                      |
|  FoundationModel | Object  | 否    |                | 基础模型                                                                                         |
|                                                                                                     |         |      |                |                                                                                              |

| 参数                                                                                                  | 类型              | 是否必填 | 示例值             | 描述                                                                                                                                          |
|-----------------------------------------------------------------------------------------------------|-----------------|------|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| ModelVersion                                                                                        | String          | 是    |                 | 基础模型版本                                                                                                                                      |
| Name                                                                                                | String          | 是    |                 | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name 字段为 "doubao-1-5-pro-32k"。 |
|  Hyperparameters | Array of Object | 是    | -               | 训练超参配置。超参数组中每一项的 Name 不能重复。                                                                                                                 |
| Name                                                                                                | String          | 是    |                 | 超参数的参数名                                                                                                                                     |
| Value                                                                                               | String          | 是    |                 | 超参数的参数值                                                                                                                                     |
| Name                                                                                                | String          | 是    | TestName        | 模型调优任务名称                                                                                                                                    |
| Description                                                                                         | String          | 否    | TestDescription | 模型调优任务描述                                                                                                                                    |
| ProjectName                                                                                         | String          | 否    | default         | 项目名                                                                                                                                         |
| CustomizationType                                                                                   | String          | 是    | FinetuneSft     |                                                                                                                                             |

| 参数                                                                                     | 类型              | 是否必填 | 示例值 | 描述                                                                                     |
|----------------------------------------------------------------------------------------|-----------------|------|-----|----------------------------------------------------------------------------------------|
|                                                                                        |                 |      |     | 训练类型，取值范围：FinetuneSft（全量 SFT）、FinetuneLoRA（SFT-LoRA）、Pretrain（继续预训练）、DPOLoRA（DPO-LoRA） |
|  Tags | Array of Object | 否    | -   | 标签信息配置                                                                                 |
| Key                                                                                    | String          | 是    |     | 标签键                                                                                    |
| Value                                                                                  | String          | 是    |     | 标签值                                                                                    |
| SaveModelLimit                                                                         | Integer         | 否    | 1   | SaveModel 数量的最大限制                                                                      |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值         | 描述             |
|----|--------|-------------|----------------|
| Id | String | mcj-test-id | 创建好的模型调优任务的 ID |

请求示例

```
{
  "Name": "测试任务",
  "Description": "这是一个测试任务",
  "Tags": [
    {
```

```
text    "Key": "test_key",
        "Value": "test_value"
      }
    ],
    "ProjectName": "default",
    "CustomizationType": "FinetuneLoRA",
    "ModelReference": {
      "FoundationModel": {
        "Name": "skylark2-lite-8k",
        "ModelVersion": "1.0"
      }
    },
    "Hyperparameters": [
      {
        "Name": "epoch",
        "Value": "6"
      },
      {
        "Name": "learning_rate",
        "Value": "0.00001"
      }
    ],
    "SaveModelLimit": 1,
    "Data": {
      "TrainingSet": {
        "TosBucket": "ark-auto-created-required-2100000000-cn-beijing",
        "TosPaths": [
          "model-customization-job-upload-set/1712561985763/test.jsonl"
        ]
      }
    }
  }
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240101000000046C7CCC3CCCE87016E3",
    "Action": "CreateModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
```

```
json {
  "Id": "mcj-20240101000000-a1b2c"
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                         | 错误信息                                                                                                                                 | 说明                                           |
|-----|---------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------|
| 400 | MissingParameter.<br>{{Parameter}}          | The required parameter<br>{{Parameter}} is missing.                                                                                  | 缺少必要的请求参数。<br>请确认请求参数后重试。                    |
| 400 | InvalidParameter.<br>{{Parameter}}          | The specified parameter<br>{{Parameter}} is invalid.                                                                                 | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。              |
| 400 | Duplicate.Tags.Key                          | The specified object of<br>tags contains duplicate<br>keys.                                                                          | 对象的标签存在重复<br>Key。                            |
| 403 | OperationDenied.Conflic<br>tedValidationSet | Operation is denied<br>because it is not<br>supported to configure<br>ValidationSet and<br>ValidationPercentage at<br>the same time. | 无法同时上传验证集和<br>设置训练集取样为验证<br>集百分比，不支持该操<br>作。 |
| 403 | OperationDenied.Permis<br>sionDenied        | Operation is denied<br>because You are not<br>permitted to access the<br>specified configuration<br>of the FoundationModel.          | 您没有权限访问基础模<br>型的配置，不支持该操<br>作。               |
| 403 |                                             |                                                                                                                                      |                                              |

| 状态码 | 错误码                                          | 错误信息                                                                                                                                                                                                             | 说明                                         |
|-----|----------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------|
|     | OperationDenied.UnsupportedCustomizationType | Operation is denied because The specified CustomizationType is not supported by the CustomModel.                                                                                                                 | 模型不支持该训练方法，不支持该操作。                         |
| 403 | OperationDenied.CustomizationNotSupported    | Operation is denied because The specified version of the FoundationModel is not configured for the specified type of customization.                                                                              | 基础模型的版本不支持该训练方法，不支持该操作。                    |
| 403 | OperationDenied.ServiceNotOpen               | Operation is denied because The model service is unavailable, please go to the Volcano Ark console activation management page to activate the corresponding model service, or submit a work order to contact us. | 模型服务不可用，不支持该操作。请前往火山方舟控制台激活模型服务，或提交工单联系我们。 |
| 403 | OperationDenied.ServiceOverdue               | Operation is denied because Your account balance is overdue, please go to the Volcano Trading Center to recharge in order to continue using the service.                                                         | 您的账单已逾期，不支持该操作。请前往火山费用中心充值。                |
| 500 | InternalServerError                          |                                                                                                                                                                                                                  |                                            |

| 状态码 | 错误码 | 错误信息                                            | 说明                          |
|-----|-----|-------------------------------------------------|-----------------------------|
|     |     | The request has failed due to an unknown error. | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |



# 12.3.4 ListModelCustomizationJobs – 获取模型调优任务列表

获取模型调优任务列表

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数                                                                                         | 类型      | 是否必填 | 示例值                        | 描述                                    |
|--------------------------------------------------------------------------------------------|---------|------|----------------------------|---------------------------------------|
| Action                                                                                     | String  | 是    | ListModelCustomizationJobs | 要执行的操作，取值：ListModelCustomizationJobs。 |
| Version                                                                                    | String  | 是    | 2024-01-01                 | API的版本，取值：2024-01-01。                 |
| PageNumber                                                                                 | Integer | 否    | 1                          | 翻页页数                                  |
| PageSize                                                                                   | Integer | 否    | 1                          | 翻页大小                                  |
| SortBy                                                                                     | String  | 否    | CreateTime                 | 排序字段                                  |
| SortOrder                                                                                  | String  | 否    | Desc                       | 排序顺序（倒序或顺序）                           |
|  Filter | Object  | 否    |                            |                                       |

| 参数                                                                                                 | 类型              | 是否必填 | 示例值 | 描述                                           |
|----------------------------------------------------------------------------------------------------|-----------------|------|-----|----------------------------------------------|
|                                                                                                    |                 |      | -   | 模型调优任务过滤条件                                   |
| Ids                                                                                                | Array of String | 否    |     | ID 过滤条件                                      |
| Name                                                                                               | String          | 否    |     | 模型调优任务名过滤条件（模糊匹配）                            |
|  FoundationModels | Array of Object | 否    |     | 基座模型过滤条件                                     |
| Name                                                                                               | String          | 是    |     | 基础模型名称                                       |
| ModelVersions                                                                                      | Array of String | 否    |     | 基础模型版本                                       |
| CustomModelIds                                                                                     | Array of String | 否    |     | 定制模型 ID 过滤条件                                 |
| Phases                                                                                             | Array of String | 否    |     | 模型调优任务状态过滤条件                                 |
| CreateTimeBefore                                                                                   | String          | 否    |     | 创建时间过滤条件，格式为 RFC3339 时间戳，过滤创建时间早于该时间戳的模型调优任务 |
| CreateTimeAfter                                                                                    | String          | 否    |     | 创建时间过滤条件，格式为 RFC3339 时间戳，过滤创建时间晚于该时间戳的模型调优任务 |
|                                                                                                    |                 |      |     |                                              |

| 参数                                                                                           | 类型              | 是否必填 | 示例值     | 描述                                                                                                                                  |
|----------------------------------------------------------------------------------------------|-----------------|------|---------|-------------------------------------------------------------------------------------------------------------------------------------|
| CustomizationTypes                                                                           | Array of String | 否    |         | 调优类型过滤条件                                                                                                                            |
| ProjectName                                                                                  | String          | 否    | default | <ul style="list-style-type: none"><li>资源所属的项目名称，默认值为 default。</li><li>若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a>。</li></ul> |
|  TagFilters | Array of Object | 否    | -       | 按 Tag 过滤                                                                                                                            |
| Key                                                                                          | String          | 是    |         | 标签键                                                                                                                                 |
| Values                                                                                       | Array of String | 否    |         | 标签值                                                                                                                                 |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                        | 类型              | 示例值 | 描述              |
|-------------------------------------------------------------------------------------------|-----------------|-----|-----------------|
| TotalCount                                                                                | Integer         | 10  | 符合查询条件的对象的总数    |
| PageNumber                                                                                | Integer         | 1   | 请求时的 PageNumber |
| PageSize                                                                                  | Integer         | 10  | 请求时的 PageSize   |
|  Items | Array of Object | -   | 查询结果            |
|                                                                                           |                 |     |                 |

| 参数                                                                                                   | 类型              | 示例值 | 描述                                                                                                                 |
|------------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------------|
| Description                                                                                          | String          |     | 模型调优任务描述                                                                                                           |
| ProjectName                                                                                          | String          |     | 项目名                                                                                                                |
| SaveModelLimit                                                                                       | Integer         |     | SaveModel 数量的最大限制                                                                                                  |
|  Tags               | Array of Object |     | 标签                                                                                                                 |
| Key                                                                                                  | String          |     | 标签键                                                                                                                |
| Value                                                                                                | String          |     | 标签值                                                                                                                |
|  ModelReference   | Object          |     | 微调基于的模型                                                                                                            |
| CustomModelId                                                                                        | String          |     | 定制模型的ID                                                                                                            |
|  Foundation Model | Object          |     | 基础模型                                                                                                               |
| Name                                                                                                 | String          |     | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字 |

| 参数                                                                                                | 类型              | 示例值 | 描述                                   |
|---------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------|
|                                                                                                   |                 |     | 段为 "doubao-1-5-pro-32k"。             |
| ModelVersion                                                                                      | String          |     | 基础模型版本                               |
|  Hyperparameters | Array of Object |     | 微调配置的超参数                             |
| Name                                                                                              | String          |     | 超参数的参数名                              |
| Value                                                                                             | String          |     | 超参数的参数值                              |
| CreateTime                                                                                        | String          |     | 资源创建时间戳                              |
| UpdateTime                                                                                        | String          |     | 资源更新时间戳                              |
|  Data          | Object          |     | 模型微调使用的数据集                           |
|  TrainingSet   | Object          |     | 训练数据集                                |
| PresetData                                                                                        | String          |     | 预置数据集名称，不填不适用预置数据集                   |
| PresetDataPercentage                                                                              | Integer         |     | 预置数据集使用百分比（0-100），仅在填写了PresetData时有效 |

| 参数                                         |           | 类型              | 示例值 | 描述                                                                   |
|--------------------------------------------|-----------|-----------------|-----|----------------------------------------------------------------------|
| <div><div></div><div>assets</div></div>    | PresetDat | Array of Object |     | 预置数据集列表                                                              |
| <div><div></div><div>VersionId</div></div> | Dataset   | String          |     | 预置数据集版本                                                              |
| <div><div></div><div>ultiplier</div></div> | InjectM   | Double          |     | 预置数据集混入倍率                                                            |
| <div><div></div><div>mpleCount</div></div> | InjectSa  | Long            |     | 预置数据集混入的样本数                                                          |
| <div><div></div><div></div></div>          | Datasets  | Array of Object |     | 数据集列表，当此字段不为空时表示使用数据集数据训练。不可与 TosBucket，TosPaths 同时存在                |
| <div><div></div><div>Id</div></div>        | Dataset   | String          |     | 数据集ID                                                                |
| <div><div></div><div>VersionId</div></div> | Dataset   | String          |     | 数据集版本ID                                                              |
| <div><div></div><div>er</div></div>        | Multipli  | Double          |     | 采样倍率                                                                 |
| <div><div></div><div>Count</div></div>     | Sample    | Long            |     | 采样的样本数                                                               |
| <div><div></div><div></div></div>          | TosBucket | String          |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训练，不可与 Datasets 同时存在。 |
|                                            |           |                 |     |                                                                      |

| 参数                                                                                              | 类型              | 示例值 | 描述                                                                      |
|-------------------------------------------------------------------------------------------------|-----------------|-----|-------------------------------------------------------------------------|
| TosPaths                                                                                        | Array of String |     | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据训练，不可与 Datasets 同时存在。 |
|  ValidationSet | Object          |     | 验证数据集                                                                   |
|  Datasets      | Array of Object |     | 数据集列表                                                                   |
| IdDataset                                                                                       | String          |     | 数据集ID                                                                   |
| VersionIdDataset                                                                                | String          |     | 数据集版本ID                                                                 |
| Multiplier                                                                                      | Double          |     | 采样倍率                                                                    |
| CountSample                                                                                     | Long            |     | 采样的样本数                                                                  |
| TosBucket                                                                                       | String          |     | TOS 桶名，需与 TosPaths 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。      |
| TosPaths                                                                                        | Array of String |     | TOS 存储路径，需与 TosBucket 同时存在，当此字段不为空时表示使用直接使用 TOS 数据，不可与 Datasets 同时存在。   |

| 参数                                                                                         | 类型      | 示例值            | 描述                                                                                            |
|--------------------------------------------------------------------------------------------|---------|----------------|-----------------------------------------------------------------------------------------------|
| ValidationPercentage                                                                       | Integer |                | 使用训练集数据作为验证集的比例（0-100）                                                                        |
| KMSTrn                                                                                     | String  |                | 加密密钥TRN，可在 KMS 中获取。当 EncryptionKeyringType为 ManagedKeyring(默认情况) 会自动生成不可填写。为CustomKeyring则必填。 |
| EncryptionKeyringType                                                                      | String  | ManagedKeyring | 加密密钥类型，默认为 ManagedKeyring。取值范围：ManagedKeyring,Custom Keyring                                  |
|  Status | Object  |                | 模型精调任务状态                                                                                      |
| PhaseTime                                                                                  | String  |                | 模型微调任务进入到当前状态的时间戳                                                                             |
| QueuePosition                                                                              | Integer |                | 排队时，模型微调任务在所属队列中的当前位次                                                                         |
| RetryCount                                                                                 | Integer |                | 模型微调任务已经失败重试的次数                                                                               |



| 参数                     | 类型      | 示例值                                                                                       | 描述                                             |
|------------------------|---------|-------------------------------------------------------------------------------------------|------------------------------------------------|
| Message                | String  |                                                                                           | 对当前模型微调任务所处状态的解释性信息                            |
| OutputExpiredTime      | String  |                                                                                           | 模型微调产物（如果有）计划过期的时间戳                            |
| Resumable              | Boolean |                                                                                           | 任务处于失败状态时，是否可以被重试                              |
| RetryLimit             | Integer |                                                                                           | 模型精调任务可以被重试的次数上限                               |
| TrainingTokensPerEpoch | Long    |                                                                                           | 数据集总tokens，包括训练集、验证集和混入数据                      |
| BillableTokens         | Long    |                                                                                           | 训练tokens量，用于精调任务计费                             |
| Phase                  | String  | Preprocessing,Queued,Deploying,Running,Completing,Completed,Terminating,Terminated,Failed | 模型微调任务状态                                       |
| Reason                 | String  |                                                                                           | 任务失败原因，有InvalidData,InternalError,UnknownError |
| Name                   | String  |                                                                                           | 模型精调任务名称                                       |

| 参数                                                                                        | 类型              | 示例值 | 描述                                                                   |
|-------------------------------------------------------------------------------------------|-----------------|-----|----------------------------------------------------------------------|
| Id                                                                                        | String          |     | 模型精调任务资源 ID                                                          |
| PublishedOutputCount                                                                      | Integer         |     | 已发布模型精调任务产物数量                                                        |
| TotalOutputCount                                                                          | Integer         |     | 模型精调产物总数                                                             |
|  Outputs | Array of Object |     | 模型精调产物列表                                                             |
| Index                                                                                     | Integer         |     | 索引                                                                   |
| CustomModelId                                                                             | String          |     | 自定义模型 id                                                             |
| CustomModelCreateTimeUnix                                                                 | Long            |     | 自定义模型创建时间                                                            |
| Name                                                                                      | String          |     | 模型产物名称                                                               |
| Status                                                                                    | String          |     | 模型产物状态                                                               |
| CustomizationType                                                                         | String          |     | 训练类型，取值范围：<br>FinetuneSft，<br>FinetuneLoRA，<br>Pretrain，DPOLoRA, DPO |

请求示例

text

```
{
  "PageNumber": 1,
  "PageSize": 10,
  "ProjectName": "default",
  "TagFilters": [
    {
      "Key": "sys:ark:createdBy",
      "Values": ["IAMUser/23454321/test.user@bytedance.com"]
    }
  ],
  "Filter": {
    "Ids": ["mcj-20240101000000-a1b2c"]
  }
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240101000000046C7CCC3CCCE87016E3",
    "Action": "ListModelCustomizationJobs",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 10,
    "Items": [
      {
        "Id": "mcj-20240101000000-a1b2c",
        "Name": "测试任务",
        "Description": "这是一个测试任务",
        "Tags": [
          {
            "Key": "sys:ark:createdBy",
            "Value": "IAMUser/23454321/test.user@bytedance.com"
          }
        ],
        "ProjectName": "default",
        "CustomizationType": "FinetuneLoRA",
      }
    ]
  }
}
```

```
json  "ModelReference": {
      "FoundationModel": {
        "Name": "skylark2-lite-8k",
        "ModelVersion": "1.0",
        "ConfigurationId": "fmvc-20240101000000-a1b2c"
      }
    },
    "Hyperparameters": [
      {
        "Name": "epoch",
        "Value": "6"
      },
      {
        "Name": "learning_rate",
        "Value": "0.00001"
      }
    ],
    "SaveModelLimit": 1,
    "Data": {
      "TrainingSet": {
        "TosBucket": "ark-auto-created-required-2100000000-cn-beijing",
        "TosPaths": [
          "model-customization-job-upload-set/1712561985763/test.jsonl"
        ]
      }
    },
    "Status": {
      "Phase": "Completed",
      "PhaseTime": "2024-01-01T00:00:00Z"
    },
    "CreateTime": "2024-01-01T00:00:00Z",
    "UpdateTime": "2024-01-01T00:00:00Z"
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                | 说明 |
|-----|------------------------------------|-----------------------------------------------------|----|
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter<br>{{Parameter}} is missing. |    |

| 状态码 | 错误码                                | 错误信息                                                  | 说明                                  |
|-----|------------------------------------|-------------------------------------------------------|-------------------------------------|
|     |                                    |                                                       | 缺少必要的请求参数。<br>请确认请求参数后重试。           |
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter<br>{{Parameter}} is invalid.  | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。     |
| 500 | InternalServerError                | The request has failed<br>due to an unknown<br>error. | 未知错误，请稍后重<br>试。如果多次尝试仍失<br>败，请提交工单。 |

# 12.3.5 UpdateModelCustomizationJob – 更新模型调优任务

更新模型调优任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数          | 类型     | 是否必填 | 示例值                         | 描述                                     |
|-------------|--------|------|-----------------------------|----------------------------------------|
| Action      | String | 是    | UpdateModelCustomizationJob | 要执行的操作，取值：UpdateModelCustomizationJob。 |
| Version     | String | 是    | 2024-01-01                  | API的版本，取值：2024-01-01。                  |
| Id          | String | 是    | mcj-test-id                 | 待更新的模型调优任务的 ID                         |
| Name        | String | 否    | TestName                    | 待更新的模型调优任务名称                           |
| Description | String | 否    | TestDescription             | 待更新的模型调优任务描述                           |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

请求示例

```
text

POST /?Action=UpdateModelCustomizationJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T083603Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "mcj-test-id"
}
```

返回示例

```
json

{
  "ResponseMetadata": {
    "RequestId": "20250115163612164250161131A08F01",
    "Action": "UpdateModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                            | 错误信息                                             | 说明                    |
|-----|--------------------------------|--------------------------------------------------|-----------------------|
| 400 | MissingParameter.{{Parameter}} | The required parameter {{Parameter}} is missing. | 缺少必要的请求参数。请确认请求参数后重试。 |
| 404 | NotFound.{{Parameter}}         |                                                  |                       |

| 状态码 | 错误码                 | 错误信息                                                             | 说明                          |
|-----|---------------------|------------------------------------------------------------------|-----------------------------|
|     |                     | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalServerError | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |



# 12.3.6 DeleteModelCustomizationJob – 删除模型调优任务

删除模型调优任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                         | 描述                                     |
|---------|--------|------|-----------------------------|----------------------------------------|
| Action  | String | 是    | DeleteModelCustomizationJob | 要执行的操作，取值：DeleteModelCustomizationJob。 |
| Version | String | 是    | 2024-01-01                  | API的版本，取值：2024-01-01。                  |
| Id      | String | 是    | mcj-20240**<br>*_**         | 待删除的模型调优任务的ID                          |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

## 请求示例

```
POST /?Action=DeleteModelCustomizationJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T083827Z
```

```
text
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "mcj-20240***_***"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20250115163836138227026138053A18",
    "Action": "DeleteModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                  | 错误信息                                                                   | 说明                              |
|-----|--------------------------------------|------------------------------------------------------------------------|---------------------------------|
| 400 | MissingParameter.<br>{{Parameter}}   | The required parameter<br>{{Parameter}} is missing.                    | 缺少必要的请求参数。<br>请确认请求参数后重<br>试。   |
| 400 | InvalidParameter.<br>{{Parameter}}   | The specified parameter<br>{{Parameter}} is invalid.                   | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。 |
| 403 | OperationDenied.Unsup<br>portedPhase | Operation is denied<br>because operation is not<br>supported while the |                                 |

| 状态码 | 错误码                    | 错误信息                                                             | 说明                          |
|-----|------------------------|------------------------------------------------------------------|-----------------------------|
|     |                        | target is in its current phase.                                  |                             |
| 404 | NotFound.{{Parameter}} | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalServerError    | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

# 12.3.7 ResumeModelCustomizationJob – 重试模型调优任务

续训任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                         | 描述                                     |
|---------|--------|------|-----------------------------|----------------------------------------|
| Action  | String | 是    | ResumeModelCustomizationJob | 要执行的操作，取值：ResumeModelCustomizationJob。 |
| Version | String | 是    | 2024-01-01                  | API的版本，取值：2024-01-01。                  |
| Id      | String | 是    | mcj-20240710130531-57fch    | ID                                     |

## 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

## 请求示例

```
text
{
  "Id": "mcj-20240101000000-a1b2c"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20240101000000046C7CCC3CCCE87016E3",
    "Action": "ResumeModelCustomizationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                  | 错误信息                                                                                                         | 说明                                  |
|-----|--------------------------------------|--------------------------------------------------------------------------------------------------------------|-------------------------------------|
| 400 | MissingParameter.<br>{{Parameter}}   | The required parameter<br>{{Parameter}} is missing.                                                          | 缺少必要的请求参数。<br>请确认请求参数后重<br>试。       |
| 400 | InvalidParameter.<br>{{Parameter}}   | The specified parameter<br>{{Parameter}} is invalid.                                                         | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。     |
| 403 | OperationDenied.Unsup<br>portedPhase | Operation is denied<br>because operation is not<br>supported while the<br>target is in its current<br>phase. | 当前精调任务的阶段不<br>支持重试，例如预处<br>理、运行中等阶段 |

| 状态码 | 错误码                                  | 错误信息                                                                                                                      | 说明                          |
|-----|--------------------------------------|---------------------------------------------------------------------------------------------------------------------------|-----------------------------|
| 403 | OperationDenied.OutputExpired        | Operation is denied because the specified output is no longer available for export as it has reached the expiration time. | 当前精调任务的产物已经过期，不支持重试         |
| 403 | OperationDenied.UnrecoverableFailure | Operation is denied because the ModelCustomizationJob was failed on an unrecoverable error and cannot be resumed.         | 当前操作被拒绝，因为此精调任务遇到不可重试错误     |
| 403 | OperationDenied.RetryLimited         | Operation is denied because the ModelCustomizationJob has reached its retry limit.                                        | 当前操作被拒绝，因为此精调任务已经触及最大重试上限   |
| 403 | OperationDenied.ConcurrentUpdate     | Operation is denied because the operation are being modified concurrently                                                 | 当前操作被拒绝，因为此精调任务正在被多个用户同时修改  |
| 404 | NotFound.{{Parameter}}               | The specified {{ResourceType}} {{ResourceContent}} is not found.                                                          | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalServerError                  | The request has failed due to an unknown error.                                                                           | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

| 状态码 | 错误码 | 错误信息 | 说明 |
|-----|-----|------|----|
|     |     |      |    |

# 12.3.8 GetModelCustomizationJobMetricData – 查询精调效果指标详细数据

查询精调效果指标详细数据接口

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数             | 类型              | 是否必填 | 示例值                                | 描述                                                 |
|----------------|-----------------|------|------------------------------------|----------------------------------------------------|
| Action         | String          | 是    | GetModelCustomizationJobMetricData | 要执行的操作，取值：GetModelCustomizationJobMetricData。      |
| Version        | String          | 是    | 2024-01-01                         | API的版本，取值：2024-01-01。                              |
| MinSampleStep  | String          | 否    | -                                  | 最小采样步长，如果采样力度与系统计算MaxMetricPoint的step相比更小时，此采样步长生效 |
| Metrics        | Array of String | 是    | -                                  | 指标名称列表                                             |
| MaxMetricPoint | String          | 否    | -                                  | 单个指标的最多返回打点上限，默认 500 个。                            |
|                |                 |      |                                    |                                                    |



| 参数                      | 类型      | 是否必填 | 示例值 | 描述                      |
|-------------------------|---------|------|-----|-------------------------|
| ToStep                  | Integer | 是    | -   | 终点 step                 |
| FromStep                | Integer | 是    | -   | 起点 step                 |
| ModelCustomizationJobId | String  | 是    | -   | ModelCustomizationJobId |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                          | 类型              | 示例值 | 描述     |
|---------------------------------------------------------------------------------------------|-----------------|-----|--------|
|  Items    | Array of Object | -   | 指标列表   |
| Metric                                                                                      | String          | -   | 指标名称   |
|  Samples | Array of Object | -   | 指标数据   |
| Step                                                                                        | Integer         | -   | 第几步    |
| Value                                                                                       | Double          | -   | 上报的打点值 |

请求示例

```
{
  "ModelCustomizationJobId": "mcj-20241128104838-g9vqg",
  "Metrics": [
    "train/total_tokens",
    "eval/loss",
    "train/loss",
```

```
json  "eval/total_tokens"
    ]
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20241212201041E7A67D3F69E447553B7F",
    "Action": "GetModelCustomizationJobMetricData",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Items": [
      {
        "Metric": "train/total_tokens",
        "Samples": [
          {
            "Step": 1,
            "Value": 2
          },
          {
            "Step": 2,
            "Value": 3
          }
        ]
      },
      {
        "Metric": "eval/loss",
        "Samples": [
          {
            "Step": 1,
            "Value": 0.0001
          },
          {
            "Step": 2,
            "Value": 0.0001
          }
        ]
      },
      {
        "Metric": "train/loss",
```

```
json    "Samples": [
        {
            "Step": 1,
            "Value": 0.0625
        },
        {
            "Step": 2,
            "Value": 0.0525
        }
    ]
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                                      | 说明                                  |
|-----|------------------------------------|---------------------------------------------------------------------------|-------------------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter<br>{{Parameter}} is invalid.                      | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。     |
| 404 | NotFound.{{Parameter}}             | The specified<br>{{ResourceType}}<br>{{ResourceContent}} is<br>not found. | 指定资源找不到。请确<br>认参数后重试。               |
| 500 | InternalServerError                | The request has failed<br>due to an unknown<br>error.                     | 未知错误，请稍后重<br>试。如果多次尝试仍失<br>败，请提交工单。 |

# 12.3.9 GetModelCustomizationJobMetrics – 查询精调效果指标

查询精调效果指标接口

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数                      | 类型     | 是否必填 | 示例值                             | 描述                                         |
|-------------------------|--------|------|---------------------------------|--------------------------------------------|
| Action                  | String | 是    | GetModelCustomizationJobMetrics | 要执行的操作，取值：GetModelCustomizationJobMetrics。 |
| Version                 | String | 是    | 2024-01-01                      | API的版本，取值：2024-01-01。                      |
| ModelCustomizationJobId | String | 是    | -                               | 模型精调任务 ID。                                 |

## 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数      | 类型              | 示例值 | 描述      |
|---------|-----------------|-----|---------|
| Metrics | Array of String | -   | 指标名称列表。 |

## 请求示例

```
json
{
  "ModelCustomizationJobId": "mcj-20241128104838-g9vqg"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "2024121216215991B48FBC86E8E61A44B1",
    "Action": "GetModelCustomizationJobMetrics",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": ""
  },
  "Result": {
    "Metrics": [
      "eval/loss",
      "eval/total_tokens",
      "train/loss",
      "train/total_tokens"
    ]
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                                      | 说明                              |
|-----|------------------------------------|---------------------------------------------------------------------------|---------------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter<br>{{Parameter}} is invalid.                      | 请求参数值不合法。请<br>检查参数值的正确性后<br>重试。 |
| 404 | NotFound.{{Parameter}}             | The specified<br>{{ResourceType}}<br>{{ResourceContent}} is<br>not found. | 指定资源找不到。请确<br>认参数后重试。           |

| 状态码 | 错误码                 | 错误信息                                            | 说明                          |
|-----|---------------------|-------------------------------------------------|-----------------------------|
| 500 | InternalServerError | The request has failed due to an unknown error. | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

## 12.4 管理定制模型

### 12.4.1 DeleteCustomModel – 删除定制模型

删除定制模型

#### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数      | 类型      | 是否必填 | 示例值               | 描述                                                                                                           |
|---------|---------|------|-------------------|--------------------------------------------------------------------------------------------------------------|
| Action  | String  | 是    | DeleteCustomModel | 要执行的操作，取值：DeleteCustomModel。                                                                                 |
| Version | String  | 是    | 2024-01-01        | API的版本，取值：2024-01-01。                                                                                        |
| Id      | String  | 是    | cm-id             | 定制模型的ID                                                                                                      |
| DryRun  | Boolean | 否    | false             | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |

#### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#) .

## 请求示例

```
json
{
  "Id": "vW1AYDY27A",
  "DryRun": true
}
```

## 返回示例

```
json
请求返回状态码：200
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。



## 12.4.2 GetCustomModel – 获取定制模型信息

获取定制模型信息

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值            | 描述                        |
|---------|--------|------|----------------|---------------------------|
| Action  | String | 是    | GetCustomModel | 要执行的操作，取值：GetCustomModel。 |
| Version | String | 是    | 2024-01-01     | API的版本，取值：2024-01-01。     |
| Id      | String | 是    | cm-id          | 定制模型的ID                   |

### 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                                  | 类型     | 示例值                     | 描述     |
|-----------------------------------------------------------------------------------------------------|--------|-------------------------|--------|
| Id                                                                                                  | String | cm-20240101000000-abcde | 资源Id   |
| Name                                                                                                | String | 模型名称                    | 资源名称   |
| Description                                                                                         | String | 模型描述                    | 资源描述   |
| SourceType                                                                                          | String | Customization           | 来源类型   |
|  FoundationModel | Object | doubao-pro-32k          | 基础模型引用 |
|                                                                                                     |        |                         |        |

| 参数                                                                                       | 类型              | 示例值                                        | 描述                                               |
|------------------------------------------------------------------------------------------|-----------------|--------------------------------------------|--------------------------------------------------|
| Name                                                                                     | String          |                                            | 基础模型名                                            |
| ModelVersion                                                                             | String          |                                            | 基础模型版本                                           |
| ConfigurationId                                                                          | String          |                                            | 基础模型配置ID                                         |
| ModelCustomizationJobId                                                                  | String          | mcj-20240101000000-abcde                   | 模型自定义任务ID                                        |
| CustomizationType                                                                        | String          | FinetuneLoRA                               | 自定义类型                                            |
| SourceModelAvailable                                                                     | Boolean         | true                                       | 如果当前模型是基于一个共享模型增量训练出来的模型，该字段用于表示共享来源模型是否仍然有效     |
| LoraBaseModelAvailable                                                                   | Boolean         | true                                       | 如果当前模型是一个基于全量SFT模型增量精调出来的模型，该字段用于表示全量SFT模型是否仍然有效 |
|  Tags | Array of Object | [{"Key": "tag_key", "Value": "Tag Value"}] | 标签列表                                             |
| Key                                                                                      | String          |                                            | 标签键                                              |
| Value                                                                                    | String          |                                            | 标签值                                              |

| 参数          | 类型     | 示例值                  | 描述   |
|-------------|--------|----------------------|------|
| ProjectName | String | default              | 项目名称 |
| CreateTime  | String | 2024-01-01T00:00:00Z | 创建时间 |
| UpdateTime  | String | 2024-01-01T00:00:00Z | 更新时间 |

请求示例

```
text

POST /?Action=GetCustomModel&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130337Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "cm-id"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "2024051421034216322206625187C9AD",
    "Action": "GetCustomModel",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
```

```
json {"CustomModel": {
  "Id": "1GSH",
  "Name": "2dYgMKVBt",
  "Description": "d4Hkd5Fe3M",
  "SourceType": "GWVZA3",
  "ModelCustomizationJobId": "4Uxl",
  "CustomizationType": "Hoev2RymwBI",
  "Status": "Ready",
  "HyperParameters": [
    {
      "Name": "rFL44dtTT9",
      "Value": "RnF7Q"
    }
  ],
  "FoundationModel": {
    "Name": "YfIRG",
    "ModelVersion": "FvVqyQtk"
  },
  "Tags": [
    {
      "Key": "QBb",
      "Value": "rwl1F860fK"
    }
  ],
  "ProjectName": "gQZXp",
  "CreateTime": "X",
  "UpdateTime": "quUkQljh"
}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.4.3 UpdateCustomModel – 更新定制模型

更新定制模型

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型      | 是否必填 | 示例值               | 描述                                                                           |
|-------------|---------|------|-------------------|------------------------------------------------------------------------------|
| Action      | String  | 是    | UpdateCustomModel | 要执行的操作，取值：UpdateCustomModel。                                                 |
| Version     | String  | 是    | 2024-01-01        | API的版本，取值：2024-01-01。                                                        |
| Id          | String  | 是    | cm-id             | 定制模型的ID                                                                      |
| Name        | String  | 否    | TestName          | 定制模型名称                                                                       |
| Description | String  | 否    | TestDescription   | 定制模型描述                                                                       |
| DryRun      | Boolean | 否    | true              | 是否仅对此请求进行预检。取值： <ul style="list-style-type: none"><li>true：发送检查请求。</li></ul> |

| 参数 | 类型 | 是否必填 | 示例值 | 描述                  |
|----|----|------|-----|---------------------|
|    |    |      |     | · false(默认): 发送正常请求 |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值   | 描述    |
|----|--------|-------|-------|
| Id | String | cm-id | 资源的ID |

请求示例

```
text

POST /?Action=UpdateCustomModel&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130759Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "cm-id",
  "Name": "TestName",
  "Description": "TestDescription",
  "DryRun": true
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514210804240055238131D7DFB2",
    "Action": "UpdateCustomModel",
    "Version": "2024-01-01",
    "Service": "ark",
```

```
json  "Region": "cn-beijing"  
    },  
    "Result": {  
      "Id": "cm-id"  
    }  
  }  
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.4.4 ListCustomModels – 获取定制模型列表

获取定制模型列表

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数                                                                                         | 类型      | 是否必填 | 示例值              | 描述                                                                                                           |
|--------------------------------------------------------------------------------------------|---------|------|------------------|--------------------------------------------------------------------------------------------------------------|
| Action                                                                                     | String  | 是    | ListCustomModels | 要执行的操作，取值：ListCustomModels。                                                                                  |
| Version                                                                                    | String  | 是    | 2024-01-01       | API的版本，取值：2024-01-01。                                                                                        |
| PageNumber                                                                                 | Integer | 否    | 1                | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                      |
| PageSize                                                                                   | Integer | 否    | 1                | 分页查询时每页显示的记录数。取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
|  Filter | Object  | 否    | -                | 待查询定制模型的筛选条件                                                                                                 |
|                                                                                            |         |      |                  |                                                                                                              |



| 参数                                                                                           | 类型              | 是否必填 | 示例值        | 描述                                                                                                                                                                                                                            |
|----------------------------------------------------------------------------------------------|-----------------|------|------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ids                                                                                          | Array of String | 否    |            | 定制模型ID数组，精确匹配                                                                                                                                                                                                                 |
| Name                                                                                         | String          | 否    |            | 定制模型名称，模糊匹配                                                                                                                                                                                                                   |
|  TagFilters | Array of Object | 否    | -          | 基于绑定的标签的筛选条件                                                                                                                                                                                                                  |
| Key                                                                                          | String          | 是    |            | 标签键                                                                                                                                                                                                                           |
| Values                                                                                       | Array of String | 否    |            | 标签值                                                                                                                                                                                                                           |
| ProjectName                                                                                  | String          | 否    | default    | <ul style="list-style-type: none"><li>· 资源所属的项目名称，默认值为 default。</li><li>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a> .</li></ul> |
| SortBy                                                                                       | String          | 否    | CreateTime | 指定排序指标。可指定值： <ul style="list-style-type: none"><li>· CreateTime：创建时间</li><li>· UpdateTime：更新时间</li></ul>                                                                                                                      |
| SortOrder                                                                                    | String          | 否    | Asc        | 指定排序顺序。可指定值：                                                                                                                                                                                                                  |

| 参数 | 类型 | 是否必填 | 示例值 | 描述                                                     |
|----|----|------|-----|--------------------------------------------------------|
|    |    |      |     | <div><div>· Asc：升序排列</div><div>· Desc：降序排列</div></div> |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数                                                                                        | 类型              | 示例值 | 描述                                                                                     |
|-------------------------------------------------------------------------------------------|-----------------|-----|----------------------------------------------------------------------------------------|
| TotalCount                                                                                | Integer         | 1   | 总定制模型数                                                                                 |
| PageNumber                                                                                | Integer         | 1   | 分页查询时的起始页码，从 1 开始，默认为 1                                                                |
| PageSize                                                                                  | Integer         | 10  | 分页查询时每页显示的记录数，取值： <div><div>· 最小值：1</div><div>· 最大值：100</div><div>· 默认值：10</div></div> |
|  Items | Array of Object | -   | 定制模型列表                                                                                 |
| Id                                                                                        | String          |     | 定制模型ID                                                                                 |
| Name                                                                                      | String          |     | 定制模型名称                                                                                 |
| Description                                                                               | String          |     | 定制模型描述                                                                                 |
| SourceType                                                                                | String          |     | 定制模型来源类型。可能取值：                                                                         |

| 参数                         | 类型              | 示例值   | 描述                                                                                                                 |
|----------------------------|-----------------|-------|--------------------------------------------------------------------------------------------------------------------|
|                            |                 |       | “Customization”：精调模型 “Import”：导入模型                                                                                 |
| ModelCustomizationJobId    | String          |       | 模型调优任务ID                                                                                                           |
| CustomizationType          | String          |       | 定制类型。可选值：<br>“FinetuneSft”：SFT精调 “FinetuneLoRA”：LoRA精调 “Pretrain”：预训练                                              |
| Status                     | String          | Ready | 定制模型的状态                                                                                                            |
| <div>HyperParameters</div> | Array of Object | /-    | 定制模型的超参列表                                                                                                          |
| Name                       | String          |       | 超参数的参数名                                                                                                            |
| Value                      | String          |       | 超参数的参数值                                                                                                            |
| <div>FoundationModel</div> | Object          |       | 基础模型引用                                                                                                             |
| Name                       | String          |       | 基础模型名称。<br><br>· 请注意模型名称为小写。<br><br>· doubao 1.5 代模型的模型名称格式为 "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字 |

| 参数                                                                                       | 类型              | 示例值 | 描述                                               |
|------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------|
|                                                                                          |                 |     | 段为 "doubao-1-5-pro-32k"。                         |
| ModelVersion                                                                             | String          |     | 基础模型版本                                           |
| SourceModelAvailable                                                                     | Boolean         |     | 如果当前模型是一个基于全量SFT模型增量精调出来的模型，该字段用于表示全量SFT模型是否仍然有效 |
| LoraBaseModelAvailable                                                                   | Boolean         |     | 如果当前模型是基于一个共享模型增量训练出来的模型，该字段用于表示共享来源模型是否仍然有效     |
|  Tags | Array of Object |     | 定制模型绑定的标签                                        |
| Key                                                                                      | String          |     | 标签键                                              |
| Value                                                                                    | String          |     | 标签值                                              |
| ProjectName                                                                              | String          |     | 项目名称                                             |
| CreateTime                                                                               | String          |     | 定制模型创建时间，RFC3339格式                               |
| UpdateTime                                                                               | String          |     | 定制模型更新时间，RFC3339格式                               |

## 请求示例

text

```
POST /?Action=ListCustomModels&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130512Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "PageNumber": 1,
  "PageSize": 1,
  "Filter": {
    "Ids": [
      "vrYVig"
    ],
    "Name": "aThQ2SZH"
  },
  "TagFilters": [
    {
      "Key": "8mYbP7pN",
      "Values": [
        "8bS"
      ]
    }
  ],
  "ProjectName": "default",
  "SortBy": "CreateTime",
  "SortOrder": "Desc"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514210517123075045154E335F9",
    "Action": "ListCustomModels",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  }
}
```

```
json},
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 10,
    "Items": [
      {
        "Id": "jJJ",
        "Name": "Xf",
        "Description": "F",
        "SourceType": "IBQb26",
        "ModelCustomizationJobId": "eYCILOD",
        "CustomizationType": "Ixb0G1",
        "Status": "Ready",
        "HyperParameters": [
          {
            "Name": "cALJ0SSf",
            "Value": "lais76"
          }
        ],
        "FoundationModel": {
          "Name": "OI",
          "ModelVersion": "jf0GoztY9"
        },
        "Tags": [
          {
            "Key": "VKk5m6sRdxl",
            "Value": "t3ieup"
          }
        ],
        "ProjectName": "bIA3",
        "CreateTime": "lYuGzty",
        "UpdateTime": "D33NRefE"
      }
    ]
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.5 管理基础模型

### 12.5.1 ListFoundationModelVersions – 获取基础模型版本列表

列出基础模型版本。

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string `%%require%%` 示例值: ListFoundationModelVersions  
要执行的操作，取值：ListFoundationModelVersions。

**Version** string `%%require%%` 示例值: 2024-01-01  
API的版本，取值：2024-01-01。

**FoundationModelName** string `%%require%%` 示例值: doubao-seed-2-0-pro  
基础模型名称

**PageNumber** integer 可选 示例值: 1  
分页查询时的起始页码，从 1 开始，默认为 1

**PageSize** integer 可选 示例值: 1  
分页查询时每页显示的记录数，取值：

- 最小值：1
- 最大值：100
- 默认值：10

**Filter** object 可选 示例值: \-  
待查询基础模型版本的筛选条件

**Description** string 可选  
基础模型版本描述，模糊匹配

**ModelVersions** string[] 可选  
基础模型版本名称列表，精准匹配

**Statuses** string[] 可选  
基础模型版本状态列表，精准匹配，Unpublished / Published / Retiring

**SortOrder** string 可选 示例值: Desc  
指定排序顺序。可指定值:

- Asc: 升序排列
- Desc: 降序排列

**SortBy** string 可选 示例值: \-  
指定排序指标。可指定值:

- CreateTime 创建时间
- UpdateTime 更新时间

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**TotalCount** integer 示例值: 2  
总基础模型版本数

**PageNumber** integer 示例值: 1  
分页查询时的起始页码，从 1 开始，默认为 1

**PageSize** integer 示例值: 1  
分页查询时每页显示的记录数，取值:

- 最小值: 1
- 最大值: 100
- 默认值: 10

**Items** object[] 示例值: \-  
基础模型版本列表

**FoundationModelName** string 示例值: doubao-seed-2-0-pro  
基础模型名称

**ModelVersion** string 示例值: 260215  
基础模型版本名称

**Description** string  
基础模型版本描述

**ActiveConfigurationId** string  
生效中的基础模型版本配置ID

**Status** string  
基础模型版本状态:

- Unpublished: 未发布
- Published: 已发布
- Retiring: 下线中

**PublishTime** string 示例值: 2006-01-02T15:04:05Z07:00  
基础模型版本发布时间，RFC3339格式



**CreateTime** string 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本创建时间, RFC3339格式

**UpdateTime** string 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本更新时间, RFC3339格式

## 请求示例

text

```
POST /?Action=ListFoundationModelVersions&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130104Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "FoundationModelName": "doubao-seed-2-0-pro",
  "PageNumber": 1,
  "PageSize": 10,
  "Filter": {
    "Description": "WU",
    "ModelVersions": [
      "783"
    ],
    "Statuses": [
      "M0"
    ]
  },
  "SortOrder": "Desc",
  "SortBy": "CreateTime"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "2024051421010908503002501682D9A8",
    "Action": "ListFoundationModelVersions",
```

```
json {"Version": "2024-01-01",
      "Service": "ark",
      "Region": "cn-beijing"
    },
    "Result": {
      "TotalCount": 2,
      "PageNumber": 1,
      "PageSize": 1,
      "Items": [
        {
          "FoundationModelName": "doubao-seed-2-0-pro",
          "ModelVersion": "260215",
          "Description": "r",
          "ActiveConfigurationId": "93RniLBUHsU",
          "Status": "Kq7b",
          "PublishTime": "2006-01-02T15:04:05Z07:00\n",
          "CreateTime": "2006-01-02T15:04:05Z07:00\n",
          "UpdateTime": "2006-01-02T15:04:05Z07:00\n"
        }
      ]
    }
  }
```

### 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.5.2 GetFoundationModelVersion – 获取基础模型版本信息

获取基础模型版本信息

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string `%%require%%` 示例值: `GetFoundationModelVersion`  
要执行的操作，取值: `GetFoundationModelVersion`。

**Version** string `%%require%%` 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**FoundationModelName** string `%%require%%` 示例值: `doubao-seed-2-0-pro`  
基础模型名称

**ModelVersion** string `%%require%%` 示例值: `260215`  
基础模型版本名称

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**FoundationModelName** string 示例值: `doubao-seed-2-0-pro`  
基础模型名称

**ModelVersion** string 示例值: `260215`  
基础模型版本名称

**Description** string 示例值: `这是一条基础模型版本描述`  
基础模型版本描述

**ActiveConfigurationId** string 示例值: `10`  
生效中的基础模型版本配置ID

**Configuration** object 示例值: `\-`  
基础模型版本正在生效的详细配置

**AppSettings** object

体验应用配置

**Greeting** string

问候语

**Parameters** object[]

基础模型参数配置

**Type** string 示例值: String

参数类型, Int / Bool / Float / String

**Name** string

参数名称

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**Prompts** object[]

基础模型预置提示词配置

**Scenario** string

提示词场景

**Message** string

提示词内容

**MaxInputTokenLength** integer

最大输入token长度

**SystemPrompt** object

系统提示词配置

**Message** string

系统提示词内容

**ModificationAllowed** boolean 示例值: True

系统提示词是否可以在体验时被修改

**MaxInputTokenLength** long

系统提示词的最大token输入长度

**CustomizationJobSettings** object

自定义任务配置

**SftSettings** object

SFT训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**LoraSettings** object

LoRA训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**ContinuePretrainSettings** object

Continue Pretrain训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**LoraDPOSettings** object

DPO LoRA训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**Status** string 示例值: Unpublished

基础模型版本状态:

- Unpublished: 未发布
- Published: 已发布
- Retiring: 下线中

**PublishTime** string 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本发布时间, RFC3339格式

**CreateTime** string 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本创建时间, RFC3339格式

**UpdateTime** string 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本更新时间, RFC3339格式

## 请求示例



text

```
POST /?Action=GetFoundationModelVersion&Version=2024-01-01&ModelVersion=1.0 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130041Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "FoundationModelName": "doubao-seed-2-0-pro"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514210046057210000044CEC5FF",
    "Action": "GetFoundationModelVersion",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "FoundationModelName": "doubao-seed-2-0-pro",
    "ModelVersion": "260215",
    "Description": "这是一条基础模型版本描述",
    "ActiveConfigurationId": "10",
    "Configuration": {
      "AppSettings": {
        "Greeting": "A",
        "Parameters": [
          {
            "Type": "String",
            "Name": "Gj5b4e",
            "DisplayName": "ZvDI",
            "Min": "YEdallBs9Uk",
            "Max": "ljs",
            "Options": [
              "MldkfhWP5"
            ]
          }
        ]
      }
    }
  }
}
```

```
    "DefaultValue": "3cftCK29K",
    "Description": "dcqEJOP"
  },
],
"Prompts": [
  {
    "Scenario": "B1SFBk4m",
    "Message": "IzFqE"
  }
],
"MaxInputTokenLength": 837,
"SystemPrompt": {
  "Message": "I",
  "ModificationAllowed": true,
  "MaxInputTokenLength": 801
},
"CustomizationJobSettings": {
  "SftSettings": {
    "Enabled": true,
    "SupportPresetDatasets": [
      {
        "Name": "E",
        "Description": "THy",
        "SampleCount": 461,
        "Labelled": false
      }
    ],
  },
  "Parameters": [
    {
      "Type": "String",
      "Name": "BZbUOmW9w",
      "DisplayName": "YcRvC7xYcs",
      "Min": "JmrRFc",
      "Max": "PbCLrR45",
      "Options": [
        "cba6tBVpzSN"
      ],
      "DefaultValue": "e5TX",
      "Description": "Fql",
      "IncrementalLearningLocked": false
    }
  ],
},
"LoraSettings": {
  "Enabled": false,
  "SupportPresetDatasets": [
```

```
{
  "Name": "0ZmrgA",
  "Description": "dE7oFXW4U",
  "SampleCount": 901,
  "Labelled": true
},
{
  "Parameters": [
    {
      "Type": "String",
      "Name": "qb6y",
      "DisplayName": "9Ms5Fo",
      "Min": "e41YOJsY",
      "Max": "ID9n4I7sY",
      "Options": [
        "TsyD"
      ],
      "DefaultValue": "im00XtrEs1S",
      "Description": "y",
      "IncrementalLearningLocked": false
    }
  ],
},
{
  "ContinuePretrainSettings": {
    "Enabled": false,
    "SupportPresetDatasets": [
      {
        "Name": "nhXR",
        "Description": "leKhyY2ZqH",
        "SampleCount": 224,
        "Labelled": true
      }
    ],
    "Parameters": [
      {
        "Type": "String",
        "Name": "8gJZg9h5iVA",
        "DisplayName": "QfPfb",
        "Min": "XWxl8F29zo",
        "Max": "ScFs4Q",
        "Options": [
          "jPkH"
        ],
        "DefaultValue": "K02A4wV38I7",
        "Description": "sTjMLmwfu",
        "IncrementalLearningLocked": false
      }
    ]
  }
}
```

```
json  ]
      }
    },
    "Status": "Unpublished",
    "PublishTime": "2006-01-02T15:04:05Z07:00",
    "CreateTime": "2006-01-02T15:04:05Z07:00",
    "UpdateTime": "2006-01-02T15:04:05Z07:00"
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.5.3 ListFoundationModels – 获取基础模型列表

列出基础模型。

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数                                                                                         | 类型              | 是否必填 | 示例值                  | 描述                                          |
|--------------------------------------------------------------------------------------------|-----------------|------|----------------------|---------------------------------------------|
| Action                                                                                     | String          | 是    | ListFoundationModels | 要执行的操作，取值：ListFoundationModels。             |
| Version                                                                                    | String          | 是    | 2024-01-01           | API的版本，取值：2024-01-01。                       |
| PageNumber                                                                                 | Integer         | 否    | 1                    | 分页查询时的起始页码，从 1 开始，默认为 1。                    |
| PageSize                                                                                   | Integer         | 否    | 10                   | 分页查询时每页显示的记录数，取值：- 最小值：1 - 最大值：100 - 默认值：10 |
|  Filter | Object          | 否    | -                    | 待查询基础模型的筛选条件                                |
|                                                                                            | Array of String | 否    |                      |                                             |

| 参数                                                                                                   | 类型              | 是否必填 | 示例值 | 描述                                                                                                                                                                                                                                                                  |
|------------------------------------------------------------------------------------------------------|-----------------|------|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| SupportedCustomizationTypes                                                                          |                 |      |     | 基础模型支持的精调类型，精准匹配                                                                                                                                                                                                                                                    |
| Names                                                                                                | Array of String | 否    |     | 基础模型名称列表，精准匹配                                                                                                                                                                                                                                                       |
| Name                                                                                                 | String          | 否    |     | 基础模型名称，模糊匹配                                                                                                                                                                                                                                                         |
|  FoundationModelTag | Object          | 否    |     | 基础模型特定标签                                                                                                                                                                                                                                                            |
| Languages                                                                                            | Array of String | 否    |     | 基础模型支持语言列表                                                                                                                                                                                                                                                          |
| UsedLibraries                                                                                        | Array of String | 否    |     | 基础模型使用库列表                                                                                                                                                                                                                                                           |
| TaskTypes                                                                                            | Array of String | 否    |     | 基础模型支持任务类型列表<br>"TextGeneration": "文本生成",<br>"VisualQuestionAnswering": "图片内容理解",<br>"TextToImage": "文生图",<br>"ImageToImage": "图生图",<br>"TextToVideo": "文生视频",<br>"ImageToVideo": "图生视频",<br>"TextTo3D": "文生 3D",<br>"ImageTo3D": "图生 3D",<br>"VoiceClone": "声音复刻", |

| 参数           | 类型              | 是否必填 | 示例值 | 描述                                                                                                                                                                              |
|--------------|-----------------|------|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|              |                 |      |     | "TextToSpeech": "文本转语音",<br>"SpeechToText": "语音转文本",<br>"SpeechToSpeech": "同声传译",<br>"TextEmbedding": "文本向量化",<br>"ImageEmbedding": "图像向量化",<br>"MultimodalEmbedding": "多模态向量化" |
| Domains      | Array of String | 否    |     | 基础模型支持领域列表<br><br>· LLM: 大语言模型<br>· Audio: 语音大模型<br>· ComputerVision: 视觉大模型<br>· MultiModal: 多模态<br>· Embedding: 向量模型<br>· VLM: VLM 模型                                          |
| Description  | String          | 否    |     | 基础模型描述，模糊匹配                                                                                                                                                                     |
| Introduction | String          | 否    |     | 基础模型介绍，模糊匹配                                                                                                                                                                     |
| Display Name | String          | 否    |     | 基础模型展示名，模糊匹配                                                                                                                                                                    |
| Access Types | Array of String | 否    |     | 基础模型访问模式列表，精准匹配                                                                                                                                                                 |

| 参数                                                                                            | 类型              | 是否必填 | 示例值  | 描述                                                                                                       |
|-----------------------------------------------------------------------------------------------|-----------------|------|------|----------------------------------------------------------------------------------------------------------|
| SortOrder                                                                                     | String          | 否    | Desc | 指定排序顺序。可指定值： <ul style="list-style-type: none"><li>· Asc：升序排列</li><li>· Desc：降序排列</li></ul>              |
| SortBy                                                                                        | String          | 否    | -    | 指定排序指标。可指定值： <ul style="list-style-type: none"><li>· CreateTime 创建时间</li><li>· UpdateTime 更新时间</li></ul> |
|  TagFilters | Array of Object | 否    | -    | 基于绑定的标签的筛选条件                                                                                             |
| Key                                                                                           | String          | 是    |      | 标签键                                                                                                      |
| Values                                                                                        | Array of String | 否    |      | 标签值                                                                                                      |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#) 。

| 参数         | 类型      | 示例值 | 描述                       |
|------------|---------|-----|--------------------------|
| TotalCount | Integer | 2   | 总基础模型数                   |
| PageNumber | Integer | 1   | 分页查询时的起始页码，从 1 开始，默认为 1。 |
| PageSize   | Integer | 1   | 分页查询时每页显示的记录数，取值：- 最小值：  |



| 参数                                                                                                | 类型              | 示例值                   | 描述                                                                      |
|---------------------------------------------------------------------------------------------------|-----------------|-----------------------|-------------------------------------------------------------------------|
|                                                                                                   |                 |                       | 1 – 最大值：100 – 默认值：10                                                    |
|  Items           | Array of Object | -                     | 基础模型列表                                                                  |
| Name                                                                                              | String          | test-foundation-model | 基础模型名称                                                                  |
| Description                                                                                       | String          |                       | 基础模型描述                                                                  |
| Introduction                                                                                      | String          | language models       | 基础模型介绍。由于返回值尺寸原因，本字段在 ListFoundationModels API 中不返回                     |
| VendorName                                                                                        | String          |                       | 基础模型提供方名称                                                               |
| DisplayName                                                                                       | String          |                       | 基础模型展示名称                                                                |
|  FeaturedImage | Object          |                       | 基础模型显示图片                                                                |
| ObjectKey                                                                                         | String          |                       | TOS对象路径                                                                 |
| BucketName                                                                                        | String          |                       | TOS桶名称<br>在创建和选择 TOS 桶时请注意，当前火山方舟只支持 华北2-北京 地域（region: cn-beijing）的存储桶。 |

| 参数                                                                                                   | 类型              | 示例值 | 描述                                                                                                                                                                                                                                                                                                                                                                                                                  |
|------------------------------------------------------------------------------------------------------|-----------------|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| PrimaryVersion                                                                                       | String          |     | 基础模型主版本                                                                                                                                                                                                                                                                                                                                                                                                             |
|  FoundationModelTag | Object          |     | 基础模型特定标签                                                                                                                                                                                                                                                                                                                                                                                                            |
| Languages                                                                                            | Array of String |     | 基础模型支持语言列表                                                                                                                                                                                                                                                                                                                                                                                                          |
| UsedLibraries                                                                                        | Array of String |     | 基础模型使用库列表                                                                                                                                                                                                                                                                                                                                                                                                           |
| TaskTypes                                                                                            | Array of String |     | 基础模型支持任务类型列表<br>"TextGeneration": "文本生成",<br>"VisualQuestionAnswering": "图片内容理解",<br>"TextToImage": "文生图",<br>"ImageToImage": "图生图",<br>"TextToVideo": "文生视频",<br>"ImageToVideo": "图生视频",<br>"TextTo3D": "文生 3D",<br>"ImageTo3D": "图生 3D",<br>"VoiceClone": "声音复刻",<br>"TextToSpeech": "文本转语音",<br>"SpeechToText": "语音转文本",<br>"SpeechToSpeech": "同声传译",<br>"TextEmbedding": "文本向量化",<br>"ImageEmbedding": "图像向量化", |

| 参数                                                                                       | 类型              | 示例值                       | 描述                                                                                                                                     |
|------------------------------------------------------------------------------------------|-----------------|---------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                          |                 |                           | "MultimodalEmbedding":<br>"多模态向量化"                                                                                                     |
| Domains                                                                                  | Array of String |                           | 基础模型支持领域列表<br><br>· LLM: 大语言模型<br>· Audio: 语音大模型<br>· ComputerVision: 视觉大模型<br>· MultiModal: 多模态<br>· Embedding: 向量模型<br>· VLM: VLM 模型 |
| AccessType                                                                               | String          | Public                    | 基础模型访问模式。可指定值:<br><br>· Public 公开模型<br>· Private 非公开模型                                                                                 |
|  Tags | Array of Object |                           | 基础模型绑定的标签                                                                                                                              |
| Key                                                                                      | String          |                           | 标签键                                                                                                                                    |
| Value                                                                                    | String          |                           | 标签值                                                                                                                                    |
| ProjectName                                                                              | String          | default                   | 项目名称                                                                                                                                   |
| CreateTime                                                                               | String          | 2006-01-02T15:04:05Z07:00 | 基础模型创建时间，RFC3339格式                                                                                                                     |
| UpdateTime                                                                               | String          |                           |                                                                                                                                        |

| 参数 | 类型 | 示例值                       | 描述                 |
|----|----|---------------------------|--------------------|
|    |    | 2006-01-02T15:04:05Z07:00 | 基础模型更新时间，RFC3339格式 |

请求示例

```
POST /?Action=ListFoundationModels&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T130015Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "PageNumber": 1,
  "PageSize": 10,
  "Filter": {
    "Name": "1yEK",
    "Names": [
      "b4"
    ],
    "FoundationModelTag": {
      "Languages": [
        "Tv0mxXamkC5"
      ],
      "TaskTypes": [
        "hmqgZGGni"
      ],
      "CustomizedTags": [
        "zafcaqOy"
      ],
      "Domains": [
        "RRamYGlqLt"
      ],
      "UsedLibraries": [
        "Rctg97iyG0G"
      ]
    },
    "Introduction": "sdQb3Q",
    "Description": "ncjtG458V89",
```

```
text  "DisplayName": "NBgVWD3XwHJ",
      "AccessTypes": [
        "b6Qw9wRLBb"
      ],
    },
    "SortOrder": "Desc",
    "SortBy": "\\-",
    "TagFilters": [
      {
        "Key": "DcuMJa",
        "Values": [
          "5M8sMT"
        ]
      }
    ]
  }
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514210020173184054004BACCC8",
    "Action": "ListFoundationModels",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 2,
    "PageNumber": 1,
    "PageSize": 1,
    "Items": [
      {
        "Name": "test-foundation-model",
        "Description": "wxr",
        "Introduction": "language models",
        "VendorName": "vERtPPat6Xz",
        "DisplayName": "sBEA",
        "FeaturedImage": {
          "ObjectKey": "J3Og",
          "BucketName": "5E"
        },
        "PrimaryVersion": "zYCdJe3n",
        "FoundationModelTag": {
```

```
json  "Languages": [
      "XEQL2sR"
    ],
    "TaskTypes": [
      "ZpMo3"
    ],
    "CustomizedTags": [
      "80woxH8k3Ly"
    ],
    "Domains": [
      "0DQGJbb"
    ],
    "UsedLibraries": [
      "Jjubh2yS"
    ]
  },
  "AccessType": "Public",
  "Tags": [
    {
      "Key": "3",
      "Value": "V"
    }
  ],
  "ProjectName": "default",
  "CreateTime": "2006-01-02T15:04:05Z07:00\n",
  "UpdateTime": "2006-01-02T15:04:05Z07:00\n"
}
]
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.5.4 GetFoundationModelVersionConfiguration – 获取基础模型版本配置信息(不推荐)

获取基础模型版本配置信息（不推荐），建议使用[GetFoundationModelVersion](#)。

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string `%%require%%` 示例值: `GetFoundationModelVersionConfiguration`  
要执行的操作，取值: `GetFoundationModelVersionConfiguration`。

**Version** string `%%require%%` 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**Id** string `%%require%%` 示例值: `fmvc-20240914*****_*****`  
基础模型版本配置ID，需从[ListFoundationModelVersions](#)接口的 `ActiveConfigurationId` 获取。

**FoundationModelName** string `%%require%%` 示例值: `doubao-seed-2-0-pro`  
基础模型名称

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Id** string 示例值: `fmvc-20240914*****_*****`  
基础模型版本配置ID

**FoundationModelName** string 示例值: `doubao-seed-2-0-pro`  
基础模型名称

**FoundationModelVersion** string 示例值: `260215`  
基础模型版本名称

**Configuration** object 示例值: `\-`  
基础模型配置详细信息

**AppSettings** object  
体验应用配置

**Greeting** string

问候语

**Parameters** object[]

基础模型参数配置

**Type** string 示例值: String

参数类型, Int / Bool / Float / String

**Name** string

参数名称

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**Prompts** object[]

基础模型预置提示词配置

**Scenario** string

提示词场景

**Message** string

提示词内容

**MaxInputTokenLength** integer

最大输入token长度

**SystemPrompt** object

系统提示词配置

**Message** string

系统提示词内容

**ModificationAllowed** boolean 示例值: True

系统提示词是否可以在体验时被修改

**MaxInputTokenLength** long

系统提示词的最大token输入长度

**CustomizationJobSettings** object

自定义任务配置



**SftSettings** object

SFT训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**LoraSettings** object

LoRA训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string

混入预置数据集描述

**SampleCount** integer

样本数量

**Labelled** boolean

混入预置数据集是否有标注

**Parameters** object[]

自定义任务参数配置

**Type** string 示例值: String

参数类型, Bool / Int / Float / String

**Name** string

参数名

**DisplayName** string

参数展示名

**Min** string

参数最小值

**Max** string

参数最大值

**Options** string[]

参数可选择项

**DefaultValue** string

参数默认值

**Description** string

参数描述

**IncrementalLearningLocked** boolean

是否锁定增量训练中的参数值可修改

**ContinuePretrainSettings** object

Continue Pretrain训练配置

**Enabled** boolean

是否开启

**SupportPresetDatasets** object[]

支持预置数据集混入配置

**Name** string

混入预置数据集名称

**Description** string  
混入预置数据集描述

**SampleCount** integer  
样本数量

**Labelled** boolean  
混入预置数据集是否有标注

**Parameters** object[]  
自定义任务参数配置

**Type** string 示例值: String  
参数类型, Bool / Int / Float / String

**Name** string  
参数名

**DisplayName** string  
参数展示名

**Min** string  
参数最小值

**Max** string  
参数最大值

**Options** string[]  
参数可选择项

**DefaultValue** string  
参数默认值

**Description** string  
参数描述

**IncrementalLearningLocked** boolean  
是否锁定增量训练中的参数值可修改

**LoraDPOSettings** object  
DPO LoRA训练配置

**Enabled** boolean  
是否开启

**SupportPresetDatasets** object[]  
支持预置数据集混入配置

**Name** string  
混入预置数据集名称

**Description** string  
混入预置数据集描述

**SampleCount** integer  
样本数量

**Labelled boolean**

混入预置数据集是否有标注

**Parameters object[]**

自定义任务参数配置

**Type string** 示例值: String

参数类型, Bool / Int / Float / String

**Name string**

参数名

**DisplayName string**

参数展示名

**Min string**

参数最小值

**Max string**

参数最大值

**Options string[]**

参数可选择项

**DefaultValue string**

参数默认值

**Description string**

参数描述

**IncrementalLearningLocked boolean**

是否锁定增量训练中的参数值可修改

**Status string** 示例值: Tested

基础模型版本配置状态:

- Untested 未测试
- Testing 测试中
- Tested 已测试
- Failed 测试失败

**CreateTime string** 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本配置创建时间, RFC3339格式

**UpdateTime string** 示例值: 2006-01-02T15:04:05Z07:00

基础模型版本配置更新时间, RFC3339格式

## 请求示例

text

```
POST /?Action=GetFoundationModelVersionConfiguration&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241108T062937Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241108/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "fmvc-20240914*****_*****",
  "FoundationModelName": "doubao-seed-2-0-pro"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20241108152417129217208184B83623",
    "Action": "GetFoundationModelVersionConfiguration",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "fmvc-20240914*****_*****",
    "FoundationModelName": "doubao-seed-2-0-pro",
    "FoundationModelVersion": "260215",
    "Configuration": {
      "AppSettings": {
        "Greeting": "PD8tc",
        "Parameters": [
          {
            "Type": "String",
            "Name": "VmyVdsskE",
            "DisplayName": "HJBjfUC",
            "Min": "g5AQZcjfzS",
            "Max": "KVb4XpKRa",
            "Options": [
              "h"
            ]
          }
        ]
      }
    }
  }
}
```

```
    "DefaultValue": "7Bj6ypR1",
    "Description": "8s5"
  },
],
"Prompts": [
  {
    "Scenario": "06hu6AVON92",
    "Message": "TnNySWLzk"
  }
],
"MaxInputTokenLength": 472,
"SystemPrompt": {
  "Message": "YIs",
  "ModificationAllowed": true,
  "MaxInputTokenLength": 525
},
"CustomizationJobSettings": {
  "SftSettings": {
    "Enabled": false,
    "SupportPresetDatasets": [
      {
        "Name": "j4",
        "Description": "U",
        "SampleCount": 49,
        "Labelled": false
      }
    ],
  },
  "Parameters": [
    {
      "Type": "String",
      "Name": "jYndBB",
      "DisplayName": "n",
      "Min": "266KPg1Twd",
      "Max": "ApLxU3",
      "Options": [
        "4"
      ],
      "DefaultValue": "7mzh7VQhze",
      "Description": "x1JwQHNDsKF",
      "IncrementalLearningLocked": false
    }
  ],
},
"LoraSettings": {
  "Enabled": true,
  "SupportPresetDatasets": [
```

```
{
  "Name": "FT3GVuNzHW",
  "Description": "AhiLwldfe6",
  "SampleCount": 521,
  "Labelled": true
},
{
  "Parameters": [
    {
      "Type": "String",
      "Name": "Y2nq7r",
      "DisplayName": "wLUKKddH1NN",
      "Min": "0kstzmQoY",
      "Max": "0VOtfU0Ki",
      "Options": [
        "EfnCdO"
      ],
      "DefaultValue": "R7QWG",
      "Description": "THT",
      "IncrementalLearningLocked": true
    }
  ],
  "ContinuePretrainSettings": {
    "Enabled": false,
    "SupportPresetDatasets": [
      {
        "Name": "vQQpQ5NLDDW",
        "Description": "TGezbHr",
        "SampleCount": 734,
        "Labelled": true
      }
    ],
    "Parameters": [
      {
        "Type": "String",
        "Name": "duxuPkFd",
        "DisplayName": "Gq1MbSizUk",
        "Min": "Bn0VW8ksTt",
        "Max": "DfqFVfmwG",
        "Options": [
          "MoqPrr"
        ],
        "DefaultValue": "6",
        "Description": "KIFatHpb5",
        "IncrementalLearningLocked": true
      }
    ]
  }
}
```

```
json  ]
      }
    },
    "Status": "Tested",
    "CreateTime": "2006-01-02T15:04:05Z07:00",
    "UpdateTime": "2006-01-02T15:04:05Z07:00"
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。



# 12.5.5 GetFoundationModel – 获取基础模型信息

获取基础模型详细信息

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: GetFoundationModel  
要执行的操作，取值：GetFoundationModel。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值：2024-01-01。

**Name** string %%require%% 示例值: doubao-seed-2-0-pro  
基础模型名称

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Name** string 示例值: doubao-seed-2-0-pro  
基础模型名称

**Description** string 示例值: 一条样例描述  
基础模型描述

**Introduction** string 示例值: 一条模型介绍  
基础模型介绍

**VendorName** string 示例值: 字节跳动  
基础模型提供方名称

**DisplayName** string 示例值: Doubao-Seed-2.0-pro  
基础模型展示名

**FeaturedImage** object 示例值: \-  
基础模型显示图片

**BucketName** string  
TOS桶名称  
在创建和选择 TOS 桶时请注意，当前火山方舟只支持 华北2-北京 地域（region: cn-beijing）的存储桶。

**ObjectKey** string

TOS对象路径

**PrimaryVersion** string 示例值: 260215

基础模型主版本

**AccessType** string 示例值: Public

基础模型访问模式。可指定值:

- Public 公开模型
- Private 非公开模型

**FoundationModelTag** object 示例值: \-

基础模型特定标签

**Languages** string[]

基础模型支持语言列表

**UsedLibraries** string[]

基础模型使用库列表

**TaskTypes** string[]

基础模型支持任务类型列表

"TextGeneration": "文本生成",  
"VisualQuestionAnswering": "图片内容理解",  
"TextToImage": "文生图",  
"ImageToImage": "图生图",  
"TextToVideo": "文生视频",  
"ImageToVideo": "图生视频",  
"TextTo3D": "文生 3D",  
"ImageTo3D": "图生 3D",  
"VoiceClone": "声音复刻",  
"TextToSpeech": "文本转语音",  
"SpeechToText": "语音转文本",  
"SpeechToSpeech": "同声传译",  
"TextEmbedding": "文本向量化",  
"ImageEmbedding": "图像向量化",  
"MultimodalEmbedding": "多模态向量化"

**Domains** string[]

基础模型支持领域列表

- LLM: 大语言模型
- Audio: 语音大模型
- ComputerVision: 视觉大模型
- MultiModal: 多模态
- Embedding: 向量模型
- VLM: VLM 模型

**Tags** object[] 示例值: \-

基础模型绑定的标签

**Key string**  
标签键

**Value string**  
标签值

**ProjectName string** 示例值: default  
项目名称

**CreateTime string** 示例值: 2006-01-02T15:04:05Z07:00  
基础模型创建时间, RFC3339格式

**UpdateTime string** 示例值: 2006-01-02T15:04:05Z07:00  
基础模型更新时间, RFC3339格式

请求示例

```
text

POST /?Action=GetFoundationModel&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240514T125935Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240514/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Name": "doubao-seed-2-0-pro"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240514205945172013199191467134",
    "Action": "GetFoundationModel",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Name": "doubao-seed-2-0-pro",
```

```
json {
  "Description": "一条样例描述",
  "Introduction": "一条模型介绍",
  "VendorName": "字节跳动",
  "DisplayName": "Doubao-Seed-2.0-pro",
  "FeaturedImage": {
    "ObjectKey": "S6",
    "BucketName": "HmD3AI0Qtk"
  },
  "PrimaryVersion": "260215",
  "AccessType": "Public",
  "FoundationModelTag": {
    "Languages": [
      "MyWisEPDOwb"
    ],
    "TaskTypes": [
      "jrP2OnqQxvA"
    ],
    "CustomizedTags": [
      "XX"
    ],
    "Domains": [
      "qdZtggWYIF"
    ],
    "UsedLibraries": [
      "wmD0DcjlWe"
    ]
  },
  "Tags": [
    {
      "Key": "fok3iEEzKOZ",
      "Value": "ewCYfJcTR3"
    }
  ],
  "ProjectName": "default",
  "CreateTime": "2006-01-02T15:04:05Z07:00",
  "UpdateTime": "2006-01-02T15:04:05Z07:00"
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.6 管理模型评测任务

### 12.6.1 TerminateEvaluationJob – 停止评测任务

停止评测任务

#### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型      | 是否必填 | 示例值                    | 描述                                              |
|---------|---------|------|------------------------|-------------------------------------------------|
| Action  | String  | 是    | TerminateEvaluationJob | 要执行的操作，取值：TerminateEvaluationJob。               |
| Version | String  | 是    | 2024-01-01             | API的版本，取值：2024-01-01。                           |
| Id      | String  | 是    | -                      | 模型评测任务的ID                                       |
| DryRun  | Boolean | 否    | -                      | 是否仅对此请求进行预检。取值：- true：发送检查请求。- false(默认)：发送正常请求 |

#### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

#### 请求示例

```
text
{
  "Id": "ej-20240326055320-x9k2h"
}
```

#### 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "2024041114371255CBA34B3A081E45B13E",
    "Action": "TerminateEvaluationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.6.2 GetEvaluationJob – 获取评测任务

获取评测任务

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数      | 类型     | 是否必填 | 示例值                  | 描述                          |
|---------|--------|------|----------------------|-----------------------------|
| Action  | String | 是    | GetEvaluationJob     | 要执行的操作，取值：GetEvaluationJob。 |
| Version | String | 是    | 2024-01-01           | API的版本，取值：2024-01-01。       |
| Id      | String | 是    | ej-202403***<br>_*** | 模型评测任务的ID                   |

### 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#) .

| 参数          | 类型     | 示例值 | 描述        |
|-------------|--------|-----|-----------|
| Id          | String | –   | 模型评测任务的ID |
| Name        | String | –   | 模型评测任务名称  |
| Description | String | –   | 模型评测任务描述  |

| 参数                                                                                                    | 类型     | 示例值 | 描述                         |
|-------------------------------------------------------------------------------------------------------|--------|-----|----------------------------|
|  ModelReference      | Object | -   | 模型评测任务的对象                  |
|  FoundationModel     | Object |     | 基础模型                       |
| Name                                                                                                  | String |     | 基础模型名称                     |
| ModelVersion                                                                                          | String |     | 基础模型版本                     |
| CustomModelId                                                                                         | String |     | 定制模型的ID                    |
| EndpointId                                                                                            | String | -   | 模型评测任务对应接入点的ID             |
|  ResultTosLocation | Object | -   | 模型评测任务运行成功后，对应评测结果的 TOS 地址 |
| ObjectKey                                                                                             | String |     | TOS对象路径                    |
| BucketName                                                                                            | String |     | TOS桶名称                     |
|  Status            | Object | -   | 模型评测任务的状态元信息               |
| Phase                                                                                                 | String |     | 模型评测任务的状态                  |
|                                                                                                       |        |     |                            |



| 参数                                                                                     | 类型              | 示例值 | 描述                     |
|----------------------------------------------------------------------------------------|-----------------|-----|------------------------|
| PhaseTime                                                                              | String          |     | 模型评测任务状态更新时间，RFC3339格式 |
| Message                                                                                | String          |     | 模型评测任务状态信息             |
|  Tags | Array of Object | -   | 模型评测任务绑定的标签            |
| Key                                                                                    | String          |     | 标签键                    |
| Value                                                                                  | String          |     | 标签值                    |
| ProjectName                                                                            | String          | -   | 项目名称                   |
| CreateTime                                                                             | String          | -   | 模型评测任务创建时间，RFC3339格式   |
| UpdateTime                                                                             | String          | -   | 模型评测任务更新时间，RFC3339格式   |

请求示例

```
POST /?Action=GetEvaluationJob&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250115T084133Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250115/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "text": "ej-202403***_***"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202501151641402430430002397DF4EA",
    "Action": "GetEvaluationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "\\-",
    "Name": "\\-",
    "Description": "\\-",
    "ModelReference": {
      "FoundationModel": {
        "Name": "n",
        "ModelVersion": "29X"
      },
      "CustomModelId": "ftsdB6bWlwP"
    },
    "EndpointId": "\\-",
    "ResultTosLocation": {
      "ObjectKey": "u",
      "BucketName": "b0E4M6"
    },
    "Status": {
      "Phase": "tpAZR4zz",
      "PhaseTime": "WDhjJFhv",
      "Message": "ntacqOQV3aw"
    },
    "Tags": [
      {
        "Key": "VERVg5xFVF",
        "Value": "dxhO22I"
      }
    ],
    "ProjectName": "\\-",
    "CreateTime": "\\-",
    "UpdateTime": "\\-"
  }
}
```

```
json
{
}
```

错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.6.3 ListEvaluationJobs – 获取评测任务列表

获取评测任务列表1

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数         | 类型      | 是否必填 | 示例值                | 描述                                                                                                           |
|------------|---------|------|--------------------|--------------------------------------------------------------------------------------------------------------|
| Action     | String  | 是    | ListEvaluationJobs | 要执行的操作，取值：ListEvaluationJobs。                                                                                |
| Version    | String  | 是    | 2024-01-01         | API的版本，取值：2024-01-01。                                                                                        |
| PageNumber | Integer | 否    | -                  | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                      |
| PageSize   | Integer | 否    | -                  | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
| SortOrder  | String  | 否    | -                  | 指定排序顺序。可指定值： <ul style="list-style-type: none"><li>· Asc：升序排列</li></ul>                                      |

| 参数                                                                                                   | 类型              | 是否必填 | 示例值        | 描述                                                                                                                                                                         |
|------------------------------------------------------------------------------------------------------|-----------------|------|------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                                      |                 |      |            | · Desc: 降序排列                                                                                                                                                               |
| SortBy                                                                                               | String          | 否    | CreateTime | 指定排序指标。可指定值:<br><br>· CreateTime: 创建时间<br>· UpdateTime: 更新时间                                                                                                               |
|  TagFilters         | Array of Object | 否    | -          | 基于绑定的标签的筛选条件                                                                                                                                                               |
| Key                                                                                                  | String          | 是    |            | 标签键                                                                                                                                                                        |
| Values                                                                                               | Array of String | 否    |            | 标签值                                                                                                                                                                        |
| ProjectName                                                                                          | String          | 否    | -          | · 资源所属的项目名称，默认值为 default。<br>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看 <a href="#">文档</a>  . |
|  Filter           | Object          | 否    | -          | 待查询模型评测任务的筛选条件                                                                                                                                                             |
|  FoundationModels | Array of Object | 否    |            | 基础模型                                                                                                                                                                       |

| 参数             | 类型              | 是否必填 | 示例值 | 描述              |
|----------------|-----------------|------|-----|-----------------|
| Name           | String          | 是    |     | 基础模型名称          |
| ModelVersions  | Array of String | 否    |     | 基础模型版本          |
| Ids            | Array of String | 否    |     | 指定模型评测任务的ID     |
| Id             | String          | 否    |     | 模糊搜索模型评测任务的ID   |
| CustomModelIds | Array of String | 否    |     | 模型评测任务对应定制模型的ID |
| Name           | String          | 否    |     | 模糊搜索模型评测任务名称    |
| Description    | String          | 否    |     | 模糊搜索模型评测任务描述    |
| Phases         | Array of String | 否    |     | 指定模型评测任务的状态值    |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数         | 类型      | 示例值 | 描述                       |
|------------|---------|-----|--------------------------|
| PageNumber | Integer | -   | 分页查询时的起始页码，从 1 开始，默认为 1。 |
|            |         |     |                          |

| 参数                                                                                                   | 类型              | 示例值 | 描述                                                                                                              |
|------------------------------------------------------------------------------------------------------|-----------------|-----|-----------------------------------------------------------------------------------------------------------------|
| PageSize                                                                                             | Integer         | -   | 分页查询时每页显示的记录数，取值：<br><ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
| TotalCount                                                                                           | Integer         | -   | 总模型评测结果数                                                                                                        |
|  Items              | Array of Object | -   | 模型评测任务数组                                                                                                        |
| Id                                                                                                   | String          |     | 模型评测任务的ID                                                                                                       |
| Name                                                                                                 | String          |     | 模型评测任务名称                                                                                                        |
| Description                                                                                          | String          |     | 模型评测任务描述                                                                                                        |
|  ModelReference   | Object          |     | 模型评测任务的对象                                                                                                       |
| CustomModelId                                                                                        | String          |     | 定制模型的ID                                                                                                         |
|  Foundation Model | Object          |     | 基础模型                                                                                                            |
| Name                                                                                                 | String          |     | 基础模型名称。<br><ul style="list-style-type: none"><li>· 请注意模型名称为小写。</li><li>· doubao 1.5 代模型的模型名称格式为</li></ul>       |

| 参数                                                                                         | 类型              | 示例值 | 描述                                                                            |
|--------------------------------------------------------------------------------------------|-----------------|-----|-------------------------------------------------------------------------------|
|                                                                                            |                 |     | "doubao-1-5-***"。<br>举例： "Doubao-1.5-pro-32k" 模型Name字段为 "doubao-1-5-pro-32k"。 |
| ModelVersion                                                                               | String          |     | 基础模型版本                                                                        |
| EndpointId                                                                                 | String          |     | 评测任务对应的接入点的ID                                                                 |
| ResultTosLocation                                                                          | String          |     | 模型评测任务结果的 TOS 地址                                                              |
|  Status | Object          |     | 模型评测任务的状态元信息                                                                  |
| Phase                                                                                      | String          |     | 模型评测任务的状态                                                                     |
| PhaseTime                                                                                  | String          |     | 模型评测任务状态更新时间，RFC3339格式                                                        |
| Message                                                                                    | String          |     | 模型评测任务状态信息                                                                    |
|  Tags   | Array of Object |     | 模型评测任务绑定的标签                                                                   |
| Key                                                                                        | String          |     | 标签键                                                                           |
| Value                                                                                      | String          |     |                                                                               |



| 参数          | 类型     | 示例值 | 描述                   |
|-------------|--------|-----|----------------------|
|             |        |     | 标签值                  |
| ProjectName | String |     | 项目名称                 |
| CreateTime  | String |     | 模型评测任务创建时间，RFC3339格式 |
| UpdateTime  | String |     | 模型评测任务更新时间，RFC3339格式 |

请求示例

```
text
{
  "PageNumber": 1,
  "PageSize": 1,
  "SortOrder": "Asc",
  "SortBy": "CreateTime",
  "TagFilters": [],
  "ProjectName": "default",
  "Filter": {
    "Phases": [
      "Finished"
    ]
  }
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20240411145356A067F3B9F09679456C28",
    "Action": "ListEvaluationJobs",
    "Version": "2024-01-01",
```

```
json  "Service": "ark",
      "Region": "cn-beijing"
    },
    "Result": {
      "TotalCount": 10,
      "PageNumber": 1,
      "PageSize": 10,
      "Items": [
        {
          "Id": "ej-20240401114848-w5b8f",
          "Name": "eval-job-20240401194800-0",
          "Description": "",
          "ModelReference": {
            "CustomModelId": "cm-20240401114541-5gzd8"
          },
          "EndpointId": "ep-20240401114848-hzfcz",
          "ResultTosLocation": {
            "BucketName": "ark-auto-created-required-0123456789-cn-beijing",
            "ObjectKey": "ark/ej-20240401114848-w5b8f/inference_result/results/"
          },
          "Status": {
            "Phase": "Finished",
            "PhaseTime": "2024-04-01T11:54:41Z",
            "RetryCount": 0,
            "Message": "评测任务已完成"
          },
          "Tags": [
            {
              "Key": "sys:ark:createdBy",
              "Value": "IAMUser/1234567/fabianlimxuhuai@acme.com"
            }
          ],
          "ProjectName": "default",
          "CreateTime": "2024-04-01T11:48:48Z",
          "UpdateTime": "2024-04-01T11:54:41Z"
        }
      ]
    }
  }
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

# 12.6.4 CreateEvaluationJob – 创建评测任务

创建评测任务

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数                                                                                                      | 类型              | 是否必填 | 示例值                 | 描述                             |
|---------------------------------------------------------------------------------------------------------|-----------------|------|---------------------|--------------------------------|
| Action                                                                                                  | String          | 是    | CreateEvaluationJob | 要执行的操作，取值：CreateEvaluationJob。 |
| Version                                                                                                 | String          | 是    | 2024-01-01          | API的版本，取值：2024-01-01。          |
| Name                                                                                                    | String          | 是    | 测试任务                | 模型评测任务名称                       |
| Description                                                                                             | String          | 否    | 这是一个测试任务            | 模型评测任务描述                       |
| EndpointId                                                                                              | String          | 是    | ep-*-               | 接入点 ID                         |
|  Evaluation Datasets | Array of Object | 是    | -                   | 模型评测任务的评测集                     |
| EvaluationAbility                                                                                       | String          | 否    |                     | 评测集评测的能力维度                     |
|                                                                                                         |                 |      |                     |                                |

| 参数                                                                                            | 类型      | 是否必填 | 示例值     | 描述                                                                                                                                                                                                                           |
|-----------------------------------------------------------------------------------------------|---------|------|---------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ScoringWeight                                                                                 | Integer | 否    |         | 评测集的评测分数比重                                                                                                                                                                                                                   |
| Method                                                                                        | String  | 是    |         | 评测算法                                                                                                                                                                                                                         |
| AdminEvaluationDatasetId                                                                      | String  | 否    |         | 平台预置评测集的ID                                                                                                                                                                                                                   |
| DatasetType                                                                                   | String  | 是    | 自动评测    | 评测任务类型                                                                                                                                                                                                                       |
|  TosLocation | Object  | 否    |         | 用户从TOS导入的评测集在TOS中的储存位置                                                                                                                                                                                                       |
| ObjectKey                                                                                     | String  | 是    |         | TOS对象路径                                                                                                                                                                                                                      |
| BucketName                                                                                    | String  | 是    |         | TOS桶名称                                                                                                                                                                                                                       |
| DryRun                                                                                        | Boolean | 否    | false   | 是否仅对此请求进行预检。取值：<br><ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求</li></ul>                                                                                                                 |
| ProjectName                                                                                   | String  | 否    | default | <ul style="list-style-type: none"><li>· 资源所属的项目名称，默认值为default。</li><li>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a> .</li></ul> |

| 参数                                                                                     | 类型              | 是否必填 | 示例值 | 描述          |
|----------------------------------------------------------------------------------------|-----------------|------|-----|-------------|
|  Tags | Array of Object | 否    | -   | 模型评测任务绑定的标签 |
| Key                                                                                    | String          | 是    |     | 标签键         |
| Value                                                                                  | String          | 是    |     | 标签值         |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数 | 类型     | 示例值       | 描述        |
|----|--------|-----------|-----------|
| Id | String | 20240**** | 模型评测任务的ID |

请求示例

```
text
{
  "Name": "测试任务",
  "EndpointId": "ep-***-***",
  "EvaluationDatasets": [
    {
      "Method": "pA",
      "DatasetType": "自动评测"
    }
  ]
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202404111449574CC61570F45B511EF0FC",
```

```
json  "Action": "CreateEvaluationJob",  
      "Version": "2024-01-01",  
      "Service": "ark",  
      "Region": "cn-beijing"  
    },  
    "Result": {  
      "Id": "ej-20240411064957-hxj6z"  
    }  
  }
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.6.5 UpdateEvaluationJob – 更新评测任务

更新评测任务1

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型      | 是否必填 | 示例值                 | 描述                                                                                                        |
|-------------|---------|------|---------------------|-----------------------------------------------------------------------------------------------------------|
| Action      | String  | 是    | UpdateEvaluationJob | 要执行的操作，取值：UpdateEvaluationJob。                                                                            |
| Version     | String  | 是    | 2024-01-01          | API的版本，取值：2024-01-01。                                                                                     |
| Id          | String  | 是    | -                   | 模型评测任务的ID                                                                                                 |
| Name        | String  | 否    | -                   | 模型评测任务名称                                                                                                  |
| Description | String  | 否    | -                   | 模型评测任务描述                                                                                                  |
| DryRun      | Boolean | 否    | -                   | 是否仅对此请求进行预检。取值： <ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求</li></ul> |

| 参数 | 类型 | 是否必填 | 示例值 | 描述 |
|----|----|------|-----|----|
|    |    |      |     |    |

返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

请求示例

```
text
{
  "Id": "ej-20240326054800-gl9rp",
  "Name": "updated-evaluation-job-name",
  "Description": "updated-evaluation-job-description"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "202404111451146E8586AD2EFA454F410C",
    "Action": "UpdateEvaluationJob",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

错误码

您可访问[公共错误码](#)，获取更多错误码信息。



## 12.6.6 ListEvaluationResults – 获取评测任务结果列表

获取评测任务结果列表

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数         | 类型      | 是否必填 | 示例值                   | 描述                                                                                                           |
|------------|---------|------|-----------------------|--------------------------------------------------------------------------------------------------------------|
| Action     | String  | 是    | ListEvaluationResults | 要执行的操作，取值：ListEvaluationResults。                                                                             |
| Version    | String  | 是    | 2024-01-01            | API的版本，取值：2024-01-01。                                                                                        |
| PageNumber | Integer | 否    | -                     | 分页查询时的起始页码，从 1 开始，默认为 1                                                                                      |
| PageSize   | Integer | 否    | -                     | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
| SortOrder  | String  | 否    | -                     | 指定排序顺序。可指定值： <ul style="list-style-type: none"><li>· Asc：升序排列</li><li>· Desc：降序排列</li></ul>                  |
| SortBy     | String  | 否    | CreateTime            | 指定排序指标。可指定值： <ul style="list-style-type: none"><li>· CreateTime：创建时间</li></ul>                               |

| 参数                                                                                       | 类型              | 是否必填 | 示例值 | 描述                                                                                                                                                                                                                          |
|------------------------------------------------------------------------------------------|-----------------|------|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                          |                 |      |     | <ul style="list-style-type: none"><li>· UpdateTime：更新时间</li></ul>                                                                                                                                                           |
| ProjectName                                                                              | String          | 否    | -   | <ul style="list-style-type: none"><li>· 资源所属的项目名称，默认值为 default。</li><li>· 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看<a href="#">文档</a> .</li></ul> |
|  Filter | Object          | 否    | -   | 待查询模型评测结果的筛选条件                                                                                                                                                                                                              |
| Ids                                                                                      | Array of String | 否    |     | 指定模型评测任务的ID                                                                                                                                                                                                                 |
| EvaluationAbilities                                                                      | Array of String | 否    |     | 模型评测任务的评测能力维度                                                                                                                                                                                                               |
| EvaluationJobId                                                                          | String          | 是    | -   | 模型评测任务的ID                                                                                                                                                                                                                   |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#) .

| 参数         | 类型      | 示例值 | 描述                      |
|------------|---------|-----|-------------------------|
| TotalCount | Integer | -   | 总评测结果数                  |
| PageNumber | Integer | -   | 分页查询时的起始页码，从 1 开始，默认为 1 |
| PageSize   | Integer |     |                         |

| 参数                                                                                                     | 类型              | 示例值 | 描述                                                                                                           |
|--------------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------------------------------------------------------------------------------------------|
|                                                                                                        |                 | -   | 分页查询时每页显示的记录数，取值： <ul style="list-style-type: none"><li>· 最小值：1</li><li>· 最大值：100</li><li>· 默认值：10</li></ul> |
|  Items                | Array of Object | -   | 模型评测结果                                                                                                       |
| Id                                                                                                     | String          |     | 模型评测结果的ID                                                                                                    |
| EvaluationJobId                                                                                        | String          |     | 模型评测任务的ID                                                                                                    |
| DatasetType                                                                                            | String          |     | 评测集种类                                                                                                        |
| AdminEvaluationDatasetId                                                                               | String          |     | 预置评测集的ID                                                                                                     |
| DatasetName                                                                                            | String          |     | 评测集名称                                                                                                        |
| DatasetDisplayName                                                                                     | String          |     | 评测集展示名称                                                                                                      |
| EvaluationAbility                                                                                      | String          |     | 模型评测结果的评测维度                                                                                                  |
| ScoringWeight                                                                                          | String          |     | 模型评测结果的分数比重                                                                                                  |
|  DatasetTosLocation | Object          |     | 自定义评测集的 TOS 地址                                                                                               |
|                                                                                                        |                 |     |                                                                                                              |

| 参数                                                                                                     | 类型              | 示例值 | 描述                       |
|--------------------------------------------------------------------------------------------------------|-----------------|-----|--------------------------|
| ObjectKey                                                                                              | String          |     | TOS对象路径                  |
| BucketName                                                                                             | String          |     | TOS桶名称                   |
| Method                                                                                                 | String          |     | 评测算法                     |
|  Metrics              | Array of Object |     | 模型评测结果指标                 |
| Name                                                                                                   | String          |     | 模型评测结果指标名称               |
| Value                                                                                                  | Double          |     | 模型评测结果指标分数               |
|  TokenUsage         | Object          |     | 模型评测结果的 token 消耗量        |
| PromptTokenCount                                                                                       | Integer         |     | 模型评测 prompt 的总 token 数   |
| ResponseTokenCount                                                                                     | Integer         |     | 模型评测 response 的总 token 数 |
| TotalTokenCount                                                                                        | Integer         |     | 模型评测的总 token 数           |
|  SamplesTosLocation | Object          |     | 模型评测结果样本的 TOS 地址         |
| ObjectKey                                                                                              | String          |     | TOS对象路径                  |

| 参数         | 类型     | 示例值 | 描述                    |
|------------|--------|-----|-----------------------|
| BucketName | String |     | TOS桶名称                |
| CreateTime | String |     | 模型评测结果的创建时间，RFC3339格式 |
| UpdateTime | String |     | 模型评测结果的更新时间，RFC3339格式 |

请求示例

```
text
{
  "EvaluationJobId": "ej-20240326054800-gl9rp",
  "PageNumber": 1,
  "PageSize": 1,
  "SortOrder": "Desc",
  "SortBy": "CreateTime"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202404111456299465E1DB51F5B325605A",
    "Action": "ListEvaluationResults",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 1,
    "Items": [
      {
```

```
json  {"Id": "er-20240326054800-shhvj",
      "EvaluationJobId": "ej-20240326054800-gl9rp",
      "DatasetType": "AdminDataset",
      "AdminEvaluationDatasetId": "aed-20240227112053-bt425",
      "DatasetName": "ark-ff-mmlu-other-5shots",
      "DatasetDisplayName": "MMLU 其他学科",
      "EvaluationAbility": "MMLU",
      "ScoringWeight": 3107,
      "Method": "BuiltIn",
      "Metrics": null,
      "TokenUsage": {
        "TotalTokenCount": 0
      },
      "SamplesTosLocation": {
        "BucketName": "",
        "ObjectKey": ""
      },
      "CreateTime": "2024-03-26T05:48:00Z",
      "UpdateTime": "2024-03-26T05:48:00Z"
    }
  ]
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.6.7 DeleteEvaluationJob – 删除评测任务

删除评测任务

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数      | 类型      | 是否必填 | 示例值                 | 描述                                                                                                        |
|---------|---------|------|---------------------|-----------------------------------------------------------------------------------------------------------|
| Action  | String  | 是    | DeleteEvaluationJob | 要执行的操作，取值：DeleteEvaluationJob。                                                                            |
| Version | String  | 是    | 2024-01-01          | API的版本，取值：2024-01-01。                                                                                     |
| Id      | String  | 是    | -                   | 模型评测任务的ID                                                                                                 |
| DryRun  | Boolean | 否    | -                   | 是否仅对此请求进行预检。取值： <ul style="list-style-type: none"><li>· true：发送检查请求。</li><li>· false(默认)：发送正常请求</li></ul> |

### 返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#) .

### 请求示例

text

```
{  
  "Id": "ej-20240314132354-rvsrg"  
}
```

## 返回示例

json

```
{  
  "ResponseMetadata": {  
    "RequestId": "20240101000000046C7CCC3CCCE87016E3",  
    "Action": "DeleteEvaluationJob",  
    "Version": "2024-01-01",  
    "Service": "ark",  
    "Region": "cn-beijing"  
  },  
  "Result": {}  
}
```

## 错误码

您可访问[公共错误码](#)，获取更多错误码信息。



## 12.6.8 GetEvaluationResult – 获取评测任务结果

获取评测任务结果

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

| 参数      | 类型     | 是否必填 | 示例值                 | 描述                             |
|---------|--------|------|---------------------|--------------------------------|
| Action  | String | 是    | GetEvaluationResult | 要执行的操作，取值：GetEvaluationResult。 |
| Version | String | 是    | 2024-01-01          | API的版本，取值：2024-01-01。          |
| Id      | String | 是    | -                   | 模型评测结果的ID                      |

### 返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

| 参数              | 类型     | 示例值 | 描述                 |
|-----------------|--------|-----|--------------------|
| Id              | String | -   | 模型评测结果的ID          |
| EvaluationJobId | String | -   | 模型评测结果对应的模型评测任务的ID |
| DatasetType     | String | -   |                    |

| 参数                                                                                                     | 类型      | 示例值 | 描述                |
|--------------------------------------------------------------------------------------------------------|---------|-----|-------------------|
|                                                                                                        |         |     | 模型评测结果对应的评测集种类    |
| AdminEvaluationDatasetId                                                                               | String  | -   | 模型评测结果对应的预置评测集的ID |
| DatasetName                                                                                            | String  | -   | 模型评测结果对应的评测集名称    |
| DatasetDisplayName                                                                                     | String  | -   | 模型评测结果对应的评测集展示名称  |
| EvaluationAbility                                                                                      | String  | -   | 模型评测结果对应的评测集的能力维度 |
| ScoringWeight                                                                                          | Integer | -   | 模型评测结果的分数比重       |
|  DatasetTosLocation | Object  | -   | 用户自定义数据集的 TOS 地址  |
| ObjectKey                                                                                              | String  |     | TOS对象路径           |
| BucketName                                                                                             | String  |     | TOS桶名称            |
| Method                                                                                                 | String  | -   | 评测算法              |
|  Metrics            | Object  | -   | 模型评测结果指标          |

| 参数                                                                                                    | 类型      | 示例值 | 描述                          |
|-------------------------------------------------------------------------------------------------------|---------|-----|-----------------------------|
| Name                                                                                                  | String  |     | 模型评测结果指标名称                  |
| Value                                                                                                 | Double  |     | 模型评测结果指标分数                  |
|  TokenUsage          | Object  | -   | 模型评测结果总 token 消耗量           |
| PromptTokenCount                                                                                      | Integer |     | 模型评测 prompt 的总 token 数      |
| ResponseTokenCount                                                                                    | Integer |     | 模型评测 response 的总 token 数    |
| TotalTokenCount                                                                                       | Integer |     | 模型评测的总 token 数              |
|  SampleTosLocation | Object  | -   | 模型评测结果文件的 TOS 地址（最多 50 条样本） |
| ObjectKey                                                                                             | String  |     | TOS对象路径                     |
| BucketName                                                                                            | String  |     | TOS桶名称                      |
| CreateTime                                                                                            | String  | -   | 模型评测结果创建时间，RFC3339格式        |

| 参数         | 类型     | 示例值 | 描述                   |
|------------|--------|-----|----------------------|
| UpdateTime | String | -   | 模型评测结果更新时间，RFC3339格式 |

请求示例

```
text
{
  "Id": "er-20240326054800-shhvj"
}
```

返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202404111438083076CAB39885F31BD671",
    "Action": "GetEvaluationResult",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Id": "er-20240326054800-shhvj",
    "EvaluationJobId": "ej-20240326054800-gl9rp",
    "DatasetType": "AdminDataset",
    "AdminEvaluationDatasetId": "aed-20240227112053-bt425",
    "DatasetName": "ark-ff-mmlu-other-5shots",
    "DatasetDisplayName": "MMLU 其他学科",
    "EvaluationAbility": "MMLU",
    "ScoringWeight": 3107,
    "Method": "BuiltIn",
    "Metrics": null,
    "TokenUsage": {
      "TotalTokenCount": 0
    },
    "SamplesTosLocation": {
      "BucketName": "",
      "ObjectKey": ""
    }
  },
}
```

```
json  {"CreateTime": "2024-03-26T05:48:00Z",  
      "UpdateTime": "2024-03-26T05:48:00Z"  
      }
```

### 错误码

您可访问[公共错误码](#)，获取更多错误码信息。

## 12.7 安全审计

### 12.7.1 ListAuditLogs – 获取安全审计日志

支持对安全相关事件进行查询和审计，当前可审计事件包括安全沙箱登录、安全沙箱对外连接、安全沙箱容器逃逸、vArmor防护、KMS访问、TKS访问。

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: ListAuditLogs  
要执行的操作，取值: ListAuditLogs。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值: 2024-01-01。

**ProjectName** string 可选 示例值: \-

- 资源所属的项目名称，默认值为default。
- 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看[文档](#)。

**ResourceId** string %%require%% 示例值: ep-\*\*\*\*\*-&ast;&ast;&ast;&ast;&ast;  
资源 ID，取值范围:

- ep-\*\*\*\*\*-\*\*\*\*\* : 推理接入点ID
- mcj-\*\*\*\*\*-\*\*\*\*\* : 模型精调任务ID

**ResourceType** string %%require%% 示例值: endpoint  
资源类型，取值范围: endpoint, modelcustomizationjob

- endpoint: 推理接入点
- modelcustomizationjob: 模型精调任务

**Filter** object %%require%% 示例值: \-  
待查询审计日志的筛选条件

**EndTime** integer 可选 示例值: 1730710684  
查询日志结束时间

**StartTime** integer 可选 示例值: 1722761884  
查询日志起始时间

**RiskLevels** string[] 可选 示例值: Info

风险等级，取值范围：Info, Low, Medium, High, Critical

- Info：正常的事件
- Low：低风险事件
- Medium：中风险事件
- High：高风险事件
- Critical：严重风险事件

**Conditions** object[] 可选

ListAuditLogsCondition

**Field** string %%require%%

Field

**Operator** string %%require%%

Operator

**Value** string %%require%%

Value

**LogType** string %%require%% 示例值: SshLogin

日志类型，取值范围: SshLogin, ContainerLogin, Connection, ContainerBreakout, VarmorDefence, KMSAccess, TksAccess。

- SshLogin：Ssh登录到安全沙箱的日志
- ContainerLogin：本地登录到安全沙箱的日志
- Connection：安全沙箱对外的网络连接日志
- ContainerBreakout：安全沙箱容器逃逸日志
- VarmorDefence：vArmor防护日志
- KMSAccess：KMS访问日志
- TksAccess：Trusted Key Service(TKS)密钥的访问/使用日志。(注意：该功能为内测收费功能，如有需求，请联系您的销售经理启用功能。)

**PageNumber** integer 可选 示例值: 1

分页查询时的起始页码，从 1 开始，默认为 1

**PageSize** integer 可选 示例值: 10

分页查询时每页显示的记录数，取值：

- 最小值：1
- 最大值：100
- 默认值：10

**SortBy** string 可选 示例值: Timestamp

指定排序指标。可指定值：

- Timestamp 审计的行为发生时间

默认值：Timestamp

**SortOrder** string 可选 示例值: Desc

指定排序顺序。可指定值:

- Asc: 升序排列
- Desc: 降序排列

默认值: Desc

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**TotalCount** integer 示例值: 1

总审计日志数

**PageNumber** integer 示例值: 1

分页查询时的起始页码, 从 1 开始, 默认为 1

**PageSize** integer 示例值: 10

分页查询时每页显示的记录数, 取值:

- 最小值: 1
- 最大值: 100
- 默认值: 10

**Items** object[] 示例值: \-

审计日志

**LogContents** object[] 示例值: \-

审计日志字段内容

**Key** string 示例值: SourceIP

日志字段名, 取值如:

- Arguments: 带参数的完整命令
- Command: 命令
- Process: 进程名
- Operation: vArmor防护日志的hook命令
- SSH: IP/Port 四元组
- Tag: 日志标签

**Value** string 示例值: curl

日志字段值, 取值如:

- curl 192.168.0.1: 对应Key为Arguments
- curl: 对应Key为Command
- /usr/bin/curl: 对应Key为Process
- cat: 对应Key为Operation
- 192.168.0.1 8122 192.168.0.2 22: 对应Key为SSH
- Docker: 对应Key为Tag



**RiskLevel** string 示例值: Info

风险等级, 取值范围: Info, Low, Medium, High, Critical

- Info: 正常的事件
- Low: 低风险事件
- Medium: 中风险事件
- High: 高风险事件
- Critical: 严重风险事件

**ResourceId** string 示例值: ep-\*\*\*\*\*-&ast;&ast;&ast;&ast;&ast;

资源 ID, 取值范围:

- ep-\*\*\*\*\*-\*\*\*\*\* : 推理接入点ID
- mcj-\*\*\*\*\*-\*\*\*\*\* : 模型精调任务ID

**ResourceType** string 示例值: endpoint

资源类型, 取值范围: endpoint, modelcustomizationjob

- endpoint: 推理接入点
- modelcustomizationjob: 模型精调任务

**LogType** string 示例值: SshLogin

日志类型, 取值范围: SshLogin, ContainerLogin, Connection, ContainerBreakout, VarmorDefence, KMSAccess, TksAccess。

- SshLogin: Ssh登录到安全沙箱的日志
- ContainerLogin: 本地登录到安全沙箱的日志
- Connection: 安全沙箱对外的网络连接日志
- ContainerBreakout: 安全沙箱容器逃逸日志
- VarmorDefence: vArmor防护日志
- KMSAccess: KMS访问日志
- TksAccess: Trusted Key Service(TKS)密钥的访问/使用日志。(注意: 当前功能为内测收费功能, 如有需求, 请联系您的销售经理启用功能。)

**LogDetail** string 示例值: 172.17.0.1 50030 172.17.0.4 22

审计日志详情。

- 对于日志类型为 SshLogin 审计日志, 展现的是登录方式、源IP/端口、目标IP/端口, 进程ID;
- 对于日志类型为 ContainerLogin 的审计日志, 展现的是登录方式、登录命令、源IP/端口、目标IP/端口;
- 对于日志类型为 Connection 的审计日志, 展现的是连接类型、连接状态、源IP/端口、目标IP/端口、进程名、进程ID;
- 对于日志类型为 ContainerLogin 的审计日志, 展现的是具体逃逸行为、命令、进程名、进程ID;
- 对于日志类型为 VarmorDefence 的审计日志, 展现的是命令、进程名、进程ID、触发防护的hook;
- 对于日志类型为 KMSAccess 的审计日志, 展现的是用户ID、密钥名称、加解密操作对象、加密或解密操作;
- 对于日志类型为 TksAccess 审计日志, 展现的是访问TKS密钥的访问方式, CreateTksKey为创建TKS密钥, GetTksKeyinfo为检查TKS密钥状态, ExportTksPubKey为请求TKS密钥的公钥, ExportTksKey为基于TEE环境远程证明报告请求TKS密钥的私钥。(注意: 当前功能为内测收费功能, 如有需求, 请联系您的销售经理启用功能。)

**Timestamp** string 示例值: 2024-05-16 12:00:00  
审计的行为发生的时间

## 请求示例 1

text

// 用于审计 SshLogin 行为

```
POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1
Host: https://open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240627T021205Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240627/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "SshLogin"
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

## 返回示例 1

```
{
  "ResponseMetadata": {
    "RequestId": "20240627101238231161005082456C1E",
    "Action": "ListAuditLogs",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,

```

```
json {
  "PageNumber": 1,
  "PageSize": 10,
  "Items": [
    {
      "ResourceId": "ep-*****_****",
      "ResourceType": "endpoint",
      "LogType": "SshLogin",
      "LogDetail": "存在通过未知源ssh登录安全沙箱容器的行为。源IP/端口: 10.0.26.52:35024;目标IP/端口: 10.0.26.52:12222;pid: 3058688",
      "LogContents": [
        {
          "Key": "Tag",
          "Value": "Unknown"
        },
        {
          "Key": "SSH",
          "Value": "10.0.26.52 35024 10.0.26.52 12222"
        },
        {
          "Key": "ProcessID",
          "Value": "3058688"
        },
        {
          "Key": "SandboxType",
          "Value": "DataPreprocess"
        }
      ],
      "RiskLevel": "Medium",
      "Timestamp": "2024-09-29T11:38:34Z"
    }
  ]
}
```

## 请求示例 2

// 用于审计 ContainerLogin 行为

POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1

Host: https://open.volcengineapi.com

Content-Type: application/json; charset=UTF-8

X-Date: 20240705T123158Z

X-Content-Sha256: 287e874e\*\*\*\*\*d653b44d21e

text  
Authorization: HMAC-SHA256 Credential=Adfks\*\*\*\*\*wekfwe/20240705/cn-beijing/ark/request,  
SignedHeaders=host;x-content-sha256;x-date,  
Signature=47a7d934ff7b37c03938\*\*\*\*\*cd7b8278a40a1057690c401e92246a0e41085f

```
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "ContainerLogin",
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

## 返回示例 2

```
{
  "ResponseMetadata": {
    "RequestId": "2024070520320624805701201829AFC4",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 10,
    "Items": [
      {
        "ResourceId": "ep-*****_*****",
        "ResourceType": "endpoint",
        "LogType": "ContainerLogin",
        "LogDetail": "存在从本地节点登录到安全沙箱容器的行为。登录方式: Docker;登录命令: docker  
exec -it ***** bash;源IP/端口: 192.168.0.1:50031;目标IP/端口: 192.168.1.2:22",
        "LogContents": [
          {
            "Key": "Tag",
            "Value": "Docker"
          },
          {
            "Key": "Arguments",

```

```
json      "Value": "docker exec -it ***** bash"
          },
          {
            "Key": "SSH",
            "Value": "192.168.0.1 50031 192.168.1.2 22"
          }
        ],
        "RiskLevel": "High",
        "Timestamp": "2024-10-25T12:05:36Z"
      }
    ]
  }
}
```

### 请求示例 3

text

// 用于审计 Connection 行为

POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1

Host: https://open.volcengineapi.com

Content-Type: application/json; charset=UTF-8

X-Date: 20240705T123428Z

X-Content-Sha256: 287e874e\*\*\*\*\*d653b44d21e

Authorization: HMAC-SHA256 Credential=Adfks\*\*\*\*\*wekfwe/20240705/cn-beijing/ark/request,

SignedHeaders=host;x-content-sha256;x-date,

Signature=47a7d934ff7b37c03938\*\*\*\*\*cd7b8278a40a1057690c401e92246a0e41085f

```
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "Connection",
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

### 返回示例 3

```
{
  "ResponseMetadata": {
    "RequestId": "202407052034340071951971433E0B1D",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 10,
    "Items": [
      {
        "ResourceId": "ep-*****_*****",
        "ResourceType": "endpoint",
        "LogType": "Connection",
        "LogDetail": "存在从安全沙箱容器向外进行网络连接的行为。连接类型:阻塞式;连接状态:成功;源IP/端口: 192.18.0.1:50031;目标IP/端口: 192.18.0.4:22;进程: curl;pid: 12345",
        "LogContents": [
          {
            "Key": "ProcessID",
            "Value": "12345"
          },
          {
            "Key": "SourceIP",
            "Value": "192.18.0.1"
          },
          {
            "Key": "SourcePort",
            "Value": "50031"
          },
          {
            "Key": "DestinationIP",
            "Value": "192.18.0.4"
          },
          {
            "Key": "DestinationPort",
            "Value": "22"
          },
          {
            "Key": "Tag",
            "Value": "Whitelisted,ConnectionSucceed,Blocking"
          },
          {
            "Key": "Process",
```

```
    "Value": "curl"
  },
],
"RiskLevel": "Info",
"Timestamp": "2024-10-25T12:04:33Z"
}
]
}
}
```

## 请求示例 4

text

// 用于审计 ContainerBreakout 行为

```
POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1
Host: https://open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241107T065420Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241107/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "ContainerBreakout"
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

## 返回示例 4

```
{
  "ResponseMetadata": {
    "RequestId": "202411071454251712321471146B325A",
  }
}
```

```
"Action": "ListAuditLogs",
"Version": "2024-01-01",
"Service": "ark",
"Region": "cn-beijing"
},
"Result": {
  "TotalCount": 1,
  "PageNumber": 1,
  "PageSize": 10,
  "Items": [
    {
      "ResourceId": "ep-*****_****",
      "ResourceType": "endpoint",
      "LogType": "ContainerBreakout",
      "LogDetail": "容器上存在连接Metadata Server的行为,疑似进行容器逃逸准备。用户: root;命令: curl;进程: /usr/bin/curl;pid: 13483",
      "LogContents": [
        {
          "Key": "Tag",
          "Value": "MetadataServer"
        },
        {
          "Key": "Command",
          "Value": "curl"
        },
        {
          "Key": "Username",
          "Value": "root"
        },
        {
          "Key": "ProcessID",
          "Value": "13483"
        },
        {
          "Key": "Process",
          "Value": "/usr/bin/curl"
        },
        {
          "Key": "SandboxType",
          "Value": ""
        }
      ],
      "RiskLevel": "Low",
      "Timestamp": "2024-10-25T12:03:36Z"
    }
  ]
}
```



```
}  
json  
}
```

## 请求示例 5

text

// 用于审计 VarmorDefence 行为

POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1

Host: https://open.volcengineapi.com

Content-Type: application/json; charset=UTF-8

X-Date: 20241107T064938Z

X-Content-Sha256: 287e874e\*\*\*\*\*d653b44d21e

Authorization: HMAC-SHA256 Credential=Adfks\*\*\*\*\*wekfwe/20241107/cn-beijing/ark/request,

SignedHeaders=host;x-content-sha256;x-date,

Signature=47a7d934ff7b37c03938\*\*\*\*\*cd7b8278a40a1057690c401e92246a0e41085f

```
{  
  "ResourceId": "ep-*****_*****",  
  "ResourceType": "endpoint",  
  "Filter": {  
    "LogType": "VarmorDefence"  
  },  
  "PageNumber": 1,  
  "PageSize": 10,  
  "SortBy": "Timestamp",  
  "SortOrder": "Desc"  
}
```

## 返回示例 5

```
{  
  "ResponseMetadata": {  
    "RequestId": "20241107144945135212178161E8A08E",  
    "Action": "ListAuditLogs",  
    "Version": "2024-01-01",  
    "Service": "ark",  
    "Region": "cn-beijing"  
  },  
  "Result": {  
    "TotalCount": 1,  

```

```
json {
  "PageNumber": 1,
  "PageSize": 10,
  "Items": [
    {
      "ResourceId": "ep-*****_****",
      "ResourceType": "endpoint",
      "LogType": "VarmorDefence",
      "LogDetail": "vArmor成功拦截了一次风险操作。命令: /usr/bin/cat;进程: 3659428;pid: cat;触发hook: open",
      "LogContents": [
        {
          "Key": "Command",
          "Value": "cat"
        },
        {
          "Key": "Operation",
          "Value": "open"
        },
        {
          "Key": "ProcessID",
          "Value": "3659428"
        },
        {
          "Key": "Process",
          "Value": "/usr/bin/cat"
        },
        {
          "Key": "SandboxType",
          "Value": ""
        }
      ],
      "RiskLevel": "Info",
      "Timestamp": "2024-10-25T12:05:36Z"
    }
  ]
}
```

## 请求示例 6

```
// 用于审计 KMSAccess 行为
```

```
POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1
```

```
text
Host: https://open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241107T073627Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241107/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "ResourceId": "ep-*****-&ast;&ast;&ast;&ast;&ast;",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "KMSAccess"
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

## 返回示例 6

```
{
  "ResponseMetadata": {
    "RequestId": "20241107153632061174073005C37DD8",
    "Action": "ListAuditLogs",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "TotalCount": 1,
    "PageNumber": 1,
    "PageSize": 10,
    "Items": [
      {
        "ResourceId": "ep-*****-&ast;&ast;&ast;&ast;&ast;",
        "ResourceType": "endpoint",
        "LogType": "KMSAccess",
        "LogDetail": "请求2100466578用户的datapipe_keyring/datapipe_key_ml_maas密钥，对基座模型doubao-pro-4k | 240909进行信封解密",
        "LogContents": [
          {
```

```
    "Key": "DataType",
    "Value": ""
  },
  {
    "Key": "RequestID",
    "Value": ""
  },
  {
    "Key": "CreateTime",
    "Value": "2024-09-09T09:22:41Z"
  },
  {
    "Key": "Operation",
    "Value": "decrypt"
  },
  {
    "Key": "ModelID",
    "Value": "doubao-pro-4k"
  },
  {
    "Key": "ModelVersion",
    "Value": "240909"
  },
  {
    "Key": "KmsAccountID",
    "Value": "2100466578"
  },
  {
    "Key": "KeyringName",
    "Value": "datapipe_keyring"
  },
  {
    "Key": "Phase",
    "Value": ""
  },
  {
    "Key": "ModelType",
    "Value": "base_model"
  },
  {
    "Key": "KeyName",
    "Value": "datapipe_key_ml_maas"
  }
],
"RiskLevel": "Info",
"Timestamp": "2024-09-09T09:22:41Z"
}
```

```
json]
}
```

## 请求示例 7

text

// 用于审计 TksAccess 行为

```
POST /?Action=ListAuditLogs&Version=2024-01-01 HTTP/1.1
Host: https://open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20240627T021205Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20240627/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "Filter": {
    "LogType": "TksAccess"
  },
  "PageNumber": 1,
  "PageSize": 10,
  "SortBy": "Timestamp",
  "SortOrder": "Desc"
}
```

## 返回示例 7

```
{
  "ResponseMetadata": {
    "RequestId": "202509221056016566EAF5A886F226338E",
    "Action": "ListAuditLogs",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
```

```
"TotalCount": 89,
"PageNumber": 1,
"PageSize": 10,
"Items": [
  {
    "ResourceId": "ep-*****_*****",
    "ResourceType": "endpoint",
    "LogType": "TksAccess",
    "LogDetail": "GetTksKeyinfo",
    "LogContents": [
      {
        "Key": "method",
        "Value": "GetTksKeyinfo"
      }
    ],
    "RiskLevel": "Info",
    "Timestamp": "2025-09-22T02:55:43Z"
  },
  {
    "ResourceId": "ep-*****_*****",
    "ResourceType": "endpoint",
    "LogType": "TksAccess",
    "LogDetail": "GetTksKeyinfo",
    "LogContents": [
      {
        "Key": "method",
        "Value": "GetTksKeyinfo"
      }
    ],
    "RiskLevel": "Info",
    "Timestamp": "2025-09-22T02:55:43Z"
  },
  {
    "ResourceId": "ep-*****_*****",
    "ResourceType": "endpoint",
    "LogType": "TksAccess",
    "LogDetail": "GetTksKeyinfo",
    "LogContents": [
      {
        "Key": "method",
        "Value": "GetTksKeyinfo"
      }
    ],
    "RiskLevel": "Info",
    "Timestamp": "2025-09-22T02:55:25Z"
  },
  {
```

```
"ResourceId": "ep-*****_****",
"ResourceType": "endpoint",
"LogType": "TksAccess",
"LogDetail": "GetTksKeyinfo",
"LogContents": [
  {
    "Key": "method",
    "Value": "GetTksKeyinfo"
  }
],
"RiskLevel": "Info",
"Timestamp": "2025-09-22T02:55:25Z"
},
{
  "ResourceId": "ep-*****_****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],
  "RiskLevel": "Info",
  "Timestamp": "2025-09-22T02:53:57Z"
},
{
  "ResourceId": "ep-*****_****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],
  "RiskLevel": "Info",
  "Timestamp": "2025-09-22T02:53:44Z"
},
{
  "ResourceId": "ep-*****_****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
```

```

    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],
  "RiskLevel": "Info",
  "Timestamp": "2025-09-22T02:53:38Z"
},
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],
  "RiskLevel": "Info",
  "Timestamp": "2025-09-22T02:52:45Z"
},
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],
  "RiskLevel": "Info",
  "Timestamp": "2025-09-22T02:52:45Z"
},
{
  "ResourceId": "ep-*****_*****",
  "ResourceType": "endpoint",
  "LogType": "TksAccess",
  "LogDetail": "GetTksKeyinfo",
  "LogContents": [
    {
      "Key": "method",
      "Value": "GetTksKeyinfo"
    }
  ],

```



```
json    "RiskLevel": "Info",
      "Timestamp": "2025-09-22T02:25:13Z"
    }
  ]
}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                             | 说明                          |
|-----|------------------------------------|------------------------------------------------------------------|-----------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid.                | 请求参数值不合法。请检查参数值的正确性后重试。     |
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.                 | 缺少必要的请求参数。请确认请求参数后重试。       |
| 404 | NotFound.<br>{{Parameter}}         | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalError                      | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

# 12.8 查询用量

## 12.8.1 GetUsage – 查询推理服务调用量（待弃用）

待弃用，查询模型推理服务调用量

### 注意事项

本接口将在2026-06-30日正式下线，请提前切换至接口 [GetInferenceUsage](#)。

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

**Action** string `%%require%%` 示例值: `GetUsage`  
要执行的操作，取值: `GetUsage`。

**Version** string `%%require%%` 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**BatchJobId** string 可选 示例值: `-`  
批量推理任务 ID

**Scenes** string[] 可选 示例值: `Ordinary`  
场景

**ProjectName** string 可选 示例值: `default`

- 资源所属的项目名称，默认值为`default`。
- 若资源不在默认项目中，需填写正确的项目名称，获取项目名称，请查看[文档](#) .

**EndpointIds** string[] 可选 示例值: `test-ep-id`  
接入点 id

**StartTime** integer `%%require%%` 示例值: `1731945600`  
开始时间

**EndTime** integer `%%require%%` 示例值: `1731945600`  
结束时间

**Interval** integer `%%require%%` 示例值: `3600`  
查询粒度，按天: `86400`，按小时: `3600`

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**UsageResults** object[] 示例值: [{"Name": "PromptTokens", "MetricItems": [{"Values": [{"Timestamp": 1731945600, "Value": 1529525715}]}]}, {"Name": "CompletionTokens", "MetricItems": [{"Values": [{"Timestamp": 1731945600, "Value": 40207324}]}]}]

查询结果

**Name** string 示例值: PromptTokens

指标名称

**MetricItems** object[]

用量统计指标值

**Tags** object[] 示例值: [{"Key": "EndpointId", "Value": "ep-20241018212998-s6wgb"}]

数据标签

**Key** string 示例值: EndpointId

key 值

**Value** string 示例值: test-ep-id

接入点 id/主账号 id/批量推理任务 id/场景值

**Values** object[] 示例值: [{"Timestamp": 1731999600, "Value": 48}]

指标数据值

**Timestamp** integer 示例值: 1731949200

时间戳

**Value** double 示例值: 20826827

具体数值

### 请求示例

```
POST /?Action=GetUsage&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20241119T104537Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20241119/cn-beijing/ark_stg/
request, SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Interval": 86400,
  "StartTime": 1731945600,
```

```
text "EndTime": 1731945600,  
      "ProjectName": "default"  
    }
```

## 返回示例

```
{  
  "ResponseMetadata": {  
    "RequestId": "20241119190556E244C5F755CB355E6405",  
    "Action": "GetUsage",  
    "Version": "2024-01-01",  
    "Service": "ark_stg",  
    "Region": "cn-beijing"  
  },  
  "Result": {  
    "UsageResults": [  
      {  
        "Name": "PromptTokens",  
        "MetricItems": [  
          {  
            "Values": [  
              {  
                "Timestamp": 1731945600,  
                "Value": 1529525715  
              }  
            ]  
          }  
        ]  
      },  
      {  
        "Name": "CompletionTokens",  
        "MetricItems": [  
          {  
            "Values": [  
              {  
                "Timestamp": 1731945600,  
                "Value": 40207324  
              }  
            ]  
          }  
        ]  
      }  
    ]  
  }  
}
```

```
json}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                             | 说明                          |
|-----|------------------------------------|------------------------------------------------------------------|-----------------------------|
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.                 | 缺少必要的请求参数。请确认请求参数后重试。       |
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid.                | 请求参数值不合法。请检查参数值的正确性后重试。     |
| 404 | NotFound.<br>{{Parameter}}         | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalServerError                | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

# 12.8.2 GetInferenceUsage – 查询推理用量

查询推理用量

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

**Action** string %%require%% 示例值: GetInferenceUsage  
要执行的操作，取值: GetInferenceUsage。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值: 2024-01-01。

**ProjectName** string 可选 示例值: default  
项目名称

**Filters** object[] 可选 示例值: \-  
过滤条件，格式如下：

```
json
{
  "Key": "ModelEndpoint",
  "Values": [
    "test-endpoint",
    "test-endpoint2"
  ]
}
```

**Key** string %%require%%  
表示过滤字段，目前支持：

- AuthToken：鉴权token
  - 若为jwt token鉴权，则默认为\*\*\*\*
  - 若为apikey鉴权，则默认为类似 37efcc63\*\*\*\*92c8fe4c880e，取apikey前8个字符，和后12个字符，中间为\*\*\*\*
- ModelUnitID：模型单元ID

- **BillingStatus**: 计费方式，后付费按量计费值为normal
  - no\_need\_billing: 表示无需付费，一般是由于客户未开通前体验的用量
  - free\_for\_model\_unit: 表示模型单元用量
  - free\_for\_free\_quota/free\_for\_limit\_boundary: 表示超过安心体验边界的用量
  - normal: 表示正常后付费按量计费用量
  - free\_for\_viptier: 表示tpm保障包用量
- **ModelName**: 模型名称
- **ModelVersion**: 模型版本
- **ModelEndpoint**: 接入点ID
- **BatchJobID**: 批量任务ID
- **EndpointName**: 接入点名称
- **BatchType**: 批量推理类型

**Values** string[] %%require%%

表示过滤条件。

若Values长度为0，表示不过滤Key，但是返回结果列包含Key

**ValueLike** string %%require%%

相似匹配值，Values与ValueLike不能同时传递

**QueryInterval** string %%require%% 示例值: Day/Hour

查询周期

**StartTime** string %%require%% 示例值: 2025-01-01

开始时间，yyyy-mm-dd

**EndTime** string %%require%% 示例值: 2025-01-02

结束时间，yyyy-mm-dd

**ShowWindowDetail** boolean 可选 示例值: \-

是否展示窗口

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Data** string[] 示例值: \-

数据

**Fields** object[] 示例值: \-

列元素

**Type** string

类型

**Name** string

列名称。包括请求参数内的Filters内的所有字段。

默认包括：

- **AccountID**: 账户ID

- Day: 日期
- Hour: 小时
- InputTokens: 输入token数
- OutputTokens: 输出token数
- TotalTokens: 总token数
- ReqCnt: 请求数

若返回按窗口划分的数据，则包含

- BillingStatus: 计费类型
- WindowMatchOrder: 窗口序列
- WindowDescription: 窗口描述
- WindowMaxInputTokens: 窗口输入token上限
- WindowMaxOutputTokens: 窗口输出token上限

**DataCount** integer 示例值: 1024  
数据长度

## 请求示例

text

```
POST /?Action=GetInferenceUsage&Version=2024-01-01 HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20250908T131049Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20250908/cn-beijing/ark_stg/
request, SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{
  "QueryInterval": "Hour",
  "StartTime": "2025-09-17",
  "EndTime": "2025-09-19",
  "Filters": [
    {
      "Key": "ModelEndpoint",
      "Values": [
        "ep-20xxx-xxx"
      ]
    }
  ]
}
```



## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202509231425196F1F971FFFC20F544E6A",
    "Action": "GetInferenceUsage",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Fields": [
      {
        "Name": "AccountID",
        "Type": "BIGINT"
      },
      {
        "Name": "ModelEndpoint",
        "Type": "STRING"
      },
      {
        "Name": "Day",
        "Type": "DATE"
      },
      {
        "Name": "Hour",
        "Type": "STRING"
      },
      {
        "Name": "InputTokens",
        "Type": "BIGINT"
      },
      {
        "Name": "OutputTokens",
        "Type": "BIGINT"
      },
      {
        "Name": "ImageCount",
        "Type": "BIGINT"
      },
      {
        "Name": "TotalTokens",
        "Type": "BIGINT"
      }
    ]
  }
}
```

```
json    "Name": "ReqCnt",
      "Type": "BIGINT"
    }
  ],
  "Data": [
    [
      "2100339946",
      "ep-20xxx-xxx",
      "2025-09-18",
      "16",
      "3062",
      "914",
      "0",
      "3976",
      "1"
    ],
    [
      "2100339946",
      "ep-20xxx-xxx",
      "2025-09-17",
      "14",
      "6955",
      "1921",
      "0",
      "8876",
      "4"
    ]
  ],
  "DataCount": 2
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                              | 说明                      |
|-----|------------------------------------|---------------------------------------------------|-------------------------|
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.  | 缺少必要的请求参数。请确认请求参数后重试。   |
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid. | 请求参数值不合法。请检查参数值的正确性后重试。 |

## 12.8.3 CreateRecordExportTask – 创建用量明细导出任务

创建用户用量明细异步导出任务。提交成功后返回任务 ID，用于调用 `GetRecordExportTask` 查询状态与导出结果。

### 注意

- 同一账号下，活跃任务数量不可超过 3 个。
- 单个账号在滚动 24 小时内最多可提交 100 个导出任务。超出上限后，新的提交请求将失败。

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: `CreateRecordExportTask`  
要执行的操作，取值: `CreateRecordExportTask`。

**Version** string %%require%% 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**StartTime** long %%require%% 示例值: `1777593600`  
任务起始时间（UTC Unix 时间戳，单位：秒）。  
取值范围: `StartTime ≥ 1777593600`（对应 UTC 时间: `2026-05-01 00:00`）。

**EndTime** long %%require%% 示例值: `1779171982`  
任务结束时间（UTC Unix 时间戳，单位：秒）。  
取值范围: `EndTime - StartTime ≤ 10800`，最大时间跨度 3 小时。

**Filters** object[] 可选 示例值: `\-`  
过滤条件。

**Key** string %%require%% 示例值: `model_name`  
过滤字段名，可取值：

- `model_name`（必填）：模型名称
- `model_endpoint`：模型接入点
- `batch_job_id`：批量推理任务 ID
- `volc_instance_id`：火山实例 ID

**Values** string[] 可选 示例值: doubao-seed-2-0-pro  
过滤值数组。

说明

当 `key` 为 `model_name` 时，可取值为：

- `doubao-seed-2-0-pro`
- `doubao-seed-2-0-lite`
- `doubao-seed-2-0-mini`
- `doubao-seed-2-0-code`
- `doubao-seedance-2-0`
- `doubao-seedance-2-0-fast`

返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Task object** 示例值: \-  
新建任务的简要信息。

**Id** string 示例值: uet-20260501140000-ABCDE  
任务 ID，调用 Create 接口时返回的唯一任务标识，格式为 `uet-YYYYMMDDhhmmss-<5位字母数字>`。

请求示例

```
text
{
  "StartTime": 1779074117,
  "EndTime": 1779081317,
  "Filters": [
    {
      "Key": "model_name",
      "Values": [
        "doubao-seedance-2-0"
      ]
    }
  ]
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "xxx",
    "Action": "CreateRecordExportTask",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Task": {
      "Id": "xxx"
    }
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                            | 错误信息                                                             | 说明                |
|-----|--------------------------------|------------------------------------------------------------------|-------------------|
| 400 | InvalidParameter               | The specified parameter %s is invalid.                           |                   |
| 400 | QuotaExceeded.{{ResourceType}} | The quota of {{ResourceType}} has reached the limit.             | 指定资源的配额超过上限。      |
| 403 | OperationDenied.AccountBlocked | account X is blocked from user record export                     | 账号被列入黑名单          |
| 404 | NotFound.{{Parameter}}         | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。 |

# 12.8.4 GetRecordExportTask – 查询用量明细导出任务状态

查询用量明细导出任务状态，并获取文件下载链接。

### 说明

- 需传入通过 `CreateRecordExportTask` 接口获取的任务 ID 作为入参。
- `CreateRecordExportTask` 任务提交后，建议等待 5 秒再发起 `GetRecordExportTask` 轮询：
  - 轮询间隔：不小于 5 秒。
  - 单任务轮询总时长：不超过 5 分钟。
  - 当接口返回 `Succeeded` 状态且包含 `DownloadUrl` 字段时，请立即下载 CSV 文件，避免链接过期失效，链接有效期为 12 小时。

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: `GetRecordExportTask`  
要执行的操作，取值: `GetRecordExportTask`。

**Version** string %%require%% 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**Id** string %%require%% 示例值: `uet-20260501140000-ABCDE`  
任务 ID，调用 `CreateRecordExportTask` 接口时返回的唯一任务标识，格式为 `uet-YYYYMMDDhhmmss-<5位字母数字>`。

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Task** object 示例值: `\-`  
任务完整状态。

**Id** string 示例值: `uet-20260501140000-ABCDE`  
任务 ID。

**Status string** 示例值: Running

任务状态机，取值：

- Pending
- Running
- Succeeded
- Failed

**ExportCount long** 示例值: 5000

实际写入 CSV 文件的行数，最大不超过 100000；当 `TotalCount` > `ExportCount` 时，表示导出结果因达到单任务行数上限而被截断。

**TotalCount long** 示例值: 5000

查询命中的总行数，用于判断导出结果是否被截断。

**QueryParams string** 示例值: {"StartTime":1761955200,"EndTime":1761998400,"Filters":[]}

原始请求参数的 JSON 字符串，用于任务回放或审计。

**DownloadUrl string**

TOS 一次性签发的下载链接，仅当任务状态为 `Succeeded` 时存在有效值。

#### 注意

下载链接有效期为 12 小时。链接过期后，`FileExpired` 字段值为 `true`，需重新提交任务获取新链接。

**DownloadUrlExpireTime long** 示例值: 1762041600

下载链接的过期时间（UTC Unix 时间戳，单位：秒），有效期 12 小时，过期后对应 TOS 文件将被清理。

**FileExpired float** 示例值: false

文件是否已过期标识，当当前时间大于等于 `DownloadUrlExpireTime` 时为 `true`。

**ErrorMessage string**

任务失败时的指引文案，仅当任务状态为 `Failed` 时存在有效值。

**CreateTime long** 示例值: 1761955200

任务创建时间（UTC Unix 时间戳，单位：秒）。

**StartTime long** 示例值: 1761955260

任务开始时间（UTC Unix 时间戳，单位：秒），对应任务状态切换为 `Running` 的时刻。任务未调度时该字段不返回；若任务触发系统重试，此字段始终保留首次启动时间。

**EndTime long** 示例值: 1761955320

任务结束时间（UTC Unix 时间戳，单位：秒）。代表任务进入 `Succeeded`、`Failed` 终态的时间；任务处理中时，该字段不返回。

## 请求示例

```
text
{
  "Id": "xxx"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "xxx",
    "Action": "GetRecordExportTask",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Task": {
      "Id": "xxx",
      "Status": "Succeeded",
      "ExportCount": 132,
      "TotalCount": 132,
      "QueryParams": "{\"StartTime\":1779074117,\"EndTime\":1779081317,\"Filters\":[{\"Key\": \"model_name\", \"Values\": [\"doubao-seedance-2-0\"]}]}",
      "DownloadUrl": "https://billing-info.tos-cn-beijing.volces.com/recordexport/...?X-Tos-...",
      "DownloadUrlExpireTime": 1779167739,
      "FileExpired": true,
      "CreateTime": 1779081338,
      "StartTime": 1779081338,
      "EndTime": 1779081339
    }
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                        | 错误信息                              | 说明                    |
|-----|----------------------------|-----------------------------------|-----------------------|
| 404 | NotFound.<br>{{Parameter}} | The specified<br>{{ResourceType}} | 指定资源找不到。请<br>确认参数后重试。 |



| 状态码 | 错误码 | 错误信息                                 | 说明 |
|-----|-----|--------------------------------------|----|
|     |     | {{ResourceContent}}<br>is not found. |    |

# 12.9 Agent Plan / Coding Plan API

## 12.9.1 CreatePersonalPlan – 创建个人版套餐

个人版用户购买 Agent Plan / Coding Plan 套餐 ( `AgentPlan` / `CodingPlan` )。

**说明**

- 单次请求仅支持订购单一套餐类型 ( 单次仅购买一个 `PlanType` )
- 支持传入 `DryRun=true` 参数, 仅执行订购合法性校验, 不实际创建订阅订单。
- 个人版同一账号同档位同一时间仅允许持有一个有效订阅, 重复提交同档位订购请求, 将返回 `OperationDenied` 类错误。
- 接口为异步下单, 自动扣费模式, 下单前请确保云账户内余额充足。
- 调用 `CreatePersonalPlan` 提交套餐创建请求后, 订单存在异步处理或状态延迟情况。建议在调用 `CreatePersonalPlan` 接口后, 通过 `GetPersonalPlan` 接口进行反查, 以确认最终的套餐创建结果。

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: `CreatePersonalPlan`  
要执行的操作, 取值: `CreatePersonalPlan`。

**Version** string %%require%% 示例值: `2024-01-01`  
API的版本, 取值: `2024-01-01`。

**Plan** string %%require%% 示例值: `AgentPlan`  
商品名称。可选值:

- `AgentPlan` : Agent Plan 个人版
- `CodingPlan` : Coding Plan 个人版

**PlanType** string %%require%% 示例值: `Medium`  
套餐档位。支持以下套餐类型及档位取值:

- `AgentPlan` : `Small` 、 `Medium` 、 `Large` 、 `Max`
- `CodingPlan` : `Lite` 、 `Pro`

**Duration** long %%require%% 示例值: `1`  
订购时长, 单位以 `PricingCycle` 为准, 取值范围 `1~12` 。

**PricingCycle** string %%require%% 示例值: `Month`  
计费周期, 当前仅支持 `Month` 包月类型。

**DryRun** boolean 可选 示例值: `\-`  
是否仅校验不下单。设为 `true` 时, 仅完成参数、额度全链路校验, 不会实际扣款, 适用于上线前预校验场景。默认值为 `false` 。

**AutoRenew** boolean 可选 示例值: \-

是否开启自动续费，默认值为 `false`。设为 `true` 时，套餐到期前将从云账户余额自动续费，仅支持单次续费。

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**PlanType** string 示例值: Medium

已购买的套餐档位

## 请求示例

text

```
{
  "Plan": "AgentPlan",
  "IsAutoPay": true,
  "DryRun": false,
  "PlanType": "Medium",
  "Duration": 1,
  "PricingCycle": "Month",
  "AutoRenew": false
}
```

## 返回示例

json

```
{
  "ResponseMetadata": {
    "RequestId": "xxx",
    "Action": "CreatePersonalPlan",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "PlanType": "Medium"
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                     | 错误信息                                                                         | 说明                            |
|-----|-----------------------------------------|------------------------------------------------------------------------------|-------------------------------|
| 400 | InvalidParameter.<br>{{Parameter}}      | The specified parameter {{Parameter}} is invalid.                            | 请求参数值不合法。请检查参数值的正确性后重试。       |
| 400 | MissingParameter.<br>{{Parameter}}      | The required parameter {{Parameter}} is missing.                             | 缺少必要的请求参数。请确认请求参数后重试。         |
| 400 | QuotaExceeded.<br>{{ResourceType}}      | The quota of {{ResourceType}} has reached the limit.                         | 指定资源的配额超过上限。                  |
| 403 | Insufficient.Balance                    | Operation is denied because of insufficient account balance.                 | 账号欠费或者不足以支付当前资源金额。            |
| 403 | OperationDenied.<br>{{Cause}}           | Operation is denied because {{CauseDescription}}.                            | 表示操作被拒绝，强调当前环境下对操作对象执行的操作不合理。 |
| 403 | OperationDenied.duplicated_subscription | The account already holds an active subscription of the specified plan type. | 同一账号同档位已有Active 订阅，重复购买被拒。    |
| 500 | InternalError                           | The request has failed due to an unknown error.                              | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。   |

## 12.9.2 RenewPersonalPlan – 续费个人版套餐

续费个人版套餐

### 说明

- 接口为异步执行，自动扣费，下单前请确保云账户内余额充足。
- 调用 `RenewPersonalPlan` 提交续费请求后，订单存在异步处理或状态延迟情况。建议在调用 `RenewPersonalPlan` 接口续费个人版套餐后，通过 `GetPersonalPlan` 接口进行反查，以确认最终的续费结果。

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: `RenewPersonalPlan`  
要执行的操作，取值: `RenewPersonalPlan`。

**Version** string %%require%% 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**Plan** string %%require%% 示例值: `AgentPlan`  
商品名称。可选值：

- `AgentPlan`
- `CodingPlan`

**Duration** long %%require%% 示例值: `1`  
续费时长。单位为月，取值范围: `1 ~ 12`。

**PricingCycle** string %%require%% 示例值: `Month`  
计费周期。固定取值: `Month`。

**DryRun** boolean 可选 示例值: `false`  
是否仅进行预检不下单。取值：

- `true` : 仅校验请求
- `false` (默认) : 正式执行请求

返回参数

本接口无特有的返回参数。更多信息请见[返回结构](#)。

请求示例

```
text
{
  "Plan": "AgentPlan",
  "Duration": 3,
  "PricingCycle": "Month",
  "DryRun": false
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "2024010112345678XXXXXXXXXXXXXXXXXX",
    "Action": "RenewPersonalPlan",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                   | 错误信息                                                         | 说明                     |
|-----|-----------------------|--------------------------------------------------------------|------------------------|
| 400 | DryRunOperation       | The request is validated by a dryrun operation.              | DryRun请求通过了全部检查，空运行成功。 |
| 403 | Insufficient.Balance  | Operation is denied because of insufficient account balance. | 账号欠费或者不足以支付当前资源金额。     |
| 404 | ResourceNotFound.Plan |                                                              | 当前用户未购买该套餐，或套餐已被回收     |

| 状态码 | 错误码           | 错误信息                                                        | 说明                          |
|-----|---------------|-------------------------------------------------------------|-----------------------------|
|     |               | The user does not have an active or existing personal plan. |                             |
| 500 | InternalError | The request has failed due to an unknown error.             | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

## 12.9.3 GetPersonalPlan – 查询个人版套餐

查询个人版套餐，包括套餐类型、到期时间、自动续费设置等

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: GetPersonalPlan

要执行的操作，取值: GetPersonalPlan。

**Version** string %%require%% 示例值: 2024-01-01

API的版本，取值: 2024-01-01。

**Plan** string %%require%% 示例值: AgentPlan

商品名称。可选值：

- AgentPlan
- CodingPlan

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**PlanType** string 示例值: Small

套餐档位。可选值：

- AgentPlan : Small 、 Medium 、 Large 、 Max
- CodingPlan : Lite 、 Pro

**Status** string 示例值: Running

套餐状态。可选值：

- Running : 生效中
- Expired : 已过期

**StartTime** string 示例值: 2025-01-01T00:00:00+08:00

首次生效时间，格式为 ISO 8601

**EndTime** string 示例值: 2026-01-01T00:00:00+08:00

当前到期时间，格式为 ISO 8601



**AutoRenew** boolean 示例值: false  
是否已开启自动续费。可选值:

- true : 已开启
- false (默认) : 未开启

请求示例

```
text
{
  "Plan": "AgentPlan"
}
```

返回示例

```
text
{
  "ResponseMetadata": {
    "RequestId": "2024010112345678XXXXXXXXXXXXXXXXXX",
    "Action": "GetPersonalPlan",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "PlanType": "Small",
    "Status": "Running",
    "StartTime": "2025-01-01T00:00:00+08:00",
    "EndTime": "2026-01-01T00:00:00+08:00",
    "AutoRenew": false
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                   | 错误信息                           | 说明                                   |
|-----|-----------------------|--------------------------------|--------------------------------------|
| 400 | InvalidParameter.Plan | The specified Plan is invalid. | Plan 参数非法，必须是 AgentPlan 或 CodingPlan |

| 状态码 | 错误码                   | 错误信息                                                        | 说明                 |
|-----|-----------------------|-------------------------------------------------------------|--------------------|
| 404 | ResourceNotFound.Plan | The user does not have an active or existing personal plan. | 当前用户未购买该套餐，或套餐已被回收 |

## 12.9.4 Agent Plan API

### 12.9.4.1 ListArkAgentPlanModel – 查询 Agent Plan 支持的模型列表

查询 Agent Plan 支持的模型列表

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: ListArkAgentPlanModel  
要执行的操作，取值: ListArkAgentPlanModel。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值: 2024-01-01。

#### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Datas** object[] 示例值: \-  
Agent Plan 支持的模型列表。格式如下:

```
json
[
  {
    "ModelID": "doubao-seed-1.6"
  }
]
```

**ModelID** string  
模型 ID

请求示例

```
text

POST /?Action=ListArkAgentPlanModel&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volces.com
Content-Type: application/json; charset=UTF-8
X-Date: 20260424T122003Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20260424/cn-beijing/ark_stg/
request, SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{}
```

返回示例

```
text

{
  "ResponseMetadata": {
    "RequestId": "2026042420200711904516115846EFE8",
    "Action": "ListArkAgentPlanModel",
    "Version": "2024-01-01",
    "Service": "ark_stg",
    "Region": "cn-beijing"
  },
  "Result": {
    "Datas": [
      {
        "ModelID": "doubao-seed-1.6"
      }
    ]
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                      | 说明 |
|-----|------------------------------------|---------------------------|----|
| 400 | MissingParameter.<br>{{Parameter}} | The required<br>parameter |    |

| 状态码 | 错误码                 | 错误信息                                            | 说明                          |
|-----|---------------------|-------------------------------------------------|-----------------------------|
|     |                     | {{Parameter}} is missing.                       | 缺少必要的请求参数。请确认请求参数后重试。       |
| 500 | InternalServerError | The request has failed due to an unknown error. | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

# 12.9.4.2 RegeneratePersonalApiKey – 轮换个人版 API Key

轮换个人版 API Key

## 调试

### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

## 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: RegeneratePersonalApiKey  
要执行的操作，取值: RegeneratePersonalApiKey。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值: 2024-01-01。

**Plan** string %%require%% 示例值: AgentPlan  
商品名称。可选值: AgentPlan （Agent Plan 个人版）

**ProjectName** string 可选 示例值: default  
项目名称。默认值为 default。

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Status** string 示例值: Success  
轮换结果。可选值：

- Success : 轮换成功
- Failed : 轮换失败

**Message** string 示例值: \-  
轮换失败时的具体原因。轮换成功时为空。

## 请求示例

POST /?Action=RegeneratePersonalApiKey&Version=2024-01-01 HTTP/1.1  
Host: ark.cn-beijing.volces.com

```
Content-Type: application/json; charset=UTF-8
text
{
  "Plan": "AgentPlan"
}
```

返回示例

```
text
{
  "ResponseMetadata": {
    "RequestId": "00000000000000000000000000000000",
    "Action": "RegeneratePersonalApiKey",
    "Version": "2024-01-01",
    "Service": "ark_stg",
    "Region": "cn-beijing"
  },
  "Result": {
    "Status": "Success",
    "Message": ""
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                                     | 说明                                         |
|-----|------------------------------------|--------------------------------------------------------------------------|--------------------------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid.                        | 请求参数值不合法。请检查参数值的正确性后重试。                    |
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.                         | 缺少必要的请求参数。请确认请求参数后重试。                      |
| 400 | InvalidParameter.Plan              | Plan must be AgentPlan and the request must be made by the main account. | 请求参数不合法。Plan 字段必须是 AgentPlan，并且请求必须是主账户发起。 |
| 404 |                                    |                                                                          |                                            |

| 状态码 | 错误码                        | 错误信息                                                                      | 说明                                  |
|-----|----------------------------|---------------------------------------------------------------------------|-------------------------------------|
|     | NotFound.<br>{{Parameter}} | The specified<br>{{ResourceType}}<br>{{ResourceContent}}<br>is not found. | 指定资源找不到。请<br>确认参数后重试。               |
| 404 | ResourceNotFound.Pl<br>an  | The user does not<br>have an active<br>personal plan.                     | 没有找到该用户已激<br>活的个人版 Agent<br>Plan。   |
| 500 | InternalServerError        | The request has<br>failed due to an<br>unknown error.                     | 未知错误，请稍后重<br>试。如果多次尝试仍<br>失败，请提交工单。 |



### 12.9.4.3 GetUsageDetails – 获取套餐用量详情

获取个人版 Agent Plan 套餐模型调用明细。

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string `%%require%%` 示例值: `GetUsageDetails`  
要执行的操作，取值: `GetUsageDetails`。

**Version** string `%%require%%` 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**Filter** object 可选 示例值: `\-`  
过滤条件，格式如下：

```
json
{
  "QueryInterval": "Day",
  "Filter": {
    "ObjectName": [
      "doubao-seed-1.6",
      "GLM-4.7"
    ],
    "PlanType": ["Large"],
    "StartTime": "2026-05-01",
    "EndTime": "2026-05-10"
  }
}
```

**ObjectName** string[] 可选  
模型名称，可以传入多个查询内容。

**StartTime** string `%%require%%`  
开始时间，格式 "2006-01-02"

**EndTime** string `%%require%%`  
结束时间，格式 "2006-01-02"

**PlanType** integer[] 可选

套餐类型，可传入多个; 整数枚举值 1, 2, 3, 4，分别代表 Small, Medium, Large, Max

**QueryInterval** string %%require%% 示例值: Day

查询周期，取值：

- Day : 天
- Hour : 小时

## 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Details** object[] 示例值: \-

调用明细列表，格式如下：

json

```
[
  {
    "Time": 1778284800000,
    "ObjectName": "doubao-seed-1.6",
    "Usage": 12500,
    "Unit": "Tokens",
    "BillingType": "WithinPlan"
  },
  {
    "Time": 1778284800000,
    "ObjectName": "GLM-4.7",
    "Usage": 8400,
    "Unit": "Tokens",
    "BillingType": "WithinPlan"
  },
  {
    "Time": 1778371200000,
    "ObjectName": "doubao-seed-1.6",
    "Usage": 26800,
    "Unit": "Tokens",
    "BillingType": "WithinPlan"
  },
  {
    "Time": 1778371200000,
    "ObjectName": "GLM-4.7",
    "Usage": 5100,
    "Unit": "Tokens",
    "BillingType": "WithinPlan"
  }
]
```

**Time** integer

消耗发生的日期或时间点，以 epoch 毫秒时间戳表示

**ObjectName** string

对象名称

**BillingType** string

计费类型，取值为：

- `WithinPlan` ：套餐内用量
- `OutsideOfPlan` ：套餐外用量

**Usage** integer

计费用量，单位为 tokens 或图片张数，具体由 `Unit` 字段决定

### Unit string

用量单位，支持 Tokens、Images 等类型

## 请求示例

text

```
POST /?Action=GetUsageDetails&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volces.com
Content-Type: application/json; charset=UTF-8
X-Date: 20260511T035210Z
X-Content-Sha256: 9f2b5c7a*****e1d4f8a23b6
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20260511/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=8c14e293ab7f6d5b04922*****df3c2e9b87a5106721d4f30e72e80a4f157918
```

```
{
  "QueryInterval": "Day",
  "Filter": {
    "ObjectName": [
      "doubao-seed-1.6",
      "GLM-4.7"
    ],
    "PlanType": ["Large"],
    "StartTime": "2026-05-01",
    "EndTime": "2026-05-10"
  }
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "20260511035211B7A29C481EFC026D935",
    "Action": "GetUsageDetails",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Details": [
      {

```

```
json  "Time": 1778284800000,
      "ObjectName": "doubao-seed-1.6",
      "Usage": 12500,
      "Unit": "Tokens",
      "BillingType": "WithinPlan"
    },
    {
      "Time": 1778284800000,
      "ObjectName": "GLM-4.7",
      "Usage": 8400,
      "Unit": "Tokens",
      "BillingType": "WithinPlan"
    },
    {
      "Time": 1778371200000,
      "ObjectName": "doubao-seed-1.6",
      "Usage": 26800,
      "Unit": "Tokens",
      "BillingType": "WithinPlan"
    },
    {
      "Time": 1778371200000,
      "ObjectName": "GLM-4.7",
      "Usage": 5100,
      "Unit": "Tokens",
      "BillingType": "WithinPlan"
    }
  ]
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                              | 说明                      |
|-----|------------------------------------|---------------------------------------------------|-------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid. | 请求参数值不合法。请检查参数值的正确性后重试。 |
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.  | 缺少必要的请求参数。请确认请求参数后重试。   |
| 404 |                                    |                                                   |                         |

| 状态码 | 错误码                        | 错误信息                                                                      | 说明                                  |
|-----|----------------------------|---------------------------------------------------------------------------|-------------------------------------|
|     | NotFound.<br>{{Parameter}} | The specified<br>{{ResourceType}}<br>{{ResourceContent}}<br>is not found. | 指定资源找不到。请<br>确认参数后重试。               |
| 500 | InternalServerError        | The request has<br>failed due to an<br>unknown error.                     | 未知错误，请稍后重<br>试。如果多次尝试仍<br>失败，请提交工单。 |

## 12.9.4.4 GetAFPUsage – 获取套餐 AFP 额度

获取 Agent Plan 个人版套餐 AFP 额度用量，包含所选席位的五小时用量、每日用量、每周用量、每月用量。

### 调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: GetAFPUsage

要执行的操作，取值：GetAFPUsage。

**Version** string %%require%% 示例值: 2024-01-01

API的版本，取值：2024-01-01。

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**PlanType** string 示例值: Large

套餐类型。取值：

- Small
- Medium
- Large
- Max

**AFPFiveHour** object 示例值: \-

5 小时窗口 AFP 用量。格式如下：

```
json
{
  "Quota": 50.0,
  "Used": 12.5,
  "SubscribeTime": 1778788800000,
  "ResetTime": 1778806800000
}
```

**Quota double**

计费周期内的总配额

**Used double**

计费周期内已使用的配额

**SubscribeTime integer**

本次计费周期的开始时间，以 epoch 毫秒时间戳表示

**ResetTime integer**

下一次配额重置的时间，以 epoch 毫秒时间戳表示

**AFPDaily object** 示例值: \-

近一天窗口 AFP 用量。格式如下:

```
json
{
  "Quota": 100.0,
  "Used": 22.5,
  "SubscribeTime": 1778716800000,
  "ResetTime": 1778803200000
}
```

**Quota double**

计费周期内的总配额

**Used double**

计费周期内已使用的配额

**SubscribeTime integer**

本次计费周期的开始时间，以 epoch 毫秒时间戳表示

**ResetTime integer**

下一次配额重置的时间，以 epoch 毫秒时间戳表示

**AFPWeekly object** 示例值: \-

近一周窗口 AFP 用量。格式如下:

```
json
{
  "Quota": 100.0,
  "Used": 22.5,
  "SubscribeTime": 1778716800000,
  "ResetTime": 1778803200000
}
```

**Quota double**

计费周期内的总配额



**Used double**

计费周期内已使用的配额

**SubscribeTime integer**

本次计费周期的开始时间，以 epoch 毫秒时间戳表示

**ResetTime integer**

下一次配额重置的时间，以 epoch 毫秒时间戳表示

**AFPMonthly object** 示例值: \-

近一月窗口 AFP 用量。格式如下：

json

```
{
  "Quota": 500.0,
  "Used": 150.0,
  "SubscribeTime": 1778457600000,
  "ResetTime": 1779062400000
}
```

**Quota double**

计费周期内的总配额

**Used double**

计费周期内已使用的配额

**SubscribeTime integer**

本次计费周期的开始时间，以 epoch 毫秒时间戳表示

**ResetTime integer**

下一次配额重置的时间，以 epoch 毫秒时间戳表示

## 请求示例

text

```
POST /?Action=GetAFPUsage&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volces.com
Content-Type: application/json; charset=UTF-8
X-Date: 20260511T034034Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20260511/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f
```

```
{}
```

## 返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "20260511034034A1B2C3D4E5F60718293",
    "Action": "GetAFPUUsage",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "PlanType": "Large",
    "AFPFiveHour": {
      "Quota": 50.0,
      "Used": 12.5,
      "SubscribeTime": 1778788800000,
      "ResetTime": 1778806800000
    },
    "AFPDaily": {
      "Quota": 100.0,
      "Used": 22.5,
      "SubscribeTime": 1778716800000,
      "ResetTime": 1778803200000
    },
    "AFPWeekly": {
      "Quota": 500.0,
      "Used": 150.0,
      "SubscribeTime": 1778457600000,
      "ResetTime": 1779062400000
    },
    "AFPMonthly": {
      "Quota": 2000.0,
      "Used": 850.5,
      "SubscribeTime": 1777939200000,
      "ResetTime": 1780531200000
    }
  }
}
```

## 错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                                                             | 说明                          |
|-----|------------------------------------|------------------------------------------------------------------|-----------------------------|
| 400 | InvalidParameter.<br>{{Parameter}} | The specified parameter {{Parameter}} is invalid.                | 请求参数值不合法。请检查参数值的正确性后重试。     |
| 400 | MissingParameter.<br>{{Parameter}} | The required parameter {{Parameter}} is missing.                 | 缺少必要的请求参数。请确认请求参数后重试。       |
| 404 | NotFound.<br>{{Parameter}}         | The specified {{ResourceType}} {{ResourceContent}} is not found. | 指定资源找不到。请确认参数后重试。           |
| 500 | InternalError                      | The request has failed due to an unknown error.                  | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

## 12.9.5 Coding Plan API

### 12.9.5.1 ListArkCodingPlanModel – 查询 Coding Plan 支持的模型列表

查询 Coding Plan 支持的模型列表

#### 调试

##### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

#### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string %%require%% 示例值: ListArkCodingPlanModel  
要执行的操作，取值：ListArkCodingPlanModel。

**Version** string %%require%% 示例值: 2024-01-01  
API的版本，取值：2024-01-01。

#### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**Datas** object[] 示例值: \-  
Coding Plan 支持的模型列表。格式如下：

```
json
[
  {
    "ModelID": "doubao-seed-1.6"
  }
]
```

**ModelID** string  
模型 ID

请求示例

```
text

POST /?Action=ListArkCodingPlanModel&Version=2024-01-01 HTTP/1.1
Host: ark.cn-beijing.volces.com
Content-Type: application/json; charset=UTF-8
X-Date: 20260602T085537Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20260602/cn-beijing/ark_stg/
request, SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{}
```

返回示例

```
text

{
  "ResponseMetadata": {
    "RequestId": "2026060216554717422120215259FAFF",
    "Action": "ListArkCodingPlanModel",
    "Version": "2024-01-01",
    "Service": "ark_stg",
    "Region": "cn-beijing"
  },
  "Result": {
    "Datas": [
      {
        "ModelID": "doubao-seed-1.6"
      }
    ]
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码                                | 错误信息                      | 说明 |
|-----|------------------------------------|---------------------------|----|
| 400 | MissingParameter.<br>{{Parameter}} | The required<br>parameter |    |

| 状态码 | 错误码                 | 错误信息                                            | 说明                          |
|-----|---------------------|-------------------------------------------------|-----------------------------|
|     |                     | {{Parameter}} is missing.                       | 缺少必要的请求参数。请确认请求参数后重试。       |
| 500 | InternalServerError | The request has failed due to an unknown error. | 未知错误，请稍后重试。如果多次尝试仍失败，请提交工单。 |

## 12.10 效果上报

### 12.10.1 CasePlatformV1BadcaseReport – 方舟

#### Seedance2.x 效果问题上报API

方舟Seedance2.x 效果问题上报API

## 使用说明

当使用Seedance2.0/fast生成视频后，可以通过此 API 把对应的 task\_id 上报为 badcase。

## 注意事项

未经您的单独同意，火山引擎不会存储和使用您的数据来训练或优化模型。由于Seedance2.0近期需求强劲，我们针对Seedance2.0系列模型效果类问题提供排障服务，可通过此API提交Badcase至方舟进行排查分析。如果您通过此方法提交Badcase，则视为您同意使用方舟排障服务，我们将严格按照用户协议章节3.7.7之（2）进行数据处理。

详细条款请查阅：<https://www.volcengine.com/docs/82379/1104498?lang=zh>。

本API及文档仅支持中国大陆火山方舟服务，不支持非中国大陆地区以及Byteplus等。

## 请求说明

通过 AK SK 调用：请参考 [API访问密钥（Access Key）](#) 获取火山引擎 AKSK，对应的子用户需开启CasePlatformAccess策略。

## 使用火山方舟API Key调用

除了AKSK，该API支持使用方舟API Key调用，示例如下，方舟API Key需要从 [API Key 管理](#) 获取。注意使用方舟API Key和AKSK的请求方式不同，请求API URL不是 <https://open.volcengineapi.com>，而是 <https://prompt-pilot.cn-beijing.volces.com>，另外需要添加路由 `/case-platform`。

bash

```
curl --location 'https://prompt-pilot.cn-beijing.volces.com/case-platform?
Action=CasePlatformV1BadcaseReport&Version=2024-01-01' \
--header 'accept: application/json, text/plain, */*' \
--header 'content-type: application/json' \
--header 'Authorization: Bearer 方舟API_KEY' \
--header 'Region: cn-beijing' \
--header 'ServiceName: ark' \
--header 'Version: 2024-01-01' \
--data-raw '{
  "Id": "cgt-20260501132104-tfm9v",
  "Feedback": "人物手部扭曲，且嘴型和中文配音对不上",
  "AccountId": "2000000000",
  "BadcaseType": "character_id_drift",
  "Source": "huosu",
  "ContactInfo": "user@example.com"
}'
```

## 调试



### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

### 请求参数

下方仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#)。

**Action** string `%%require%%` 示例值: `CasePlatformV1BadcaseReport`  
要执行的操作，取值: `CasePlatformV1BadcaseReport`。

**Version** string `%%require%%` 示例值: `2024-01-01`  
API的版本，取值: `2024-01-01`。

**Id** string `%%require%%` 示例值: `cgt-20260501132104-tfm9v`  
单个 task\_id，或 task\_id 列表。至少 1 个，最多 50 个，超出直接 422。接口会自动对传入 task\_id 做标准化处理：支持单个字符串、多个字符串列表，且会自动按逗号、中文逗号、换行、空格、Tab 等分隔符拆分成统一的 task\_id 列表，同时去掉首尾空白和空片段；

**Feedback** string `%%require%%` 示例值: `人物手部扭曲，且嘴型和中文配音对不上`  
问题描述，最少1字符，最多 2000 字符，拒绝纯空白字符串。会作为一条 feedback 注解持久化。

**AccountId** string 可选 示例值: `2000000000`  
Id(task id)所属的火山账号ID，未传时，根据AKSK或者方舟API Key解析账号ID

**BadcaseType** string 可选 示例值: `character_id_drift`  
BadcaseType 只能填写接口支持的枚举值；如果传入了不合法的值，整个请求会直接返回 422 参数校验错误。与此同时，当前基于 task\_id 的导入能力只支持 Seedance 2.0 / Seedance 2.0 fast 任务；如果 task\_id 对应的真实模型不在支持范围内，后端会返回业务错误，例如 60002，并提示该任务对应模型不受支持。

**Source** string 可选 示例值: `case_import`  
反馈来源，省略或 null 时默认 case\_import。

**ContactInfo** string 可选 示例值: `user@example.com`  
联系方式（邮箱/电话），最多 255 字符。

**ProjectName** string 可选 示例值: `default`  
ProjectName

### 返回参数

下方仅列出本接口特有的返回参数。更多信息请参见[返回结构](#)。

**SubmissionId** string 示例值: `badcase-sub-7c2e1f88-...`  
本次批量提交的 id，格式 badcase-sub-，可用于排查日志。

**Total** integer 示例值: `1`  
提交的 task\_id 总数（等于去重前的 Id 长度）。

**Accepted object[]** 示例值: [{ "TaskId": "vpv-aaa", "CaselId": "instance-11111111-...", "Code": 0, "Message": "Success" }]  
校验通过、已预写入 case 的 task\_id 列表。

**TaskId string**  
提交时传入的 task\_id。

**CaselId string** 示例值: instance-11111111-...  
预分配的 case\_id, 格式 instance-。返回时 case 处于 processing 状态, 后台会异步转存视频、输入帧并补齐 conversation/message, 完成后 case 翻成 completed, 异常则为 failed。

**Code integer** 示例值: 0  
恒为 0。

**Message string** 示例值: Success  
恒为 "Success"。

**Rejected object[]** 示例值: [{ "TaskId": "vpv-bbb", "Code": "40002", "Message": "task\_id 不存在或不属于当前 account\_id" }]  
校验失败、未写入的 task\_id 列表。

**TaskId string** 示例值: vpv-bbb  
被拒的 task\_id。

**Code string** 示例值: 40002  
业务错误码

**Message string** 示例值: task\_id 不存在或不属于当前 account\_id  
中文可读的拒绝原因。

## 请求示例

```
POST /?Action=CasePlatformV1BadcaseReport&Version=2024-01-01&ProjectName=default HTTP/1.1
Host: open.volcengineapi.com
Content-Type: application/json; charset=UTF-8
X-Date: 20260508T071922Z
X-Content-Sha256: 287e874e*****d653b44d21e
Authorization: HMAC-SHA256 Credential=Adfks*****wekfwe/20260508/cn-beijing/ark/request,
SignedHeaders=host;x-content-sha256;x-date,
Signature=47a7d934ff7b37c03938*****cd7b8278a40a1057690c401e92246a0e41085f

{
  "Id": "cgt-20260501132104-tfm9v",
  "Feedback": "人物手部扭曲, 且嘴型和中文配音对不上",
  "AccountId": "2000000000",
  "BadcaseType": "character_id_drift",
  "Source": "huosu",
```

```
text
{
  "ContactInfo": "user@example.com"
}
```

返回示例

```
json
{
  "ResponseMetadata": {
    "RequestId": "2026050800200011803712817624A398",
    "Action": "CasePlatformV1BadcaseReport",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "SubmissionId": "badcase-sub-7c2e1f88-...",
    "Total": 1,
    "Accepted": [
      {
        "TaskId": "vpv-aaa",
        "Caseld": "instance-11111111-...",
        "Code": 0,
        "Message": "Success"
      }
    ],
    "Rejected": [
      {
        "TaskId": "vpv-bbb",
        "Code": "40002",
        "Message": "task_id 不存在或不属于当前 account_id"
      }
    ]
  }
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码   | 错误信息                         | 说明                                        |
|-----|-------|------------------------------|-------------------------------------------|
| 200 | 40002 | task_id 不存在或不属于当前 account_id | task_id 不存在或 task_id 存在，但不属于当前 account_id |

| 状态码 | 错误码   | 错误信息                                                                                                                                        | 说明                                                                         |
|-----|-------|---------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------|
|     |       |                                                                                                                                             | 于当前 AccountId / API Key 对应账号                                               |
| 200 | 40003 | task_id 已经提交过 badcase                                                                                                                       | task_id 历史上已经提交过 badcase                                                   |
| 200 | 40004 | task_id 任务仍在生成中，请等待任务完成后再次提交 badcase                                                                                                        | task_id 对应任务仍在生成中，尚未完成                                                     |
| 200 | 40005 | task_id 已经提交过 badcase                                                                                                                       | 同一请求中重复提交了相同 task_id                                                       |
| 200 | 60002 | "请求中的 ModelId 不是支持的 Seedance 2.0 系列，仅支持 Seedance 2.0 和 Seedance 2.0 fast" or "task_id 对应模型不是 Seedance 2.0 系列，当前 badcase 导入仅支持 Seedance 2.0" | 请求中的 ModelId 不是支持的 Seedance 2.0 系列或 task_id 反查出的真实模型不属于支持的 Seedance 2.0 系列 |
| 200 | 60003 | task_id 对应真实模型与请求中的 ModelId 不一致，正确的 ModelId 应为                                                                                              | 请求中的 ModelId 与 task_id 反查出的真实模型不一致                                         |
| 400 | 40006 | AccountId is required when not authenticating with an Ark API key                                                                           | 未使用 Ark API Key 鉴权，且请求体中未传 AccountId                                       |
| 422 | 40007 | account_id must not be empty or whitespace                                                                                                  | AccountId 传了，但内容为空或全是空白字符                                                  |
| 422 | 40008 | model_id must not be empty or whitespace                                                                                                    | ModelId 传了，但内容为空或全是空白字符                                                    |
| 422 | 40009 | feedback must not be empty or whitespace                                                                                                    | Feedback 为空或全是空白字符                                                         |
| 422 | 40010 | "badcase_type list must contain at least one value" or "badcase_type contains invalid value '<非法值>'. Allowed values: <允许的枚举值，以逗号分隔>"        | BadcaseType 传空列表或 BadcaseType 传入非法枚举值                                      |

| 状态码 | 错误码   | 错误信息                                                                           | 说明                                                 |
|-----|-------|--------------------------------------------------------------------------------|----------------------------------------------------|
| 422 | 40011 | "id must contain at least one task_id" or "id may contain at most 50 task_ids" | Id 经过拆分后为空，没有任何有效 task_id 或Id 经过拆分后超过 50 个 task_id |

枚举值介绍

BadcaseType

仅当 task 的 model Id为以下之一时可接受 `BadcaseType`：

- `doubao-seedance-2-0-260128`
- `doubao-seedance-2-0-fast-260128`

| 枚举值                            | 含义            |
|--------------------------------|---------------|
| character_id_drift             | 角色 ID 漂移      |
| subtitle_generation_error      | 字幕生成错误        |
| logo_watermark_generated       | 生成了 logo / 水印 |
| style_drift                    | 风格漂移          |
| regular_flickering             | 规律性闪烁         |
| extended_video_joint_jump      | 续写视频接缝跳变      |
| duplicate_character_appearance | 角色重复出现        |
| audio_end_noise                | 尾部音频杂音        |
| chinese_pronunciation_error    | 中文发音错误        |
| voice_tone_reference_error     | 音色参考错误        |
| other                          | 其他            |

Source

| 枚举值         | 场景      |
|-------------|---------|
| huosu       | 火速助手    |
| huoshan     | 火山助手    |
| qianzhi     | 钳知      |
| case_import | 默认值/缺省值 |

## 12.10.2 CasePlatformV1BadcaseQuery – 方舟Seedance2.x 效果问题结果查询API

方舟Seedance2.x 效果问题结果查询API

### 使用说明

当通过 CasePlatformV1BadcaseReport上报 Badcase 后，可以通过此 API 查询对应的 badcase 的处理结果。

### 注意事项

未经您的单独同意，火山引擎不会存储和使用您的数据来训练或优化模型。由于Seedance2.0近期需求强劲，我们针对Seedance2.0系列模型效果类问题提供排障服务，可通过此API提交Badcase至方舟进行排查分析。如果您通过此方法提交Badcase，则视为您同意使用方舟排障服务，我们将严格按照用户协议章节3.7.7之（2）进行数据处理。

详细条款请查阅：<https://www.volcengine.com/docs/82379/1104498?lang=zh>。

本API及文档仅支持中国大陆火山方舟服务，不支持非中国大陆地区以及Byteplus等。

### 请求说明

**使用 AK SK 调用：**请参考 [API访问密钥（Access Key）](#) 获取火山引擎 AKSK，对应的子用户需开启 CasePlatformAccess策略。

**使用火山方舟API Key调用：**除了AKSK，该API支持使用方舟API Key调用，示例如下，方舟API Key需要从 [API Key 管理](#) 获取。注意使用方舟API Key和AKSK的请求方式不同，请求API URL不是 <https://open.volcengineapi.com>，而是\*\* <https://prompt-pilot.cn-beijing.volces.com>，另外需要添加路由\*\* `/case-platform` \*\*。

bash

```
curl --location 'https://prompt-pilot.cn-beijing.volces.com/case-platform?
Action=CasePlatformV1BadcaseQuery&Version=2024-01-01' \
--header 'accept: application/json, text/plain, */*' \
--header 'content-type: application/json' \
--header 'Authorization: Bearer 方舟API_KEY' \
--header 'Region: cn-beijing' \
--header 'ServiceName: ark' \
--header 'Version: 2024-01-01' \
--data-raw '{
  "Id": "cgt-20260501132104-tfm9v"
}'
```

### 调试

API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

 去调试

请求参数

下表仅列出该接口特有的请求参数和部分公共参数。更多信息请见[公共参数](#) .

| 参数          | 类型     | 是否必填 | 示例值                        | 描述                                                                                                 |
|-------------|--------|------|----------------------------|----------------------------------------------------------------------------------------------------|
| Action      | String | 是    | CasePlatformV1BadcaseQuery | 要执行的操作，取值：CasePlatformV1BadcaseQuery。                                                              |
| Version     | String | 是    | 2024-01-01                 | API的版本，取值：2024-01-01。                                                                              |
| Id          | String | 是    | cgt-20260501132104-tfm9v   | 单个 task_id 或 task_id 列表。1~50 个，超出 422；同一请求内重复 task_id 去重后只返回一次；自动按逗号/中文逗号/换行/空格/Tab 拆分，去掉首尾空白与空片段。 |
| ProjectName | String | 否    | default                    | ProjectName                                                                                        |

返回参数

下表仅列出本接口特有的返回参数。更多信息请参见[返回结构](#) .

| 参数    | 类型      | 示例值 | 描述 |
|-------|---------|-----|----|
| Total | Integer | 1   |    |

| 参数                  | 类型              | 示例值                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          | 描述                                       |
|---------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------|
|                     |                 |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 去重后查询的 task_id 总数（ Accepted + Rejected ） |
| <div>Accepted</div> | Array of Object | <pre>[{   "TaskId":   "cgt-2026050113210   4-tfm9v",   "BadcaseType":   ["character_id_drift"],   "Feedback": "人物手   部扭曲，且嘴型和中   文配音对不上",   "SubmitTime":   "2026-05-08T07:19:   22Z",   "Status": "done",   "ProblemLabel": "人   物一致性",   "Solution": "策略调   整",   "SolutionNote": {     "Text": "已确认为     LoRA 加载顺序问     题，建议在 prompt     中显式指定 style 标     签",     "Attachments": [       { "Type": "image",         "Url": "https://case-         platform-files-cn-         beijing.tos-cn-         beijing.volces.com/.../         repro.png?X-Tos-         Signature=...",         "MimeType": "image/         png", "Name":         "repro.png" }     ]   } }]</pre> | 命中且归属当前账号的 task_id，返回提交快照 + 处理结果         |



| 参数                                                                                               | 类型              | 示例值                                                                                                                                            | 描述                                                        |
|--------------------------------------------------------------------------------------------------|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------|
|                                                                                                  |                 | <pre>] } }]</pre>                                                                                                                              |                                                           |
| TaskId                                                                                           | String          | cgt-20260501132104-tfm9v                                                                                                                       | 任务 ID                                                     |
| BadcaseType                                                                                      | Array of String | character_id_drift                                                                                                                             | 用户提交时选择的分类（枚举值见上报 API）                                    |
| Feedback                                                                                         | String          | 人物手部扭曲，且嘴型和中文配音对不上                                                                                                                             | 用户提交时填写的反馈文本（客户反馈）                                        |
| Status                                                                                           | String          | done                                                                                                                                           | 处理状态 processing / done                                    |
| ProblemLabel                                                                                     | String          | 人物一致性                                                                                                                                          | 问题标签——支持人员打标的 Case 问题（有限枚举值）                              |
| Solution                                                                                         | String          | 安全合规流程                                                                                                                                         | 解决方案——支持人员打标的解决方案（有限枚举值）                                  |
|  SolutionNote | Object          | <pre>{ "Text": "已确认为 LoRA 加载顺序问题，建议在 prompt 中显式指定 style 标签", "Attachments": [ { "Type": "image", "Url": "https://case-platform-files-cn-</pre> | 解决方案说明——文本 + 图文附件（结构见 1.3.1）；仅 done 时返回，processing 为 null |

| 参数                     | 类型              | 示例值                                                                                                                                                                                                                       | 描述                                                           |
|------------------------|-----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|
|                        |                 | beijing.tos-cn-<br>beijing.volces.com/.../<br>repro.png?X-Tos-<br>Signature=...",<br>"MimeType": "image/<br>png", "Name":<br>"repro.png" } ] }                                                                            |                                                              |
| Text                   | String          | 已确认为 LoRA 加载<br>顺序问题，建议在<br>prompt 中显式指定<br>style 标签                                                                                                                                                                      | 解决方案说明文本                                                     |
| <div>Attachments</div> | Array of Object | [<br>{ "Type": "image",<br>"Url": "https://case-<br>platform-files-cn-<br>beijing.tos-cn-<br>beijing.volces.com/.../<br>repro.png?X-Tos-<br>Signature=...",<br>"MimeType": "image/<br>png", "Name":<br>"repro.png" }<br>] | 图文附件，元素 {Type,<br>Url, MimeType?, Name?};<br>读时 TOS URL 自动重签 |
| Type                   | String          | image                                                                                                                                                                                                                     | 文件类型                                                         |

|  |  |  |  |
|--|--|--|--|
|  |  |  |  |
|--|--|--|--|

| 参数                                                                                           | 类型              | 示例值                                                                                                           | 描述                                    |
|----------------------------------------------------------------------------------------------|-----------------|---------------------------------------------------------------------------------------------------------------|---------------------------------------|
| Url                                                                                          | String          | https://case-platform-files-cn-beijing.tos-cn-beijing.volces.com/2100000825/.../repro.png?X-Tos-Algorithm=... | 文件链接                                  |
| Name                                                                                         | String          | repro.png                                                                                                     | 文件名称                                  |
| MimeType                                                                                     | String          | image/png                                                                                                     | 多用途互联网邮件扩展类型                          |
| SubmitTime                                                                                   | String          | 2026-05-08T07:19:22Z                                                                                          | 提交时间，ISO 8601 UTC                     |
|  Rejected | Array of Object | [{"TaskId": "cgt-zzz", "Code": 40012, "Message": "task_id 未提交过 badcase"}]                                     | 未命中 / 不归属 / 未提交过 badcase 的 task_id 列表 |
| TaskId                                                                                       | String          | cgt-zzz                                                                                                       | 任务 ID                                 |
| Message                                                                                      | String          | task_id 未提交过 badcase                                                                                          | 拒绝原因                                  |
| Code                                                                                         | Integer         | 40012                                                                                                         | 错误码                                   |

请求示例

text

POST /?Action=CasePlatformV1BadcaseQuery&Version=2024-01-01&ProjectName=default HTTP/1.1

Host: open.volcengineapi.com

Content-Type: application/json; charset=UTF-8

X-Date: 20260625T001714Z

X-Content-Sha256: 287e874e\*\*\*\*\*d653b44d21e

Authorization: HMAC-SHA256 Credential=Adfks\*\*\*\*\*wekfwe/20260625/cn-beijing/ark/request,

SignedHeaders=host;x-content-sha256;x-date,

Signature=47a7d934ff7b37c03938\*\*\*\*\*cd7b8278a40a1057690c401e92246a0e41085f

```
{
  "Id": "cgt-20260501132104-tfm9v"
}
```

## 返回示例

```
{
  "ResponseMetadata": {
    "RequestId": "202606241717181540900962155418EE",
    "Action": "CasePlatformV1BadcaseQuery",
    "Version": "2024-01-01",
    "Service": "ark",
    "Region": "cn-beijing"
  },
  "Result": {
    "Total": 1,
    "Accepted": [
      {
        "TaskId": "cgt-20260501132104-tfm9v",
        "BadcaseType": [
          "character_id_drift"
        ],
        "Feedback": "人物手部扭曲，且嘴型和中文配音对不上",
        "Status": "done",
        "ProblemLabel": "人物一致性",
        "Solution": "安全合规流程",
        "SolutionNote": {
          "Text": "已确认为 LoRA 加载顺序问题，建议在 prompt 中显式指定 style 标签",
          "Attachments": [
            {
              "Type": "image",
              "Url": "https://case-platform-files-cn-beijing.tos-cn-beijing.volces.com/2100000825/.../"
            }
          ]
        }
      }
    ]
  }
}
```

```
text
{
  "repro.png?X-Tos-Algorithm=...",
  "Name": "repro.png",
  "MimeType": "image/png"
}
],
{
  "SubmitTime": "2026-05-08T07:19:22Z"
},
{
  "Rejected": [
    {
      "TaskId": "cgt-zzz",
      "Code": 40012,
      "Message": "task_id 未提交过 badcase"
    }
  ]
}
}
```

错误码

下表为您列举了该接口与业务逻辑相关的错误码。公共错误码请参见[公共错误码](#)文档。

| 状态码 | 错误码   | 错误信息                                                                      | 说明                                  |
|-----|-------|---------------------------------------------------------------------------|-------------------------------------|
| 200 | 40002 | task_id 不存在或不属于当前 account_id                                              | 不存在/不归属当前账号；落 Rejected              |
| 200 | 40012 | task_id 未提交过 badcase                                                      | 合法且归属当前账号，但从未通过上报 API 提交；落 Rejected |
| 422 | 40011 | id must contain at least one task_id / id may contain at most 50 task_ids | id 拆分后为空或超过 50                      |

## 13. 其他说明

### 13.1 兼容 OpenAI SDK

为方便您集成和使用，火山方舟模型 API 会尽可能兼容 OpenAI API。修改 `base url`、`model`、`api_key` 等少量配置，轻松将方舟模型服务集成到您已有的系统中。

#### 说明

社区第三方 SDK 不由火山引擎团队维护，本文仅供参考。

### 前提条件

#### 说明

方舟平台的新用户？获取 API Key 及 开通模型等准备工作，请参见 [快速入门](#)。

### OpenAI SDK

- Python版本：3.7及以上。
- OpenAI SDK：1.0版本及以上，安装命令：

Python

```
pip install --upgrade "openai>=1.0"
```

### 快速开始示例

```
from openai import OpenAI
import os

client = OpenAI(
    # The base URL for model invocation
    base_url="https://ark.cn-beijing.volces.com/api/v3",
    # Replace with your API Key
    api_key=os.environ.get("ARK_API_KEY"),
)

completion = client.chat.completions.create(
```

```
Python
# Replace with Model ID
model="doubao-seed-2-1-pro-260628",
messages = [
    {"role": "user", "content": "Hello"},
],
)
print(completion.choices[0].message.content)
```

## 设置额外字段

传入OpenAI SDK中不支持的字段，可以通过 **extra\_body** 字典传入，如开关模型是否深度思考的 **thinking** 字段。

```
Python

from openai import OpenAI
import os

client = OpenAI(
    # The base URL for model invocation
    base_url="https://ark.cn-beijing.volces.com/api/v3",
    # Replace with your API Key
    api_key=os.environ.get("ARK_API_KEY"),
)

completion = client.chat.completions.create(
    # Replace with Model ID
    model="doubao-seed-2-1-pro-260628",
    messages = [
        {"role": "user", "content": "Hello"},
    ],
    extra_body={
        "thinking": {
            "type": "disabled", # 不使用深度思考能力
            "type": "enabled", # 使用深度思考能力
        }
    }
)
print(completion.choices[0].message.content)
```

## 设置自定义header

可以用于传递额外信息，如配置 ID来串联日志，使能数据加密能力。

Python

```
from openai import OpenAI
import os

client = OpenAI(
    # The base URL for model invocation
    base_url="https://ark.cn-beijing.volces.com/api/v3",
    # Replace with your API Key
    api_key=os.environ.get("ARK_API_KEY"),
)

completion = client.chat.completions.create(
    # Replace with Model ID
    model="doubao-seed-2-1-pro-260628",
    messages = [
        {"role": "user", "content": "Hello"},
    ],
    # 自定义request id
    extra_headers={"X-Client-Request-Id": "202406251728190000B7EA7A9648AC08D9"}
)
print(completion.choices[0].message.content)
```

## 向量化 Embedding

### 注意

- 文本向量化模型已经逐步下线，建议您使用多模态向量化模型。
- [向量化能力](#) 模型不支持 OpenAI API，请使用 方舟 SDK，详细请参见 [向量化](#)。

## LangChain OpenAI SDK

安装 LangChain OpenAI SDK：

Python

```
pip install langchain-openai
```

## 示例代码



Python

```
from langchain_openai import ChatOpenAI
from langchain_core.prompts import PromptTemplate
import os

llm = ChatOpenAI(
    # Replace with your API Key
    openai_api_key=os.environ.get("ARK_API_KEY"),
    # The base URL for model invocation
    openai_api_base="https://ark.cn-beijing.volces.com/api/v3",
    # Replace with Model ID
    model="doubao-seed-2-1-pro-260628",
)

template = """Question: {question}

Answer: Let's think step by step."""

prompt = PromptTemplate.from_template(template)

question = "What NFL team won the Super Bowl in the year Justin Beiber was born?"

llm_chain = prompt | llm

print(llm_chain.invoke(question))
```

# 13.2 错误码

本文列举您调用火山方舟 API 可能会涉及的错误码信息，包含方舟错误码和公共错误码。

## 推理错误码

| HTTP 状态码 | 错误类型 Type  | 错误码 Code                       | 错误信息 Message                                                                                                                                  | 含义                                                                                    |
|----------|------------|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| 400      | BadRequest | MissingParameter               | The request failed because it is missing one or multiple required parameters. Request ID: {{id}}                                              | 请求缺少必要参数，请查阅 API 文档。                                                                  |
| 400      | BadRequest | InvalidParameter               | One or more parameters specified in the request are not valid. Request ID: {{id}}                                                             | 请求包含非法参数，请查阅 API 文档。                                                                  |
| 400      | BadRequest | InvalidParameter               | The parameter <code>instructions</code> specified in the request are not valid: caching is not supported for instructions. Request id: {{id}} | Responses API 中，当配置过 <code>instructions</code> 字段信息，后续轮次无法配置 <code>Caching</code> 字段。 |
| 400      | BadRequest | InvalidEndpoint.ClosedEndpoint | The request targeted an endpoint that is currently closed or temporarily unavailable. Request ID: {{id}}                                      | 推理接入点处于已被关闭或暂时不可用，请稍后重试，或联系推理接入点管理员。                                                  |
| 400      | BadRequest | SensitiveContentDetected       | The request failed because the input text may contain sensitive information.                                                                  | 输入文本可能包含敏感信息，请您使用其他 prompt。                                                           |
| 400      | BadRequest |                                | The request failed because                                                                                                                    | 输入文本可能包含严重违规相关                                                                        |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                                      | 错误信息<br>Message                                                                                                    | 含义                                         |
|-------------|--------------|--------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|--------------------------------------------|
|             |              | SensitiveContent<br>Detected.Severe<br>Violation | the input text<br>may contain<br>severe violation<br>information.                                                  | 信息，请您使用<br>其他 prompt                       |
| 400         | BadRequest   | SensitiveContent<br>Detected.Violenc<br>e        | The request<br>failed because<br>the input text<br>may contain<br>violence<br>information.                         | 输入文本可能包<br>含激进行为相关<br>信息，请您使用<br>其他 prompt |
| 400         | BadRequest   | InputTextSensiti<br>veContentDete<br>cted        | The request<br>failed because<br>the input text<br>may contain<br>sensitive<br>information.Req<br>uest ID: {{id}}  | 输入文本可能包<br>含敏感信息，请<br>您更换后重试。              |
| 400         | BadRequest   | InputImageSensi<br>tiveContentDete<br>cted       | The request<br>failed because<br>the input image<br>may contain<br>sensitive<br>information.Req<br>uest ID: {{id}} | 输入图像可能包<br>含敏感信息，请<br>您更换后重试。              |
| 400         | BadRequest   | InputVideoSensi<br>tiveContentDete<br>cted       | The request<br>failed because<br>the input video<br>may contain<br>sensitive<br>information.                       | 输入视频可能包<br>含敏感信息，请<br>您更换后重试。              |
| 400         | BadRequest   | InputAudioSensi<br>tiveContentDete<br>cted       | The request<br>failed because<br>the input audio<br>may contain<br>sensitive<br>information.Req<br>uest ID: {{id}} | 输入音频可能包<br>含敏感信息，请<br>您更换后重试               |
| 400         | BadRequest   | OutputTextSensi<br>tiveContentDete<br>cted       | The request<br>failed because<br>the output may<br>contain<br>sensitive<br>information.                            | 生成的文字可能<br>包含敏感信息，<br>请您更换输入内<br>容后重试      |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                                        | 错误信息<br>Message                                                                                         | 含义                         |
|-------------|--------------|----------------------------------------------------|---------------------------------------------------------------------------------------------------------|----------------------------|
| 400         | BadRequest   | OutputImageSensitiveContentDetected                | The request failed because the output image may contain sensitive information.                          | 生成的图像可能包含敏感信息，请您更换输入内容后重试。 |
| 400         | BadRequest   | OutputVideoSensitiveContentDetected                | The request failed because the output video may contain sensitive information. Request ID: {{id}}       | 生成的视频可能包含敏感信息，请您更换输入内容后重试。 |
| 400         | BadRequest   | OutputAudioSensitiveContentDetected                | The request failed because the output audio may contain sensitive information. Request ID: {{id}}       | 生成的音频可能包含敏感信息，请您更换输入内容后重试。 |
| 400         | BadRequest   | InputTextSensitiveContentDetected.PolicyViolation  | The request failed because the input text may be related to copyright restrictions. Request ID: {{id}}  | 输入文本可能涉及版权限制，请您更换后重试。      |
| 400         | BadRequest   | InputImageSensitiveContentDetected.PolicyViolation | The request failed because the input image may be related to copyright restrictions. Request ID: {{id}} | 输入图片可能涉及版权限制，请您更换后重试。      |
| 400         | BadRequest   | InputVideoSensitiveContentDetected.PolicyViolation | The request failed because the input video may be related to copyright restrictions. Request ID: {{id}} | 输入视频可能涉及版权限制，请您更换后重试。      |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                                           | 错误信息<br>Message                                                                                                                                                                           | 含义                                 |
|-------------|--------------|-------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------|
| 400         | BadRequest   | InputAudioSensitiveContentDetected.PolicyViolation    | The request failed because the input audio may be related to copyright restrictions.<br>Request ID: {{id}}                                                                                | 输入音频可能涉及版权限制，请您更换后重试。              |
| 400         | BadRequest   | OutputVideoSensitiveContentDetected.PolicyViolation   | The request failed because the output video may be related to copyright restrictions.<br>Request ID: {{id}}                                                                               | 生成的视频可能涉及版权限制，请您更换输入内容后重试。         |
| 400         | BadRequest   | InputImageSensitiveContentDetected.PrivacyInformation | The request failed because the input image may contain real person.<br>Request ID: {{id}}                                                                                                 | 输入图片可能包含真人，请您更换后重试。                |
| 400         | BadRequest   | InputVideoSensitiveContentDetected.PrivacyInformation | The request failed because the input video may contain real person.<br>Request ID: {{id}}                                                                                                 | 输入视频可能包含真人，请您更换后重试。                |
| 400         | BadRequest   | InputTextRiskDetection                                | The request could not be processed because the input text includes sensitive content that violates ContentSecurity Detection.<br>ARKRequest ID: {{id}};CSDRequestId: {{RequestId}};Label: | 火山引擎风险识别产品检测到输入文本可能包含敏感信息，请您更换后重试。 |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                  | 错误信息<br>Message                                                                                                                                                                                                        | 含义                                 |
|-------------|--------------|------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------|
|             |              |                              | {{Label}};SubLabel:{{SubLabel}}                                                                                                                                                                                        |                                    |
| 400         | BadRequest   | InputImageRisk<br>Detection  | The request could not be processed because the input image includes sensitive content that violates ContentSecurity Detection.ARKRequest ID: {{id}};CSDRequestId: {{RequestId}};Label: {{Label}};SubLabel:{{SubLabel}} | 火山引擎风险识别产品检测到输入图片可能包含敏感信息，请您更换后重试。 |
| 400         | BadRequest   | OutputTextRisk<br>Detection  | The request could not be processed because the output text includes sensitive content that violates ContentSecurity Detection.ARKRequest ID: {{id}};CSDRequestId: {{RequestId}};Label: {{Label}};SubLabel:{{SubLabel}} | 火山引擎风险识别产品检测到输出文本可能包含敏感信息，请您更换后重试。 |
| 400         | BadRequest   | OutputImageRisk<br>Detection | The request could not be processed because the output image includes sensitive content that                                                                                                                            | 火山引擎风险识别产品检测到输出图片可能包含敏感信息，请您更换后重试。 |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                              | 错误信息<br>Message                                                                                                                                            | 含义                                           |
|-------------|--------------|------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------|
|             |              |                                          | violates<br>ContentSecurity<br>Detection.ARKRe<br>quest ID:<br>{{id}};CSDReques<br>tId:<br>{{RequestId}};Lab<br>el:<br>{{Label}};SubLab<br>el:{{SubLabel}} |                                              |
| 400         | BadRequest   | ContentSecurity<br>DetectionError        | Internal<br>error.ARKReques<br>t ID:<br>{{id}};CSDReques<br>tId:<br>{{RequestId}};CS<br>Dcode:<br>{};CSDmessage:{{}}                                       | 火山引擎风险识<br>别产品请求失<br>败。                      |
| 400         | BadRequest   | InvalidParamete<br>r.{{Parameter}}       | The specified<br>parameter<br>{{Parameter}} is<br>invalid.                                                                                                 | 请求参数值不合<br>法。请检查参数<br>值的正确性后重<br>试。          |
| 400         | BadRequest   | MissingParamet<br>er.{{Parameter}}       | The required<br>parameter<br>{{Parameter}} is<br>missing.                                                                                                  | 缺少必要的请求<br>参数。请确认请<br>求参数后重试。                |
| 400         | BadRequest   | Duplicate.Tags.K<br>ey                   | The specified<br>object of tags<br>contains<br>duplicate keys.                                                                                             | 对象的标签存在<br>重复Key。                            |
| 400         | BadRequest   | InvalidArgument<br>Error                 | MissingRole:<br>Invalid<br>message:<br>{{Message}}                                                                                                         | 请求中的<br>messages 列表<br>里, 有消息体缺<br>少 role 字段 |
| 400         | BadRequest   | InvalidArgument<br>Error.UnknownR<br>ole | Unknown the<br>role of message:<br>{{Role}}                                                                                                                | 消息体中的 role<br>值不被支持, 如<br>user_ 。            |
| 400         | BadRequest   | InvalidArgument<br>Error.UnknownR<br>ole | The Inference<br>role not found:<br>{{Role}}                                                                                                               | 指定的<br>inference_role<br>未在配置中定<br>义。        |
| 400         | BadRequest   |                                          |                                                                                                                                                            |                                              |

| HTTP 状态码 | 错误类型 Type  | 错误码 Code                                | 错误信息 Message                                                                              | 含义                                                                             |
|----------|------------|-----------------------------------------|-------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
|          |            | InvalidArgumentError.InvalidImageDetail | Invalid image detail: {{Parameter}}                                                       | image_url 中的 detail 参数值无效，只接受 "auto", "high", "low"                            |
| 400      | BadRequest | InvalidArgumentError.InvalidPixelLimit  | Customized min_pixels 100 is greater than max_pixels 50                                   | 用户自定义的图片像素限制（min_pixels, max_pixels）无效（例如 min_pixels > max_pixels，或超出了服务配置的范围） |
| 400      | BadRequest | InvalidImageURL.EmptyURL                | Empty base64 image url                                                                    | 传入的图片 URL 为空                                                                   |
| 400      | BadRequest | InvalidImageURL.InvalidFormat           | Invalid base64 image url                                                                  | 无法解析或处理图片，可能是 Base64 格式不正确、图片数据损坏或格式不支持                                        |
| 400      | BadRequest | OutOfContextError                       | Total tokens of image and text exceed max message tokens.                                 | 当请求中包含图片时，文本和图片编码后的总 token 数超过了模型上下文长度限制                                       |
| 400      | BadRequest | InvalidParameter.UnsupportedParameter   | The parameters {{Parameter}} specified in the request are not supported by this endpoint. | 传入的参数 {{Parameter}} 在此推理接入点不可用。                                                |
| 400      | BadRequest | InvalidParameter.TosURLInvalid          | TOS URI invalid. url:%s.                                                                  | TOS URI 不合法。                                                                   |
| 400      | BadRequest | InvalidParameter                        | The given Lean code is not compilable under Lean version %s                               | 输入的不是一个合法的 Lean Code。                                                          |
| 400      | BadRequest |                                         |                                                                                           |                                                                                |



| HTTP 状态码 | 错误类型<br>Type | 错误码<br>Code                  | 错误信息<br>Message                                                                                                                                                                                                                                     | 含义                                                            |
|----------|--------------|------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------|
|          |              | InvalidParameter             | The format of the given lean code is not supported so far.                                                                                                                                                                                          | 输入的Lean code格式暂不支持。                                           |
| 400      | BadRequest   | InvalidParameter             | /                                                                                                                                                                                                                                                   | 输入的Lean code必须包含 theorem                                      |
| 400      | Forbidden    | InvalidSubscription          | Your account ({{account_identifier}}) does not have a valid coding plan subscription, or your subscription has expired. Please visit {{subscription_check_url}} to review your subscription status or complete the subscription or renewal process. | Coding Plan 套餐未订阅或已过期。                                        |
| 401      | Unauthorized | AuthenticationError          | The API key or AK/SK in the request is missing or invalid. Request ID: {{id}}                                                                                                                                                                       | 请求携带的 API Key 或 AK/SK 校验未通过，请您重新检查设置的鉴权凭证，或者查看 API 调用文档来排查问题。 |
| 401      | Forbidden    | InvalidAccountStatus         | There is an issue with your account status. If you need assistance, please contact the platform administrators.                                                                                                                                     | 当前使用的账号异常。                                                    |
| 403      | Forbidden    | OperationDenied.InvalidState | The specified context is in invalid state:                                                                                                                                                                                                          | 请求所关联的 Context ID处于非空闲状态，不可调用。                                |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                                  | 错误信息<br>Message                                                                                                                     | 含义                               |
|-------------|--------------|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------|
|             |              |                                              | InProgress.Request ID: {{id}}                                                                                                       |                                  |
| 403         | Forbidden    | OperationDenied.ConflictedValidationSet      | Operation is denied because it is not supported to configure ValidationSet and ValidationPercentage at the same time.               | 无法同时上传验证集和设置训练集取样为验证集百分比，不支持该操作。 |
| 403         | Forbidden    | OperationDenied.PermissionDenied             | Operation is denied because you are not permitted to access the specified configuration of the FoundationModel.                     | 您没有权限访问基础模型的配置，不支持该操作。           |
| 403         | Forbidden    | OperationDenied.UnsupportedCustomizationType | Operation is denied because the specified CustomizationType is not supported by the CustomModel.                                    | 模型不支持该训练方法，不支持该操作。               |
| 403         | Forbidden    | OperationDenied.CustomizationNotSupported    | Operation is denied because the specified version of the FoundationModel is not configured for the specified type of customization. | 基础模型的版本不支持该训练方法，不支持该操作。          |
| 403         | Forbidden    | OperationDenied.ServiceNotOpen               | Operation is denied because the model service is                                                                                    | 模型服务不可用，不支持该操作。请前往火山方舟控制台激活      |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                    | 错误信息<br>Message                                                                                                                                                                                     | 含义                                                                                    |
|-------------|--------------|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
|             |              |                                | unavailable,<br>please go to the<br>Volcano Ark<br>console<br>activation<br>management<br>page to activate<br>the<br>corresponding<br>model service,<br>or submit a<br>work order to<br>contact us. | 模型服务，或提交工单联系我们。                                                                       |
| 403         | Forbidden    | OperationDenied.ServiceOverdue | Operation is<br>denied because<br>your account<br>balance is<br>overdue, please<br>go to the Volc<br>Trading Center<br>to recharge in<br>order to<br>continue using<br>the service.                 | 您的账单已逾期，不支持该操作。请前往火山费用中心充值。                                                           |
| 403         | Forbidden    | AccountOverdue<br>Error        | The request<br>failed because<br>your account<br>has an overdue<br>balance.<br>Request ID: {{id}}                                                                                                   | 当前账号欠费（余额<0），如需继续调用，请前往 <a href="#">火山引擎费用中心</a> 进行充值，详细操作参见 <a href="#">充值操作指引</a> 。 |
| 403         | Forbidden    | AccessDenied                   | The request<br>failed because<br>you do not have<br>access to the<br>requested<br>resource.<br>Request ID: {{id}}                                                                                   | 没有访问该资源的权限，请检查权限设置，或联系管理员添加白名单。                                                       |
| 403         | Forbidden    | OperationDenied.InvalidState   | Operation is<br>denied because<br>the specified<br>context is in<br>invalid state:                                                                                                                  | 请求的缓存信息状态是不可用状态。请查看缓存信息是否正在被更新中。                                                      |

| HTTP<br>状态码 | 错误类型<br>Type | 错误码<br>Code                           | 错误信息<br>Message                                                                                                                           | 含义                                        |
|-------------|--------------|---------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------|
|             |              |                                       | InProgress.<br>Request id: {{id}}                                                                                                         |                                           |
| 403         | Forbidden    | OperationDenied.UnsupportedPhase      | Operation is denied because operation is not supported while the target is in its current phase.                                          | 操作失败，操作目标在特殊状态，请检查目标是否存在或者被锁定等特殊状态中。      |
| 403         | Forbidden    | OperationDenied.FileQuotaExceeded     | Your account %s has exhausted its file storage quota. To continue using the service, please delete historical files.                      | 当前账号 %s 已耗尽文件存储额度，如需继续使用，请删除历史文件。         |
| 403         | Forbidden    | OperationDenied.ArkAccessRoleNotFound | Please go to Ark Project Settings → Project Authorization, and grant permission to the TOS resource before trying again.                  | 请到方舟项目配置-项目授权，对tos资源授权后再进行操作。             |
| 403         | Forbidden    | OperationDenied.TosAccessDenied       | Access denied for TOS resource %s. TOS responded: %s. Please verify your account / project has permission to access the specified bucket. | 无权访问 TOS 资源，请确认您的账户 / 项目对该 bucket 拥有访问权限。 |
| 403         | Forbidden    | OperationDenied.InvalidState          | The specified file is in invalid state: InProgress. Request ID: {{id}}                                                                    | 请求所关联的 File ID处于非可用状态，不可调用。               |
| 404         | NotFound     |                                       | The model or endpoint %s does not exist or                                                                                                | 模型或者推理接入点 %s 不存在                          |

| HTTP<br>状态码 | 错误类型<br>Type    | 错误码<br>Code                                      | 错误信息<br>Message                                                                                                                                   | 含义                                                               |
|-------------|-----------------|--------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
|             |                 | InvalidEndpoint<br>OrModel.NotFound              | you do not have access to it.                                                                                                                     | 或者您无权访问它。                                                        |
| 404         | NotFound        | ModelNotOpen                                     | Your account %s has not activated the model %s. Please activate the model service in the Ark Console.                                             | 当前账号 %s 暂未开通 %s 模型服务，请前往火山方舟控制台开通管理页开通对应模型服务。                    |
| 404         | NotFound        | NotFound.<br>{{Parameter}}                       | The specified {{ResourceType}} {{ResourceContent}} is not found.                                                                                  | 指定资源找不到。请确认参数后重试。                                                |
| 404         | NotFound        | InvalidEndpoint<br>OrModel.ModelIDAccessDisabled | Accessing the model via Model ID is not allowed for your account. Please use a custom endpoint ID instead. Request id:{{id}}                      | 未能找到指定的模型ID。你的账号不允许使用模型ID来调用模型，请确认你账号权限或者使用有权限的推理接入点 ID 来调用模型服务。 |
| 404         | NotFound        | UnsupportedModel                                 | The {{model_name}} model does not support the coding plan feature. Please refer to the documentation at {{doc_url}} to select a compatible model. | 当前模型不支持 Coding Plan。                                             |
| 429         | TooManyRequests | RateLimitExceeded.EndpointRPMExceeded            | The Requests Per Minute (RPM) limit of the associated endpoint for your account has been                                                          | 请求所关联的推理接入点已超过 RPM (Requests Per Minute) 限制，请稍后重试。               |

| HTTP 状态码 | 错误类型 Type       | 错误码 Code                              | 错误信息 Message                                                                                                           | 含义                                                             |
|----------|-----------------|---------------------------------------|------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------|
|          |                 |                                       | exceeded.<br>Request ID: {{id}}                                                                                        |                                                                |
| 429      | TooManyRequests | RateLimitExceeded.EndpointTPMExceeded | The Tokens Per Minute (TPM) limit of the associated endpoint for your account has been exceeded.<br>Request ID: {{id}} | 请求所关联的推理接入点已超过 TPM (Tokens Per Minute) 限制, 请稍后重试。              |
| 429      | TooManyRequests | ModelAccountRpmRateLimitExceeded      | RPM (Requests Per Minute) limit of the model is exceeded.<br>Request ID: {{id}}                                        | 请求已超过帐户模型 RPM (Requests Per Minute) 限制: 请您稍后重试, 或者联系平台技术同学进行解决 |
| 429      | TooManyRequests | ModelAccountTpmRateLimitExceeded      | TPM (Tokens Per Minute) limit of the model is exceeded.<br>Request ID: {{id}}                                          | 请求已超过帐户模型 TPM (Tokens Per Minute) 限制: 请您稍后重试, 或者联系平台技术同学进行解决   |
| 429      | TooManyRequests | APIAccountRpmRateLimitExceeded        | The RPM (Requests Per Minute) limit for the API on your account has been exceeded.<br>Request ID: {{id}}               | 当前账号该接口的 RPM (Requests Per Minute) 限制已超出, 请稍后重试。               |
| 429      | TooManyRequests | ModelAccountIpmRateLimitExceeded      | IPM (Images Per Minute) limit of the model is exceeded.                                                                | 请求已超过账户模型 IPM (Images Per Minute) 限制: 请您稍后重试, 或者联系平台技术同学进行解决   |
| 429      | TooManyRequests | QuotaExceeded                         | Your account [%s] has exhausted its free trial quota for the [%s]                                                      | 当前账号 %s 对 %s 模型的免费试用额度已消耗完毕, 如需继续调用, 请前往火                      |

| HTTP<br>状态码 | 错误类型<br>Type    | 错误码<br>Code         | 错误信息<br>Message                                                                                                              | 含义                                                                                                                                                                                                  |
|-------------|-----------------|---------------------|------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|             |                 |                     | model. Request ID: {{id}}                                                                                                    | 山方舟控制台开通管理页开通对应模型服务。                                                                                                                                                                                |
| 429         | TooManyRequests | QuotaExceeded       | The request has exceeded the quota. Request ID: {{id}}                                                                       | 当前账号处于排队中状态的任务数已超过限制，请稍后重试。                                                                                                                                                                         |
| 429         | TooManyRequests | ServerOverloaded    | The service is currently unable to handle additional requests due to server overload. Please retry later. Request ID: {{id}} | <p>服务资源紧张，请您稍后重试。常出现在调用流量突增或刚开始调用长时间未使用的推理接入点。</p> <div><p><b>说明</b></p><p>调用 <code>doubao-<br/>seed-1.8</code> 及之前版本模型触发突增流量限制时，返回此错误码。可参考<a href="#">突发流量处理最佳实践</a> <a href="#">处理</a>。</p></div> |
| 429         | TooManyRequests | RequestBurstTooFast | System protection triggered by request burst. Please slow down traffic growth and increase                                   | <p>请求量激增触发系统保护，请放缓流量提升速度，逐步增加请求量后再尝试</p> <div><p><b>说明</b></p></div>                                                                                                                                |

| HTTP<br>状态码 | 错误类型<br>Type        | 错误码<br>Code                   | 错误信息<br>Message                                                                                                                                                                                                                                         | 含义                                                                                                                                                                                                                                                                    |
|-------------|---------------------|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|             |                     |                               | requests<br>gradually before<br>retrying.                                                                                                                                                                                                               | <div><div>调用</div><div>doubao-</div><div>seed-2.0</div><div>及之后</div><div>版本模</div><div>型触发</div><div>突增流</div><div>量限制</div><div>时，返</div><div>回此错</div><div>误码，</div><div>可参考</div><div>突发流</div><div>量处理</div><div>最佳实</div><div>践 <a href="#">处理</a>。</div></div> |
| 429         | TooManyReques<br>ts | SetLimitExceede<br>d          | Your account [%s] has reached the set inference limit for the [%s] model, and the model service has been paused. To continue using this model, please visit the Model Activation page to adjust or close the "Safe Experience Mode". Request ID: {{id}} | 当前账号 %s 对 %s 模型已达到设置的推理限额值，如需继续调用，请前往火山方舟控制台开通管理页修改限额值或关闭安心体验模式。                                                                                                                                                                                                      |
| 429         | TooManyReques<br>ts | InflightBatchsize<br>Exceeded | The Inflight Batchsize limit has been exceeded.Request ID: {{id}}                                                                                                                                                                                       | 您已经达到当前充值金额下的最大并发数限制，您可以充值解锁更大并发额度或降低并发数。                                                                                                                                                                                                                             |



| HTTP<br>状态码 | 错误类型<br>Type        | 错误码<br>Code                  | 错误信息<br>Message                                                                                                                    | 含义                        |
|-------------|---------------------|------------------------------|------------------------------------------------------------------------------------------------------------------------------------|---------------------------|
| 429         | TooManyReques<br>ts | AccountRateLimi<br>tExceeded | Requests are<br>too frequent.<br>Please reduce<br>your request<br>frequency, wait<br>a short moment,<br>and retry your<br>request. | 请求超出RPM /<br>TPM限制。       |
| 429         | TooManyReques<br>ts | QuotaExceeded                | You have<br>exceeded the 5-<br>hour/weekly/<br>monthly usage<br>quota. It will<br>reset at<br>{{reset_time}}.                      | 使用的额度超出<br>5小时/周/月限<br>额。 |
| 500         | InternalServerError | InternalServiceEr<br>ror     | The service<br>encountered an<br>unexpected<br>internal error.<br>Please retry<br>later. Request<br>ID: {{id}}                     | 内部系统异常，<br>请您稍后重试。        |

精调错误码

本部分将介绍模型精调相关的错误码信息及其建议的解决方案。

| 错误码                      | 示例错误信息                                                                                   | 说明与建议解决方案                                                                                   |
|--------------------------|------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| InvalidData.MissingKey   | Data format is not<br>expected:column not found                                          | 数据格式不符合预期, 未找到<br>名为的列, 建议检查并补全数<br>据集中相应键值.                                                |
| InvalidData.UnknownKey   | Wrong Key, parsing sample<br>failed                                                      | 数据中有错误的Key, 解析样本<br>失败, 建议检查错误信息中对<br>应样本的键值                                                |
| InvalidData.InvalidValue | Unsupported data type:, only<br>pretrain, dialog, dialog-dpo<br>and multimodal supported | 不支持的数据集类型, 仅支<br>持"pretrain", "dialog", "dialog-<br>dpo", 和"multimodal"类型, 建<br>议检查填入的数据集类型 |
|                          | Content is empty, original text<br>content is:                                           | content字段内容为空, 原文本<br>内容为, 建议检查原文本的数据<br>完整性.                                               |

| 错误码                      | 示例错误信息                                                                                                            | 说明与建议解决方案                                    |
|--------------------------|-------------------------------------------------------------------------------------------------------------------|----------------------------------------------|
| InvalidData.InvalidJsonl | not supported                                                                                                     | 数据集文件格式不支持, 建议调整对应文件为 <code>jsonl</code> 格式. |
|                          | No jsonl file available                                                                                           | 无可用的jsonl文件, 建议检查数据集包含的文件列表.                 |
| InvalidData.InvalidJson  | Expecting value: line 1 column 1 (char 0) in fileatrow                                                            | 在<文件名>中第行, JSON解析失败, 建议检查数据集文件内容是否符合JSON规范.  |
| InvalidData              | failed to init data preprocess builder: training tos bucket: maas-data-test, tos path: : tos objects do not exist | 提供的数据集地址在TOS中不存在, 建议检查TOS中数据集文件是否出现缺失或地址错误.  |
| UnknownError             | service error occur, please contact customer service for help                                                     | 平台服务错误, 不可重试, 建议发起工单协助排查                     |
| InternalError            | task failed, please check the logs                                                                                | 训练失败, 建议检查日志后发起重试, 如仍无法解决问题, 建议发起工单协助排查.     |

公共错误码

查询火山引擎的[公共错误码](#)。

## 13.3 SDK 常见使用示例

当您使用官方 SDK 时，设置自定义header等典型的使用，可以参考本说明。

### 设置超时&重试次数

当您的网络环境不稳定或者响应时间较长的场景，可以设置超时和重试次数，以提高服务可用性。

- 超时设置 ( `timeout` )：适用于对响应时间较长的场景（如深度思考模型回复问题时间较长），避免请求时间超时导致服务中断，这里推荐30分钟（1800秒）。
  - Python SDK：默认 60秒 连接超时（建立网络连接的最大等待时间），600 秒 socket 超时（连接建立后的数据传输超时）。
  - Java SDK：默认 60秒 连接超时，600 秒 socket 超时。
  - Go SDK：默认 600s 端到端的总超时（从请求发起至响应接收的总超时）。
- 重试次数 ( `max_retries` )：适用于网络不稳定场景，自动重试因瞬时故障（如网络波动）失败的请求，默认2次，即请求失败默认会再重试2次，您可以按需配置。

#### Python

Python

```
import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]'
from volcenginesdkarkruntime import Ark

client = Ark(
    api_key=os.environ.get("ARK_API_KEY"),
    # 设置服务响应超时时间，单位秒，推荐1800秒及以上
    timeout=1800,
    # 设置重试次数
    max_retries=2,
    # The base URL for model invocation .
    base_url="https://ark.cn-beijing.volces.com/api/v3",
)
```

#### Go

```
import (
    "os"
    "time"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
)

client := arkruntime.NewClientWithApiKey(
    os.Getenv("ARK_API_KEY"),
```

```
Go arkruntime.WithTimeout(30*time.Minute), //设置后端处理完本次请求的整体超时时间，单位分
    钟，推荐30分钟及以上
    arkruntime.WithRetryTimes(2), //设置最大重试次数
    arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"), // The base URL for model
    invocation .
    )
```

## Java

```
package com.example;

import com.volcengine.ark.runtime.model.completion.chat.ChatCompletionRequest;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessage;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessageRole;
import com.volcengine.ark.runtime.service.ArkService;
import java.time.Duration;
import java.util.ArrayList;
import java.util.List;

public class ChatCompletionsExample {
    public static void main(String[] args) {
        String apiKey = System.getenv("ARK_API_KEY");
        ArkService service = ArkService
            .builder()
            .baseUrl("https://ark.cn-beijing.volces.com/api/v3") // The base URL for model invocation .
            .apiKey(apiKey)
            .timeout(Duration.ofSeconds(1800))// 设置后端处理完请求的超时时间，单位秒，推荐为
            1800秒及以上
            .connectTimeout(Duration.ofSeconds(20))// 设置连接超时时间为20秒
            .retryTimes(2)// 设置重试次数为2次
            .build();
        final List<ChatMessage> messages = new ArrayList<>();
        final ChatMessage userMessage =
            ChatMessage.builder().role(ChatMessageRole.USER).content("你好")
                .build();
        messages.add(userMessage);

        ChatCompletionRequest chatCompletionRequest = ChatCompletionRequest.builder()
            .model("doubao-seed-2-1-pro-260628") //Replace with Model ID .
            .messages(messages)
            .build();

        service.createChatCompletion(chatCompletionRequest).getChoices()
            .forEach(choice -> System.out.println(choice.getMessage().getContent()));
```

```
Java // shutdown service
    service.shutdownExecutor();
    }
}
```

## 使用Access Key鉴权

当需要通过火山引擎云服务的标准鉴权体系（Access Key/Secret Key）认证时使用。

使用 Access Key 鉴权的实现原理是通过接口 [GetApiKey](#) 获取临时 API Key 进行鉴权，此接口限流较低，务必使用单例模式进行请求，避免因限流导致鉴权失败，可参考[单例请求](#)。

## Python

```
Python

import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]' .
from volcenginesdkarkruntime import Ark
client = Ark(
    ak=os.environ.get("VOLC_ACCESSKEY"),
    sk=os.environ.get("VOLC_SECRETKEY"),
    # The base URL for model invocation .
    base_url="https://ark.cn-beijing.volces.com/api/v3",
)
```

## Go

```
Go

import (
    "os"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
)

client := arkruntime.NewClientWithAkSk(
    os.Getenv("VOLC_ACCESSKEY"),
    os.Getenv("VOLC_SECRETKEY"),
    arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"), // The base URL for model invocation .
)
```

## Java

Java

```
import com.volcengine.ark.runtime.service.ArkService;

public class CreateArkClientExample1 {
    public static void main(String[] args) {
        String ak = System.getenv("VOLC_ACCESSKEY");
        String sk = System.getenv("VOLC_SECRETKEY");
        ArkService service = ArkService.builder().ak(ak).sk(sk)
            // The base URL for model invocation .
            .baseUrl("https://ark.cn-beijing.volces.com/api/v3")
            .build();
    }
    // do your operation...
}
```

## 设置自定义 header

自定义的 `header` 字段采用键值对（key-value）结构，以对象形式呈现，具体格式示例如下：

JSON

```
{
  "key1": "value1",
  "key2": "value2",
  ...,
  "keyN": "valueN"
}
```

可以用于传递额外信息，如配置 ID 来串联日志，使能数据加密能力。支持该字段的接口有 [对话（Chat）API](#)、[批量（Chat）API](#)，下面是典型示例。

## 问题定位

您可以在请求时，为多个请求设置 **key** 为 `X-Client-Request-Id`，**value** 配置为自定义的 ID，并提供 ID 给方舟售后团队，为您串联客户端和服务端日志，方便问题定位。

## Python

```
import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]' .
from volcenginesdkarkruntime import Ark

client = Ark(
    api_key=os.environ.get("ARK_API_KEY"),
```

```
Python
# The base URL for model invocation .
base_url="https://ark.cn-beijing.volces.com/api/v3",
)

completion = client.chat.completions.create(
    # Replace with Model ID .
    model = "doubao-seed-2-1-pro-260628",
    messages = [
        {"role": "user", "content": "Hello"},
    ],
    # 自定义request id
    extra_headers={"X-Client-Request-Id": "My-Request-Id"}
)
print(completion.choices[0].message.content)
```

## Go

```
package main

import (
    "context"
    "fmt"
    "os"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime/model"
    "github.com/volcengine/volcengine-go-sdk/volcengine"
)

func main() {
    client := arkruntime.NewClientWithApiKey(
        os.Getenv("ARK_API_KEY"),
        arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"), // The base URL for model
        invocation .
    )
    ctx := context.Background()
    req := model.CreateChatCompletionRequest{
        Model: "doubao-seed-2-1-pro-260628", //Replace with Model ID .
        Messages: []*model.ChatCompletionMessage{
            {
                Role: model.ChatMessageRoleUser,
                Content: &model.ChatCompletionMessageContent{
                    StringValue: volcengine.String("Hello"),
                },
            },
        },
    },
}
```

```
Go    },
    }

    // 自定义request id
    resp, err := client.CreateChatCompletion(
        ctx,
        req,
        arkruntime.WithCustomHeader(model.ClientRequestHeader, "my-request-id"), // 自定义请求头
    )
    if err != nil {
        fmt.Printf("standard chat error: %v\n", err)
        return
    }
    fmt.Println(*resp.Choices[0].Message.Content.StringValue)
}
```

## Java

```
package com.example;

import com.volcengine.ark.runtime.model.completion.chat.ChatCompletionRequest;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessage;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessageRole;
import com.volcengine.ark.runtime.service.ArkService;
import java.util.ArrayList;
import java.util.HashMap;
import java.util.List;

public class ChatCompletionsExample3 {
    public static void main(String[] args) {
        String apiKey = System.getenv("ARK_API_KEY");
        // The base URL for model invocation .
        ArkService arkService = ArkService.builder().apiKey(apiKey).baseUrl("https://ark.cn-
beijing.volces.com/api/v3").build();
        final List<ChatMessage> messages = new ArrayList<>();
        final ChatMessage userMessage =
ChatMessage.builder().role(ChatMessageRole.USER).content("常见的十字花科植物有哪些? ").build();
        messages.add(userMessage);
        ChatCompletionRequest chatCompletionRequest = ChatCompletionRequest.builder()
            .model("doubao-seed-2-1-pro-260628") //Replace with Model ID .
            .messages(messages)
            .build();
        // 使用自定义的请求头
```



```
Java service.createChatCompletion(chatCompletionRequest, new HashMap<String, String>()
{{put(Const.CLIENT_REQUEST_HEADER, "my_request_id");}}).getChoices().forEach(choice ->
System.out.println(choice.getMessage().getContent()));
    // shutdown service
    service.shutdownExecutor();
}
}
```

## 加密数据

为了保证推理会话数据的传输安全，你可以为在线推理的会话数据加密。使能力后，SDK 会对推理会话的内容进行加密。

更多能力介绍和原理信息请参考[推理会话数据应用层加密方案](#) [🔗](#)。

- 版本要求：
  - Python SDK：需要保证 SDK 版本 `volcengine-python-sdk` `1.0.104` 及以上。参考[升级 Python SDK](#)获得 SDK 的最新版本。
  - Java SDK：需要保证 SDK 版本 `volcengine-java-sdk-ark-runtime` `0.2.50` 及以上。参考[升级 Java SDK](#)获得 SDK 的最新版本。
- 能力支持：
  - 仅支持文本生成模型和视觉理解图片理解模型请求。
  - 图片仅支持 Base64 图片加密，URL 图片无法加密。
  - 仅支持官方 Python SDK、Java SDK 的 [Chat API](#)。
  - 支持单轮、多轮会话，支持流式、非流式，同步、异步调用。

## Python

```
import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]' .
from volcenginesdkarkruntime import Ark

client = Ark(
    api_key=os.environ.get("ARK_API_KEY"),
    # The base URL for model invocation .
    base_url="https://ark.cn-beijing.volces.com/api/v3",
)

completion = client.chat.completions.create(
    # Replace with Model ID .
    model = "doubao-seed-2-1-pro-260628",
    messages = [
        {"role": "user", "content": "Hello"},
    ],
)
```

```
Python#按下述代码设置自定义header，免费开启推理会话应用层加密
extra_headers={'x-is-encrypted': 'true'}
)
print(completion.choices[0].message.content)
```

## Java

在 `pom.xml` 文件中增加以下配置：

XML

```
<dependencies>
  <!-- BouncyCastle 核心加密库（bcprov依赖此包）-->
  <dependency>
    <groupId>org.bouncycastle</groupId>
    <artifactId>bcprov-jdk18on</artifactId>
    <version>1.78.1</version>
  </dependency>
  <!-- 包含PEMParser的模块（处理PEM格式证书）-->
  <dependency>
    <groupId>org.bouncycastle</groupId>
    <artifactId>bcpkix-jdk18on</artifactId>
    <version>1.78.1</version>
  </dependency>
</dependencies>
```

代码示例如下：

```
package com.ark.sample;

import com.volcengine.ark.runtime.model.completion.chat.ChatCompletionRequest;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessage;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessageRole;
import com.volcengine.ark.runtime.service.ArkService;
import java.time.Duration;
import java.util.ArrayList;
import java.util.List;
import java.util.Map;
import java.util.HashMap;

public class ChatCompletionsExample {
  public static void main(String[] args) {
    String apiKey = System.getenv("ARK_API_KEY");
    ArkService service = ArkService
```

```
Java    .builder()
        .apiKey(apiKey)
        .timeout(Duration.ofSeconds(1800)) // Set the backend request processing timeout in
seconds, recommended to be 1800 seconds or longer
        .connectTimeout(Duration.ofSeconds(20)) // Set the connection timeout to 20 seconds
        .retryTimes(2) // Set the retry count to 2
        .build();
    final List<ChatMessage> messages = new ArrayList<>();
    final ChatMessage userMessage =
ChatMessage.builder().role(ChatMessageRole.USER).content("Hello")
        .build();
    messages.add(userMessage);

    ChatCompletionRequest chatCompletionRequest = ChatCompletionRequest.builder()
        .model("doubao-seed-2-1-pro-260628") // Replace with Model ID
        .messages(messages)
        .build();

    // Set custom headers with the code below to enable application-layer encryption for inference
sessions at no cost
    Map<String, String> customHeaders = new HashMap<>();
    customHeaders.put("x-is-encrypted", "true");
    service.createChatCompletion(chatCompletionRequest, customHeaders).getChoices()
        .forEach(choice -> System.out.println(choice.getMessage().getContent()));
    // shutdown service
    service.shutdownExecutor();
}
}
```

## 开启数据上报

为了便于快速排查和定位问题，你可以在 Responses API 请求的 header 中增加 `"X-Fornax-Trace: true"` 开启数据上报。支持统计分析的数据见[分析统计](#)。

该能力限时免费提供使用。

- 版本要求：如果请求上报未生效，需升级 SDK 到最新版本。
- 能力支持：仅支持 [Responses API](#)。

## Python

```
import os
from volcenginesdkarkruntime import Ark

client = Ark(
```

```
Python
base_url='https://ark.cn-beijing.volces.com/api/v3',
api_key=os.getenv('ARK_API_KEY'),
)

response = client.responses.create(
    model="<Endpoint_ID>",
    input="hello",
    extra_headers={'X-Fornax-Trace': 'true'}
)
print(response)
```

## Go

```
Go

package main

import (
    "context"
    "fmt"
    "os"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime/model/responses"
)

func main() {
    client := arkruntime.NewClientWithApiKey(
        // Get API Key: https://console.volcengine.com/ark/region:ark+cn-beijing/apikey
        os.Getenv("ARK_API_KEY"),
        arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"),
    )
    ctx := context.Background()

    resp, err := client.CreateResponses(ctx, &responses.ResponsesRequest{
        Model: "<Endpoint_ID>",
        Input: &responses.ResponsesInput{Union: &responses.ResponsesInput_StringValue{StringValue:
"hello"}},
    }, arkruntime.WithCustomHeader("X-Fornax-Trace", "true"))
    if err != nil {
        fmt.Printf("response error: %v\n", err)
        return
    }
    fmt.Println(resp)
}
```

## Java

Java

```
package com.ark.sample;

import com.volcengine.ark.runtime.service.ArkService;
import com.volcengine.ark.runtime.model.responses.request.*;
import com.volcengine.ark.runtime.model.responses.response.ResponseBody;
import java.util.HashMap;
import java.util.Map;

public class demo {
    public static void main(String[] args) {
        String apiKey = System.getenv("ARK_API_KEY");
        // The base URL for model invocation
        ArkService arkService = ArkService.builder().apiKey(apiKey).baseUrl("https://ark.cn-beijing.volces.com/api/v3").build();

        CreateResponsesRequest request = CreateResponsesRequest.builder()
            .model("<Endpoint_ID>")
            .input(ResponsesInput.builder().stringValue("hello").build())
            .build();
        Map<String, String> customHeaders = new HashMap<>();
        customHeaders.put("X-Fornax-Trace", "true");
        ResponseObject resp = arkService.createResponse(request, customHeaders);
        System.out.println(resp);

        arkService.shutdownExecutor();
    }
}
```

## 单例请求

请使用单例方式请求模型服务，勿重复创建实例导致额外资源消耗。

## Python

```
import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]' .
from volcenginesdkarkruntime import Ark

client = Ark(
    # Get API Key: https://console.volcengine.com/ark/region:ark+cn-beijing/apikey
    api_key=os.environ.get("ARK_API_KEY"),
    # The base URL for model invocation .
    base_url="https://ark.cn-beijing.volces.com/api/v3",
```

Python

```
)  
  
# 请求1  
completion = client.chat.completions.create(  
    model="doubao-seed-2-1-pro-260628",  
    messages=[  
        {"role": "user", "content": "Nice day"},  
    ],  
)  
print(completion.choices[0].message.content)  
  
# 请求2  
completion = client.chat.completions.create(  
    model="doubao-seed-2-1-pro-260628",  
    messages=[  
        {"role": "user", "content": "Hello"},  
    ],  
)  
print(completion.choices[0].message.content)
```

Go

```
package main  
  
import (  
    "context"  
    "fmt"  
    "os"  
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"  
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime/model"  
    "github.com/volcengine/volcengine-go-sdk/volcengine"  
)  
  
func main() {  
    client := arkruntime.NewClientWithApiKey(  
        os.Getenv("ARK_API_KEY"),  
        arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"), // The base URL for model  
        invocation .  
    )  
    ctx := context.Background()  
    // 第一次请求  
    req1 := model.CreateChatCompletionRequest{  
        // Replace with Model ID .  
    }
```

```
Go  Model: "doubao-seed-2-1-pro-260628",
    Messages: []*model.ChatCompletionMessage{
        {
            Role: model.ChatMessageRoleUser,
            Content: &model.ChatCompletionMessageContent{
                StringValue: volcengine.String("Nice day"),
            },
        },
    },
}

resp1, err := client.CreateChatCompletion(ctx, req1)
if err != nil {
    fmt.Printf("standard chat error: %v\n", err)
    return
}
fmt.Println(*resp1.Choices[0].Message.Content.StringValue)

// 第二次请求
req2 := model.CreateChatCompletionRequest{
    // Replace with Model ID .
    Model: "doubao-seed-2-1-pro-260628",
    Messages: []*model.ChatCompletionMessage{
        {
            Role: model.ChatMessageRoleUser,
            Content: &model.ChatCompletionMessageContent{
                StringValue: volcengine.String("Hello"),
            },
        },
    },
}

resp2, err := client.CreateChatCompletion(ctx, req2)
if err != nil {
    fmt.Printf("standard chat error: %v\n", err)
    return
}
fmt.Println(*resp2.Choices[0].Message.Content.StringValue)
}
```

## Java

```
package com.example;
```

```

Java
import com.volcengine.ark.runtime.model.completion.chat.ChatCompletionRequest;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessage;
import com.volcengine.ark.runtime.model.completion.chat.ChatMessageRole;
import com.volcengine.ark.runtime.service.ArkService;
import java.util.ArrayList;
import java.util.List;

public class ChatCompletionsExample4 {
    public static void main(String[] args) {
        String apiKey = System.getenv("ARK_API_KEY");
        // The base URL for model invocation .
        ArkService arkService = ArkService.builder().apiKey(apiKey).baseUrl("https://ark.cn-
beijing.volces.com/api/v3").build();

        // 第一次请求
        final List<ChatMessage> messages1 = new ArrayList<>();
        final ChatMessage userMessage1 =
ChatMessage.builder().role(ChatMessageRole.USER).content("今天天气不错? ").build();
        messages1.add(userMessage1);
        ChatCompletionRequest chatCompletionRequest1 = ChatCompletionRequest.builder()
            .model("doubao-seed-2-1-pro-260628")// Replace with Model ID .
            .messages(messages1)
            .build();
        service.createChatCompletion(chatCompletionRequest1).getChoices().forEach(choice ->
System.out.println(choice.getMessage().getContent()));
        // 第二次请求
        final List<ChatMessage> messages2 = new ArrayList<>();
        final ChatMessage userMessage2 =
ChatMessage.builder().role(ChatMessageRole.USER).content("你好").build();
        messages2.add(userMessage2);
        ChatCompletionRequest chatCompletionRequest2 = ChatCompletionRequest.builder()
            .model("doubao-seed-2-1-pro-260628")// Replace with Model ID .
            .messages(messages2)
            .build();
        service.createChatCompletion(chatCompletionRequest2).getChoices().forEach(choice ->
System.out.println(choice.getMessage().getContent()));
        // shutdown service
        service.shutdownExecutor();
    }
}

```

## 设置Base Url

初始化时 `Ark` 、 `AsyncArk` 实例时，默认无需配置 `base_url` 参数，当需要连接非默认区域的服务端点时使用，示例如下。



## Python

Python

```
import os
# 通过命令安装方舟SDK pip install 'volcengine-python-sdk[ark]' .
from volcenginesdkarkruntime import Ark

client = Ark(
    api_key=os.environ.get("ARK_API_KEY"),
    # The base URL for model invocation .
    base_url="https://ark.cn-beijing.volces.com/api/v3",
)
```

## Go

Go

```
import (
    "os"
    "github.com/volcengine/volcengine-go-sdk/service/arkruntime"
)

client := arkruntime.NewClientWithApiKey(
    os.Getenv("ARK_API_KEY"),
    arkruntime.WithBaseUrl("https://ark.cn-beijing.volces.com/api/v3"), // The base URL for model
    invocation .
)
```

## Java

Java

```
import com.volcengine.ark.runtime.service.ArkService;

public class CreateArkClientExample {
    public static void main(String[] args) {
        String apiKey = System.getenv("ARK_API_KEY");
        ArkService service = ArkService.builder()
            .apiKey(apiKey)
            .baseUrl("https://ark.cn-beijing.volces.com/api/v3") // The base URL for model invocation .
            .build();

        // do your operation...
    }
}
```

# 14. 分词 API

## 14.1 分词 API

POST <https://ark.cn-beijing.volces.com/api/v3/tokenization> [运行](#)

本文介绍分词 API 的输入输出参数，供您使用接口时查阅字段含义。当前接口只支持文本信息。

### 快速入口

[体验中心](#) [模型计费](#) [API Key](#)  
[接口文档](#) [常见问题](#) [开通模型](#)

### 鉴权说明

本接口支持 API Key 鉴权，详见[鉴权认证方式](#)。

### 在线调试

#### API Explorer

您可以通过 API Explorer 在线发起调用，无需关注签名生成过程，快速获取调用结果。

[去调试](#)

### 请求参数

[跳转](#) [响应参数](#)

### 请求体

**model** `string` 必选

本次请求使用模型的 Model ID 或[推理接入点](#) (Endpoint ID)。

**text** `string / string[]` 必选

需要分词的内容，支持字符串或字符串列表。

## 响应参数

[跳转](#) [请求参数](#)

**id** `string`

本次请求的唯一标识。

**model** `string`

本次请求实际使用的模型 ID（ `模型名称-版本` ）。

doubao 1.5 代模型的模型名称格式为 `doubao-1-5-*`。如调用部署 `doubao-1.5-pro-32k 250115` 模型的推理接入点，返回 `model` 字段信息 `doubao-1-5-pro-32k-250115`。

**created** `integer`

本次请求创建时间的 Unix 时间戳（秒）。

**object** `string`

固定为 `list`。

**data** `object[]`

本次请求的分词的结果。

属性

**data.\*\*index** `** integer`

当前元素在 `data` 列表的索引。

**data.object** `string`

固定为 `tokenization`。

**data.total\_tokens** `integer`

对应内容的总 token 数量。

**data.token\_ids** `integer[]`

对文本进行分词后的具体词语在词表中的 id 列表。

**data.offset\_mapping** `Array<Array<Integer>>`

对文本进行分词后的词语偏移量，列表中每个元素是一个包含两个整数的列表：第一个整数表示词或标记在原始文本中的起始索引（是从0开始），第二个整数表示结束索引（不包括该索引处的字符）。