


模型列表

火山方舟



法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
(周一至周五 10:00-18:00)

目录

法律声明-----1

目录-----1

1. 模型列表-----1

1. 模型列表

方舟提供多种模型供您使用。您可浏览所有模型，比较它们的能力。

模型推荐

Doubao Seed 2.0

豆包旗舰级 Agent 通用模型
面向 Agent 时代的复杂推理与长链路任务执行场景

Doubao Seedance 2.0

豆包最强视频生成模型
极致拟真的视听稳定，赋予创作者如同导演般的掌控权

Doubao Seedream 5.0

豆包最强图片生成模型
搭载联网检索，增强知识广度、参考一致性及专业场景生成质量

深度思考能力

教程: [深度思考](#) | API: [Responses API](#)、[Chat API](#)

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见 文档
doubao-seed-2-0-lite-260428	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260428	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 ↗
doubao-seed-2-0-pro-260215 ↗	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-lite-260215 ↗	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260215 ↗	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-code-preview-260215 ↗	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

往期模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 文档
doubao-seed-1-8-251228	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 64k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-code-preview-251028	深度思考 编程场景增强 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 5000 最大 TPM: 1200000
doubao-seed-1-6-flash-250828	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 GUI任务 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-251015	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-250615	深度思考 文本生成 多模态理解	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) :	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 文档
	工具调用 结构化输出	32k 最大思维链: 32k	
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 GUI任务 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-flash-250828	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-flash-250615	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
glm-4-7-251222	深度思考 文本生成 工具调用	上下文窗口: 200k 最大输入: 200k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 15000 最大 TPM: 1500000
deepseek-v4-pro-260425	深度思考 文本生成 工具调用	上下文窗口: 1024k 最大输入: 1024k 最大回答(默认 4k) : 384k 最大思维链: 384k	最大 RPM: 15000 最大 TPM: 1500000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
deepseek-v4-flash-260425	深度思考 文本生成 工具调用	上下文窗口: 1024k 最大输入: 1024k 最大回答(默认 4k) : 384k 最大思维链: 384k	最大 RPM: 15000 最大 TPM: 1500000
deepseek-v3-2-251201	深度思考 文本生成 工具调用	上下文窗口: 128k 最大输入: 128k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 15000 最大 TPM: 1500000

文本生成能力

教程: [文本生成](#) | API: [Responses API](#)、[Chat API](#)

注意

此处特指支持无深度思考的文本生成任务的模型。

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-2-0-lite-260428	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 ↗
doubao-seed-2-0-mini-260428 ↗	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-pro-260215 ↗	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-lite-260215 ↗	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260215 ↗	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-code-preview-260215 ↗	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-character-251128 ↗	文本生成 工具调用	上下文窗口: 128k 最大输入: 96k 最大回答(默认 4k) ↗ : 32k	最大 RPM: 30000 最大 TPM: 5000000

往期模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-1-8-251228	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 64k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-code-preview-251028	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 5000 最大 TPM: 1200000
doubao-seed-1-6-flash-250828	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-translation-250915	文本生成 翻译增强	上下文窗口: 4k 最大输入: 1k 最大回答(默认 3k) : 3k 最大思维链: -	最大 RPM: 5000 500000 TPM
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 GUI 任务处理 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
	深度思考 文本生成	上下文窗口: 256k 最大输入: 224k	

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 🔗
doubao-seed-1-6-250615 🔗	多模态理解 工具调用 结构化输出	最大回答(默认 4k) 🔗 : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-251015 🔗	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) 🔗 : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-flash-250615 🔗	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) 🔗 : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-1-5-pro-32k-250115 🔗	文本生成 工具调用	上下文窗口: 128k 最大输入: - 最大回答(默认 4k) 🔗 : 16k 最大思维链: -	最大 RPM: 30000 最大 TPM: 5000000
doubao-1-5-pro-32k-character-250715 🔗	文本生成 角色扮演场景增强	上下文窗口: 32k 最大输入: - 最大回答(默认 4k) 🔗 : 12k 最大思维链: -	最大 RPM: 15000 最大 TPM: 10000000
doubao-1-5-lite-32k-250115 🔗	文本生成 工具调用	上下文窗口: 32k 最大输入: - 最大回答(默认 4k) 🔗 : 12k 最大思维链: -	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 ↗
glm-4-7-251222 ↗	深度思考 文本生成 工具调用	上下文窗口: 200k 最大输入: 200k 最大回答(默认 4k) ↗ : 128k 最大思维链: 128k	最大 RPM: 15000 最大 TPM: 1500000
deepseek-v4-pro-260425 ↗	深度思考 文本生成 工具调用	上下文窗口: 1024k 最大输入: 1024k 最大回答(默认 4k) ↗ : 384k 最大思维链: 384k	最大 RPM: 15000 最大 TPM: 1500000
deepseek-v4-flash-260425 ↗	深度思考 文本生成 工具调用	上下文窗口: 1024k 最大输入: 1024k 最大回答(默认 4k) ↗ : 384k 最大思维链: 384k	最大 RPM: 15000 最大 TPM: 1500000
deepseek-v3-2-251201 ↗	深度思考 文本生成 工具调用	上下文窗口: 128k 最大输入: 128k 最大回答(默认 4k) ↗ : 32k 最大思维链: 32k	最大 RPM: 15000 最大 TPM: 1500000

视觉理解能力

教程: [图片理解](#) [↗](#)、[视频理解](#) [↗](#)、[文档理解](#) [↗](#) | API: [Responses API](#) [↗](#)、[Chat API](#) [↗](#)

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流
doubao-seed-2-0-lite-260428 ↗	深度思考 文本生成	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) ↗ :	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流
	多模态理解 工具调用	128k 最大思维链: 128k	
doubao-seed-2-0-mini-260428	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-pro-260215	深度思考 文本生成 多模态理解 视觉定位 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-lite-260215	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260215	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-code-preview-260215	深度思考 文本生成 多模态理解 视觉定位 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

往期模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 文档
doubao-seed-1-8-251228	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 视觉定位 GUI 任务处理 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-code-preview-251028	深度思考 文本生成 多模态理解 视觉定位 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 5000 最大 TPM: 1200000
doubao-seed-1-6-flash-250828	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-250615	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-1-6-251015	深度思考 文本生成 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-flash-250615	深度思考 文本生成 视觉定位 多模态理解 视觉定位 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-1-5-vision-pro-32k-250115	图片理解 工具调用	上下文窗口: 32k 最大输入: - 最大回答(默认 4k) : 12k 最大思维链: -	最大 RPM: 30000 最大 TPM: 5000000

音频理解能力

教程: [音频理解](#) | API: [Responses API](#)、[Chat API](#)

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
	深度思考 文本生成	上下文窗口: 256k 最大输入: 224k	

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-2-0-lite-260428	多模态理解 工具调用	最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260428	深度思考 文本生成 多模态理解 工具调用	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

GUI 任务处理能力

教程: [GUI 任务处理](#) | API: [Responses API](#)、[Chat API](#)

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 GUI 任务处理 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000

工具调用能力

模型 ID (Model ID)	函数调用 Responses API ↗ & Chat API ↗	知识库 Responses API ↗	MCP Responses API ↗	联网内容 插件 Responses API ↗	图像处理 Responses API ↗	豆包助手 Responses API ↗
doubao-seed-2-0-lite-260428 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-2-0-mini-260428 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-2-0-pro-260215 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-2-0-lite-260215 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-2-0-mini-260215 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-2-0-code-preview-260215 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-1-8-251228 ↗	✓	✓	✓	✓	✓	✓
doubao-seed-character-251128 ↗	✓	—	—	—	—	—
doubao-seed-code-preview-251028 ↗	✓	—	—	—	—	—

模型 ID (Model ID)	函数调用 Responses API ↗ & Chat API ↗	知识库 Responses API ↗	MCP Responses API ↗	联网内容 插件 Responses API ↗	图像处理 Responses API ↗	豆包助手 Responses API ↗
doubao-seed-1-6-251015 ↗	✓	✓	✓	✓	—	✓
doubao-seed-1-6-250615 ↗	✓	✓	✓	✓	—	✓
doubao-seed-1-6-flash-250828 ↗	✓	✓	✓	✓	—	✓
doubao-seed-1-6-flash-250615 ↗	✓	✓	✓	✓	—	—
doubao-seed-1-6-vision-250815 ↗	✓	✓	✓	✓	✓	—
doubao-1-5-pro-32k-250115 ↗	✓ 仅支持 Chat API	✓	—	✓	—	—
doubao-1-5-pro-32k-character-250715 ↗	✓ 仅支持 Chat API	✓	—	✓	—	—
doubao-1-5-vision-pro-32k-250115 ↗	✓ 仅支持	—	—	—	—	—

模型 ID (Model ID)	函数调用 Responses API ↗ & Chat API ↗	知识库 Responses API ↗	MCP Responses API ↗	联网内容 插件 Responses API ↗	图像处理 Responses API ↗	豆包助手 Responses API ↗
	Chat API					
doubao-1-5-lite-32k-250115 ↗	仅支持 Chat API		—		—	—
glm-4-7-251222 ↗					—	—
deepseek-v4-pro-260425 ↗					—	—
deepseek-v4-flash-260425 ↗					—	—
deepseek-v3-2-251201 ↗					—	—

相关教程：

- [Function Calling（函数调用）](#) [↗](#)
- [私域知识库搜索 Knowledge Search](#) [↗](#)
- [云部署 MCP / Remote MCP](#) [↗](#)
- [Web Search（联网内容插件）](#) [↗](#)
- [图像处理 Image Process](#) [↗](#)
- [豆包助手](#) [↗](#)（Beta）

上下文缓存能力

介绍: [原理及选型](#) [↗](#) | API: [Responses API](#) [↗](#)、[Context Create API](#) [↗](#)、[Chat API](#) [↗](#)、[Batch API](#) [↗](#)

推荐模型

模型ID (Model ID)	隐式缓存	显式缓存
doubao-seed-2-0-lite-260428	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-2-0-mini-260428	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-2-0-pro-260215	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-2-0-lite-260215	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-2-0-mini-260215	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-2-0-code-preview-260215	Responses API Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-character-251128	-	Responses API 前缀缓存 Session缓存

往期模型

模型ID (Model ID)	隐式缓存	显式缓存
doubao-seed-1-8-251228	Batch API	Responses API 前缀缓存 Session缓存
doubao-seed-code-preview-251028	Chat API	Responses API 前缀缓存 Session缓存
doubao-seed-1-6-vision-250815	Batch API	Responses API 前缀缓存 Session缓存
doubao-seed-1-6-flash-250828	Batch API	Responses API 前缀缓存 Session缓存
doubao-seed-1-6-250615	Batch API	Responses API 前缀缓存 Session缓存
doubao-seed-1-6-251015	Batch API	Responses API 前缀缓存 Session缓存
doubao-seed-1-6-flash-250615	Batch API	Responses API 前缀缓存 Session缓存
doubao-1-5-pro-32k-character-250715	Batch API	Context API 前缀缓存 Session 缓存的rolling_tokens 模式
doubao-1-5-pro-32k-250115	Batch API	Context API 前缀缓存 Session 缓存的rolling_tokens 模式

模型ID (Model ID)	隐式缓存	显式缓存
doubao-1-5-lite-32k-250115	Batch API	Context API 前缀缓存 Session 缓存的rolling_tokens 模式
glm-4-7-251222	Batch API	Responses API 前缀缓存 Session缓存
deepseek-v4-pro-260425	Responses API Chat API	Responses API 前缀缓存 Session缓存
deepseek-v4-flash-260425	Responses API Chat API	Responses API 前缀缓存 Session缓存
deepseek-v3-2-251201	Batch API	Responses API 前缀缓存 Session缓存

结构化输出能力(beta)

介绍: [结构化输出\(beta\)](#) | API: [Responses API](#)、[Chat API](#)

推荐模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-2-0-lite-260215	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-2-0-mini-260215	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 128k 最大思维链: 128k	最大 RPM: 30000 最大 TPM: 5000000

往期模型

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档
doubao-seed-1-8-251228	深度思考 文本生成 多模态理解 工具调用 结构化输出	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 64k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-vision-250815	深度思考 文本生成 多模态理解 GUI 任务处理 工具调用 结构化输出 · json_schema	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k) : 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流 非刚性保障，受平台负载/调用方式影响，详见文档 文档
	· json_object		
doubao-seed-1-6-flash-250828	深度思考 文本生成 视觉定位 多模态理解 工具调用 结构化输出 · json_schema · json_object	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k): 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-250615	深度思考 文本生成 多模态理解 工具调用 结构化输出 · json_schema · json_object	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k): 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-251015	深度思考 文本生成 多模态理解 工具调用 结构化输出 · json_schema · json_object	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k): 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000
doubao-seed-1-6-flash-250615	深度思考 文本生成 视觉定位 多模态理解	上下文窗口: 256k 最大输入: 224k 最大回答(默认 4k): 32k 最大思维链: 32k	最大 RPM: 30000 最大 TPM: 5000000

模型 ID (Model ID)	能力支持	长度限制 (token)	限流
	工具调用 结构化输出 · json_schema · json_object		非刚性保障，受平台负载/调用方式影响，详见 文档

视频生成能力

教程: [Doubao Seedance 2.0 系列教程](#) | API: [Video Generation API](#)

模型 ID (Model ID)	模型能力	输出视频格式	限流
			非刚性保障，受平台负载/调用方式影响，详见 文档 default: 在线推理 flex: 离线推理
doubao-seedance-2-0-260128 🔗 音画同生	多模态生视频 编辑视频 延长视频 图生视频-首尾帧 图生视频-首帧 文生视频	分辨率: 480p, 720p, 1080p 帧率: 24 fps 时长: 4~15 秒 视频格式: mp4	default: · 最大 RPM: ◦ 企业用户: 600 ◦ 个人用户: 180 · 最大并发: ◦ 企业用户: 10 ◦ 个人用户: 3 flex: · 暂不支持
doubao-seedance-2-0-	多模态生视频 编辑视频 延长视频 图生视频-首尾帧	分辨率: 480p, 720p 帧率: 24 fps	default: · 最大 RPM: ◦ 企业用户: 600

模型 ID (Model ID)	模型能力	输出视频格式	限流 非刚性保障，受平台负载/调用方式影响，详见文档 default: 在线推理 flex: 离线推理
fast-260128 音画同生	图生视频-首帧 文生视频	时长: 4~15 秒 视频格式: mp4	◦ 个人用户: 180 · 最大并发: ◦ 企业用户: 10 ◦ 个人用户: 3 flex: · 暂不支持
doubao-seedance-1-5-pro-251215 音画同生	图生视频-首尾帧 图生视频-首帧 文生视频	分辨率: 480p, 720p, 1080p 帧率: 24 fps 时长: 4~12 秒 视频格式: mp4	default: · 最大 RPM: 600 · 最大并发: 10 flex: · 最大 TPD: 5000亿
doubao-seedance-1-0-pro-250528	图生视频-首尾帧 图生视频-首帧 文生视频	分辨率: 480p, 720p, 1080p 帧率: 24 fps 时长: 2~12 秒 视频格式: mp4	default: · 最大 RPM: 600 · 最大并发: 10 flex: · 最大 TPD: 5000亿
doubao-seedance-1-0-pro-fast-251015	图生视频-首帧 文生视频	分辨率: 480p, 720p, 1080p 帧率: 24 fps 时长: 2~12 秒 视频格式: mp4	default: · 最大 RPM: 600 · 最大并发: 10 flex: · 最大 TPD: 5000亿

图片生成能力

教程: [Doubao Seedream 4.0-5.0 教程](#) | API: [Image generation API](#)

推荐模型

模型 ID (Model ID)	能力支持	限流 非刚性保障，受平台负载/调用方式影响，详见文档 最大 IPM 张 / 分钟
doubao-seedream-5-0-260128 (同时支持: doubao-seedream-5-0-lite-260128)	文生图 图生图 · 单张图生图 · 多参考图生图生成组图 · 文生组图 · 单张图生组图 · 多参考图生组图	500
doubao-seedream-4-5-251128		500
doubao-seedream-4-0-250828		500

3D生成能力

教程: [3D 生成](#) | API: [3D生成 API](#)

模型 ID (Model ID)	能力支持	产物规格	限流 非刚性保障，受平台负载/调用方式影响，详见文档	免费额度 (token)
doubao-seed3d-2-0-260328	图生3D · 生成带纹理和 PBR 材质的3D文件	产物面数 · 100000 · 500000 · 1000000产物格式	最大 RPM: 300 最大并发: 5	200万

模型 ID (Model ID)	能力支持	产物规格	限流 非刚性保障，受平台负载/调用方式影响，详见 文档 🔗	免费额度 (token)
		· glb, obj, usd, usdz		
hyper3d-gen2-260112 🔗	文生3D、图生3D · 白模 · 带纹理模型 · PBR 材质模型 · 带纹理 + PBR 材质模型	产物面数 · 三角面模型：[500, 1,000,000] · 四边面模型：[1,000, 200,000]产物格式 · glb, obj, stl, fbx, usdz	最大 RPM: 60 最大并发: 3	15万
hitem3d-2-0-251223 🔗	图生3D · 标准白模 · 标准纹理模型 · 高精白模 · 高精纹理模型	产物面数 · [100000, 2000000]产物格式 · glb, obj, stl, fbx, usdz产物分辨率 · 1536、1536 pro	最大 RPM: 600 最大并发: 30	50万

向量化能力

教程: [向量化](#) [🔗](#) | API: [Embeddings Multimodal API](#) [🔗](#)

模型 ID (Model ID)	能力支持	上下文窗口	最高向量维度	限流 非刚性保障，受平台负载/调用方式影响，详见 文档 🔗
doubao-embedding-vision-251215 🔗	多模态向量化 支持 视频、文本、图片输入	128k	2048 支持1024降维使用	最大 RPM: 15000 最大 TPM: 1200000
doubao-embedding-vision-250615 🔗	多模态向量化 支持 视频、文本、图片输入	128k	2048 支持1024降维使用	最大 RPM: 15000 最大 TPM: 1200000